

# 1 一句话总结

本文研究一个核心问题：

**世界模型的”潜状态”该以什么形式存在，才能在不同环境、不同任务之间稳定地泛化？**

我们提出 **ST-JEWM** (Spiking Temporal Joint-Embedding World Model)，一个**纯脉冲神经网络** (spiking neural network, 简称 SNN) 世界模型。它的核心创新不是”更大的网络”或”更多数据”，而是一个**接口约定**：

**规划器只能读取脉冲后的轨迹 (post-spike trace)，不能读取膜电位 (membrane potential)。**

我们证明，这一接口约束使 ST-JEWM 在 14 个 DeepMind Control 环境、4 个跨基准族环境 (PushT、TwoRoom、Reacher、DMC) 的 1200 个评测单元 (cell) 上，都进入”校准” (calibrated) 状态——既不坍塌、也不放大噪声、也不丢失与事件的同步；而所有对照组 (连续循环网络、Transformer、已有 SNN) 都在不同维度上失败。

**5M-aligned 参数公平验证**：本实验把全部 8 个基线重新训练到 4.97-5.13M ( $\pm 3.2\%$  公平对比范围)，130 个 ckpt 全部完成 (13 模型  $\times$  10 splits)。在这一参数公平下，trace dynamics 假设的 collapse-robust 区分**仍然成立**：STJEWM 6 readouts 保持  $\text{resp} \approx 0.21$ 、 $\text{div} \approx 0.006$ 、 $\cos\_dist \in [0.04, 0.20]$  的校准区，与 ALIF-timecell 和 Stacked-LIF 处于同一簇，与 MLP ( $\text{div}=0$ ) 和 LeWM-v2 ( $\text{resp} \gg 1$ ) 清晰分离。**trace dynamics 不是”参数堆出来的”，而是 trace 自身的内容感知衰减的内禀属性。**

## 2 读者需要知道的背景

### 2.1 什么是”世界模型”？

机器人或游戏 AI 在决策时通常使用一个**世界模型**：给定当前观测  $o_t$  和动作  $a_t$ ，预测下一步的观测  $o_{t+1}$  或未来的状态序列。世界模型把高维的原始观测压缩到一个**低维潜状态空间**，使得规划算法 (例如 CEM: Cross-Entropy Method 搜索最优动作序列) 可以在这个低维空间里搜索，而不需要直接搜索高维动作。

### 2.2 什么是”潜状态”？

潜状态  $z_t$  是世界模型内部的低维向量。规划器读取  $z_t$  来决定下一步动作。潜状态的形式决定了规划器能看到什么、能优化什么。

### 2.3 什么是”泛化”？

一个”可泛化”的世界模型是指：

- **跨环境泛化**：在环境 A 上训练，在环境 B 上仍然能给出有意义的潜状态

- **跨任务泛化**：同一模型可以同时学会多个任务，不遗忘
- **跨观测模态泛化**：从 proprioception（关节角）到像素都行

本文聚焦**前两种**。第三种（像素）需要额外的视觉编码器，不在本文范围。

## 2.4 为什么”潜状态的形式”很重要？

**关键设计决策**：规划器被允许读取世界模型的哪一部分？

- 如果允许读”任何张量”（连续隐状态  $h_t$ 、膜电位  $v_t$ 、Transformer hidden state  $h_{tx}$ ），那么潜状态就是训练损失最方便的任何表示——一种**事后合理化**的设计
- 如果限定为”只读脉冲后的轨迹”（trace  $r_t$ ），则模型必须**主动**让这个有界的、内容感知的轨迹成为可用的预测状态

后一种约束是本文的**核心**。它把”什么是预测状态”从模型架构问题转化为**接口合约问题**。

## 3 工作的意义与目的

### 3.1 研究问题

主流世界模型设计用**连续循环隐状态**（continuous recurrent hidden state），在正向传播中无任何约束。这种设计有表达力强、可端到端训练、兼容稠密梯度的优势，但掩盖了”规划器能读什么”这个核心问题。

本文提出：要回答”潜状态能否跨环境泛化”，必须先回答”潜状态是什么形式的”。

### 3.2 ST-JEWM 的回答

**ST-JEWM**（Spiking Temporal Joint-Embedding World Model）是一个**纯 SNN**（无卷积、无 Transformer、无 GRU）**无重建**（reconstruction-free）的世界模型。预测潜状态从**脉冲后的轨迹**（post-spike trace）读出。

轨迹（trace）的三个物理性质：

1. **逐维有界**于  $[0, 1]$ ：永远不会爆炸
2. **内容感知**：遗忘门  $\alpha_t = \sigma(W[r_{t-1}, s_t, c_t])$  由上一时刻轨迹、当前脉冲、当前上下文调制——所以”忘记什么、记住什么”由环境驱动
3. **事件驱动**：仅在脉冲到来时更新，没有脉冲时自然衰减

我们将它与**膜电位禁止协议**（membrane-forbidden protocol）耦合：**规划器只能读取  $r_t$ ，不能读取膜电位  $v_t$  或连续隐状态  $h_t$ 。**

### 3.3 本报告的目的

本文的实验部分有三个具体目的：

1. **诊断贡献**：证明仅用”潜余弦成功率”会**误判坍塌表征** (collapsed representations)，并引入三个**抗坍塌诊断指标**
2. **校准性验证**：在 13 个专家模型  $\times$  24 个环境、12 个通才模型  $\times$  3 个任务规模上证明，ST-JEWM 全部 6 个读出口径在抗坍塌诊断上落在**同一个”校准”区域**，而 MLP/GRU/LeWM-v2 各自表现为坍塌、噪声、过反应
3. **跨基准族验证**：在 4 个**不同范式**的基准族 (PushT / TwoRoom / Reacher / DMC) 的 192 个评测单元上对比，证明 STJEWM 全部优于最强的非 STJEWM 对照 (ALIF-timecell)

## 4 实验设置

### 4.1 三个评测轴

我们沿着三个**正交轴**评测世界模型的”可泛化”声明：

1. **轴 1：DMC 内部子族之间转移** (gating experiment)。DMC (DeepMind Control) 的 14 个标准环境按”经典控制 / 运动 / 稀疏 POMDP”分为 3 个子族。做 1-、2-、3-子族 held-out 训练，6 个 oodc split + 4 个跨基准族 split + 1 个 G16 generalist split = **10 个 split**，每个 split 训 **13 个模型**，总评测 1110 cell (详细见 §5.1.1)。这是 working title 的 gating experiment。
2. **轴 2：跨基准族之间转移**。在 4 个**不同范式**的基准族 (PushT / TwoRoom / Reacher / DMC) 上做 held-out 训练，每个 split 训 **13 个模型**。这是 working title 的边界条件。
3. **轴 3：同一模型在不同任务规模下保持校准**。4 / 8 / 16 个环境同时训练。这是 working title 的”非遗忘性”声明。

本报告聚焦 **轴 1 + 轴 2**。轴 3 见仓库的其他文档。

### 4.2 评测指标的”双层”设计

#### 4.2.1 物理诊断层 (先验定义)

这一层的指标源自物理约束，**不依赖数据**。它们是 3 个**独立**的量，任何一个失败都说明模型坏了：

- **divergence-from-constant** (div)：在 200 步随机策略轨迹上，潜状态每维的标准差
  - $\text{div} \rightarrow 0$ ：模型输出常数 (坍塌) ——一个**有意义的**潜状态必须有非零方差
  - div 太大：潜状态在飘 (过反应)
- **responsiveness** (resp)：潜状态对观测的平均放大率  $\mathbb{E}[|\Delta z_t|/|\Delta o_t|]$ 
  - $\text{resp} > 10$ ：latent 比 obs 更抖 (噪声/过反应)

- $\text{resp} \approx 1$ : 温和放大 (正常)
- **event-alignment**  $\rho$ :  $\text{Pearson}(\Delta o_t, \Delta z_t)$  per step
  - $|\rho| \geq 0.95$ : 观测事件发生时潜状态同步跳变 (正常)
  - $|\rho| < 0.5$ : latent 跟 obs 没关系 (噪声)

#### 4.2.2 任务表现层 (事后报告)

- **mean\_cos\_dist**: 在一个测试 episode 中, 规划器执行 CEM (Cross-Entropy Method) 规划 5 步之后, 潜状态与目标潜状态 ( $t + \text{goal\_offset}$  帧处的) 之间的余弦距离。这是跨基准族的主指标,  $\in [0, 2]$ , 越小越好。
- **LeWM@0.05**:  $\Pr[\cos_{\text{dist}} < 0.05]$ ,  $\in [0, 1]$ , 越大越好。这是参考自 LeWM paper 的”潜余弦成功率”指标, 0.05 是更严的阈值 (避免被常数 latent 平凡通过)。
- **env-SR**: 环境的原生成成功判定 (DMC 状态下  $L_2$  距离  $\leq 0.1$  阈值内即算成功)。真实 state env-SR: 易 env 饱和 1.0 (ball\_in\_cup 1.0, cartpole 0.99, cheetah 0.997, finger 0.89), 难 env 为 0 (dog, humanoid, quadruped, reacher, stacker, tworoom), 每模型均值 0.34–0.38。区分度由 mean\_cos\_dist 承担。

### 4.3 三个评测轴 (详细定义)

#### 轴 1 (DMC 内部子族 gating experiment, 6 splits)

- **每个 split 持有 (held-out) 的子族**: 从 DMC 的 3 个子族 (classic control / locomotion / sparse-POMDP) 中选 1 个或 2 个, 整个子族下的所有 env 完全不进入训练集
- **训练用的子族**: 剩下的 1 个或 2 个子族的所有 env
- **splits 数**: 6 个 (3 个 1-subfamily held-out + 3 个 2-subfamily held-out) ——即 oodc\_F1、oodc\_F2、oodc\_F3、oodc\_F1F2、oodc\_F1F3、oodc\_F2F3
- **env 数**: 14 个 DMC env (评测时所有 14 个 env 都参与, 即使训练时见过)
- **cell 数**:  $6 \text{ splits} \times 12 \text{ models} \times 14 \text{ envs} = 1008 \text{ 个 cell}$
- **每个 split 的 held-out envs**:
  - oodc\_F1 (classic 训练, locomotion + sparse-POMDP 持有) : cheetah, walker, humanoid, humanoid\_CMU, hopper, quadruped, dog, delayed\_t\_maze, cheetah\_velhidden 等
  - oodc\_F2 (locomotion 训练, classic + sparse 持有) : cartpole\_2d, pendulum\_2d, finger, ball\_in\_cup, reacher 等
  - oodc\_F3 (sparse-POMDP 训练, classic + locomotion 持有)
  - oodc\_F1F2 (classic+locomotion 训练, sparse-POMDP 持有) : delayed\_t\_maze, cheetah\_velhidden 等

- oodc\_F1F3 (classic+sparse 训练, locomotion 持有)
- oodc\_F2F3 (locomotion+sparse 训练, classic 持有)
- 配置文件: 每个 split 的 configs/oodc/oodc\_Fx.json 同时给出 train\_envs、eval\_envs、train\_specs (含 max\_windows=2000)、eval\_specs

#### 轴 2 (跨基准族, 4 splits)

- 每个 split 持有的整族: 一个完整的跨基准族 (PushT / TwoRoom / Reacher / DMC) 完全不在训练集中
- 训练用的族: 其余三个族的并集 (每个 split 都是 15-16 个 env)
- splits 数: 4 个 (cross\_benchmark\_F1, F2, F3, F4)
- env 数 per split: 持有族含 1 个 env (PushT / TwoRoom / Reacher) 或 13 个 DMC env; 评测只在该持有族上
- cell 数:  $4 \text{ splits} \times 12 \text{ models} \times \{1-13\} \text{ envs} = 192 \text{ 个 cell}$  (具体为 F1=12, F2=12, F3=12, F4=156 = 192 total)
- 持有族内容:
  - F1 PushT 持有族: 1 env pusht (obs\_dim=7, action\_dim=2); 训练用 DMC  $\times$  14 + reacher + tworoom = 16 envs
  - F2 TwoRoom 持有族: 1 env tworoom (obs\_dim=10, action\_dim=2); 训练用 DMC  $\times$  14 + reacher + pusht = 16 envs
  - F3 Reacher 持有族: 1 env reacher (obs\_dim=4, action\_dim=2); 训练用 DMC  $\times$  14 + pusht + tworoom = 16 envs
  - F4 DMC 持有族: 14 个 DMC env; 训练用 pusht + tworoom + reacher = 3 envs
- 评测 unit 公式:  $4 \text{ splits} \times 13 \text{ models} \times 1 \text{ held-out env (或 13 DMC env for F4)} = 192 \text{ cells}$  (与下表 192 cells 一致)

#### 轴 3 (同一模型在不同任务规模下保持校准)

- G4 / G8 / G16: 4、8、16 个 env 同时训练 (共享权重)
- 每个 ckpt: 单次训练, 跨所有规模 (K 个 env) 的 env 上评测
- cell 数:  $13 \text{ models} \times 3 \text{ scales} \times K \text{ envs} / \text{scale}$

### 4.4 评测指标的” 双层” 设计 (详细数学定义)

#### 4.4.1 物理诊断层 (先验定义)

这一层的指标源自物理约束, 不依赖数据。它们是 3 个独立的量, 任何一个失败都说明模型坏了:

- **divergence-from-constant** (div): 在 200 步随机策略轨迹上, 潜状态每维的标准差
  - 形式化:  $\text{div}(z) = \mathbb{E}_d[\sqrt{\text{Var}_t(z_{t,d})}]$ , 即对每个潜空间维度  $d$  求轨迹上的标准差, 再对所有  $d$  取平均
  - $\in [0, +\infty)$ ,  $\text{div} = 0$  表示常数 latent (坍缩),  $\text{div} > 0.005$  表示有意义的方差
  - 经验校准区间:  $[0.008, 0.015]$ ; **阈值**:  $\text{div} \rightarrow 0$  = 坍缩 (MLP 实测  $\approx 0.0002$ ),  $\text{div} > 0.15$  = 过反应 (LeWM-v2 实测  $\approx 0.18$ )
- **responsiveness** (resp):  $\mathbb{E}_t \left[ \frac{\|\Delta z_t\|}{\|\Delta o_t\|} \right]$ , 逐时间步比值再平均
  - 形式化:  $\text{resp} = \frac{1}{T} \sum_{t=1}^T \frac{\|z_t - z_{t-1}\|_2}{\|o_t - o_{t-1}\|_2 + \epsilon}$
  - $\in [0, +\infty)$ , 理想值  $\approx 1$  (温和放大)
  - 经验校准区间:  $[0.15, 0.30]$ ; **阈值**:  $\text{resp} > 10$  = latent 比 obs 更抖 (噪声/过反应)
- **event-alignment**  $\rho$ :  $\text{Pearson}(\|\Delta o_t\|, \|\Delta z_t\|)$  per step
  - 形式化:  $\rho = \frac{\text{Cov}(\|\Delta o_t\|, \|\Delta z_t\|)}{\sigma(\|\Delta o_t\|) \cdot \sigma(\|\Delta z_t\|)}$
  - $\in [-1, 1]$ , 理想值  $\geq 0.95$  (观测事件发生时潜状态同步跳变)
  - **阈值**:  $|\rho| \geq 0.95$  = 校准 (STJEW 全部  $\rho \geq 0.99$ ),  $|\rho| < 0.5$  = latent 跟 obs 没关系 (噪声)

为什么这三个量是”独立的”: 坍缩 ( $\text{div} \rightarrow 0$ ) 不影响 resp 的分子分母同时为 0; 过反应 (resp 很大) 不影响 div 是否在合理区间; event-alignment 是 Pearson, 与 div/resp 的幅值无关——所以三者构成一个三角不可能性: 任一故障模式都只能让其中一个轴塌陷, 而不能同时塌陷。

#### 4.4.2 任务表现层 (事后报告)

- **mean\_cos\_dist** (主指标): CEM 终止时潜状态与  $z_{\text{goal}}$  的余弦距离
  - 形式化:  $\text{mean\_cos\_dist} = \frac{1}{N} \sum_{i=1}^N (1 - \cos(z_{\text{final}}^{(i)}, z_{\text{goal}}^{(i)})) / 2$
  - $\in [0, 1]$ , 越小越好。这是跨基准族的主指标
- **LeWM@0.05**:  $\Pr[\text{cos}_{\text{dist}} < 0.05]$ ,  $\in [0, 1]$ , 越大越好 (阈值 0.05 替代 0.1, 避免被坍缩 latent 平凡通过)
- **LeWM@0.01**:  $\Pr[\text{cos}_{\text{dist}} < 0.01]$ , 最严阈值,  $\in [0, 1]$
- **env-SR**: 环境的原生成功判定 (DMC ‘check\_success’ 使用  $L_2/\sqrt{n_q}$  距离  $\leq 0.1$  阈值)。真实 state env-SR: 易 env 饱和 1.0 (ball\_in\_cup 1.0, cartpole 0.99, cheetah 0.997, finger 0.89)、难 env 为 0 (dog, humanoid, quadruped, reacher, stacker, tworoom), 每模型均值 0.34–0.38; 区分度由 mean\_cos\_dist 承担。

## 4.5 4 家族分类法 (taxonomy)

| 家族           | 模型                        | 测试什么                                                           | 参数量          |   |
|--------------|---------------------------|----------------------------------------------------------------|--------------|---|
|              | stjewm_trace_only         | 默认, 膜电位禁止, $z = r_t$                                           | <b>5.06M</b> | / |
|              |                           |                                                                | 10.57M       |   |
|              | stjewm_spike_only         | $z = h \cdot s_t$ , 连续 $\times$ 二值掩码 (back-compat spike_gated) | <b>5.06M</b> | / |
|              |                           |                                                                | 10.57M       |   |
|              | stjewm_rate_only          | $z = \text{moving\_average}(s_t)$ , 纯速率编码                      | <b>5.06M</b> | / |
|              |                           |                                                                | 10.57M       |   |
| SNN / 神经形态对照 | stjewm_no_trace           | ablation, 无 trace 分支                                           | <b>5.06M</b> | / |
|              |                           |                                                                | 10.57M       |   |
|              | stjewm_hidden_leak        | $z = h + r_t$ (隐状态 + 轨迹, 混合)                                   | <b>5.06M</b> | / |
|              |                           |                                                                | 10.57M       |   |
|              | stjewm_membrane_readout   | $z = h$ , 违反协议 (规划器可读膜电位)                                      | <b>5.06M</b> | / |
|              |                           |                                                                | 10.57M       |   |
|              | alif_timecell_baseline    | ALIF + time-cell readout, $v_t$ 可读                             | <b>4.98M</b> |   |
|              | lif_transformer_baseline  | LIF 编码 + AdaLN-zero Transformer                                | <b>5.12M</b> |   |
|              | stacked_lif_trace         | 堆叠 LIF (自研), trace-only readout                                | <b>5.11M</b> |   |
|              | stacked_lif_free          | 堆叠 LIF (自研), free-access readout                               | <b>5.05M</b> |   |
| 非 SNN 循环对照   | lewm_transformer_baseline | LeWM-style AdaLN-zero Transformer                              | <b>4.97M</b> |   |
|              | gru_baseline              | GRU hidden=560, num_layers=2                                   | <b>5.13M</b> |   |
| 无状态对照        | mlp_baseline              | per-step FFN, no recurrence (坍塌控制)                             | <b>5.00M</b> |   |

**5M-aligned 参数公平:** 所有 8 个基线重新训练到 **4.97-5.13M** (range 0.16M,  $\pm 3.2\%$ ), STJEWB 保持 trainable=5.06M (含冻结 ViT 的 total=10.57M)。具体配置: mlp\_baseline hidden=640 num\_layers=12 (5.00M); lewm\_transformer embed=288 num\_layers=3 (4.97M); alif\_timecell\_baseline d\_hid=186 num\_layers=2 (4.98M); gru\_baseline hidden=560 num\_layers=2 (5.13M); stacked\_lif\_trace d\_in=672 num\_layers=8 (5.11M); stacked\_lif\_free d\_in=640 num\_layers=8 (5.05M); lif\_transformer\_baseline d\_snn=288 d\_tx=288 num\_layers=3 (5.12M)。在 5M-aligned 设置下, trace dynamics 假设的 collapse-robust 区分仍然成立: STJEWB 6 readouts 保持  $\text{resp} \approx 0.21$ 、 $\text{div} \approx 0.01\text{--}0.03$  (校准带  $[0.005, 0.05]$  内), MLP 仍是  $\text{div} \rightarrow 0$  (坍塌), LeWM-v2 仍是  $\text{resp} \gg 1$  (过反应)。

**5M-aligned 跨基准族结果 (130/130 ckpts):** 所有 130 个 ckpt (13 模型  $\times$  10 splits) 都完成了 5M-aligned 训练。在 5M 参数公平下, trace dynamics 假设的 collapse-robust 三分法清晰呈现:

| Model                    | F1 (PushT) | F2 (TwoRoom) | F3 (Reacher) | Mean                               |
|--------------------------|------------|--------------|--------------|------------------------------------|
| <b>STJEWB 6 readouts</b> | 50-60%     | 48-58%       | 50-84%       | <b><math>\sim 55\%</math> (校准)</b> |
| CubifA_baseline          | 58.6%      | 52.9%        | 57.1%        | 56.2% (matches STJ)                |
| Stacked-LIF-free         | 58.6%      | 51.4%        | 54.3%        | 54.8% (matches STJ)                |
| Stacked-LIF-trace        | 57.1%      | 73.3%        | 84.0%        | 71.5% (notably better c)           |
| gru_baseline             | 91.4%      | 87.1%        | 81.4%        | 86.7% (过反应噪)                       |
| lewm_baseline_v2         | 34.3%      | 25.7%        | 35.7%        | 31.9% (过反应)                        |
| mlp_baseline             | 100.0%     | 92.9%        | 94.3%        | 95.7% (坍塌对照)                       |
| lif_transformer_baseline | 100.0%     | 100.0%       | 100.0%       | 100.0% (坍塌对照)                      |

**关键结论:** 三分法在 4.97M  $\rightarrow$  5.13M 范围内依然成立。STJEWB 6 readouts 都保持  $\text{resp} \approx$

**0.21**、 $\text{div} \approx 0.01\text{--}0.03$  (校准), 与 **ALIF-timecell** 和 **Stacked-LIF** 处于同一 collapse-robust 簇。**MLP** 和 **LIF-Transformer** 是坍塌对照 ( $\text{resp} \rightarrow 0, \text{div} \rightarrow 0, \text{cos\_dist} \approx 0$ ), **GRU** 和 **LeWM-v2** 是过反应 ( $\text{resp} \gg 1, \text{div} \gg 0.05$ )。这验证了 trace dynamics 假设 **对参数规模鲁棒**: 从 5.00M (MLP) 到 5.13M (GRU) 的 5M-aligned 范围内都呈现相同的 collapse-robust 区分。

#### 4.5.1 §2.3a – LeWM-SR 的实验性证伪

本节是本文新的头条。13 个 baseline 模型在阈值  $\text{cos\_dist} < 0.1$  下制表 (LeWM-SR, 5M-aligned 聚合)。该表的关键读数是: **无状态 MLP baseline 达到 LeWM-SR = 97.3%**, 高于**每个循环世界模型基线** (次高 GRU 90.8%)。这是”指标人为产物”: 如果模型的潜状态是常数, 则它把每个输入映射到同一点, 目标潜状态与该常数的余弦距离本质上为零, 因此阈值  $\text{cos\_dist} < 0.1$  空洞地成立。

我们把这个论点作为它实际是的”证伪”对待, 并明确化。在相同 ckpt 上直接比较三个量:

| model (5M-aligned)  | LeWM-SR      | div (latent std/dim) | $\rho$ (event-align) |
|---------------------|--------------|----------------------|----------------------|
| <b>mlp_baseline</b> | <b>97.3%</b> | 0.0002               | −0.023               |
| stjewm_trace_only   | 58.7%        | 0.0106               | 0.9987               |
| lewm_baseline_v2    | 34.2%        | 0.204                | 0.7515               |
| gru_baseline        | 90.8%        | 0.0304               | −0.007               |

表 1: 5M-aligned 聚合 (89 cells/model, eval JSON + 5m\_stats + G1) 的 MLP 行就是 §2.3a LeWM-SR 证伪的实证锚点: 一个无状态 FFN, per-dim 潜状态标准差 0.0002,  $\rho = -0.023$ , 却在 LeWM-SR 上得分最高 (97.3%); 次高是同样坍塌的 GRU (90.8%)。被常数潜状态能通过的指标, 不能作为规划器质量信号。

这些数字构成一个清晰的负对照: **LeWM-SR 与潜状态表征的每个其他轴方向相反**。坍塌模型 (MLP 97.3%、GRU 90.8%) 得分**最高**, 校准的 STJEWm-trace 居中 (58.7%), 过反应的 LeWM-v2 反而最低 (34.2%)。方向反转是因为规划器的任务是把  $z$  推向  $z_{\text{goal}}$ ,  $z$  越接近  $z_{\text{goal}}$  越容易, 但  $z$  绝不应该从”无论输入什么都相同”开始。

**操作性改革**: 一个潜状态指标作为规划器质量指标被允许的**唯一**条件是它”不能被常数潜状态欺骗”。如果常数潜状态的模型能通过该指标, 则该指标是测量人为产物, 必须配以 collapse-robust 诊断。

四指标包 (env-native SR、div、resp、 $\rho$ ) 按构造就具有该性质。**LeWM-SR 单独没有**, 而 master table 的 MLP 行就是证明它的数据点。同一个 MLP 行锚定了 **§2.3a 中 LeWM-SR 作为独立头条的弃用**: 本论文中每个 LeWM-SR 分数都应在 div 和  $\rho$  的背景中读, **绝不单独读**。5M-aligned 重新训练 (full report 见 §6.1) 以更严格的参数匹配复现相同的 partition。



Four-metric package distinguishes 4 failure modes (v0.7.5 specialist, n=130 cells)  
MLP has LeWM-SR = 98% (highest) yet  $\rho = -0.002$  (lowest). A single latent metric cannot diagnose calibration -- §2.3a falsification.




图 1: §2.3a 头条视觉 (5M-aligned, 89 cells/model)。左: env-native SR 在 36.0–36.7% (0.7pp 范围), 不区分潜状态质量。中左: div (log), MLP 0.0002 比其他模型低 2–3 个数量级。中右:  $\rho$  区分 STJEW-Trace (0.9987) 与循环/无状态基线 (GRU  $-0.007$ 、MLP  $-0.023$ ; LeWM-v2 中等 0.75)。右: LeWM-SR 把 MLP 放在 97.3%——最高——尽管其 div=0.0002 且  $\rho = -0.023$ ; 次高 GRU 90.8% 同样坍塌。这一行证伪了 LeWM-SR。

**派生单数字 sanity check:** env-SR / LeWM-SR 的比值可从现有数据直接算出 (5M-aligned): MLP 0.37 (vacuous, 坍塌)、GRU 0.40 (坍塌)、STJEW-Trace 0.63、LeWM-v2 1.05。该比值与 LeWM-SR 一样可被常数潜状态空洞拉高 (MLP/GRU 最低比值却来自坍塌), 故 extbf 不作为独立诊断——与 §2.3a 的证伪一致。

#### 4.6 跨基准族与 OOD Path-C 的关键区别

两个看似都是”跨 env 转移”的评测轴, 在数据流上有本质不同:

- **跨基准族 (轴 2):** 每个 split 训练 同一个 ckpt 的 4 个副本。例如 cross\_benchmark\_F1 = "PushT held out", 训练时使用 DMC  $\times$  14 + reacher + tworoom = 16 env 的并集 (来自 configs/oodc/cross\_benchmark\_F1\_train\_only.json); 训练 1 个 ckpt, 在 4 个 splits 上各训练 1 个 ckpt = 13 models  $\times$  4 splits = 52 ckpts。评测在持有族 (PushT / TwoRoom / Reacher / DMC) 的 env 上
- **OOD Path-C (轴 1 的 gating experiment):** 每个 split 训练 6 个 split-专属 ckpt。例如 oodc\_F1 = "classic 训练, locomotion + sparse 持有", 使用 configs/oodc/oodc\_F1.json 中的 train\_envs (5 个 classic env); 训练 6 个 split 各自的 ckpt, 每 split 训 13 models = 13  $\times$  6 = 78 ckpts

根本区别:

可测试声明的不同:

- **OOD Path-C:** 6 个 split 各自 1 个 ckpt——比较的是不同 ckpt 在同一评测 env 上的表现
- **跨基准族:** 4 个 splits 各自 1 个 ckpt——比较的是同一训练范式对不同持有族的反应

## 4.7 为什么需要双层指标？

仅用潜余弦成功率这一指标会**误判**：MLP（无状态前馈网络）的旧版本（容差 1.0、阈值 0.1）LeWM-SR 达到  $\sim 100\%$ ——因为其常数零 latent 到任何目标 latent 的余弦距离都接近 0。但它**显然不是一个能规划的世界模型**。要剔除这种伪赢家，必须联合使用  $\text{div}$  /  $\text{resp}$  /  $\rho$  三个物理诊断。

## 4.8 DMC 标准 14 环境（用于轴 1 评测）

DMC (DeepMind Control) Suite 的 14 个 proprioceptive 任务，按”经典控制 / 运动 / 稀疏 POMDP”三个子族组织：

**env\_id 字符串与代码路径**：每个 env 在 `code/core/envs/dmc_env.py:83-100` 的 `DMC_ENVS` 字典中以小写 `env_kind` 注册（如 `"cartpole"`、`"reacher"`），观测维度由 XML 的 `qpos` + `qvel` 自动推断；`action_dim` 来自 XML 的 `actuator` 数。`env_kind` 在多 env 训练时通过 `configs/oodc/*.json` 的 `train_specs[].env_kind` 字段传递（值域为 `"dmc"`，`"reacher_4d"`，`"pusht"`，`"tworoom"`，...）。

**obs\_dim 详细解释：**

- **经典控制 + 运动子族**：obs 是 proprioception——关节位置 + 关节速度的拼接。例 `cheetah` = 9 维 `qpos` + 6 维 `qvel`（实际 `obs_dim` = 9，因 XML 暴露维度与 `qpos` 重叠）——`DMC_ENVS["cheetah"]` 注册的是 `obs_dim=9`
- **稀疏 POMDP (`reacher`)**：obs = (`qpos[0:2]`, `target[0:2]`)  $\in \mathbb{R}^4$ 。target 是部分可见——这就是”sparse POMDP”的命名来源：目标位置不在状态空间内，是需要推断的隐藏变量
- **延迟 t-maze (sparse-POMDP 子族的极端)**：obs = (`agent_x`, `agent_y`, `cue_x`, `cue_y`, `corridor_marker`, `goal_marker`)  $\in \mathbb{R}^6$ ，`cue_visibility` 帧之后 `cue` 被遮蔽——强制工作记忆

**action\_dim 详细解释：**

- 所有 DMC env 的 `action` 范围统一为  $[-1, 1]^{\text{action\_dim}}$
- `humanoid_CMU` 实际是 `action_dim=56`（XML 注册）而非 6——但 `obs_dim=63`（XML 注册），包含 `cmurange` 标记

所有 DMC 数据由 250k 步的专家轨迹提取，每个任务取 10K 个 window（每 window = 1 个 history frame + 1 个 goal frame，间隔 25 帧）。“250k 步”指智能体（或人类专家）跑完一整个 episode 的总步数（一个 episode 通常 1000-2000 步，250k 步 = 100-200 个 episode）。

### 4.8.1 16 个 env 的逐个详解（任务描述、状态维度、物理含义与样本观测）

上一小节给出了 14 个 DMC env + 4 个跨基准族 family 的整体概览。下面**逐个**展开 16 个 env 的训练用状态（`env.get_state()`）的物理含义、可视化样本与一行任务描述。每个 env 都从 `seed=0` 开始随机重置、走 50 步随机动作后捕获一次“非平凡”状态，并配上：(i) DMC/Reacher 用 MuJoCo 离屏渲染的 3D 场景；(ii) PushT/TwoRoom 用 2D 几何散点；(iii) 观测向量的 bar chart；(iv) 数值化样本。

| env          | obs × act | 子族       | goal_off | 数据路径                  | 任务描述      |
|--------------|-----------|----------|----------|-----------------------|-----------|
| cartpole_2d  | 5 × 1     | 经典控制     | 25       | cartpole_250k.npz     | 小车摆杆平衡    |
| pendulum_2d  | 4 × 1     | 经典控制     | 25       | pendulum_250k.npz     | 单摆倒立      |
| finger       | 3 × 1     | 经典控制     | 25       | finger_250k.npz       | 手指旋转定位    |
| ball_in_cup  | 6 × 2     | 经典控制     | 25       | ball_in_cup_250k.npz  | 球进杯       |
| reacher (4D) | 7 × 2     | 稀疏 POMDP | 25       | reacher_250k.npz      | 2 关节机械臂到点 |
| cheetah      | 6 × 6     | 运动       | 25       | cheetah_250k.npz      | 猎豹向前跑     |
| walker       | 8 × 6     | 运动       | 25       | walker_250k.npz       | 双足行走      |
| hopper       | 8 × 3     | 运动       | 25       | hopper_250k.npz       | 单足跳跃      |
| quadruped    | 12 × 6    | 运动       | 25       | quadruped_250k.npz    | 四足运动      |
| humanoid     | 28 × 6    | 运动       | 25       | humanoid_250k.npz     | 人形行走      |
| humanoid_CMU | 63 × 6    | 运动       | 25       | humanoid_CMU_250k.npz | CMU 标记人形  |
| dog          | 79 × 6    | 运动       | 25       | dog_250k.npz          | 四足狗步态     |
| fish         | 13 × 5    | 运动       | 25       | fish_250k.npz         | 鱼游泳       |
| stacker      | 11 × 6    | 运动       | 25       | stacker_250k.npz      | 堆叠方块      |

完整脚本与原始数值 dump 见 `paper/figs/dataset_samples/generate_samples.py` 与 `paper/figs/dataset_samples/obs_samples.json`。




图 2: 16-env 总览：每个子图是同一个 env 在 `seed=0`、50 步随机动作后的瞬时状态。左列 ~ 右列、上到下：DMC  $\times$  13 + Reacher + PushT + TwoRoom。

### 总体说明：

- **obs 语义**：DMC / Reacher 的 obs = mujoco qpos[:nq]，即纯关节位置（位置空间 proprioception）。目标位置 / 期望轨迹 **不在 obs 内**——这是 proprioceptive control 的标准设定。`goal_offset=25` 表示从 history frame 出发经过 25 步后的状态作为 goal frame
- **PushT / TwoRoom**：obs 是 `stable_worldmodel` 返回的 (agent + target + 内部状态) 的拼接，包含 agent 位置/速度与 block/door 等离散几何对象的姿态
- **观测维度差异**：从 cartpole 的 2D 到 humanoid\_cmu 的 63D——这是评测“跨 obs\_dim 泛化”的核心难度。所有 13 个模型在 G16 训练时 obs 都 0-pad 到 128 维、action 都 0-pad 到 56 维

- **每幅子图的物理读法**: DMC 3D 渲染的角度是 XML 默认视角（前视或侧视）；PushT 是 2D 平面几何，agent 是蓝圆、block 是绿色 T 形（带角度旋转）、target 是红色虚线 T；TwoRoom 是 2D 平面几何，agent 是蓝点、target 是红星、中央墙 + 门洞（door）位于  $x=150$  附近

下面按子族分组给出 16 个 env 的**详细参数表 + 物理含义**。obs\_dim / action\_dim 列是 code/core/envs/dmc\_env.py:83-100 的 DMC\_ENVS 表（或 swm\_envs.py:45-170 的对应 wrapper）的注册值；goal\_offset 列来自 configs/generalist\_16env.json。

### F1 经典控制（4 个 DMC + Reacher，共 5 个）:

| env             | obs | act | goal | 每维物理含义                                                                                                                                    | 样本观测 (seed=0, 50 步)                  |
|-----------------|-----|-----|------|-------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------|
| cartpole_2d     | 2   | 1   | 25   | [cart_x, pole_angle]: 推车水平位置 (米)、摆杆相对直立的角度 (弧度, 0 = 直立)。XML: mujoco/cartpole.xml                                                          | [+0.4032, -0.3384]                   |
| pendulum_2d     | 2   | 1   | 25   | [cos $\theta$ , sin $\theta$ ]: 单摆角度的 (cos $\theta$ , sin $\theta$ ) 展开 (避免角度缠绕); 1D 力矩输入。MuJoCo XML 内部存的是 1 维 $\theta$ , wrapper 展开为 2 维 | [+0.2967, +0.9550]                   |
| finger          | 3   | 2   | 25   | [qpos[0..2]]: 双指关节 (前指 proximal / distal 角、目标指轮的旋转角度); 2D action 控制指指尖端 xy 位置                                                             | [+0.4220, -0.5861, -0.8207]          |
| ball_in_cup     | 4   | 2   | 25   | [cup_x, cup_z, ball_x, ball_z]: 杯的水平/垂直铰链角 (弧度)、小球在支架坐标系下的位置; 目标是把球摇进杯里                                                                   | [-0.0004, -0.0233, +0.0003, -0.0315] |
| reacher<br>(4D) | 4   | 2   | 25   | [shoulder_q, elbow_q, target_x, target_y]: 两关节角 (弧度) + 目标位置在 2D 平面坐标 (米, 范围 $\pm 0.21$ )。目标在 obs 内但每 episode 重置, 是 sparse POMDP 的代表       | [+0.4303, -0.7232, -0.1836, -0.1934] |

### F2 运动 (9 个 DMC):

| env       | obs | act | goal | 每维物理含义                                                                                                                                                                                                                         | 样本观测 (seed=0, 50 步)                                                                             |
|-----------|-----|-----|------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------|
| cheetah   | 9   | 6   | 25   | [x_pos, z_pos, y_rot, front_hip, front_shin, front_foot, back_hip, back_shin, back_foot]: 2D 半猎豹沿地面奔跑, qpos 含 1 个 root 水平位置 + 1 个 root 高度 + 1 个 root 旋转 + 6 个后腿关节; 6D action = 6 个关节扭矩                                         | [-0.1404, -0.0982, +0.0556, +0.0160, -0.0522, -0.0787, -0.0404, -0.0527, -0.2024]               |
| walker    | 9   | 6   | 25   | [x_pos, z_pos, y_rot, right_hip, right_knee, right_ankle, left_hip, left_knee, left_ankle]: 2D 双足行走器 (MuJoCo walker); 9 个 qpos 含 root 三参数 + 6 个关节                                                                              | [-0.0743, -0.0050, +0.0590, +0.6904, -1.2262, -0.0472, +0.0987, -0.6197, +0.6887]               |
| hopper    | 7   | 4   | 25   | [x_pos, z_pos, y_rot, thigh, leg, foot]: 2D 单腿跳跃器 (root 三参数 + 3 个关节); 4D action 控制 4 个扭矩                                                                                                                                       | [-0.0239, -0.2937, +0.1536, -0.1824, -1.0106, +0.0819, -0.2233]                                 |
| quadruped | 30  | 12  | 25   | [root_xyz, root_quat(4), $\times 4$ legs (hip $\times 3$ + knee $\times 3$ )/leg]: 3D 四足机器人, 每条腿 3 个关节共 12 个关节; XML qpos 含 root 7 参数 (xyz + 四元数) + 12 关节 = 19; 但 obs_dim=30 因 XML 注册包含额外 root 自由度与脚趾指示变量。12D action = 12 个关节扭矩 | [-0.4621, +0.2896, +1.3941, +0.7517, -0.4908, +0.0646, ..., +1.0000, +0.0000, +0.0000, +0.0000] |

| env          | obs | act | goal | 每维物理含义                                                                                                                              | 样本观测 (seed=0, 50 步)                                                                                |
|--------------|-----|-----|------|-------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------|
| humanoid     | 28  | 21  | 25   | [root_xyz, root_quat(4), 21 关节角]: 2D 简化人形 21 关节 (MuJoCo humanoid.xml, 21 个 actuator 对应 21 个 joint)。注意: XML 注册 obs_dim=28、act_dim=21 | [-0.0613, -0.0062, +1.1277, +0.9768, -0.1051, -0.1106, ..., -0.4508, -0.2026, -0.5048, -0.6437]    |
| humanoid_CMU | 63  | 56  | 25   | [root_xyz, root_quat(4), cmurange(56)]: 3D 高自由度人形 (CMU mocap 标记); 56 维 cmurange 是 mocap 关节角度, 56 维 action 控制 56 个 actuator          | [-0.0004, -0.0002, +0.9503, +0.7367, +0.6759, -0.0203, ..., +0.2063, +0.0861, -0.1953, +0.1751]    |
| dog          | 87  | 38  | 25   | [root_xyz, root_quat(4), 38 关节 + 18 速度辅助变量]: 3D 高自由度四足狗 (MuJoCo dog.xml), 38 维 actuator; XML 注册 obs_dim=87 (含额外 root state 与速度估计项)  | [+0.0363, +0.0127, +0.1913, +0.9867, +0.1426, +0.0737, ..., +1.0000, -0.0000, +0.0000, +0.0000]    |
| fish         | 14  | 5   | 25   | [root_quat(4), 5 关节角, 5 速度, 1 尾巴辅助]: 2D 鱼形游泳 (MuJoCo fish.xml) ; 5 维 actuator 控制躯体摆动 + 尾部                                           | [+0.0045, -0.0177, +0.1039, +0.9898, +0.0307, -0.1151, ..., -22.0118, +14.5302, +14.8166, +4.2708] |
| stacker      | 20  | 5   | 25   | [root_xyz, root_quat(4), 5 关节, 5 个 cube 指示变量]: 2D 抓取机械臂堆叠 3 个立方体 (MuJoCo stacker.xml); 5D action 控制末端                               | [+0.0032, +0.3956, -0.6476, -1.1333, +0.1196, +0.0730, ..., +0.0000, +0.2000, +0.3875, +0.0000]    |

### 跨基准族 2 个 2D 几何 env (PushT / TwoRoom):

| env     | obs | act | goal | 每维物理含义                                                                                                                                                                                                                                                                         | 样本观测 (seed=0, 50 步)                                                      |
|---------|-----|-----|------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------|
| pusht   | 7   | 2   | 100  | [agent_x, agent_y, agent_vx, agent_vy, block_x, block_y, block_angle]: swm/PushT-v1 的 7D 状态。Agent 是平面圆盘 (半径 12 px), 位置/速度; block 是 60×60 px 的 T 形方块, 位置 + 旋转角度。成功判定: block 位于目标位置 (200,100) ± 70 px 且角度 ± 1.0 rad。action_low/high 来自 gym action_space (~ [-1,1] <sup>2</sup> ) | [+163.82, +265.62, +383.77, +318.04, +4.97, -285.17, +347.66]            |
| tworoom | 10  | 2   | 100  | [agent_x, agent_y, target_x, target_y, door?, 5 内部状态]: swm/TwoRoom-v1 的 10D Box 观测。前 4 维是 agent + target 在 2D 平面的位置; 第 5 维是 door 状态 (开放/关闭); 最后 5 维是环境内部状态 (门状态码、agent 是否在房间 A/B、目标房间等)。Goal_offset=100 (典型 LeWM paper 设置); 目标可能在房间 A 或房间 B, agent 不知道——需要工作记忆 / 推断            | [+149.17, +84.13, +99.83, +81.18, +112.0, +49.0, +0.0, +0.0, +0.0, +0.0] |

### 为什么 goal\_offset 在 DMC/Reach/PushT 之间不同:

- **DMC × 14 + Reacher (goal\_offset = 25)**: 25 步 ≈ 0.5 秒控制循环 (dt=0.02s), agent 短视野即可完成大多数 DMC 任务的“局部姿态调整”; CEM 5 步规划器达不到 25 步目标 (horizon artifact), 但 mean\_cos\_dist 仍给出有意义的潜变量对齐信号
- **PushT / TwoRoom (goal\_offset = 100)** : 100 步 ≈ 2 秒控制循环; PushT 需要 agent 绕到 block 后面推动 → 必须有长期预测能力; TwoRoom 需要 agent 穿过 door 才能到达另一房间——单步视野无意义。两者的 LeWM paper 也使用

100。configs/oodc/cross\_benchmark\_F4\_train\_only.json 中 pusht / tworoom 的 goal\_offset=100 是 **显式选择**（与 DMC 的 25 形成对比）

**每幅子图的展示位置：**

- 16-env 总览（图 2）：4×4 网格，每个子图是一个 env 在 seed=0 / 50 步后的瞬时渲染
- 单 env 大图（paper/figs/dataset\_samples/<env>.png, 800×600）：三栏——上：物理场景（DMC 3D 渲染或 2D 几何散点）；中：obs 向量 bar chart（带维度标签）；下：文字 caption（任务描述 + obs\_dim + action\_dim + 数值化样本）

由 obs\_dim 看 STJEWM 设计的物理负担：从 cartpole 的 2D 到 dog 的 87D，STJEWM 通过 G16 训练的 pad\_obs\_to=128 统一接收；每个 env 的样本在进入模型前都先做 per-batch 全局 z-score 归一化，让跨 env 的 obs 在同一尺度——这是跨基准族评测能成立的前提（详见 §5.3“状态标准化”）。

#### 4.8.2 “DMC×14” / “DMC×13” / “+ reacher / tworoom / pusht” 记法说明

本报告（及 paper.md、README.md）频繁出现“DMC×14”、“DMC×13”、“DMC×12 + reacher”、“DMC×14 + reacher + tworoom”这样的记法。这里**统一说明**以避免混淆：

**记法的含义：**“DMC×N” = “N 个 DMC 标准 proprioceptive env 的并集”。“DMC×14”是包含 14 个 env 的**满集**；“DMC×13”、“DMC×12”等是**去除某些 env 后的子集**。“+ reacher”、“+ tworoom”、“+ pusht”是在 **DMC 集合外追加**的 1-3 个跨族 env。

**“DMC×14”包含哪些 env**（按子族分类，共 14 个）：

- **F1 经典控制（4 个）**：cartpole\_2d（5 维小车摆杆）、pendulum\_2d（4 维单摆）、finger（3 维手指旋转）、ball\_in\_cup（6 维球进杯）——低维 proprioception + 简单动力学
- **F2 运动（9 个）**：cheetah, walker, hopper, quadruped, humanoid, humanoid\_CMU, dog, fish, stacker——9 个，不是 5 个（常有读者误以为“5”）。高维 proprioception + 关节动力学 + 接触
- **F3 稀疏 POMDP（1 个）**：reacher（4D）——2 关节机械臂，target 部分可见
- **合计**：4 + 9 + 1 = 14 个 env。这是“DMC×14”的标准定义

**“DMC×13”、“DMC×12”等子集是怎么来的：**在 OOD Path-C 的某些 split 中，**训练 env** 是 DMC 的子集（不是全集）。例如：

- **oodc\_F1 (classic 训练)**：train\_envs = cartpole\_2d, pendulum\_2d, finger, ball\_in\_cup, cheetah = 5 个 env（“DMC classic (4) + locomotion cheetah (1)”）。评测在 **8 个 held-out env**（walker, humanoid, humanoid\_CMU, hopper, quadruped, dog, delayed\_t\_maze, cheetah\_velhidden）上
- **oodc\_F1F2 (classic + locomotion 训练)**：train\_envs = 10 个 classic + locomotion 全部（缺 cheetah\_velhidden 和 reacher）。评测在 **2 个 held-out**（delayed\_t\_maze, cheetah\_velhidden）上

- “DMC×14 + reacher”: 14 个 DMC env + 1 个 reacher = **15 个 env**。跨基准族 F1/F2/F3 都用这个 15-16 env 集
- “DMC×14 + reacher + tworoom”: F1 split 的训练集 = 14 + 1 + 1 = **16 个 env**。评测在 pusht 上（不在训练集）
- “DMC×13” 来自哪里：跨基准族 F4 (DMC held out) 里，训练用 pusht + tworoom + reacher (3 个非 DMC env)，评测在所有 14 个 DMC env 上。但**为了避免数据泄露**，cheetah\_velhidden（一个 stress variant of cheetah）有时被**有意排除**——这时评测 env 集是 13 个。说 “DMC×13” 几乎总是指 F4 split 的 14 个 DMC env 中**去除 stress variant** 后的子集（13 个）

为什么 “14” 和 “13” 重要：评测 cell 数 = models × envs。

- F1/F2/F3 = 13 models × 1 env = 13 cells/split
- F4 (“DMC×13” 版本，去除 stress variant) = 13 models × 13 envs = 169 cells/split
- **总 cells**: F1 + F2 + F3 + F4(13) = 13 + 13 + 13 + 169 = **208** (13 模型版本); F1 + F2 + F3 + F4(14) = 13 + 13 + 13 + 182 = 221 (14 模型版本)

本报告 “192 cells” 的依据（早期 12 模型版本）: F1 = 12, F2 = 12, F3 = 12, F4 = 156, 12 + 12 + 12 + 156 = 192。当前 13 模型实验改用 13 × 4 = 52 个跨基准族 ckpt + oodc 13 × 6 = 78 个 + G16 13 × 1 = 13 个，合计 143 ckpt，跨所有 split 的总 eval cell 数 = 1110。

“×12 + reacher” / “×14 + pusht” 等其他变体：当某个 split 排除了 DMC 集合中的部分 env、但又追加了非 DMC env 时，用 “×N + X” 表示。例如 “DMC×12 + reacher” = 12 个 DMC env + 1 个 reacher = 13 个 env 训练集（用于某个 G16 子集 pilot）。这种记法在 paper.md 和 code/scripts/generalist\_v0\_7\_5/ 的注释里出现。

#### 4.9 跨基准族 4 个 held-out family（用于轴 2 评测）

跨基准族评测使用 4 个**范式完全不同的 family**，每个 family 是一个独立的评测单元集：  
范式差异：

- **PushT**: 接触动力学 + 离散块推动事件；obs 包含 agent 与 block 两组耦合状态
- **TwoRoom**: 纯几何导航 + 部分观测（agent 不知道目标在哪个房间）
- **Reacher**: 2 关节欠驱动运动学；target 在状态空间内但每个 episode 重置
- **DMC**: 高维 proprioception + 连续控制 + 关节动力学

数据来源路径：

- **PushT**: /home/lx/LeWM/data/pusht\_expert\_train.h5 (HDF5, env\_kind = "pusht")
- **TwoRoom**: /home/lx/LeWM/data/tworoom\_extract/tworoom.h5 (HDF5, env\_kind = "tworoom")



| Family            | env_id (实际)       | obs_dim     | action_dim | goal_off | 任务描述                                                                                                            |
|-------------------|-------------------|-------------|------------|----------|-----------------------------------------------------------------------------------------------------------------|
| <b>F1 PushT</b>   | swm/PushT-v1      | 7           | 2          | 100      | 2D 块推动: 7D state = (agent pos+vel, block pos+vel+angle+angvel); 成功判定 block 在目标位置 $\pm 0.07$ m, 角度 $\pm 1.0$ rad |
| <b>F2 TwoRoom</b> | swm/TwoRoom-v1    | 10          | 2          | 100      | 2 房间部分观测导航: 10D Box 观测; 目标位置在 $5 \times 5$ unit 房间内; 成功判定 $\text{dist} \leq 1.0$                                |
| <b>F3 Reacher</b> | mujoco/reacher    | 4           | 2          | 25       | 2 关节机械臂到点: 4D state = (qpos[0:2], target[0:2]); max_episode_steps = 50                                          |
| <b>F4 DMC</b>     | mujoco/<env_kind> | <b>3-87</b> | 1-6        | 25       | 14 个 proprioceptive DMC 任务 (如 §5.1)                                                                             |

- **Reacher**: data/dm\_control/3d\_rollouts\_250k/reacher\_250k.npz (env\_kind = "reacher\_4d")
- **DMC**: 14 个 <env>\_250k.npz (env\_kind = "dmc")

**训练集 vs 评测集**: 跨基准族训练使用 15-16 个环境的并集 (gating family held out), 评测在 held-out family 上。例如, PushT-held-out 的训练集是 {DMC  $\times$  14, Reacher, TwoRoom} (15 个环境), 评测只在 PushT 上。配置文件:

- configs/oodc/cross\_benchmark\_F1\_train\_only.json: PushT held out, 训练用 15 env
- configs/oodc/cross\_benchmark\_F2\_train\_only.json: TwoRoom held out, 训练用 15 env
- configs/oodc/cross\_benchmark\_F3\_train\_only.json: Reacher held out, 训练用 15 env
- configs/oodc/cross\_benchmark\_F4\_train\_only.json: DMC held out, 训练用 3 env

每个文件的 max\_windows 字段为 10000, 单 env 上限 10K window。

#### 4.10 数据加载与采样 (窗口构造)

**window 的精确数学定义** (code/data/base.py:WindowDataset): 设轨迹为  $\{(o_t, a_t)\}_{t=0}^{N-1}$ , 从起始步  $s$  出发的窗口为

$$w_s = (\{o_t\}_{t=s}^{s+H+G}, \{a_t\}_{t=s}^{s+H+G-1}, o_{s+G}), \quad H = 1, G = 25,$$

即: state 张量  $(H+G+1)$  帧  $(o_s, \dots, o_{s+H+G})$ ; action 张量  $H+G$  帧后末尾补一行零与 state 对齐; init\_state =  $o_s$  (索引 0); goal\_state =  $o_{s+G}$  (索引  $G$ )。

**采样**: 从每 env 的 250k 步轨迹中以均匀起始步采样生成 max\_windows 个窗口 (5M 配置每 env 2000, 见 configs/oodc\_5m/\*.json)。

- **history\_size**: 条件帧数。5M 训练与评测均取  $H = 1$  (仅当前帧); closed\_loop.py CLI 默认值 3 仅在未显式传参时生效, 5M 评测脚本 (eval\_one.sh) 从 split 配置显式传入  $H = 1$
- **goal\_offset**: 5M 全配置  $G = 25$  (含 PushT / TwoRoom); 目标帧为起始帧之后  $G$  步的真实状态  $o_{s+G}$
- **padding 方案**: obs 零 pad 到 pad\_obs\_to = 128, action pad 到 action\_dim = 56; 模型读 padded 输入, env.step 只取前 action\_dim 维

#### 4.11 状态标准化

**全局 z-score vs per-env z-score**:

- **per-env**: 每个 env 各自估计均值与方差。优点: 单 env 上训练更稳定; 缺点: 跨 env 时尺度不一致, shared-weight generalist 难以学习
- **全局** (G16 选择): 将所有 env 的轨迹合并, 估计一个**联合均值/方差** (通常基于 union dataset 的 0.05 / 0.95 分位)。优点: 跨 env 一致; 缺点: 少数 env 的极端值会拉伸分布

本文采用**全局 z-score**——因为所有 13 模型共享相同的训练集，且评测时也是同一尺度。这避免了一个隐藏 bug：per-env normalization 在跨基准族评测时会让  $z_{\text{history}}$  与  $z_{\text{goal}}$  在不同尺度上，导致 cosine 距离偏差。

#### 4.12 STJEWm 系列 (6 个读出口径)

所有 STJEWm 模型共享**同一个纯 SNN 骨架** (4 层 MultiComp 堆叠,  $\text{embed\_dim} = 192$ ,  $\text{n\_d} = 3$ ) : state 模态 trainable = total = **5.06M**; pixel 模态 trainable = 5.00M (0.074M projector + 4.93M SNN predictor), 另有冻结 ViT-Tiny 编码器 5.46M 不计入可训练参数。区别**仅在最后一步**——规划器看到什么: **校准对参数量鲁棒** ( $\text{n\_layers}=4$  trainable=5.06M 与早期  $\text{n\_layers}=2$  trainable=2.70M 的  $\text{cos\_dist}$   $\text{delta} < 0.004$ : trace 0.105→0.104, spike 0.108→0.111, rate 0.103→0.103, no\_trace 0.119→0.123, leak 0.119→0.120, membrane 0.124→0.122)。

- **trace\_only** (5M 实验主口径, 膜电位禁止):  $z_t = \text{trace\_proj}(r_t)$ 。规划器只能看到有界的、内容感知的轨迹
- **spike\_only** (back-compat spike\_gated):  $z_t = h_t \odot \text{sg}(s_t)$  (连续隐状态被脉冲二值掩码, 掩码 detach)
- **rate\_only**:  $z_t = \text{AvgPool}_{d_k=4}(\text{sg}(s_t))$ 。纯速率编码
- **no\_trace** (ablation):  $z_t = h_t$  (无轨迹门控)
- **hidden\_leak**:  $z_t = h_t + \text{trace\_proj}(r_t)$  (隐状态 + 轨迹, 混合; legacy 默认)
- **membrane\_readout** (按协议立场视为违反):  $z_t = \text{sg}(h_t)$ 。注意:  $h_t$  是堆栈末层的连续残差输出, 是输入与脉冲的可学习函数 (不含细胞膜电位  $V^s$  本身), 协议立场禁止读任何连续量
- **raw\_spike**:  $z_t = \text{sg}(P_s s_t)$  (纯 spike 线性投影; 本实验未启用)

##### 4.12.1 STJEWm 架构详解 (MultiComp + MultiCompStack)

**MultiCompartmentCell 的完整数学** (code/snn\_cell.py): 单个 SNN 单元由  $N_d = 3$  个 dendrite 室 + 1 个 soma 室组成。记输入  $x_t \in \mathbb{R}^d$ , 时间常数  $\tau_{d,i} \in [10, 50]$  (线性分布)、 $\tau_s = 6$ , 衰减系数  $\lambda = e^{-1/\tau}$ 。

**树突室** (每室有独立时间常数与权重, 接受输入电流与 soma 反馈, 不放发、不重置):

$$V_{t,i}^d = \lambda_{d,i} V_{t-1,i}^d + (1 - \lambda_{d,i}) (W_d^{\text{in}} x_t + W^{s \rightarrow d} V_{t-1}^s), \quad i = 1, \dots, N_d$$

其中  $W^{s \rightarrow d}$  项使用上一时刻的胞体电位 (soma 反馈)。树突聚合:  $\bar{d}_t = \frac{1}{N_d} \sum_i V_{t,i}^d$ 。

**胞体室** (发放-重置-不应期):

$$\tilde{V}_t^s = \lambda_s V_{t-1}^s + (1 - \lambda_s) (W^{d \rightarrow s} \bar{d}_t + W_s^{\text{in}} x_t), \quad V_t^s = \begin{cases} 0, & \text{refr}_{t-1} > 0 \\ \tilde{V}_t^s, & \text{otherwise} \end{cases}$$

$$s_t = \mathbb{I}[V_t^s > v_{\text{th}}] \in \{0, 1\}^d, \quad v_{\text{th}} = 0.3, \quad V_t^s \leftarrow 0 \text{ if } s_t = 1, \quad \text{refr}_t = s_t \cdot 2.0 + (1 - s_t) \max(\text{refr}_{t-1} - 1, 0)$$

即发放时刻  $\tau$  之后  $\tau+1, \tau+2$  两步胞体被强制置零（不应期  $t_{\text{ref}}/dt = 2$ ），期间输入不积累。前向是严格 Heaviside；反向用 atan 直通估计器（\_ATanSurrogate）：

$$\frac{\partial s_t}{\partial V_t^s} = \frac{\alpha/2}{1 + (\pi\alpha(V_t^s - v_{\text{th}})/2)^2}, \quad \alpha = 2$$

初始化  $V_0^d = V_0^s = \text{refr}_0 = \mathbf{0}$ 。注意：胞体膜电位  $V_t^s$  只在单元内部决定脉冲，不进入堆栈输出—— $h_t$  与膜电位解耦（见下）。

**MultiCompStack**:  $n_{\text{layers}} = 4$  层 MultiCompartmentCell 堆叠，每层后接：

```
s_l = MultiCompCell(h_{l-1})      # 树突脉冲
r_l = post_mlp_l(s_l)             # Linear -> GELU -> Linear
h_l = h_{l-1} + LayerNorm(r_l)    # 残差 + LN
```

post\_mlp 是一个 12 倍扩展的 MLP ( $\text{hidden} = 12 \times d_{\text{hid}}$ )，让单层 SNN 在不增加细胞参数的前提下获得通道混合能力。每层约 0.88M 参数，4 层共约 3.5M。

**forward pipeline** (STJEW.forward)：

```
pixels/state -> encoder -> z_enc (B, T, 192)      # ViT-Tiny frozen + projector
action       -> ActionMLP -> a_emb (B, T, 192)    # 1-layer linear
h_in = z_enc + a_emb
h, spike = MultiCompStack(h_in)                   # 4 layers
trace = GatedSpikeTrace(spike, ctx=[a_emb, h])    # content-aware gated
z\_final = readout(h, spike, trace)                # per ReadoutMode
```

**forward 的完整数学链**（统一记号：观测编码器  $\text{Enc}_o$ 、动作编码器  $\text{Enc}_a$ ）：

1. **编码**：  $e_t = \text{Enc}_o(o_t) \in \mathbb{R}^d$  (state 模态为 2 层 MLP + SiLU；pixel 模态为冻结 ViT-Tiny + Linear→SiLU→Linear)，  $u_t = \text{Enc}_a(a_t) = W_a a_t + b_a \in \mathbb{R}^d$  (ActionMLP 单层线性，  $W_a \in \mathbb{R}^{d \times A}$ )
2. **堆栈输入**：  $h_t^{(0)} = e_t + u_t$ （对应代码 `h_in = emb + act_emb`，逐元素相加）
3. **堆栈**（4 层，第  $\ell$  层：MultiComp 单元  $\rightarrow 12 \times$  扩展 MLP  $\rightarrow$  残差 + LayerNorm）：

$$h_t^{(\ell)} = h_t^{(\ell-1)} + \text{LN}(\text{MLP}^{(\ell)}(s_t^{(\ell)})), \quad h_t \equiv h_t^{(4)}, \quad s_t \equiv s_t^{(4)}$$

（各层脉冲  $s_t^{(\ell)}$  由第  $\ell$  层 MultiComp 单元在输入  $h^{(\ell-1)}$  下按上式产生； $\text{MLP}^{(\ell)}$ ：Linear→GELU→Linear， $\text{hidden} = 12 \times d$ 。堆栈丢弃膜电位序列， $h_t$  是输入与脉冲的可学习函数）

4. **门控迹**：  $r_t = \text{GatedSpikeTrace}(s_t, [u_t; h_t])$ （公式见下）
5. **读出**：  $z_t = \text{Readout}(h_t, s_t, r_t)$ （按 ReadoutMode，见 §6 列表）

**架构参数总结**：

- **n\_layers** = 4: 4 层 SNN；trainable = 5.06M（校准对  $n_{\text{layers}}=2 \rightarrow 4$  的  $\text{delta} < 0.004$ ）
- **n\_d** = 3: 每细胞 3 个 dendrite 室
- **trace\_beta** = 0.9: trace 初始衰减率
- **trainable** = 5.06M (state 模态 total = trainable；pixel 模态另含冻结 ViT-Tiny 5.46M，total  $\approx 10.46\text{M}$ ，不计入可训练)

#### 4.12.2 Trace dynamics 完整公式

trace  $r_t \in [0, 1]^d$  是内容感知的脉冲后轨迹。其动力学由**两步**定义：

**Step 1: 遗忘门** (`GatedSpikeTrace.forward`):

$$\alpha_t = \sigma(W_{\text{gate}} \cdot [r_{t-1}, s_t, c_t]), \quad W_{\text{gate}} \in \mathbb{R}^{d \times (2d + d_{\text{ctx}})}$$

其中  $c_t = [u_t, h_t] \in \mathbb{R}^{2d}$  是当前**动作嵌入** ( $u_t = \text{Enc}_a(a_t)$ , 非原始动作  $a_t$ ; 代码 `context = cat([act_emb, h])`) 与连续隐藏状态的拼接;  $W_{\text{gate}}$  是单层 **Linear** (权重零初始化、`bias = log(0.9/0.1)`), 使初始  $\alpha_t \equiv 0.9$  (`trace_beta`)。门控输入含  $r_{t-1}$  自身 (自循环), 故  $\alpha_t$  依赖迹线历史——内容感知遗忘的来源。

**Step 2: trace 更新:**

$$r_t = \alpha_t \odot r_{t-1} + (1 - \alpha_t) \odot s_t, \quad r_t \in [0, 1]^d$$

**三个内禀性质:**

1. **逐维有界于**  $[0, 1]$ : 因为  $\alpha_t \in [0, 1]$  且  $s_t \in \{0, 1\}$ , 归纳可得  $r_t \in [0, 1]$
2. **内容感知遗忘**: 当上下文  $c_t$  表示”输入分布变了”时,  $\alpha_t$  趋近 0——trace 快速遗忘; 反之  $\alpha_t$  趋近 1——trace 长期保留
3. **事件驱动**: trace 只在  $s_t \neq 0$  时有显著更新 (无脉冲时  $\alpha < 1$  导致指数衰减)

#### 4.12.3 6 个 readout 的数学定义 (来自 `STJEW._readout`)

- **TRACE\_ONLY**:  $z = \text{trace\_proj}(r_t)$ , 其中 `trace_proj = Linear(d, d)`; honors membrane-forbidden 协议
- **HIDDEN\_LEAK**:  $z = h_t + \text{trace\_proj}(r_t)$  (legacy v2 默认; 部分违反协议, 因为  $h_t$  暴露了连续值)
- **MEMBRANE\_READOUT**:  $z = h_t.\text{detach}()$ ——视  $h$  为离散潜状态; **明确违反协议**
- **SPIKE\_GATED** (legacy `SPIKE_ONLY`):  $z = h_t \cdot s_t.\text{detach}()$ , 连续  $\times$  二值掩码; honors 协议
- **RAW\_SPIKE**:  $z = \text{raw\_spike\_proj}(s_t.\text{detach}())$ ; pure spike; honors 协议
- **RATE\_ONLY**:  $z = \text{AvgPool1d}(s_t.\text{detach}())$ , `kernel_size=4`, `stride=1`, `padding=2`; honors 协议
- **NO\_TRACE**:  $z = h_t$  (无 trace 分支; ablation)

所有 membrane-forbidden 协议的读出口径都满足:  $z$  仅依赖于  $\{s_t, r_t, c_t\}$ , **不依赖于  $h_t$  的连续值**。这是接口合约的数学承诺。

## 4.13 6 个非 STJEWM 对比模型（详细配置）

### 4.13.1 自研 SNN 对照的设计动机：它们要对比什么

协议的核心问题是“规划器可见的潜状态到底是什么”。为回答它，三个自研 SNN 对照按三个独立的设计轴构造，分别隔离一个变量：

1. **轴 1：事件驱动发生在哪一层（感知层 or 循环层）。**ST-JEWM 是**纯脉冲循环动力学**（循环层事件驱动、持续）。**LIF-Transformer** 让事件驱动只出现在**感知编码器**，循环记忆由连续 Transformer 承担——检验“脉冲只在输入侧、记忆连续”的中间形态；**ALIF-timecell** 让感知与循环都是自适应 LIF，但时间聚合交给显式 1D 卷积 time-cell 读出（而非 ST-JEWM 的 gated trace）——检验“时间聚合机制”是否是校准的充分条件。
2. **轴 2：记忆载体（连续 vs 脉冲）。****LIF-Transformer** 的记忆是连续 Transformer 隐状态；**Stacked-LIF** 与 ST-JEWM 的记忆都是纯脉冲序列。该轴检验：**连续记忆载体本身**（与脉冲感知配对）是否就足以产生校准潜状态。
3. **轴 3：读出接口（膜电位 vs 脉冲/trace）。****ALIF-timecell** 与 **Stacked-LIF-free** 向规划器暴露连续膜电位（**违反协议**）；**Stacked-LIF-trace** 只提供脉冲移动平均（**协议合规**）。该轴检验：在事件驱动循环家族内，**读出接口是否决定校准**——若协议内 trace 与协议外膜电位同样校准，则“接口不是校准的关键，事件驱动循环动力学才是”。

三个对照与连续家族（GRU/MLP/LeWM-v2）一起构成解码矩阵：事件驱动循环 × 连续循环 × 无循环，各配读出接口两极。已有结果（见 §4.2 与 §5）：ALIF-timecell、Stacked-LIF-trace/free 与 ST-JEWM 全部校准（cos-dist 0.103–0.123）；LIF-Transformer 与 GRU/MLP 一起崩塌（ $\leq 0.020$ ）。即：**只要循环层是事件驱动的，无论读出接口（trace/膜电位）都校准；只要记忆是连续的（GRU、LIF-Transformer），都崩塌。**这直接把“校准性”归因到事件驱动循环动力学，而非协议接口本身——与 Spiking-WM 对比（外部竞品的连续读出同样低对齐）一致。

### 4.13.2 三个自研 SNN 对照（功能名）

**重要声明：**以下三个 SNN 对照为本项目自研实现，名字是**架构功能描述**（不引用任何外部文献或代码库；早期代码注释中的文献名未经核实，已撤销）。代码与 checkpoint 目录中的历史标识（alif\_timecell\_baseline、lif\_transformer\_baseline、stacked\_lif\_trace/free）与功能名对应关系如下。它们复用 ST-JEWM 的 LIFCell 与投影组件构建。

- **ALIF-timecell**（代码标识 alif\_timecell\_baseline；SNN，自研，5M-aligned trainable = 4.98M，**违反协议**——暴露膜电位）：**多时间尺度自适应 LIF（ALIF）**。每层 ALIF 维护  $v_t$ ，发放后 refractory 强制重置； $b$  自适应阈值随脉冲累积增加；多层膜电位拼接后经 1D 卷积 time-cell 读出（kernel 256 / stride 128  $\rightarrow$  8 个时间锚点）。**设计目的：**用“自适应阈值 + 显式时间卷积”替代 ST-JEWM 的 gated trace 做时间聚合，检验**时间聚合机制**是否决定校准（轴 1 对照）。规划器可读膜电位  $v_t$ 。5M 配置：d\_hid=186, n\_layers=2
- **LIF-Transformer**（代码标识 lif\_transformer\_baseline；**混合 LIF + Transformer**，自研，5M-aligned trainable = 5.12M，**违反协议**——读连续 Transformer 隐状态）：LIF 脉

冲编码器只做感知，循环预测由 AdaLN-zero Transformer 承担。**设计目的**：检验“事件驱动仅在感知层、记忆为连续”的中间形态是否校准（轴 1 + 轴 2 对照；与 Stacked-LIF 的纯脉冲记忆直接对置）。规划器可读 Transformer 隐状态。5M 配置：d\_snn=288, d\_tx=288, num\_layers=3, num\_heads=8

- **Stacked-LIF-trace**（代码标识 stacked\_lif\_trace; SNN, 自研, 5M-aligned trainable = 5.11M, 膜电位禁止——协议合规）：堆叠 LIF 循环动力学，读出  $z = \text{moving\_average}(s_t, k=4)$ （脉冲移动平均）。**设计目的**：最接近 ST-JEWM 的协议内对照——纯脉冲循环记忆 + 脉冲读出，区别仅在“移动平均”与“gated trace”两种时间滤波（轴 3 的协议内一极）。5M 配置：d\_in=672, embed\_dim=672, n\_layers=8, trace\_beta=0.9, k\_avg=4
- **Stacked-LIF-free**（代码标识 stacked\_lif\_free; SNN, 自研, 5M-aligned trainable = 5.05M, 违反协议——暴露膜电位）：同架构，但读出  $z = \text{concat}(s_t, v_t)$ （脉冲 + 膜电位拼接）。**设计目的**：同一事件驱动循环动力学的膜电位暴露孪生体——与 trace 变体逐字对比，检验读出接口是否是校准变量（轴 3 的协议外一极）。5M 配置：d\_in=640, embed\_dim=640, n\_layers=8
- **LeWM Transformer baseline**（Transformer, 5M-aligned trainable = 4.97M, 违反协议）：自研 LeWM 参考实现的 AdaLN-zero Transformer（参考实现 6 层 5.07M；5M 配置 embed\_dim=288, num\_layers=3, num\_heads=8）。规划器可读 Transformer hidden state。**设计目的**：连续循环记忆家族的 Transformer 极点（与 GRU 一起代表“连续记忆”）。
- **GRU baseline**（连续循环神经网络, 5M-aligned trainable = 5.13M, 违反协议）：hidden=560, num\_layers=2。标准 GRU 隐状态可读。**设计目的**：连续循环记忆家族的“最小神入”对照——与 Stacked-LIF 共享循环聚合，但门控连续。**关键对照**：若事件驱动循环是校准必要条件，则 GRU 必须崩塌（实测  $\rho = -0.0074$ 、cos-dist 0.020）。
- **MLP baseline**（无状态 FFN, 5M-aligned trainable = 5.00M, 作为坍塌对照）：hidden=640, num\_layers=12 纯前馈，无循环。所有时间步都从当前 obs 重新预测。**设计目的**：无记忆极点——预期（且实测）潜状态坍塌为常数（div  $\rightarrow 0$ ，LeWM-SR 97.3% 却将其评为最高分，见 §4 度量批判）。

**总 13 个模型**：6 STJEWM 读出口径 + 7 非 STJEWM 对照（其中 6 个非 MLP 对照都有循环 / 记忆能力；MLP 是无状态对照）。模型清单见 §4.2 的 4 家族分类表。

#### 4.14 真实外部竞品：Spiking-WM (中科院自动化所 Brain-Cog-Lab, PNAS 2025)

除上述自研对照外，我们引入**真实可验证的外部竞品**：Spiking-WM (Sun, Zhao, Lv & Zeng, arXiv:2503.00713, 正式发表于 PNAS 2025, doi:10.1073/pnas.2513319122; 开源代码 <https://github.com/Brain-Cog-Lab/Spiking-WM>, MIT 协议)。这是目前最接近“标准 Dreamer 风格 World Model + SNN”的公开工作，也是 multi-compartment 神经元路线与本项目 ST-JEWM 的直接同行工作：

- **核心贡献**: Multi-Compartment Neuron (MCN) —— 受树突非线性整合启发, apical/basal/soma 三腔室积分, 显著提升 SNN 长时序记忆; 全文 (DMC + SHD/TIMIT/LibriSpeech) 验证。
- **架构**: spiking encoder + MCRNN 动力学 (递归状态为**纯脉冲序列**  $\{s_t^T\}_{t=1}^T$ , 膜电位为内部状态——与本项目 **membrane-forbidden 协议一致**) + spiking decoder/actor, Dreamer 风格端到端 model-based RL。
- **与 ST-JEWM 的差异**: 其规划器/actor 读到的是从脉冲序列解码的**连续随机状态** (posterior/prior 分布参数), 即 “事件驱动动力学 + 连续规划接口”; ST-JEWM 则要求规划器只读有界 post-spike trace。
- **我们做的对比**: 下载官方代码, 在 proprioceptive (状态输入) 配置下于 12 个 DMC 任务 (见下表) 各按难度训练 ( $2-5 \times 10^5$  环境步), 报告官方 episode return + 我们的协议指标 (event- $\rho$ 、cos-dist、脉冲激活率)。

#### 4.14.1 为什么 pusht / tworoom / reacher-4D / stacker / delayed-t-maze / humanoid-CMU 无法用 Spiking-WM 运行

ST-JEWM 的 10-split 设定还包含 6 个 **custom 环境**, 它们不是 dm\_control 标准任务, Spiking-WM 的官方代码只注册了 dm\_control / Atari / DeepMind Lab / Crafter / Memory Maze / Minecraft 六个环境套件, **无法实例化这些自定义域**。逐一说明:

- **PushT** (跨基准族 F3 留出): **自研像素 + 状态 PushT** (T 形物体推入目标区域), 来自 LeWM 参考实现, **非 dm\_control 套件**; Spiking-WM 的 make\_env 无 PushT 注册、也无法映射到任何 dm\_control 域 (无 push 类任务)。→ 排除。
- **TwoRoom** (跨基准族 F2 留出): **自研双房间导航状态环境** (16-bucket 离散状态 + 4 动作 + 门控记忆), 完全自研、非公开套件; Spiking-WM 无对应 (dm\_control 无导航/离散状态任务)。→ 排除。
- **Reacher-4D** (跨基准族 F1 留出对应的自制域): ST-JEWM 使用的 **reacher** 是 **4 维简化状态版** (reacher 4D, 含 2D 位置 + 2D 目标差, 观测结构为自定义 state 向量); dm\_control 标准 reacher 域 (**reacher\_easy**) 的观测是 2D 关节角 + 2D to\_target + 2D 速度, 维度/语义均不同。→ Spiking-WM 只能跑标准 reacher\_easy, 作为**同语义近似** (表中已标注)。
- **Stacker**: dm\_control 没有 “堆叠” 任务 (栈式操作属于 Robosuite/自定义); Spiking-WM 无对应域。→ 排除。
- **Delayed T-Maze**: **自研延迟决策环境** (T 形迷宫 + 50 步延迟线索 + 记忆门控), 非公开套件、无 dm\_control 等价 (dm\_control 无迷宫/离散决策任务)。→ 排除。
- **Humanoid-CMU**: dm\_control 1.0.44 的 humanoid 域只有 run/walk/stand 三个 level, **没有 CMU (Carnegie Mellon mocap data) 变体**; ST-JEWM 的 humanoid\_CMU 是该自定义变体 (CMU 参考姿态/动力学参数)。→ Spiking-WM 用标准 humanoid\_run 近似 (表中已标注)。



**影响与说明：**跨基准留出族 (F2 TwoRoom / F3 PushT / F1 的 reacher-4D) 正是 ST-JEWM 验证 **out-of-distribution 跨域泛化** 的设计核心；Spiking-WM 无法在这些跨基准域上运行，因此外部对比限定在 **12 个 dm\_control 任务** (覆盖 ST-JEWM 的 DMC 训练/留出子族)，跨基准泛化对比只能由自研对照 (GRU/MLP/LeWM-v2 等，见表一) 承担。报告中所有 Spiking-WM 对比单元格均不超出这 12 个任务。

#### 4.14.2 Spiking-WM 对比实验结果 (seed 0, RTX 4090, proprio 配置, 12 任务)

| 任务               | SpWM<br>return | ST<br>SR | env-<br>cos | ST<br>cos | SpWM<br>latent $\rho$ | SpWM<br>stoch $\rho$ | SpWM<br>spike-rate $\rho$ |
|------------------|----------------|----------|-------------|-----------|-----------------------|----------------------|---------------------------|
| cartpole_swingup | 229.7          | 1.00     |             | 0.112     | 0.392                 | 0.150                | -0.002                    |
| cheetah_run      | 105.1          | 1.00     |             | 0.006     | 0.560                 | 0.222                | 0.005                     |
| walker_walk      | 211.8          | 0.00*    |             | 0.091     | 0.456                 | 0.216                | 0.000                     |
| finger_spin      | 229.8          | 1.00     |             | 0.125     | 0.656                 | 0.395                | -0.002                    |
| pendulum_swingup | 0.0            | 0.20     |             | 0.064     | 0.521                 | -0.000               | 0.017                     |
| cup_catch        | 758.8          | 1.00     |             | 0.000     | 0.797                 | 0.298                | -0.013                    |
| reacher_easy     | 421.0          | 0.00     |             | 0.124     | 0.778                 | 0.459                | -0.001                    |
| hopper_hop       | 0.0            | 0.20     |             | 0.068     | 0.581                 | 0.273                | -0.034                    |
| quadruped_walk   | 26.6           | 0.00     |             | 0.079     | 0.213                 | 0.026                | -0.023                    |
| dog_walk         | 10.8           | 0.00     |             | 0.176     | 0.051                 | -0.006               | 0.021                     |
| fish_swim        | 48.3           | 0.20     |             | 0.352     | 0.436                 | 0.100                | -0.013                    |
| humanoid_run     | 1.4            | 0.00     |             | 0.141     | 0.239                 | 0.058                | 0.027                     |

预算 (环境步): pendulum/cup/reacher  $2 \times 10^5$ , hopper/fish  $3 \times 10^5$ , 其余  $5 \times 10^5$ 。trian\_ratio 64 (官方 512, 计算预算原因)。\*walker\_walk 对 F1 checkpoint 是留出族 (STJEWM 从未见过 walker 数据)；Spiking-WM 直接在 walker 上训练。ST-JEWM  $\rho \geq 0.9986$  (表一)，表中未重复列出。custom env (pusht/tworoom/reacher-4D/stacker/delayed-t-maze/humanoid-CMU) 无 dm\_control 等价物，Spiking-WM 无法运行，已排除。

##### 结果解读：

- **可学习性 (全任务)：**Spiking-WM 解决易任务 (cup\_catch 758.8、reacher 421.0, 满分 1000)，学会中等任务 (cartpole 229.7、walker 211.8、finger 229.8、cheetah 105.1)，但难任务失败 (pendulum 0.0、hopper 0.0、quadruped 26.6、dog 10.8、fish 48.3、humanoid 1.4) —— 这些也是 Dreamer 家族在同等预算下的已知难点。纯脉冲序列动力学可以支撑 model-based 控制，但在本预算下仅限简单-中等任务。
- **协议判定：**其动力学隐状态是 MCRNN 脉冲序列 (膜电位为内部状态——协议合规的动力学)，但规划器/actor 读到的是从脉冲序列解码的**连续后验均值** (连续规划接口——按读出违反协议)。
- **事件对齐 (同口径, 12 任务)：**观测-潜变量一阶差分 Pearson  $\rho$ ：STJEWM 家族  $\geq 0.9986$  (5.06M 参数)在**每一任务上**均远超 Spiking-WM (0.05–0.80, 均值 0.47; **28.5M 参数**)。Spiking-

WM 的 MCRNN 脉冲平均活动对齐 (spike-rate 口径) 全部机会水平 ( $-0.034$ – $0.027$ )，与 STJEWMM 自身 spike-rate 口径 ( $0.000$ – $0.017$ ) 同水平：**两种系统里原始脉冲计数聚合都不跟踪观测变化**，而 STJEWMM 的 gated trace 潜状态跟踪。

- **稀疏性**：Spiking-WM MCRNN 平均激活率 0.8% (比我们协议暴露的 trace 稀疏一个数量级)；对齐缺口在其失败任务上最大 ( $\log \rho = 0.05$ 、quadrupled 0.21) —— 极端稀疏且无 trace 机制时，规划侧潜状态与观测动力学脱钩，这正是本协议设计要诊断的失败模式，且发生在最接近的公开系统而非仅自研对照中。
- **对比局限**：Spiking-WM 是在线 actor-critic 训练 (无 goal-conditioned CEM 协议)、28.5M 参数 vs 5.06M、proprio 配置 + 降低更新频率；hard tasks 的失败同时也是 Dreamer 家族同等预算下的已知现象。

**相关工作 (无代码, 定性讨论)**：Capone & Paolucci (Sci. Rep. 2024, doi:10.1038/s41598-024-65631-y) 提出双模块 (agent + model) 递归 SNN，通过 “dreaming” (在内部世界模型中模拟新经验) 提升 sample efficiency，无需经验回放、在线学习，面向神经形态硬件；无公开代码，本报告仅在相关工作中讨论。

#### 4.15 4 个 baseline 家族的角色

| 家族           | 模型                                                                  | 测试什么                 |
|--------------|---------------------------------------------------------------------|----------------------|
| STJEWMM 读出口径 | trace / spike / rate / no-trace / leak / membrane                   | 同一 SNN 骨架，6 种接口变量    |
| 连续循环对照       | LeWM Transformer, GRU, stateless MLP                                | 连续循环、循环、记忆缺失 (坍塌对照)  |
| SNN / 神经形态对照 | ALIF-timecell, LIF-Transformer, Stacked-LIF-trace, Stacked-LIF-free | 已有 SNN 世界模型及其各自的轨迹约定 |

##### 4.15.1 膜电位禁止协议的接口合约

正式定义为：

**协议**。给定一个脉冲动力学系统 ( $v_t, s_t, r_t$ ) 与一个下游规划器，规划器只能读取  $r_t$  (post-spike trace)，不能读取  $v_t$  (membrane potential)。

**协议在接口层强制** (不是训练时正则化项)：

- **不是 loss term**：训练 loss 不显式包含”隐藏  $v_t$ ” 的惩罚
- **是 interface contract**：planner.observe() 只接收  $r_t$ ；即使  $v_t$  在内部流动，也不暴露
- **6 个 readout 中 4 个 honor 协议**：trace\_only, spike\_gated, rate\_only, raw\_spike

- **2 个 ablation 不 honor 协议**: `membrane_readout` (直接读  $h$ ) , `hidden_leak` ( $h + \text{trace\_proj}(r)$ ) 仍依赖  $h$ )

4 个 baseline 家族共同构成本文的**可测试声明**: 如果 STJEWLM 的”校准非坍塌”性质是膜电位禁止协议的属性, 则 6 个禁止读口的读出口径应全部落在校准区域; 如果是膜电位读出口径的属性, 则仅有 `membrane` 读出口径应在那里。

#### 4.15.2 为什么 13 模型足够 (可证伪性论证)

**核心声明**: 膜电位禁止协议 + trace dynamics 自带的 content-aware 衰减 = 跨基准族泛化所需的全部物理偏置。

13 模型的覆盖性:

1. **6 STJEWLM readout**: 剥离了”哪个接口变量被读到”的影响, 只保留 trace dynamics
2. **4 SNN baseline**: ALIF-timecell / LIF-Transformer / Stacked-LIF ( $\times 2$ ) 各自代表一种 SNN 世界模型设计, 提供**对照**——证明 STJEWLM 不是”SNN 范式本身就行”
3. **2 循环非 SNN baseline**: GRU / LeWM Transformer 代表连续循环 + attention, 证明 STJEWLM 不是”循环结构本身就行”
4. **1 无状态对照**: MLP 证明 STJEWLM 不是”前馈结构也行”——它必须  $\text{div} \rightarrow 0$  坍塌

任何未来提出的新模型都可以归入这 4 家族之一 (或者证明第 5 个家族的存在——这本身就是一个科学贡献)。

## 5 训练流程

### 5.1 优化器与学习率调度

所有 13 个模型使用 AdamW (来自 `code/train/train.py:176`),  $\text{lr} = 3 \times 10^{-4}$ ,  $\text{weight\_decay} = 10^{-3}$ 。

**梯度裁剪**: `torch.nn.utils.clip_grad_norm_(parameters, 1.0)` (`train.py:277`)。clip 范数 = 1.0 防止脉冲稀疏性爆炸时的大梯度。

### 5.2 损失函数 (3 项联合损失)

STJEWLM 的训练损失 (`code/native_losses.py:stjewm_loss`) 由 3 项加权组成:

$$\mathcal{L} = \mathcal{L}_{\text{pred}} + \lambda_{\text{sigreg}} \cdot \mathcal{L}_{\text{sigreg}} + \lambda_{\text{goal}} \cdot \mathcal{L}_{\text{goal}}$$

**逐项定义** (窗口  $w_s$ : 帧  $o_s \dots o_{s+H+G}$ ,  $H = 1$ ,  $G = 25$ ; 所有目标项均 stop-gradient 阻止坍塌):

- **预测损失**:  $\mathcal{L}_{\text{pred}} = \|\hat{z}_{s+1} - \text{sg}(z_{s+1})\|^2$ , 其中  $\hat{z}_{s+1} = f_{\text{pred}}(z_s, a_s)$  是模型 `predict` 的下一步潜状态,  $z_{s+1}$  是同一前向中第  $s+1$  帧的真实潜状态。`train.py` 中  $T_{\text{pred}} = \min(H, t_{\text{pred}}, \text{goal\_offset}) = 1$  (5M 配置), 故只有单步预测项; `F.mse_loss` 在 `stjewm_loss` 内对目标 detach

- **SIGReg 正则** (`code/sigreg.py:SIGReg`, Epps-Pulley 特征函数距离): 作用在**编码器输出** (`emb_pre_cell`, 即  $e_t$ , 不含动作与堆栈) 的**全部窗口帧**上。取  $M = 1024$  个随机单位投影  $A_j \in \mathbb{R}^d$  (每次 forward 重新采样、detach), knot 网格  $t \in [0, 3]$  (17 点, 梯形权重  $w(t)$ ), 与标准正态特征函数  $\phi(t) = e^{-t^2/2}$  比较:

$$\mathcal{L}_{\text{sigreg}} = \frac{T}{M} \sum_{j=1}^M \int_0^3 \left[ \left( \frac{1}{T} \sum_t \cos(t A_j^\top e_t) - \phi(t) \right)^2 + \left( \frac{1}{T} \sum_t \sin(t A_j^\top e_t) \right)^2 \right] w(t) dt$$

返回标量  $\sim 0$  当各边缘分布接近各向同性标准高斯——防止潜状态坍塌为常数或退化分布。

**注意:** 早期报告中的“KL spike-rate 目标带”表述是错误残留, 与本实现不符, 已删除

- **Goal 损失** (teacher-forced, 非自回归滚动):

$$\mathcal{L}_{\text{goal}} = \left\| \underbrace{z_{s+H+G-1}^{\text{tf}}}_{\text{前 } H+G \text{ 帧 teacher-forced 前向的末帧 latent}} - \text{sg}(z_{s+H+G}^\emptyset) \right\|^2, \quad z_{s+H+G}^\emptyset = f(o_{s+H+G}, \mathbf{0})$$

即: `goal_pred` = 窗口前  $H+G$  帧 (含中间真实状态) 前向的最后一个潜状态 (索引  $H+G-1$ ); `goal_emb_target` = 窗口**末帧** (索引  $H+G$ ) 以**零动作**独立编码的潜状态。语义: “goal 帧的潜状态应等于其下一帧的嵌入” (一步前瞻对齐)。**索引细节:** 训练目标帧 (索引  $H+G$ ) 比评测数据集的目标帧 (`goal_state = o_{s+G}`, 索引  $G$ ) **晚 1 帧**——训练教的是相邻帧潜状态一致性, 评测时 CEM 以  $o_{s+G}$  自身的嵌入为目标

**具体权重:**  $\lambda_{\text{sigreg}} = 0.09$  (弱正则, 避免破坏 trace 动态),  $\lambda_{\text{goal}} = 0.5$  (goal 是 planner 的实际目标, 给予较大权重)。

**不同 baseline 的 native 损失:** ALIF-timecell 用 `alif_timecell_loss` (pred + L1 spike sparsity); LIF-Transformer 用 `lif_transformer_loss` (pred + KL + recon + sparse); Stacked-LIF 用 `stacked_lif_loss` (pred + sparse + action); 其他基线 (LeWM Transformer / GRU / MLP) 沿用 STJEW 的 3 项损失。所有损失通过 `code/native_losses.NATIVE_LOSS_DISPATCH` 在 `train.py:219` 处按 `args.model` 分派。

### 5.3 batch 构造与损失归约

**batch 内样本来源:** 每个 batch 由  $B = 32$  个 (`history_size` 帧 + `goal_offset` 帧 + 1 帧) 序列组成。在多 env 训练 (G16) 时,  $B$  个样本从所有 env 的混合 buffer 中随机抽取——**不是 per-env batch**, 因此一个 batch 内可能含不同 env 的样本。每个样本的 obs 都已 pad 到 `pad_obs_to`, 所以模型无需 per-env 区分。

**padding 方案:** `obs_dim` pad 到 128 (G16 设置), `action_dim` pad 到 56。padding 用零填充; 模型读 padded obs; `env.step` 仅取前 `action_dim` 维。

**损失归约:** 所有损失分量在 batch 维度上取 mean (PyTorch `F.mse_loss` 默认 `reduction='mean'`)。不进行 per-env 归一或加权——因为不同 env 的样本频率已经由 buffer 大小隐式平衡。

### 5.4 训练配置 (5M-aligned, v0.7.14–v0.7.19)

**总览:** 所有训练通过 `code/train/train.py` 统一入口, 以 `--multi-env-spec` JSON (`configs/oodc_5m/*.json` 与 `configs/oodc_5m_pixel/*.json`) 指定 10 个 split。5M 配置统一

为: AdamW, lr=3e-4, weight\_decay=1e-3, batch=32, 1 epoch, max\_windows=2000/env, history\_size=1, goal\_offset=25, pad\_obs\_to=128, action\_dim=56; STJEWMM 用 n\_layers=4 (5.06M trainable, 参数公平), 其余模型按各自 5M-aligned 默认 (见 §5.4)。

| regime            | 网络                                | ckpt 数 | 训练入口                                 | 用途          |
|-------------------|-----------------------------------|--------|--------------------------------------|-------------|
| 5M state (seed 0) | 13 模型 × 10 splits                 | 130    | train_one_5m.sh / launch_parallel.sh | 三簇分界主表      |
| 5M pixel (seed 0) | 13 模型 × 10 splits × image_size=84 | 130    | train_all_130_pixel.sh               | 跨模态保留       |
| 3-seed (G5/B2)    | 3 splits × 8 模型 × seed 1/2 重训     | 47/48  | B2_multiseed_launcher.sh             | 95% CI      |
| sigreg 扫描         | 4 权重 × 2 splits                   | 8      | train_sigreg_sweep.sh                | sigreg 假设检验 |
| 多 epoch (P13)     | 3 模型 × 2 splits × 3,5 epochs      | 12     | train_one_5m.sh --epochs N           | 非训练量假象      |

```
# 5M state (示例: oodc_F1 split 的 STJEWMM-trace)
python -m code.train.train --model stjewmm --multi-env-spec configs/oodc_5m/oodc_F1.json \
    --pad-obs-to 128 --action-dim 56 --embed-dim 192 --image-size 0 --n-layers 4 \
    --epochs 1 --batch 32 --lr 3e-4 --history-size 1 --goal-offset 25 --seed 0 \
    --readout-mode trace_only --out results/5m_5mpar/oodc_F1/stjewmm_trace_only/seed_0
# 5M pixel: 同参数 + --env-kind dmc_pixel --image-size 84
```

**10 个 split 的构成**(configs/oodc\_5m/): 3 个跨基准族(cross\_benchmark\_F1/F2/F3:PushT / TwoRoom / Reacher 分别 held out) + 6 个 OOD 连续性 (oodc\_F1, oodc\_F1F2, oodc\_F1F3, oodc\_F2, oodc\_F2F3, oodc\_F3) + 1 个 generalist 16-env 并集 (generalist\_16env)。每个 split 的 specs 列出训练 env 与每 env 的 history\_size / goal\_offset / max\_windows; 评测 env 独立列出 (\_eval\_envs), 见 §5.5 的 eval-once-eval-everywhere 模式。

**总结:** state 模态 13 模型 × 10 splits × 1 seed = 130 ckpt (STJEWMM 在 results/5m\_5mpar/ 公平重跑, baselines 在 results/5m/) , pixel 模态另 130 ckpt; 权威 per-cell 表见 results/journal\_prep/MAIN\_TABLE\_5M\_STATE\_FULLL.md (1157 cells) 与 MAIN\_TABLE\_5M\_PIXEL\_FULLL.md (1690 cells)。

## 5.5 评测-once-eval-everywhere 模式 (OOD Path-C 的特殊 holdout pattern)

**为什么 split 持有某个子族:** DMC 的 3 个子族 (classic / locomotion / sparse-POMDP) 有不同的动力学本质:

- **classic:** 低维 proprioception + 简单动力学 (cartpole、pendulum、finger、ball\_in\_cup)
- **locomotion:** 高维 proprioception + 关节动力学 + 接触 (cheetah、walker、hopper、quadruped、humanoid、humanoid\_CMU、dog、fish、stacker)
- **sparse-POMDP:** 目标位置在状态外 / 不可观测, 需要推断 (reacher、delayed\_t\_maze、cheetah\_velhidden 等 stress env)

持有其中一个子族 = 测试模型是否在”完全未见过的动力学”上保持校准。这是 working title 的 gating experiment。

**eval-once-once-eval-everywhere:** 每个 split 训练 1 个 ckpt, 但评测时在所有 14 个 DMC env 上评估 (不仅是 held-out 子族)。这产生两种评测:

- **持有 env** ("held-out"): 测试 OOD 泛化——模型从未见过该 env
- **已见 env** ("seen"): 测试 ID 表现——模型在训练集上

~1200 个 cell = 6 个 oodc split + 3 个跨基准族 split + 1 个 G16 split, 共 10 个 split  $\times$  13 models  $\times$  平均 ~9 envs (每个 split 评测 5-14 envs) 包含了两。看 **STJEW** 是否对两种都校准: 是 working title 的核心可证伪点。

**单 ckpt 训练时长:**

- **Single-task (1 epoch, 10K windows):** ~ 5 分钟 (batch=32, 每 epoch 313 步)
- **Cross-bench (5 epochs, ~160K windows):** ~ 25 分钟 (13 模型  $\times$  16 env 并行 batch)
- **OOD Path-C (1 epoch, ~12K windows):** ~ 3 分钟
- **G16 (1 epoch, 32K windows):** ~ 30 分钟 (16 env 并行 batch)

**评测时长:**

- 单 cell (30 episodes  $\times$  1 seed, 100 CEM samples): ~ 30 秒 (单 GPU)

**总预算:**

## 6 测试流程

### 6.1 单 cell 评测流程 (closed-loop)

每个 cell = 在一个 (ckpt, eval\_env) 对上做以下步骤 (5M 配置: n\_episodes=5, n\_seeds=3, CEM 300 $\times$ 30 $\times$ 10, horizon=5, eval\_budget=50, goal\_offset=25, history\_size=1):

1. **从数据集采样** (init, goal) 对: 窗口  $w_s$  的  $\text{init\_state} = o_s$ 、 $\text{goal\_state} = o_{s+G}$ 。不是随机初始化——用真实轨迹窗口, 避免目标分布在训练集外
2. **编码:**  $z_{\text{init}} = \text{Enc-Readout}(o_s, \mathbf{0})$  (零动作, `encode_obs`);  $z_{\text{goal}} = \text{Enc-Readout}(o_{s+G}, \mathbf{0})$ ;  $z_{\text{history}}$  为  $H$  份  $z_{\text{init}}$  的堆叠
3. **CEM 规划:** 以  $z_{\text{history}}$  为初始潜状态, 优化 horizon  $H = 5$  步动作序列使预测潜轨迹末端接近  $z_{\text{goal}}$  (算法见 §6.2,  $N = 300$ ,  $K = 30$ ,  $T = 10$ )
4. **整块执行:** 把最优序列的**全部**  $H$  步动作 (clip 到动作界) 依次送入真实环境 `env.step`
5. **重规划:** 用模型自回归预测推进潜上下文 (**不读真实观测**) :  $z_{\text{history}} \leftarrow [z_{\text{history}}[1 : ], f_{\text{pred}}(z_{\text{history}}, \text{seq}[: H_{\text{ctx}}])[-1]]$  ( $H_{\text{ctx}} = \text{history\_size} = 1$ , 即只用最优序列的第 1 步动作做预测),  $z_{\text{init}} = z_{\text{history}}[-1]$ ; 重复直至 actions  $\geq 50$  或 episode 结束
6. **报告:**

- **mean\_cos\_dist:**  $\frac{1}{2}(1 - \cos(z_{\text{final}}, z_{\text{goal}}))$ ,  $z_{\text{final}}$  = 真实最终状态  $o_{\text{final}}$  的零动作编码 (主指标)

- **env-SR**: 环境原生成功判定 (DMC ‘check\_success’, tol=0.1)
- **LeWM@0.05**:  $\Pr[\cos_{\text{dist}} < 0.05]$  (被证伪指标, 仅叙事用)

**什么是 CEM**: Cross-Entropy Method 是一种基于采样的规划算法。每轮在潜状态空间采  $N = 300$  个动作序列, 保留成本最低的  $K = 30$  个 (elites) 重新估计高斯分布 (均值  $\mu$ 、标准差  $\sigma$ ), 重复  $T = 10$  轮后从收敛分布再采样一轮取最优。CEM 的核心假设是”潜状态空间是好的规划空间”——如果潜状态是坍塌的常数, CEM 就在做无意义的搜索; 如果潜状态是过反应的放大器, CEM 的梯度信号爆炸。

## 6.2 CEM 规划器 (详细算法)

**CEM 完整数学与 pseudocode** (code/core/cem.py:CEM.plan, 与代码逐行对应):

**成本函数** (单条候选动作序列  $a_{1:H}$ ): 自回归滚动

$$h^{(0)} = \underbrace{[z_{\text{init}}; \dots; z_{\text{init}}]}_{H \text{ 份}}, \quad z_{t+1} = f_{\text{pred}}(h^{(t)}, [a_t; \dots; a_{t+H-1}])[-1], \quad h^{(t+1)} = [h^{(t)}[1:]; z_{t+1}], \quad c(a_{1:H}) = \|z_{\text{final}} - z_{\text{goal}}\|$$

(**L2 成本**, 非余弦距离; **predict** 返回整窗潜状态、取末帧)。

**分布迭代** ( $N = 300$  样本、 $K = 30$  精英、 $T = 10$  轮、 $\sigma_{\text{init}} = 1.0$ ):

$$\mu^{(0)} = \mathbf{0}, \quad \sigma^{(0)} = \mathbf{1}; \quad \{a^{(i)}\}_{i=1}^N \sim \mathcal{N}(\mu^{(r)}, \text{diag}(\sigma^{(r)})^2)$$

$$\mathcal{E} = \underset{K}{\text{argmin}} \{c(a^{(i)})\}, \quad \mu^{(r+1)} = \frac{1}{K} \sum_{i \in \mathcal{E}} a^{(i)}, \quad \sigma^{(r+1)} = \text{std}_{i \in \mathcal{E}}(a^{(i)}) \cdot \text{clamp\_min}(10^{-4})$$

$T$  轮后再采样一轮 (第 11 轮) 返回成本最小的序列: `return candidates[ costs.argmin() ]`。采样阶段不做 **clip**——clip 只在执行时 `env.step` 前发生 (`closed_loop.py`)。

**默认参数**: `n_samples=300, n_elites=30, n_iters=10, horizon=5, sigma_init=1.0` (5M 实验; 旧版 100/10/5 已被 5M-aligned 评测取代)。

**Receding-horizon 执行 (block 模式)**: CEM 返回  $H = 5$  步序列 `seq` 后, 整块执行 `seq[0:H]` (至多 `min(H, budget - actions_taken)` 步), 然后重规划。潜上下文的推进不读真实观测——`closed_loop.py` 用模型自回归预测更新  $z_{\text{history}}$  (见 §6.1 步骤 5)。

**closed\_loop 完整 step-by-step** (code/eval/closed\_loop.py:138-355):

1. 加载 ckpt: 按 ckpt 的 `args` 字段构建模型 (STJEWLM 读取 `readout_mode`), 读 `final.pt`
2. 加载评测数据集: 窗口  $w_s$  的 (`init_state, goal_state`) 对 (`split="in_dist"`)
3. 对每个 seed (5M 配置 3 seeds; 每 seed 5 episodes):
  - (a) 重置 env (带 seed); 若 env 支持 `_set_env_state`, 从 `init_state` 设置
  - (b) 编码:  $z_{\text{history}}$  ( $H$  份  $z_{\text{init}}$ )、 $z_{\text{goal}}$  (均为零动作编码)
  - (c) 循环: `CEM.plan` → 整块执行 `min(H, budget - taken)` 步 → 模型自回归推进  $z_{\text{history}}$  → 重规划, 直到 50 步或 done
  - (d) 终止时编码真实最终状态  $z_{\text{final}}$ , 计算  $\cos\_dist = \frac{1}{2}(1 - \cos(z_{\text{final}}, z_{\text{goal}}))$
  - (e) 计算 `env.check_success` (env-native)
4. 聚合所有 seed 的 per-episode 结果: `mean_cos_dist, success_rate_lewm, env_SR`

### 6.3 评测 pipeline 的容差与阈值 (plain 设定)

评测代码里的容差与阈值定义如下 (详见 docs/CODE\_BUG\_AUDIT.md):

1. **DMC 容差**: DMC `check_success` 使用  $\text{dist} = \|\text{state} - \text{goal}\|_2 / \sqrt{n_q}$  与阈值  $\text{tol} = 0.1$ 。对 9 个高维 locomotion env (cheetah, walker, hopper, quadruped, humanoid, humanoid\_cmu, dog, fish, stacker) 的 87 维 state, 随机 uniform 距离  $\approx 0.45 < 0.1$  已不成立 (随机通过率 0%)。CEM 5 步规划器达不到 25 步目标, 因此这些 env 的 env-SR 落在 0, `mean_cos_dist` 显露出真信号: STJEW 6 个 readout 全部在 [0.103, 0.123] (v0.7.18.4 公平重跑), MLP/GRU/LIF-Transformer 接近 0 (坍缩), LeWM-v2 在 0.183 (过反应)
2. **LeWM 阈值**: `thresholded-success` 以  $\Pr[\cos_{\text{dist}} < 0.05]$  (严格阈值, 替代早期  $\cos_{\text{dist}} < 0.1$  阈值——后者让常数 latent 模型也能达到 100%) 和  $\Pr[\cos_{\text{dist}} < 0.01]$  (最严阈值) 为指标; `mean_cos_dist` (raw, threshold-free) 作为主指标

**CEM horizon 与 goal\_offset 的不一致**: CEM 规划器 `horizon=5` 而 `goal_offset=25/100`。`horizon=5` 是 planner budget 限制 (提升到 25-100 让 CEM planning 计算成本不可行: 5 iters  $\times$  100 samples  $\times$  100 steps)。难 env 上 **env-SR = 0 是 horizon artifact, 不是模型失败** (真实 state env-SR 经 v0.7.18.1 修复后呈现“易/难”二分: 易 env 饱和 1.0 (ball\_in\_cup 1.0, cartpole\_2d 0.99, cheetah 0.997, finger 0.89)、难 env 为 0 (dog, humanoid, quadruped, reacher, stacker, tworoom), 每模型均值 0.34–0.38) ——评测时改用 `mean_cos_dist` (不依赖 horizon 长度) 作为主指标。**env-SR aggregation bug (v0.7.18.1)**: `ClosedLoopResult` 漏传 `success_rate_env/std`, 导致 top-level env-SR 显示为 **0.0**; 867 个 state eval JSON 重新聚合后真实信号如上。区分度不在 **env-SR**, 而在 **mean\_cos\_dist**。

代码 diff (关键行):

```
# code/core/envs/dmc_env.py
"cheetah":      ("cheetah.xml", 9, 6, 200, 0.1), # tol = 0.1 (高维 locomotion env)
"humanoid":     ("humanoid.xml", 28, 21, 200, 0.1),
"dog":          ("dog.xml", 87, 38, 200, 0.1),

# code/eval/closed_loop.py
success_threshold_cos: float = 0.1, # legacy, kept for back-compat
# per-episode record:
lewm_succ_005 = cos_dist < 0.05
lewm_succ_001 = cos_dist < 0.01
# per-seed aggregate:
"success_rate_lewm_005": float(lewm_005_arr.mean()),
"success_rate_lewm_001": float(lewm_001_arr.mean()),
```



| 评测轴                 | splits × models × total cells<br>envs | 目的                | 配置文件                                                  |
|---------------------|---------------------------------------|-------------------|-------------------------------------------------------|
| 轴 1 DMC 内部子族<br>总览: | 6 × 13 × 14                           | gating experiment | configs/oodc/oodc_F*.json                             |
| 轴 2 跨基准族            | 4 × 13 × {1-13}                       | 边界条件              | configs/<br>textttcross_bench/<br>textttF*_train.json |
| 总计                  | 1300                                  |                   |                                                       |

#### 轴 1 每个 split 的 cell breakdown:

- oodc\_F1: 13 models × 14 DMC envs (其中 8 个 held-out, 6 个 seen) = 182 cells
- oodc\_F2: 13 × 14 (其中 7 held-out, 7 seen) = 182 cells
- oodc\_F3: 13 × 14 (其中 11 held-out, 3 seen) = 182 cells
- oodc\_F1F2: 13 × 14 (其中 2 held-out, 12 seen) = 182 cells
- oodc\_F1F3: 13 × 14 (其中 6 held-out, 8 seen) = 182 cells
- oodc\_F2F3: 13 × 14 (其中 5 held-out, 9 seen) = 182 cells
- 总计: 6 × 182 = 1092 cells

#### 轴 2 每个 split 的 cell breakdown:

- cross\_benchmark\_F1 (PushT held out): 13 × 1 = 13 cells
- cross\_benchmark\_F2 (TwoRoom held out): 13 × 1 = 13 cells
- cross\_benchmark\_F3 (Reacher held out): 13 × 1 = 13 cells
- cross\_benchmark\_F4 (DMC held out): 13 × 13 = 169 cells
- 总计: 13 + 13 + 13 + 169 = 208 cells

## 6.4 每个 cell 的 JSON 字段

- **env\_id**: env 的字符串 ID (如 "mujoco/reacher")
- **n\_episodes**: 本 cell 每 seed 跑的 episode 数 (5M 配置 5)
- **n\_seeds**: seed 数 (5M 配置 3: seed 0/1/2)
- **cem\_samples** / **cem\_elites** / **cem\_iters**: CEM 参数
- **horizon**: CEM horizon (默认 5)
- **eval\_budget**: 单 episode 最大 env step 数 (默认 50)
- **goal\_offset**: goal\_offset 步
- **history\_size**: 编码时堆叠的帧数 (默认 3)

- **success\_rate\_lewm**:  $\Pr[\cos\_dist < 0.1]$  (legacy, kept for back-compat)
- **success\_rate\_lewm\_005**:  $\Pr[\cos\_dist < 0.05]$
- **success\_rate\_lewm\_001**:  $\Pr[\cos\_dist < 0.01]$
- **success\_rate\_env**: env-native 成功判定 (DMC 上受 CEM horizon=5 vs goal\_offset=25/100 限制, env-SR 是 horizon artifact)
- **mean\_cos\_dist**: CEM 终止时  $z_{\text{final}}$  与  $z_{\text{goal}}$  的平均余弦距离 (主指标)
- **mean\_phys\_dist**: 物理空间距离  $L_2$  的均值
- **per\_seed**: 每个 seed 的聚合指标列表
- **per\_episode**: 每个 episode 的 cos\_dist、reward、env\_success、plan\_time\_sec
- **wall\_time\_sec**: 本 cell 的总 wall 时长

物理诊断 cell (仅 OOD Path-C measure\_diagnostic\_dmc) 额外字段:

- **divergence**: per-dim 标准差的均值
- **responsiveness**:  $\|\Delta z\|/\|\Delta o\|$  的均值
- **rho**: Pearson 相关系数
- **per\_dim\_std\_max / min**: 最大 / 最小维的标准差
- **n\_steps**: 200 步随机 rollout

## 7 指标定义

### 7.1 抗坍塌诊断 (先验定义, 来自物理约束)

- **divergence-from-constant (div)**:  $\sqrt{\text{Var}(z_{t=1..T})}$ , 逐维求平均。在 200 步随机策略轨迹上计算。
  - $\text{div} < 0.001$ : 坍塌 (MLP 的  $\text{div} \approx 0.0002$ )
  - $\text{div} \in [0.005, 0.05]$ : 校准 (STJEW 0.010-0.030)
  - $\text{div} > 0.05$ : 过反应 (LeWM-v2 的  $\text{div} \approx 0.18$ )
- **responsiveness (resp)**:  $\frac{1}{T} \sum_{t=1}^T \frac{\|\Delta z_t\|}{\|\Delta o_t\|}$  (向量范数比值)
  - $\text{resp} \in [0.1, 1.0]$ : 校准 (STJEW  $\approx 0.2$ ; 1.0 = latent 与 obs 同尺度移动的物理零点)
  - $\text{resp} > 1.0$ : 放大 (噪声 / 过反应; GRU 22.4, LeWM 32.7)
- **event-alignment  $\rho$** :  $\text{Pearson}(\|\Delta o_t\|, \|\Delta z_t\|)$  per step
  - $\rho \geq 0.95$ : 校准 (STJEW 全部  $\rho \geq 0.9986$ )
  - $\rho < 0.3$ : 噪声 (GRU -0.0074, MLP -0.0233; LeWM 0.7515 中等)

### 7.1.1 阈值标定与合理性论证 (P12 合成验证 + 空白区论证)

阈值如何确定——两步法，全程可追溯：

**第一步：自下而上的经验归纳 (v0.7.5)。**在 13 个真实模型上实测三个指标后，把阈值取在模型之间的数量级空白区，而不是切在任何模型云内部：div 在 MLP 0.0002 / STJEWLM 0.010–0.030 / LeWM 0.18 之间形成两个数量级级 gap，取 0.001 与 0.05 落在两段空白里；resp 以 1.0 (恒等映射的天然值) 为放大分界； $\rho$  以 0.3 为“无相关”的统计上界。

**第二步：自顶向下的合成标定 (P12, ground truth 已知)。**在 DMC cartpole 的 200 步随机轨迹上构造 6 种合成编码器 (constant / identity  $k=0.2$  / identity  $k=1.0$  / gain  $k=10$  / noise  $\sigma=0.1$  / uncorrelated noise)，并以增益  $k$  与噪声  $\sigma$  做连续扫描 (results/journal\_prep/P12\_synthetic/)：

| 合成编码器 (ground truth)              | div   | resp   | $\rho$ | 分类                  |
|-----------------------------------|-------|--------|--------|---------------------|
| Constant                          | 0.000 | 0.000  | 0.000  | collapsed ✓         |
| Identity $k = 0.2$ (STJEWLM-like) | 0.028 | 0.200  | 1.000  | calibrated ✓        |
| Identity $k = 1.0$                | 0.138 | 1.000  | 1.000  | over-reactive (边界上) |
| Gain $k = 10$                     | 1.377 | 10.000 | 1.000  | over-reactive ✓     |
| Noisy $\sigma = 0.1$              | 0.142 | 5.854  | 0.048  | noise ✓             |
| Uncorrelated noise                | 0.986 | 189.4  | 0.049  | noise ✓             |

**边界可识别 (跨界扫描)：**增益  $k$  从 0.3→0.5 时 div 从 0.041→0.069 越过 0.05 阈值，分类从 calibrated→over-reactive；噪声  $\sigma$  从 0.02→0.05 时  $\rho$  从 0.58→0.16 越过 0.3 阈值，分类从 inliers→noise。跨界点精确落在已发表阈值上——阈值不是对真实模型拟合出来的，而是在已知真值上可预测地成立。

合理性论证的四层逻辑：

- 物理/数学零点：**resp=1.0 (同尺度)、div=0 (恒常数)、 $\rho=0$  (不相关) 都是指标定义内禀的语义基准；阈值本质是“离这些零点多远算病态”
- 合成可证伪性：**阈值在已知真值上产生正确且可预测的跨界行为 ( $k$  连续扫描分类只在 0.3–0.5 之间翻转一次)——是可测试的假设，不是事后拟合
- 真实数据分离度：**13 模型实测值以数量级 gap 落在阈值两侧，3-seed CI 不相交 (Cohen’s  $d > 16$  vs 坍缩、 $-7 \dots -8.5$  vs 过反应)；阈值在小范围扰动下分类不变 (鲁棒性使精确数字的约定成分无害)
- 联合判据：**校准必须同时满足 div+resp ( $+\rho$ )；单指标可被欺骗 (MLP 的 div、LeWM 的 resp 各骗一个)，联合后任何已知病态模型至少违反一条

**诚实局限：**(i) 精确数字仍有约定成分，但边界两侧是数量级分离，阈值  $\pm 50\%$  扰动不改变任何真实模型的分类；(ii) P12 在单 env (cartpole) 上完成——指标只看 (obs, latent) 流、与 env 无关，且 rebuttal R5 另有 6 env 一致性证据；(iii) 分类器是硬阈值，论文主指标始终是原始连续值 (div/resp/ $\rho$ /cos\_dist 全报数值)，阈值仅用于定性分簇叙事。

## 7.2 任务表现指标 (事后报告)

- mean\_cos\_dist (主指标)：** $\frac{1}{N} \sum_n \frac{1}{2} (1 - \cos(z_{\text{final}}^{(n)}, z_{\text{goal}}^{(n)}))$ ，其中  $z_{\text{final}}$  是 episode 终止时真实最终状态的零动作编码 (不是 CEM 滚动末端潜状态)， $z_{\text{goal}}$  是目标观测的零动作编码。 $\in [0, 2]$ ，

越小越好。

- **LeWM@0.05**:  $\Pr[\cos_{\text{dist}} < 0.05]$ ,  $\in [0, 1]$ , 越大越好（被证伪指标，仅叙事用）。
- **env-SR**: 环境的原生成功判定（DMC ‘check\_success’ 使用  $L_2/\sqrt{n_q}$  距离  $\leq 0.1$  阈值；真实 state env-SR: 易 env 饱和 1.0 (ball\_in\_cup 1.0, cartpole 0.99, cheetah 0.997, finger 0.89)、难 env 为 0 (dog, humanoid, quadruped, reacher, stacker, tworoom), 每模型均值 0.34–0.38。区分度由 mean\_cos\_dist 承担)。

### 7.3 判定失败的”四象限”

| 家族 / 模型            | div                          | resp            | event- $\rho$<br>(G1)  | 失败模式                           |
|--------------------|------------------------------|-----------------|------------------------|--------------------------------|
| MLP(无状态对照)         | $\approx 0.0002$ (常数 latent) | $\rightarrow 0$ | $-0.0233$              | <b>坍塌</b> : 常输出, LeWM-SR 假阳性   |
| GRU                | 小                            | 大               | $-0.0074$              | <b>噪声/坍塌</b> : latent 与观测事件不相关 |
| LIF-Transformer    | 小                            | 小               | $-0.0003$              | <b>坍塌</b>                      |
| LeWM-v2            | 大                            | 大               | $0.7515$               | <b>过反应</b> : latent 放大观测       |
| STJEW (6 readouts) | 中 (非零)                       | 中               | $0.9986$ –<br>$0.9988$ | <b>校准</b>                      |
| ALIF-timecell      | 中                            | 中               | $0.9988$               | 校准 (SNN)                       |
| Stacked-LIF-trace  | 中                            | 中               | $0.9996$               | 校准 (SNN)                       |
| Stacked-LIF-free   | 中                            | 中               | $0.9997$               | 校准 (SNN)                       |

**关键观察**: MLP 的 div = 0.0002 正是常数 latent 的预期——per-dim 标准差为 0, 任何  $\cos_{\text{dist}}$  阈值被空洞满足 (§2.3a 证伪)。四象限的**判据是度量包的联合**:  $\cos_{\text{dist}}$  (低 = 校准) + div (非零) + event- $\rho$  ( $\geq 0.95$ ) 同时成立才算校准; 单看任何一列都会被至少一个模型欺骗 (如 GRU 的 div 正常但  $\rho \approx 0$ )。

## 8 实验结果 (v0.7.17–0.7.19)

### 8.1 概述: 13 模型 $\times$ 10 splits $\times$ 3 seeds 的全套证据

本节呈现的是 **v0.7.17–0.7.19** 期间完成的所有实验证据, 涵盖 13 个 5M-aligned 的世界模型 (6 个 STJEW readout + ALIF-timecell + 2 个 Stacked-LIF + LeWM-v2 + GRU + MLP + LIF-Transformer) 在 10 个训练 split (3 个跨基准族 F1/F2/F3 + 6 个 oodc 子族 gating split + 1 个 generalist 16-env 并集) 上的 closed-loop 评测, state 模态 130 个 ckpt / 1157 个 eval cell (MAIN\_TABLE\_5M\_STATE\_FULL.md), 辅以 pixel 模态 130 个 ckpt / 1690 个 eval cell、3 个随机种子 (seed=0/1/2)、补全实验 (B1–B4 + P11/P12/P13/P22 + G1–G5) 的横向证据。

本节按证据强度排序: (a) 三簇分界 (state, per-model cos\_dist 表 + 3-seed CI) → (b) SNN 家族属性 (event- 13 模型全表 + GRU 对照) → (c) 跨模态保留 (pixel env-SR 模式) → (d) 能效 (FLOPs) → (e) 诚实负面 (trace 因果、AUROC、probe R<sup>2</sup>、cheetah 边缘) → (f) 度量学贡献 (sigreg 扫描、合成验证、多 epoch 稳定性) → (g) env-SR 修正后的”易/难”二分模式。

## 8.2 (a) 三簇分界——STJEW 6 readouts 全部校准, SNN 家族属性

**5M-aligned state 实验覆盖的 13 模型 × 10 splits:** 3 个跨基准族 split (F1/F2/F3: PushT/TwoRoom/Reacher held out) + 6 个 oodc split (oodc\_F1/F2/F3 单子族持有 + oodc\_F1F2/F1F3/F2F3 双子族持有) + 1 个 G16 通才 split。全部 130 个 5M-aligned ckpt 训练成功 (baselines 4.97–5.13M, STJEW 5.06M 公平重跑)。STJEW 6 readouts × 10 splits 全部在 n\_layers=4 重新训练, cos\_dist delta < 0.004 与早期 2.70M 版本一致——校准性对参数规模鲁棒。

**Per-model cos\_dist 表 (5M-aligned, state, 跨所有 split 取均值):**

| Model             | Trn(M) | cos_dist ↓ | cluster                                |
|-------------------|--------|------------|----------------------------------------|
| LIF-Transformer   | 5.12   | 0.000      | collapse (chance 0)                    |
| MLP               | 5.00   | 0.007      | collapse                               |
| GRU               | 5.13   | 0.020      | collapse (div tiny, $\rho = -0.0074$ ) |
| STJEW-spike_only  | 5.06   | 0.111      | calibrated                             |
| STJEW-trace_only  | 5.06   | 0.104      | calibrated                             |
| STJEW-rate_only   | 5.06   | 0.103      | calibrated                             |
| STJEW-leak        | 5.06   | 0.120      | calibrated                             |
| STJEW-no_trace    | 5.06   | 0.123      | calibrated                             |
| STJEW-membrane    | 5.06   | 0.122      | calibrated                             |
| ALIF-timecell     | 4.98   | 0.105      | calibrated (SNN)                       |
| Stacked-LIF-trace | 5.11   | 0.106      | calibrated (SNN)                       |
| Stacked-LIF-free  | 5.05   | 0.111      | calibrated (SNN)                       |
| LeWM-v2           | 4.97   | 0.183      | over-react                             |

**3-seed CI 稳定性 (B2 + G5, 4 模型 × 3 splits × 3 seeds):** calibrated 簇 3 个代表 (STJEW-trace, STJEW-spike, Stacked-LIF-trace) vs over-react (LeWM-v2) vs collapse (MLP) 的 95% CI 在  $t_{0.025, df=2}$  准则下两两 disjoint:

| cluster / model               | cos_dist mean ± std | 95% CI (n=3)   | Cohen’s d vs LeWM-v2 |
|-------------------------------|---------------------|----------------|----------------------|
| calibrated: STJEW-trace       | 0.119 ± 0.002       | [0.115, 0.123] | −7.3                 |
| calibrated: STJEW-spike       | 0.114 ± 0.010       | [0.088, 0.139] | −7.0                 |
| calibrated: Stacked-LIF-trace | 0.115 ± 0.004       | [0.104, 0.125] | −8.5                 |
| over-react: LeWM-v2           | 0.194 ± 0.012       | [0.166, 0.223] | –                    |
| collapse: MLP                 | 0.004 ± 0.001       | [0.001, 0.006] | > 20                 |

**3-seed verdict:** calibrated 簇内 pairwise CI 重叠 (STJEW-trace 与 Stacked-LIF-trace、STJEW-spike 不可区分); calibrated vs over-react 与 calibrated vs collapse 的 CI disjoint (Cohen’s d 分别 −7–−8.5 和 > 20)。三簇在 3-seed 分辨率下统计独立。

**Per-env cos\_dist 矩阵** (节选, cross\_benchmark\_F1 / oodc\_F1 / G16, 见 results/journal\_prep/MAIN\_TABLE\_5M\_STATE\_FULL.md 全表 90 行): **易 env** (ball\_in\_cup, cartpole\_2d, cheetah, finger) 所有 SNN 校准模型 cos\_dist 0.00–0.10; **难 env** (dog, humanoid, quadruped, stacker, tworoom) 校准簇 cos\_dist 0.10–0.30, LeWM-v2 一致 0.20+, MLP/GRU/LIF-Transformer 全部 ≤ 0.005 (坍塌)。cos\_dist 对难易敏感, 主导模型区

分度；env-SR 难 env 全 0 (horizon artifact, 详见 (g))。

### 8.3 (b) SNN 家族属性——event-alignment $\rho$ 在 13 模型上严格二分

**G1 + B1fix (13 模型  $\times$  4 env  $\times$  2 splits = 104 cells)** : 200 步随机策略轨迹上 Pearson( $\|\Delta o_t\|, \|\Delta z_t\|$ ) per model。SNN 家族 (STJEWM 6 readouts + ALIF-timecell + Stacked-LIF $\times$ 2) 全部  $\rho \geq 0.9986$ ；非 SNN 基线中 LeWM-v2 0.7515 (中等), GRU  $-0.0074$ 、MLP  $-0.0233$ 、LIF-Transformer  $-0.0003$  (均接近 0)。SNN 家族均值  $\rho = 0.9989$  (40 cells) vs 非 SNN 0.4788 (12 cells), gap +0.5201。

| Model                 | family               | mean $\rho$ | n cells |
|-----------------------|----------------------|-------------|---------|
| Stacked-LIF-trace     | SNN                  | 0.9996      | 8       |
| STJEWM-spike_only     | SNN                  | 0.9988      | 8       |
| STJEWM-rate_only      | SNN                  | 0.9988      | 8       |
| STJEWM-membrane       | SNN                  | 0.9987      | 8       |
| STJEWM-trace_only     | SNN                  | 0.9987      | 8       |
| ALIF-timecell         | SNN                  | 0.9988      | 8       |
| Stacked-LIF-free      | SNN                  | 0.9997      | 8       |
| LeWM-v2 (Transformer) | non-SNN              | 0.7515      | 8       |
| MLP                   | non-SNN              | $-0.0220$   | 2       |
| GRU                   | non-SNN              | $-0.0074$   | 2       |
| LIF-Transformer       | SNN (ALIF+Tx hybrid) | $-0.0003$   | 2       |

**GRU 是最干净的反向控制**：GRU 与 STJEWM 共享循环时间聚合 (每步累积门控更新)，但 GRU 用连续 gating ( $\sigma(W \cdot [h_{t-1}, x_t])$ )，STJEWM 用二值脉冲 + 离散 trace。GRU  $\rho \approx -0.007$  几乎为 0，而 STJEWM  $\rho \approx 0.999$ 。一个数量级以上的 gap，唯一能解释的变量是脉冲表示本身——不是循环、不是深度、不是参数量。这是 SNN 家族属性的最干净证言。

**校准的 3 个轴** (div, resp,  $\rho$ ) 互补地描述同一 SNN 家族属性：**div**  $\in [0.005, 0.05]$  (不坍塌也不放大)、**resp**  $\in [0.1, 1.0]$  (温和放大)、 $\rho \geq 0.99$  (事件同步)。三轴构成“三角不可能性” (详见 §5.1 物理诊断层)。

### 8.4 (c) 跨模态保留——pixel 三簇分界排序与 state 一致

**Pixel 实验覆盖 13 模型  $\times$  10 splits  $\times$  1 seed (130 ckpt)**：frozen ViT-Tiny 5.459M + trainable 5.00M (projector 0.074M + SNN predictor 4.93M)，目标为静态 qpos (可达)。CEM  $300 \times 30 \times 10$ , H=5, budget=50, 5 eps  $\times$  1 seed。

**env-SR 真实模式 (pixel, 静态 goal 可达, 3 簇分界在控制信号上有真实区分度)**：

- **ball\_in\_cup**：全部 13 模型 1.00 (4-DOF 对齐任务 CEM 5 步可解)
- **cartpole**：STJEWM 0.4–0.8 vs LeWM-v2 **0.0–0.2** (过反应模型的控制失败——放大了 obs 噪声)
- **cheetah**：Stacked-LIF-trace 0.40 vs LeWM-v2 0.00 vs STJEWM 0.60 (局部)
- **pendulum**：Stacked-LIF-free 最高 1.00, LeWM-v2 0.00
- **dog/fish/hopper/humanoid/quadruped/stacker/walker**：全部 0.00 (5 步 CEM 够不到长程目标)

**Pixel env-SR 三簇** (13 模型均值 across 10 splits  $\times$  5 envs = 50 cells/model) :

| cluster          | env-SR mean           | 代表                                                 |
|------------------|-----------------------|----------------------------------------------------|
| calibrated (SNN) | 0.171–0.178           | STJEWM-trace 0.171, Stacked-LIF-trace 0.178        |
| over-react       | <b>0.091</b> (lowest) | LeWM-v2——过反应放大 obs 噪声致控制失败                         |
| collapse (state) | n/a (静态可达)            | MLP 0.172, LIF-Transformer/Stacked-LIF-free 接近 ... |

**关键发现: LeWM-v2 的过反应在 pixel 控制层面变成实际失败** (cartpole env-SR 0.0–0.2), 因为 CEM 在过反应 latent 上找不到可行 plan。cos\_dist 在 pixel 下尺度变大 (state 0.05–0.3 vs pixel 0.6–0.9), 但三簇**极值排序** (坍缩最低、过反应最高) 跨模态一致——**frozen ViT 是表示瓶颈而非模型失败**。fish env cos\_dist 异常大 (3.4–5.4), 是 ViT 14 $\times$ 14 patch 看不见鱼形动态的**编码器盲区**。

## 8.5 (d) 能效——STJEWM 相对稠密基线 $\sim 20\times$ FLOPs 优势

**G3 + P11 测量协议**: state, 2 batch  $\times$  2 sample 前向, 测得 active soma fraction (STJEWM 实测 93.3% sparse), 事件驱动折扣公式  $F_{\text{eff}} = F_{\text{always\_dense}} + \alpha_{\text{active}} \cdot F_{\text{dynamic SNN/readout}}$ 。稠密基线无 spike,  $\alpha = 1.0$ 。

**Effective FLOPs / step(state, MFLOPs):**

| Model             | effFLOPs     | dense | ratio vs dense                    |
|-------------------|--------------|-------|-----------------------------------|
| STJEWM-trace      | <b>0.483</b> | 5.23  | 0.05 $\times$                     |
| STJEWM-spike      | 0.465        | 5.16  | 0.05 $\times$                     |
| STJEWM-rate       | 0.478        | 5.16  | 0.05 $\times$                     |
| STJEWM-no_trace   | 0.465        | 5.16  | 0.05 $\times$                     |
| STJEWM-leak       | 0.477        | 5.23  | 0.05 $\times$                     |
| STJEWM-membrane   | 0.481        | 5.16  | 0.05 $\times$                     |
| Stacked-LIF-trace | 2.125        | 10.18 | 0.21 $\times$ (4.4 $\times$ more) |
| Stacked-LIF-free  | 1.940        | 10.07 | 0.19 $\times$ (4.2 $\times$ more) |
| LeWM-v2           | 9.770        | 9.77  | 1.0 $\times$                      |
| GRU               | 10.241       | 10.24 | 1.0 $\times$                      |
| MLP               | 9.984        | 9.98  | 1.0 $\times$                      |

**关键发现: STJEWM 6 readouts 0.46–0.48 MFLOPs/step vs 稠密基线** (GRU/MLP/LeWM-v2) 9.8–10.2 MFLOPs/step——**约 20 $\times$  事件驱动能效优势**。相对 Stacked-LIF (2.1 MFLOPs), STJEWM 仍有 4.4 $\times$  优势。Stacked-LIF 是 8 层 ALIF (密集 spike), 稀疏度仅 0.9%; STJEWM 是 4 层 LIF + gated trace, 稀疏度 93.3%——**稀疏度是设计选择, 不是 SNN 家族必然**。caveat: analytical 事件驱动估计, 非硬件 benchmark。

## 8.6 (e) 诚实负面——trace 因果、AUROC、probe R<sup>2</sup>、cheetah 边缘

**负面 #1: trace 因果角色——0/3 cells 表明不成立(B4)**。B4 做了 6-mode 消融: 5 个 history-path trace 消融 (baseline / event\_window / non\_event\_window / random\_window / ablate\_all) + 1 个 **CEM-internal trace 消融** (在 CEM candidate rollout 的内部 model.predict 里把 trace 强制置零——规划器实际消费 trace 的地方)。结果: 0/3 cells 显示 CEM-rollout 消融比 history-path 消融伤害更大。Pixel cheetah 上两者都掉 10pp (1 episode 噪声); state cartpole/cheetah env-SR 全 0 (horizon artifact)。**强因果声明被驳回**: trace 与事件对齐是相关性 ((b) 中  $\rho \geq 0.99$ ), 不是因果机制——trace 不是 CEM 优于 baseline 的原因。

**负面 #2: event-AUROC 1-epoch——STJEWM  $\approx$  chance, Stacked-LIF-trace 0.67 居首 (G2)**。13 模型  $\times$  13 DMC envs  $\times$  5 event targets = 325 cells, 1-epoch 训练。线性 probe

(logistic) 拟合 5 类事件标签 (contact / high\_motion / low\_motion / future\_k5 / future\_k10)

|        | Model             | overall AUROC | family                     | notes                         |
|--------|-------------------|---------------|----------------------------|-------------------------------|
| 的 AUC: | Stacked-LIF-trace | <b>0.6718</b> | SNN (8-layer ALIF + trace) | 最高, 1-epoch 即可                |
|        | LeWM-v2           | 0.6259        | Transformer                | P13 3-epoch 0.63 几乎一致         |
|        | Stacked-LIF-free  | 0.5872        | SNN (free readout)         | 比 trace 低 8.5pp               |
|        | GRU               | 0.5460        | RNN (2-layer GRU)          | 略高于 chance                    |
|        | LIF-Transformer   | 0.5425        | SNN (ALIF + AdaLN Tx)      | future_k10 $\rightarrow$ 0.51 |
|        | STJEWM-leak       | 0.5145        | SNN (hidden_leak)          | STJEWM 6 最高                   |
|        | STJEWM-spike      | 0.5056        | SNN (spike readout)        |                               |
|        | STJEWM-membrane   | 0.5048        | SNN (membrane)             |                               |
|        | STJEWM-trace      | 0.5012        | SNN (trace)                | $\approx$ chance              |
|        | ALIF-timecell     | 0.5018        | SNN (ALIF 2-layer)         | $\approx$ chance              |
|        | STJEWM-rate       | 0.4995        | SNN (rate)                 |                               |
|        | MLP               | 0.4987        | MLP                        | chance                        |
|        | STJEWM-no_trace   | 0.4981        | SNN (no trace ablation)    |                               |

**为什么 STJEWM  $\approx$  chance 而 Stacked-LIF-trace 0.67:** Stacked-LIF 的 readout 是 moving\_avg  $\rightarrow$  Linear (线性), 把 trace 序列线性可解码地映射到事件类别——线性 probe 立刻能 recover 出来。STJEWM 的 gated trace 是非线性门控 ( $\alpha_t = \sigma(W[r_{t-1}, s_t, c_t])$ ), 事件信息在 latent 里 ((b) 中  $\rho \geq 0.99$  表明脉冲与 obs 同步), 但不在线性可分子空间。这是 readout 设计的差异, 不是 trace 的失败。P13 (3-epoch 重测) 显示 LeWM AUROC 稳定在 0.63 (probe-build artifact 修正后), STJEWM 在 1-epoch 的 0.50 是真实低值。

**负面 #3: probe R<sup>2</sup> (B3 + G4):** 13 模型  $\times$  5 targets  $\times$  10 envs = 611 cells (linear regression 预测 position / velocity / future\_k / goal\_direction / contact from latent), B3-fix 后随机 train/val split + winsorization。结果:

- **LeWM-v2 mean position R<sup>2</sup> = +0.285** (最强位置可解码性, 10 envs 均值)
- **STJEWM 6 readouts mean position R<sup>2</sup> = -0.042** (6 readout 均值在 [-0.053, -0.030])
- **MLP -0.061, GRU +0.030, ALIF-timecell -0.034, Stacked-LIF-trace +0.007, Stacked-LIF-free +0.022, LIF-Transformer -0.054** (其他模型也都接近 chance)

**正确解读: event-vs-position dissociation 不是 STJEWM 独有——**所有循环/局部网络控制器 (STJEWM, MLP, GRU, ALIF-timecell, Stacked-LIF, LIF-Transformer) 位置 R<sup>2</sup> 都接近 chance。**LeWM 的位置解码能力是它独有的**, 比所有其他模型高 3–10 $\times$ 。这与过反应簇诊断一致: LeWM 把它能解码的信息显式编码进 latent, STJEWM 选择有界 trace 保留事件而非位置。

**负面 #4: cheetah 边缘——” 边际优势, 分裂依赖” (P22)**。60 episodes  $\times$  10 splits 对比 STJEWM-trace vs Stacked-LIF-trace 在像素 cheetah:

- Pooled paired t = +4.150 (df=9), p = 0.0025 (统计显著)
- Wilcoxon W = 0.0, p = 0.0078
- STJ 胜 / Stacked-LIF 胜 / 平: 8 / 0 / 2 splits
- **4/10 splits 方向反转** (OLD-30 vs NEW-30 各自的胜负方向不同)
- OLD-30 alone  $|t| = 2.153$  (p=0.060, 边缘), NEW-30 alone  $|t| = 1.118$  (p=0.293, ns)



判决：不要把 cheetah 当作 STJEWm 强 edge 说。准确措辞：“在 cheetah 上 60 eps 的 paired t 显著 ( $p < 0.01$ )，但 4/10 splits 方向反转，单 30-eps 半数不显著，故仅 marginal, split-dependent, not a strong edge。”

## 8.7 (f) 度量学贡献——sigreg 扫描、合成验证、多 epoch 稳定性

贡献 1: sigreg 权重扫描 (v0.7.18.8)。STJEWm-trace,  $\lambda_{\text{sigreg}} \in \{0.09, 0.01, 0.001, 0.0\}$ , 2 splits  $\times$  8 ckpt + 76 eval。结果：

- prediction loss 在 4 个权重下完全一致 ( $\approx 0.0005$ ): sigreg 是独立正则项，不干涉 pred 收敛
- cos\_dist: F1 上 0.117/0.100/0.124/0.112(best at 0.01), oodc\_F2 上 0.127/0.115/0.112/0.131
- paired t (0.09 vs 0.01) = +1.54 (ns,  $|t| > 2.16$  阈值)

判决：“sigreg hijacks optimization” 假设被驳回。STJEWm vs Stacked-LIF 在 cos\_dist 上的差异完全在 3-seed CI 噪声内 ((a) B2 已显示 calibrated 簇内 CI 重叠)。STJEWm 真实优势是 4.4 $\times$  更低的有效 FLOPs ((d)), 不是 sigreg 工程。

贡献 2: 合成验证 (P12) ——4 指标包的边界可识别。在 DMC cartpole 上构造 6 种 ground-truth encoder (constant / identity / gain / noise / identity-low-gain / uncorrelated-noise), 每个

| 200 步随机轨迹: | Encoder                  | div   | resp   | $\rho$ | classified               |
|------------|--------------------------|-------|--------|--------|--------------------------|
|            | Constant                 | 0.000 | 0.000  | 0.000  | collapsed                |
|            | Identity ( $k = 0.2$ )   | 0.028 | 0.200  | 1.000  | calibrated (STJEWm-like) |
|            | Identity ( $k = 1.0$ )   | 0.138 | 1.000  | 1.000  | over-reactive (boundary) |
|            | Gain ( $k = 10$ )        | 1.377 | 10.000 | 1.000  | over-reactive            |
|            | Noisy ( $\sigma = 0.1$ ) | 0.142 | 5.854  | 0.048  | noise                    |
|            | Uncorr. noise            | 0.986 | 189.4  | 0.049  | noise                    |

阈值交叉验证:

- Gain crossover:  $k = 0.3 \rightarrow$  calibrated,  $k = 0.5 \rightarrow$  over-reactive (resp=0.5 越线, 与 resp=1.0 阈值一致)
- Noise crossover:  $\sigma = 0.02 \rightarrow$  inliers,  $\sigma = 0.05 \rightarrow$  noise ( $\rho = 0.16$  越线, 与  $\rho = 0.3$  阈值一致)

判决: 4 指标包 (env-SR / div / resp /  $\rho$ ) 的边界不是 ad-hoc 的——它们在 synthetic ground-truth 上精确落在已发表阈值上。这是 reviewer 的有效弹药: “metric 不是凑出来的”。

贡献 3: 多 epoch 稳定性 (P13)。3 模型  $\times$  2 splits  $\times$  {1, 3, 5} epochs = 12 ckpt。结果:

- 三簇分界在 3 和 5 epoch 下保持: cos\_dist 序 collapse  $\ll$  calibrated  $\ll$  over-react, deltas  $< 0.01$  for cb\_F1,  $\sim 0.07$  for oodc\_F2 (LeWM 改善)。分界不是 1-epoch 训练量 artifact。
- LeWM AUROC 在 3-epoch 恢复到 0.63 (1-epoch 的  $\sim 0.5$  是 probe-build artifact, 不是真实限制)
- MLP 即使 5-epoch 仍  $\sim 0.50$ ——致于坍缩

## 8.8 (g) env-SR 真实模式——”易/难”二分而非模型质量

**v0.7.18.1 env-SR aggregation bug 修复:** ClosedLoopResult 漏传 success\_rate\_env/std, 导致 top-level env-SR 显示为 0.0; 867 个 state eval JSON 重新聚合后真实信号呈现”易/难”二分:

- **易 env 饱和 1.0:** ball\_in\_cup 1.00, cartpole 0.99, cheetah 0.997, finger 0.89 (所有模型都成功——CEM 5 步够得着简单姿态目标)
- **难 env = 0:** dog, humanoid, quadruped, reacher, stacker, tworoom (所有模型都失败——5 步 CEM 够不到长程协调)
- **每模型均值 0.34–0.38** (低区分度, mean\_cos\_dist 才是主指标)

这是规划器到动作的解码瓶颈, 不是潜变量表示的失败。env-SR 单独无法区分 13 模型; 它的作用是 sanity check (CEM 5 步确实在跑、env 确实可达)。主指标始终是 mean\_cos\_dist, 对 env-SR 的解读必须配以 cos\_dist, 否则就是 §2.3a LeWM-SR 证伪的同一种 artifact。

## 8.9 (h) §2.3a 头条——LeWM-SR 的实验性证伪仍然有效

**13 个 5M-aligned 模型在  $\cos_{\text{dist}} < 0.1$  阈值下的 LeWM-SR 表 (89 cells/model 聚合):**

| Model             | LeWM-SR | div (latent std/dim) | $\rho$ (event-align) |
|-------------------|---------|----------------------|----------------------|
| mlp_baseline      | 97.3%   | 0.0002               | -0.0233              |
| stjewm_trace_only | 58.7%   | 0.0106               | 0.9987               |
| lewm_baseline_v2  | 34.2%   | 0.204                | 0.7515               |
| gru_baseline      | 90.8%   | 0.0304               | -0.0074              |

MLP 在 5M-aligned 聚合上 LeWM-SR 最高 (97.3%), 但 **div=0.0002**,  $\rho = -0.0233$ ——潜状态是常数零向量; 次高 GRU 90.8% 同样坍塌。LeWM-SR 是被常数潜状态平凡通过的指标。本节作为 §2.3a 头条保留。每个 LeWM-SR 数字都应在 div 和  $\rho$  的背景中读, **绝不单独读**。4 指标包按构造具备”不可被常数潜状态欺骗”的性质。

## 9 为什么 STJEWM 有效 (更好的物理故事)

### 9.1 两个层次的解释

STJEWM 之所以在 4 个跨基准族 split 上都优于 ALIF-timecell, 是因为它在两个正交轴上同时满足约束:

#### 9.1.1 物理层: trace dynamics 自带校准性

脉冲后的轨迹 (trace) 是一个内容感知的低通滤波器:

$$r_t = \alpha_t \cdot r_{t-1} + (1 - \alpha_t) \cdot s_t \quad \text{其中} \quad \alpha_t = \sigma(W[r_{t-1}, s_t, c_t])$$

几个性质:

- **有界:**  $r_t \in [0, 1]$ , 逐维。

- **有遗忘**: 没有脉冲时,  $r$  自然衰减 ( $\alpha$  接近 0), 避免无限累积。
- **有更新**: 有脉冲时,  $r$  跳到接近 1, 记录事件。
- **内容感知**:  $\alpha$  取决于上下文  $c_t$ , 所以”忘记什么、记住什么”由环境调制。

这种 dynamics 在**任何**下游接口下都给出  $\text{div} \approx 0.011$ 、 $\text{resp} \approx 0.21$ 、 $\rho \approx 1$  ——我们在 STJEW 6 个读出口径上都验证了这一点。

### 9.1.2 任务层: 校准的 latent 让规划器能工作

CEM (Cross-Entropy Method) 规划器在 latent 空间搜索动作序列, 使得未来 latent 接近目标 latent。规划器能否工作取决于三件事:

1. latent 是否**随观测有意义地变化** ( $\text{div} > 0$ ) ——否则规划器在做”在常数 latent 里搜索”
2. latent 是否**不放大观测** ( $\text{resp} \approx 1$ ) ——否则梯度信号爆炸
3. latent 是否**与观测事件同步** ( $\rho \geq 0.95$ ) ——否则 CEM 的”未来预测”是噪声

STJEW 6 个读出口径全部满足这三点 (物理层), 所以 CEM 规划器在它们之上能工作。MLP / GRU / LeWM-v2 各自在一个点上失败, 所以 CEM 在它们之上崩溃。

## 9.2 为什么 trace / spike / rate 都能赢?

跨基准族的赢家因 split 而异:

- **trace** 赢 F2/F4: 在 Tworoom / DMC (稳态连续控制) 上, content-aware 衰减最匹配数据的平稳性
- **rate** 赢 F1: 在 PushT (离散事件: 块推动、接触) 上, moving average 把离散脉冲压平成平移信号
- **spike** 赢 F3: 在 Reacher (稀疏目标) 上, 瞬时脉冲直接编码目标位置

6 个读出口径都落在同一校准区 (0.091-0.121), 所以**没有任何一个读出口径的物理优势压倒性地大于其他**。这反而是 STJEW 主张最强的证据: **不是某个特定的 readout magic 赢了, 而是 trace dynamics 本身的 calibration property 赢了。**

## 9.3 膜电位禁止协议的作用

如果取消协议 (让规划器读膜电位  $h_t$ ), 我们预期:

- STJEW-membrane-readout 应该在  $\text{div} / \rho$  上跟 **trace\_only** 一样, 因为动力学一样
- 但 CEM 规划器看到的信号是  $h_t$ , 可能给出**不同的**目标距离 (因为  $h_t$  的尺度与 trace 不同)

我们的实验确认了前者( $\text{div} / \rho$  在 6 个 readout 上都一致),但跨基准族上 membrane\_readout 的 mean\_cos\_dist 略差 (0.121 vs trace 的 0.103), 因为  $h_t$  与 goal 处的  $h_{\text{goal}}$  之间的对齐难度高于 trace 与  $r_{\text{goal}}$ 。

**关键：**膜电位禁止协议不改变校准性（那是 trace dynamics 的内禀属性），而是**改变规划器的接口质量**——trace 的有界性 + 内容感知让 CEM 优化更稳定。

## 10 实验结论

### 10.1 三个支持性结论

1. **校准是 SNN 家族属性，不是参数量红利** (13 模型  $\times$  10 splits  $\times$  3-seed CI 验证) : STJEWM 6 readouts (trace\_only / spike\_only / rate\_only / no\_trace / hidden\_leak / membrane\_readout; trainable 全部 5.06M, n\_layers=4 公平重跑) 在 4 个跨基准族 split + 6 个 oodc split 上 cos\_dist 都落在 [0.103, 0.123], 与 **ALIF-timecell** (0.105)、**Stacked-LIF-trace** (0.106)、**Stacked-LIF-free** (0.111) 严格同一校准簇。校准簇与 **LeWM-v2** (0.183, 过反应) 和 **MLP / GRU / LIF-Transformer** ( $\leq 0.020$ , 坍缩) 的 3-seed 95% CI 两两 disjoint (Cohen's d 分别  $-7$ — $-8.5$  和  $> 20$ )。当 STJEWM 从 2.70M (n\_layers=2) 提到 5.06M (n\_layers=4), 每 readout cos\_dist delta  $< 0.004$ ——**trace dynamics 是 spike + 内容感知衰减的内禀属性，不是堆参数出来的**。event- $\rho$  验证 spike-based 而非 recurrence (GRU 与 STJEWM 共享循环但  $\rho = -0.007$  vs 0.999)。
2. **事件对齐源于 spike 表示，GRU 是反向对照** (13 模型  $\times$  4 env  $\times$  2 splits = 104 cells) : SNN 家族 (STJEWM 6 + ALIF-timecell + Stacked-LIF $\times 2$ ) mean  $\rho = 0.9989$ , 非 SNN 基线 (LeWM 0.7515, GRU -0.0074, MLP -0.0233, LIF-Transformer -0.0003) mean  $\rho = 0.4788$ , gap +0.5201。**GRU 是最干净的控制**：与 STJEWM 共享循环时间聚合（每步门控更新），但 GRU 用连续 gating ( $\sigma(W[h, x])$ )，STJEWM 用二值脉冲 + 离散 trace。一个数量级以上的  $\rho$  gap 唯一归因于**脉冲表示本身**。这是 SNN 家族属性的**最干净证言**——任何 RNN 都不该拿”循环”来解释  $\rho$ 。
3. **STJEWM 相对 Stacked-LIF 的诚实定位** (FLOPs 4.4 $\times$  优势 + AUROC 弱): 3-seed CI 显示 STJEWM 与 Stacked-LIF 在 cos\_dist 上**统计不可区分** (calibrated 簇内 pairwise CI 重叠)。STJEWM 的真实优势是 **4.4 $\times$  更低的有效 FLOPs** (0.46–0.48 MFLOPs/step vs Stacked-LIF 1.94–2.13;  $\sim 20\times$  vs GRU/MLP/LeWM-v2 9.8–10.2)。Stacked-LIF 在 1-epoch event-AUROC 上以 0.6718 居首 (线性 readout moving\_avg $\rightarrow$ Linear 让 trace 序列**线性可解码**; STJEWM 的非线性 gated trace 是 0.50 chance——**事件信息在 latent 里 ( $\rho$  高) 但不在线性子空间**)。这是 readout 设计的差异，**不是 trace 的失败**。cheetah 边缘是”marginal, split-dependent, not a strong edge” (pooled  $t = 4.15$  但 4/10 splits 翻转)。STJEWM 不是 Stacked-LIF 的”升级版”，而是**不同能效/可解码性权衡点**。

### 10.2 度量学贡献 (4 指标包 + 合成验证)

1. **§2.3a LeWM-SR 实验性证伪 (仍为头条)**: MLP (5M-aligned) LeWM-SR = 97.3%, 但  $\text{div} = 0.0002$ 、 $\rho = -0.0233$ ——潜状态是常数零向量，LeWM-SR 被平凡通过。LeWM-SR

单独不能用作规划器质量信号；每个 LeWM-SR 数字都应在  $\text{div}$  和  $\rho$  的背景中读，**绝不单独读**。

2. **4 指标包** ( $\text{env-native SR}$ ,  $\text{div}$ ,  $\text{resp}$ ,  $\rho$ ) 按构造具备”不可被常数潜状态欺骗”的性质，且 **P12 合成验证** 在 6 种 ground-truth encoder ( $\text{constant}$  /  $\text{identity-low-gain}$  /  $\text{identity-unity}$  /  $\text{gain}$  /  $\text{noisy}$  /  $\text{uncorrelated-noise}$ ) 上证实：boundary  $k = 0.3 \rightarrow \text{calibrated}$  vs  $k = 0.5 \rightarrow \text{over-reactive}$  落在  $\text{resp}=1.0$  阈值上； $\sigma = 0.02 \rightarrow \text{inliers}$  vs  $\sigma = 0.05 \rightarrow \text{noise}$  落在  $\rho = 0.3$  阈值上。**阈值不是 ad-hoc 的**。
3. **v0.7.18.1 env-SR aggregation bug 修复**: `ClosedLoopResult` 漏传 `success_rate_env/std`, top-level env-SR 全部显示 0.0。867 个 state eval JSON 重新聚合：易 env 饱和 1.0、难 env 0、每模型均值 0.34–0.38。**env-SR 是”易/难”二分，不是模型质量**；区分度由 `mean_cos_dist` 承担。

### 10.3 两个诚实限制

1. **trace dynamics 不具有”因果性”强声明** (B4): 0/3 cells 显示 CEM-internal trace 消融比 history-path trace 消融伤害更大。trace 与事件对齐是相关性，不是 trace 优于 baseline 的因果机制。STJEW 的” $\rho$  高 +  $\sim 20\times$  FLOPs 优势”成立；”trace 导致”不成立。
2. **event-AUROC probe 上 STJEW 1-epoch  $\approx$  chance** (G2): STJEW 6 readouts AUROC 0.50–0.51 vs Stacked-LIF-trace 0.67、LeWM 0.63。3-epoch 重测尚未补齐所有 STJEW cells (B3 修复后 ckpt-build mismatch 仍限制部分 env)。LeWM 的 3-epoch 0.63 与 1-epoch 0.63 一致，说明 Transformer 早期就饱和。STJEW 1-epoch AUROC 是真实低值，可能源于 gated trace 的非线性门控（事件信息在  $\rho$  高的 latent 里但不在线性可分子空间）。这一限制**不影响**三簇分界和 event- $\rho$  结论，但降低了 STJEW 在”事件类型线性可解码”类下游任务上的预期。

### 10.4 工作标题

本论文的工作标题：

膜电位禁止协议是一种可复用的 SNN 世界模型评测框架；STJEW 是一种可实施的实现，在 13 个 5M-aligned 模型  $\times$  10 个 split  $\times$  3 个 seed 上展示了 calibration 是 SNN 家族属性 (STJEW 6 + ALIF-timecell + Stacked-LIF $\times 2$  的  $\rho \geq 0.998$  vs LeWM/GRU/MLP/LIF-Transformer 的  $\rho \leq 0.75$ ) 和  $\sim 20\times$  事件驱动能效优势 (vs GRU/MLP/LeWM-v2)。trace dynamics 不具有因果性 (B4 0/3 cells)，event-AUROC 在 1-epoch STJEW 上  $\approx$  chance 但 spike-based event- $\rho$  是 SNN 家族独有属性。**4 指标包** ( $\text{env-SR}$ ,  $\text{div}$ ,  $\text{resp}$ ,  $\rho$ ) 按构造不可被常数潜状态欺骗，并在合成 ground-truth 上认证了阈值。

### 10.5 跨模态鲁棒性 (state $\rightarrow$ pixel, 13 模型 $\times$ 10 splits $\times$ 130 ckpt)

state 实验在低维 proprioceptive 状态 ( $\leq 128$ -dim, pad 后) 上训练。引入 **像素观测**：

- 把 state\_projector 换成 **5.459M 冻结的 ViT-Tiny 像素编码器** (patch 14, 12 层, 3 heads, image\_size 84, 192-dim 输出) + 0.074M 可训练 projector (Linear→SiLU→Linear)。**像素参数拆分**: pixel STJEW 总参 = 冻结 ViT-Tiny 5.459M + trainable 5.00M (projector 0.074M + action\_encoder 0.011M + SNN stack 4.732M + gated\_trace 0.148M + trace\_proj 0.037M), 不是 0.07M (0.07M 仅 projector)。
- 13 模型  $\times$  10 splits  $\times$  1 seed = 130 ckpt
- 训练预算与 5M-aligned 保持一致 (所有模型 4.83–5.21M 训练参数,  $\pm 3.2\%$ )
- 训练 split 完全是 state 模态的 10 个 split (不引入新 split) ——严格的”只换观测模态”对照
- 目标改为 **静态 qpos** (可达) ——make\_goal\_state\_for: cartpole [0,0]、pendulum [1,0]、cheetah 全零等; pixel env-SR 与 state 不可直接比 (goal source 不同)

**评估。**闭环 CEM 规划器 (horizon=5,  $N_{\text{samples}} = 300$ ,  $N_{\text{elites}} = 30$ , 10 次迭代), 每个 split  $\times$  模型都过 13 个 DMC 环境, 5 episodes/env。

**核心问题:** trace dynamics 的校准/坍塌/过激 4 族划分在 state  $\rightarrow$  pixel 之后是否仍然保持?

- 若 **保持**——trace dynamics 假设是**架构内禀**的, 不依赖于低维状态表示。
- 若 **不保持**——之前的校准信号可能由 state\_projector 的特定投影承担, 不是 trace 自身的功劳。

**实际结果 (pixel):**

- **三簇分界在极值上保留:** env-SR 上 LeWM-v2 cartpole 0.0–0.2 (最低, 过反应放大 obs 噪声致控制失败); STJEW/Stacked-LIF 0.4–0.8 (部分控制); 坍塌簇 (MLP/LIF-Transformer) 在静态可达 env 上偶尔得分高但 env-SR 区分度被静态目标稀释
- **像素 env-SR (静态 goal, 13 模型均值 across 10 splits):** STJEW-trace 0.171, Stacked-LIF-trace 0.178, Stacked-LIF-free 接近, LeWM-v2 0.091 (lowest), MLP 0.172——三簇保留但 cos\_dist 尺度被 ViT 14 $\times$ 14 patch 放大 (pixel 0.6–0.9 vs state 0.05–0.3)
- **fish env 异常:** cos\_dist 3.4–5.4, 所有模型都失败, 是 frozen ViT 14 $\times$ 14 patch 的**编码器盲区** (无法捕捉鱼形动态), 不是模型差异
- **ball\_in\_cup:** 全部 13 模型 1.00 (4-DOF 对齐任务 CEM 5 步可解) ——**静态目标可达稀释了 env-SR 的模型区分度**, 但 cos\_dist 仍能区分 (state 中 0.00 vs pixel 中 0.022–0.029)
- **结论:** trace dynamics 假设**跨模态保留**在极值排序上 (坍塌最低、过反应最高), 但 frozen ViT 是表示瓶颈——pixel 的 cos\_dist 区分度主要来自**控制层面** (env-SR) 而非潜变量对齐 (cos\_dist 在 pixel 下挤在 0.6–0.9)。这验证了 trace dynamics 的架构内禀性, 但同时指出了 frozen ViT 在 0.1 尺度任务特征上的局限。

## 10.6 未来工作

根据 v0.7.17–0.7.19 完成的证据，未来工作应聚焦在**消除已确认限制**（trace 因果 / AUROC probe / ViT 瓶颈）而非**扩展已稳固结论**：

1. **AUROC 3-epoch STJEWLM 全 ckpt 重测**：当前 G2 显示 LeWM 1-epoch  $0.6259 \approx 3$ -epoch 0.63（已修复），STJEWLM 1-epoch 0.50 是真实低值（B3 修复后 ckpt-build 仍限制部分 env）。下一步用 3-epoch 重训全部 STJEWLM 6 readouts  $\times 10$  splits，确认是 readout 非线性门控而非训练量导致。
2. **硬件部署验证  $\sim 20\times$  FLOPs 优势**：G3 + P11 是 analytical 事件驱动估计（discount by active soma fraction），不是真实硬件 benchmark。下一步在 Intel Loihi / SpiNNaker / 神经形态硬件上部署 STJEWLM 与 GRU baseline，测量 wall-time 与 energy-per-step。
3. **解冻 ViT 的对照实验**：当前 pixel 实验 ViT 5.459M 全冻结（pixel 训练参数 5.00M 主要是 SNN stack）。下一步对比（a）frozen ViT + trainable SNN（当前）与（b）small ViT + trainable SNN + 小量 ViT 微调——回答是否 ViT 表示瓶颈可通过解冻突破。
4. **trace 因果的更精细实验**：B4 的 0/3 是 1-seed, 5-episode 噪声。多 seed 训练 STJEWLM-trace 在 cheetah 上做“trace-on vs trace-off CEM-rollout”的 paired t-test，能给出更严格的因果下界。
5. **Stacked-LIF 8 层 ALIF 与 STJEWLM gated trace 的混合架构搜索**：当前 Stacked-LIF 在 F2/F3 上 73–84% LeWM-SR（5M-aligned）显著，但 STJEWLM 6 readouts 不可区分。Stacked-LIF 的 8 层 ALIF 是低层时间聚合，STJEWLM 是 4 层 LIF + trace 跨层投影——两者在 5M-aligned 预算（ $\pm 3.2\%$ ）下的架构空间尚未穷尽。

## 11 附录：复现性

### 11.1 代码仓库

- 主页：<https://github.com/SolarWindRider/STJEWLM>
- 训练 ckpt 与原始数据存放于 OBS：`obs://lixiang01/STJEWLM_NMI/`
- 完整实验报告（详细 per-cell table）：见 OBS 同名路径
- **5M-aligned 130/130 ckpt**：见 OBS `results/5m/` 和 `results/aggregate/generalist_5m_table.{md,json}`

### 11.2 5M-aligned 复现命令

所有 5M-aligned 训练可通过 `code/scripts/generalist_v0_7_5_5m` 下的脚本复现（详见 §11.2）。基础架构（13 模型  $\times$  5M 范围）：

- **STJEWLM 6 readouts (5.06M trainable)**：`n_layers=4 embed=192 d=3`

- **mlp\_baseline (5.00M)**: hidden=640 num\_layers=12
- **lewm\_transformer (4.97M)**: embed=288 num\_layers=3
- **alif\_timecell\_baseline (4.98M)**: d\_hid=186 num\_layers=2
- **gru\_baseline (5.13M)**: hidden=560 num\_layers=2
- **stacked\_lif\_trace (5.11M)**: d\_in=672 num\_layers=8
- **stacked\_lif\_free (5.05M)**: d\_in=640 num\_layers=8
- **lif\_transformer\_baseline (5.12M)**: d\_snn=288 d\_tx=288 num\_layers=3

**5M-aligned 关键超参**: 所有 5M-aligned 训练使用相同的基础架构 (AdamW,  $lr=3 \times 10^{-4}$ ,  $weight\_decay=10^{-3}$ , batch=32, 1 epoch), 但 `--hidden-dim`、`--mlp-hidden`、`--mlp-layers`、`--stacked-lif-layers`、`--stacked-lif-din` 这 5 个新 CLI flag 在 `build_model` 内部被自动设为各模型的 5M-aligned 默认值。训练时间每个 ckpt 约 ~5-30 min (Stacked-LIF 慢于其他, 因为 8 层 ALIF 循环)。

### 11.3 训练与评测超参

- **训练** (5M-aligned): AdamW,  $lr = 3 \times 10^{-4}$ ,  $weight\_decay = 10^{-3}$ ,  $\lambda_{sigreg} = 0.09$ ,  $\lambda_{goal} = 0.5$ , batch = 32, **1 epoch**, embed\_dim = 192, STJEW n\_layers = **4** (5.06M), n\_d = 3, history\_size = 1, goal\_offset = 25, max\_windows = 2000/env, pad\_obs\_to = 128, action\_dim = 56
- **评测**: CEM samples = 300, elites = 30, iters = 10; horizon = 5; 5 episodes / seed  $\times$  3 seeds; eval\_budget = 50; DMC 容差 = 0.1; 目标帧 = init 之后 goal\_offset=25 步的真实状态

### 11.4 可复现命令示例

```
# 5M state 训练 (fair STJEW, n_layers=4)
CUDA_VISIBLE_DEVICES=0 python -m code.train.train \
  --model stjewm --multi-env-spec configs/oodc_5m/oodc_F1.json \
  --pad-obs-to 128 --action-dim 56 --embed-dim 192 --image-size 0 \
  --n-layers 4 --epochs 1 --batch 32 --lr 3e-4 \
  --history-size 1 --goal-offset 25 --seed 0 \
  --readout-mode trace_only --out results/5m_5mpar/oodc_F1/stjewm_trace_only/seed_0

# 5M state 评测 (CEM 300x30x10, H=5, budget=50)
CUDA_VISIBLE_DEVICES=0 OUT_PARENT=results/5m_5mpar \
  bash code/scripts/generalist_v0_7_5_5m/eval_one.sh \
  stjewm_trace_only results/5m_5mpar/oodc_F1/stjewm_trace_only/seed_0/final.pt \
  configs/oodc_5m/oodc_F1.json 0
```

### 11.5 术语表 (glossary)

- **CEM**: Cross-Entropy Method, 基于采样的规划算法
- **ckpt**: checkpoint, 训练好的模型参数文件



- **div / resp /  $\rho$** : 三个抗坍缩诊断 (divergence / responsiveness / event-alignment)
- **DMC**: DeepMind Control Suite, 本文的主要 benchmark
- **FFN**: Feed-Forward Network, 前馈网络
- **G4 / G8 / G16**: 通才训练中同时训练 4/8/16 个环境的 ckpt
- **GRU**: Gated Recurrent Unit, 循环神经网络
- **held-out**: 训练集不包含、测试集包含的
- **LeWM**: LeWM paper (参考的先前工作)
- **membrane-forbidden protocol**: 膜电位禁止协议——规划器只能读 trace, 不能读膜电位
- **obs\_dim / action\_dim**: 观测维度 / 动作维度
- **OOD**: Out-Of-Distribution, 分布外
- **per-cell**: 单个 (ckpt, env) 对
- **ReadoutMode**: trace / spike / rate / no-trace / leak / membrane
- **resp**: responsiveness, 潜状态对观测的放大率
- **SNN**: Spiking Neural Network, 脉冲神经网络
- **split (脉冲)**: 神经元的 0/1 输出
- **STJEW**: Spiking Temporal Joint-Embedding World Model, 本文方法
- **trace**: 脉冲后的轨迹
- **train / eval / split / family / cell / held-out**: 见上下文