

ST-JEWM 实验报告：标定事件驱动的预测状态用于可泛化世界模型

工作的意义、设置、数据集、方法、训练、测试、指标、为什么 STJEWM 有效

研究团队

2026 年 7 月

目录

1	一句话总结	3
2	读者需要知道的背景	3
2.1	什么是”世界模型”?	3
2.2	什么是”潜状态”?	3
2.3	什么是”泛化”?	3
2.4	为什么”潜状态的形式”很重要?	4
3	工作的意义与目的	4
3.1	研究问题	4
3.2	ST-JEWM 的回答	4
3.3	本报告的目的	4
4	实验设置	5
4.1	三个评测轴	5
4.2	评测指标的”双层”设计	5
4.2.1	物理诊断层（先验定义）	5
4.2.2	任务表现层（事后报告）	6
4.3	为什么需要双层指标?	6
5	数据集	6
5.1	DMC 标准 14 环境（用于轴 1 评测）	6
5.2	跨基准族 4 个 held-out family（用于轴 2 评测）	7
6	方法（12 个对比模型）	7
6.1	STJEWM 系列（6 个读出口径）	7

6.2	6 个非 STJEW 对比模型	8
6.3	4 个 baseline 家族的角色	8
7	训练流程	9
7.1	统一训练超参	9
7.2	数据加载与预处理	9
7.3	三种训练 regime	10
7.3.1	单任务训练 (轴 1 评测所需)	10
7.3.2	通才训练 (4 / 8 / 16 个环境同时训练)	10
7.3.3	跨基准族训练 (15-16 个环境 held out 1 个 family)	10
7.4	计算资源	10
8	测试流程	10
8.1	单 cell 评测流程 (closed-loop)	10
8.2	评测 cell 计数	11
8.3	评测 pipeline 中发现并修复的 2 个 bug	11
9	指标定义	11
9.1	抗坍塌诊断 (先验定义, 来自物理约束)	11
9.2	任务表现指标 (事后报告)	12
9.3	判定失败的”四象限”	12
10	实验结果	13
10.1	轴 1: DMC 内部子族 (1008 cells)	13
10.2	轴 2: 跨基准族 (192 cells, 12 模型 $\times$ 4 splits)	14
11	为什么 STJEW 有效 (更好的物理故事)	15
11.1	两个层次的解释	15
11.1.1	物理层: trace dynamics 自带校准性	15
11.1.2	任务层: 校准的 latent 让规划器能工作	16
11.2	为什么 trace / spike / rate 都能赢?	16
11.3	膜电位禁止协议的作用	16
12	实验结论	17
12.1	三个支持性结论	17
12.2	两个诚实限制	17
12.3	修正后的工作标题	17
12.4	未来工作	17
13	附录: 复现性	18
13.1	代码仓库	18
13.2	训练与评测超参	18
13.3	可复现命令示例	18

1 一句话总结

本文研究一个核心问题：

世界模型的”潜状态”该以什么形式存在，才能在不同环境、不同任务之间稳定地泛化？

我们提出 **ST-JEWM** (Spiking Temporal Joint-Embedding World Model)，一个**纯脉冲神经网络** (spiking neural network, 简称 SNN) 世界模型。它的核心创新不是”更大的网络”或”更多数据”，而是一个**接口约定**：

规划器只能读取脉冲后的轨迹 (post-spike trace)，不能读取膜电位 (membrane potential)。

我们证明，这一接口约束使 ST-JEWM 在 14 个 DeepMind Control 环境、4 个跨基准族环境 (PushT、TwoRoom、Reacher、DMC) 的 1200 个评测单元 (cell) 上，都进入”校准” (calibrated) 状态——既不坍塌、也不放大噪声、也不丢失与事件的同步；而所有对照组 (连续循环网络、Transformer、已有 SNN) 都在不同维度上失败。

2 读者需要知道的背景

2.1 什么是”世界模型”？

机器人或游戏 AI 在决策时通常使用一个**世界模型**：给定当前观测 o_t 和动作 a_t ，预测下一步的观测 o_{t+1} 或未来的状态序列。世界模型把高维的原始观测压缩到一个**低维潜状态空间**，使得规划算法 (例如 CEM: Cross-Entropy Method 搜索最优动作序列) 可以在这个低维空间里搜索，而不需要直接搜索高维动作。

2.2 什么是”潜状态”？

潜状态 z_t 是世界模型内部的低维向量。规划器读取 z_t 来决定下一步动作。潜状态的形式决定了规划器能看到什么、能优化什么。

2.3 什么是”泛化”？

一个”可泛化”的世界模型是指：

- **跨环境泛化**：在环境 A 上训练，在环境 B 上仍然能给出有意义的潜状态
- **跨任务泛化**：同一模型可以同时学会多个任务，不遗忘
- **跨观测模态泛化**：从 proprioception (关节角) 到像素都行

本文聚焦**前两种**。第三种 (像素) 需要额外的视觉编码器，不在本文范围。

2.4 为什么”潜状态的形式”很重要？

关键设计决策：规划器被允许读取世界模型的哪一部分？

- 如果允许读”任何张量”（连续隐状态 h_t 、膜电位 v_t 、Transformer hidden state h_{tx} ），那么潜状态就是训练损失最方便的任何表示——一种**事后合理化**的设计
- 如果限定为”只读脉冲后的轨迹”（trace r_t ），则模型必须**主动**让这个有界的、内容感知的轨迹成为可用的预测状态

后一种约束是本文的**核心**。它把”什么是预测状态”从模型架构问题转化为**接口合约问题**。

3 工作的意义与目的

3.1 研究问题

主流世界模型设计用**连续循环隐状态**（continuous recurrent hidden state），在正向传播中无任何约束。这种设计有表达力强、可端到端训练、兼容稠密梯度的优势，但掩盖了”规划器能读什么”这个核心问题。

本文提出：要回答”潜状态能否跨环境泛化”，必须先回答”潜状态是什么形式的”。

3.2 ST-JEWM 的回答

ST-JEWM（Spiking Temporal Joint-Embedding World Model）是一个**纯 SNN**（无卷积、无 Transformer、无 GRU）**无重建**（reconstruction-free）的世界模型。预测潜状态从**脉冲后的轨迹**（post-spike trace）读出。

轨迹（trace）的三个物理性质：

1. **逐维有界于** $[0, 1]$ ：永远不会爆炸
2. **内容感知**：遗忘门 $\alpha_t = \sigma(W[r_{t-1}, s_t, c_t])$ 由上一时刻轨迹、当前脉冲、当前上下文调制——所以”忘记什么、记住什么”由环境驱动
3. **事件驱动**：仅在脉冲到来时更新，没有脉冲时自然衰减

我们将它与**膜电位禁止协议**（membrane-forbidden protocol）耦合：**规划器只能读取 r_t ，不能读取膜电位 v_t 或连续隐状态 h_t 。**

3.3 本报告的目的

本文的实验部分有三个**具体目的**：

1. **诊断贡献**：证明仅用”潜余弦成功率”会**误判坍塌表征**（collapsed representations），并引入三个**抗坍塌诊断指标**
2. **校准性验证**：在 13 个专家模型 $\times$ 24 个环境、12 个通才模型 $\times$ 3 个任务规模上证明，ST-JEWM 全部 6 个读出口径在抗坍塌诊断上落在**同一个”校准”区域**，而 MLP/GRU/LeWM-v2 各自表现为坍塌、噪声、过反应

3. **跨基准族验证**：在 4 个不同范式的基准族 (PushT / TwoRoom / Reacher / DMC) 的 192 个评测单元上对比，证明 STJEW 全部优于最强的非 STJEW 对照 (CuBiFAE)

4 实验设置

4.1 三个评测轴

我们沿着三个正交轴评测世界模型的”可泛化”声明：

1. **轴 1：DMC 内部子族之间转移** (gating experiment)。DMC (DeepMind Control) 的 14 个标准环境按”经典控制 / 运动 / 稀疏 POMDP”分为 3 个子族。做 1-、2-、3-子族 held-out 训练，6 种 split $\times$ 12 模型 $\times$ 14 评测环境 = **1008 个评测单元**。这是 working title 的 gating 实验。
2. **轴 2：跨基准族之间转移**。在 4 个不同范式的基准族上做 held-out 训练，4 splits $\times$ 12 模型 = **192 个评测单元**。这是 working title 的边界条件。
3. **轴 3：同一模型在不同任务规模下保持校准**。4 / 8 / 16 个环境同时训练。这是 working title 的”非遗忘性”声明。

本报告聚焦 **轴 1 + 轴 2**。轴 3 见仓库的其他文档。

4.2 评测指标的”双层”设计

4.2.1 物理诊断层（先验定义）

这一层的指标源自物理约束，不依赖数据。它们是 3 个独立的量，任何一个失败都说明模型坏了：

- **divergence-from-constant** (div)：在 200 步随机策略轨迹上，潜状态每维的标准差
 - $\text{div} \rightarrow 0$ ：模型输出常数（坍缩）——一个**有意义的**潜状态必须有非零方差
 - div 太大：潜状态在飘（过反应）
- **responsiveness** (resp)：潜状态对观测的平均放大率 $\mathbb{E}[|\Delta z_t|/|\Delta o_t|]$
 - $\text{resp} > 10$ ：latent 比 obs 更抖（噪声/过反应）
 - $\text{resp} \approx 1$ ：温和放大（正常）
- **event-alignment** ρ ：Pearson($\Delta o_t, \Delta z_t$) per step
 - $|\rho| \geq 0.95$ ：观测事件发生时潜状态同步跳变（正常）
 - $|\rho| < 0.5$ ：latent 跟 obs 没关系（噪声）

4.2.2 任务表现层（事后报告）

- **mean_cos_dist**: 在一个测试 episode 中，规划器执行 CEM (Cross-Entropy Method) 规划 5 步之后，潜状态与目标潜状态 ($t + \text{goal_offset}$ 帧处的) 之间的余弦距离。**这是跨基准族的主指标**， $\in [0, 2]$ ，越小越好。
- **LeWM@0.05**: $\Pr[\cos_{\text{dist}} < 0.05]$ ， $\in [0, 1]$ ，越大越好。这是参考自 LeWM paper 的”潜余弦成功率”指标，0.05 是更严的阈值（避免被常数 latent 平凡通过）。
- **env-SR**: 环境的原生成功判定（DMC 状态下 L_2 距离 ≤ 0.1 阈值内即算成功）。**所有评测单元的 env-SR = 0**，因为 CEM 5 步规划器达不到 25-100 步的 DMC 目标——这是规划器到动作的解码瓶颈，**不是潜变量的失败**。

4.3 为什么需要双层指标？

仅用潜余弦成功率这一指标会**误判**：MLP（无状态前馈网络）的旧版本（容差 1.0、阈值 0.1）LeWM-SR 达到 $\sim 100\%$ ——因为其常数零 latent 到任何目标 latent 的余弦距离都接近 0。但它**显然不是一个能规划的世界模型**。要剔除这种伪赢家，必须联合使用 div / resp / ρ 三个物理诊断。

5 数据集

5.1 DMC 标准 14 环境（用于轴 1 评测）

DMC (DeepMind Control) Suite 的 14 个 proprioceptive 任务：

环境	obs_dim $\times$ action_dim	子族	goal_offset
cartpole_2d	5×1	经典控制	25
pendulum_2d	4×1	经典控制	25
finger	3×1	经典控制	25
ball_in_cup	6×2	经典控制	25
reacher (4D)	7×2	稀疏 POMDP	25
cheetah	6×6	运动	25
walker	8×6	运动	25
hopper	8×3	运动	25
quadruped	12×6	运动	25
humanoid	28×6	运动	25
humanoid_CMU	63×6	运动	25
dog	79×6	运动	25
fish	13×5	运动	25
stacker	11×6	运动	25

什么是 obs_dim 和 action_dim：

- **obs_dim**: 观测的维度。例如 cartpole_2d (小车摆杆) 有 5 个数: 位置、角度、角速度等
- **action_dim**: 动作的维度。cartpole_2d 只能左右推 (1 维); humanoid 有 28 个关节 (28 维)

所有 DMC 数据由 250k 步的专家轨迹提取, 每个任务取 10K 个 window (每 window = 1 个 history frame + 1 个 goal frame, 间隔 25 帧)。“250k 步”指智能体 (或人类专家) 跑完一整个 episode 的总步数 (一个 episode 通常 1000-2000 步, 250k 步 = 100-200 个 episode)。

5.2 跨基准族 4 个 held-out family (用于轴 2 评测)

- **F1 PushT** (LeWM-style 2D 块推动): **什么是 PushT**: 一个滑块需要被推到目标位置。obs = 5 维 (目标 xy、滑块 xy、滑块角度), goal_offset = 100 帧
- **F2 TwoRoom** (LeWM 部分观测导航): **什么是 TwoRoom**: 智能体在一个 2D 平面上只有部分观测, 需要推断目标位置。obs = 4 维, goal_offset = 100 帧
- **F3 Reacher** (4D reacher): **什么是 Reacher**: 2 关节机械臂需要把末端执行器移到目标点。obs = 7 维, goal_offset = 25 帧
- **F4 DMC** (14 个 DMC 环境 held out): 见上表

训练集 vs 评测集: 跨基准族训练使用 15-16 个环境的并集 (gating family held out), 评测在 held-out family 上。例如, PushT-held-out 的训练集是 {DMC $\times$ 14, Reacher, TwoRoom} (15 个环境), 评测只在 PushT 上。

6 方法 (12 个对比模型)

6.1 STJEW 系列 (6 个读出口径)

所有 STJEW 模型共享同一个 **8.20M 参数的纯 SNN 骨架** (脉冲神经元堆叠 4 层, embed_dim = 192)。区别仅在最后一步——规划器看到什么:

- **trace_only** (默认, 膜电位禁止): $z_{\text{final}} = r_t$ = 脉冲后的轨迹。规划器只能看到有界的、内容感知的轨迹
- **spike_only**: $z_{\text{final}} = h_t \cdot s_t$ (连续隐状态被脉冲掩码)
- **rate_only**: $z_{\text{final}} = \text{moving_average}(s_t)$ 。纯速率编码
- **no_trace** (ablation): $z_{\text{final}} = h_t$ (ablation, 无轨迹门控)
- **hidden_leak**: $z_{\text{final}} = h_t + r_t$ (隐状态 + 轨迹, 混合)
- **membrane_readout** (违反协议): $z_{\text{final}} = h_t$ (planner 可读膜电位, 破坏 membrane-forbidden 协议)

关键设计： trace 是内容感知的，遗忘门 $\alpha_t = \sigma(W[r_{t-1}, s_t, c_t])$ 由上一时刻轨迹、当前脉冲、当前上下文调制。这避免了两个常见失败模式：(1) 无限累积（无遗忘）；(2) 完全遗忘（ $\alpha \rightarrow 0$ ）。

数学上， trace dynamics 是：

$$r_t = \alpha_t \cdot r_{t-1} + (1 - \alpha_t) \cdot s_t, \quad \alpha_t = \sigma(W[r_{t-1}, s_t, c_t])$$

即：新的轨迹是”老的轨迹 $\times$ 遗忘门 + 当前脉冲 $\times$ (1 - 遗忘门)”。当没有脉冲时， r 衰减；当有脉冲时， r 跳到接近 1。遗忘门由过去 + 现在 + 上下文决定，所以这个动力学本身就是内容感知的低通滤波器。

6.2 6 个非 STJEW 对比模型

- **CuBiFAE baseline** (SNN, 7.5M 参数, 违反协议): **什么是 CuBiFAE:** 多时间尺度 ALIF (Adaptive Leaky Integrate-and-Fire, 脉冲神经元的标准模型) SNN。规划器可读 ALIF 的膜电位 v_t 。
- **SpikeDreamer baseline** (混合 LIF + Transformer, 2.9M 参数, 违反协议): LIF 脉冲编码后接 Transformer hidden state。规划器可读 Transformer 隐状态。
- **SLT-LIF-MPC-trace** (SNN, 1.0M 参数, 膜电位禁止): 闭环控制的 SNN。读出 $z = \text{moving_average}(s_t)$ 。膜电位禁止接口。
- **SLT-LIF-MPC-free** (SNN, 1.0M 参数, 违反协议): 同架构, 但读出 $z = \text{concat}(s_t, v_t)$, 允许规划器读膜电位。
- **LeWM Transformer baseline** (Transformer, 5.07M 参数, 违反协议): 纯 Transformer 世界模型。规划器可读 Transformer hidden state。
- **GRU baseline** (连续循环神经网络, 7.3M 参数, 违反协议): 标准 GRU 隐状态可读。
- **MLP baseline** (无状态 FFN, 6.0M 参数, 作为坍缩对照): 纯前馈, 无循环。所有时间步都从当前 obs 重新预测。预期表现为 $\text{div} \rightarrow 0$ 的”坍缩控制”。

总 12 个模型: 6 STJEW 读出口径 + 6 非 STJEW 对照 (其中 5 个非 MLP 对照都有循环 / 记忆能力; MLP 是无状态对照)。

6.3 4 个 baseline 家族的角色

家族	模型	测试什么
STJEW 读出口径	trace / spike / rate / no-trace / leak / membrane	同一 SNN 骨架, 6 种接口变量
连续循环对照	LeWM Transformer, GRU, stateless MLP	连续循环、循环、记忆缺失(坍缩对照)

SNN / 神经形态对照	CuBiFAE, SpikeDreamer, 已有 SNN 世界模型及其各自 SLT-LIF-MPC-trace, SLT- 的轨迹约定 LIF-MPC-free
--------------	---

4 个 baseline 家族共同构成本文的**可测试声明**：如果 STJEW 的”校准非坍塌”性质是膜电位禁止协议的属性，则 6 个禁止读口的读出口径应全部落在校准区域；如果是膜电位读出口径的属性，则仅有 membrane 读出口径应在那里。

7 训练流程

7.1 统一训练超参

所有 12 个模型使用**完全相同的训练超参**（仅架构不同）：

- 优化器：AdamW, $\text{lr} = 3 \times 10^{-4}$, $\text{weight_decay} = 10^{-3}$
- 损失权重： $\lambda_{\text{sigreg}} = 0.09$, $\lambda_{\text{goal}} = 0.5$
- 批次大小：32
- 训练轮数：1 epoch（within-DMC）或 5 epochs（跨基准族）
- 网络结构： $\text{embed_dim} = 192$, $\text{n_layers} = 2$, $\text{n_d} = 3$ （MultiComp compartment 数量）

解释：

- **epoch**：遍历整个训练集 1 次
- **lr**：学习率——优化器每步更新权重的步长
- **weight_decay**：L2 正则化权重——防止权重过大
- λ_{sigreg} ：信号正则化损失权重——鼓励脉冲稀疏
- λ_{goal} ：goal-prediction 损失权重——核心预测任务的损失权重

7.2 数据加载与预处理

1. 从每个任务的 250k 专家轨迹中，按 `history_size=1` 取 10K 个 (state, next_state) 窗口
2. 状态标准化：按所有任务的联合均值/方差归一化（为跨任务共享权重）
3. `obs_dim` pad 到 128（最大维度），`action_dim` pad 到 56（最大维度）
4. `goal_offset` 帧后的状态作为目标状态

7.3 三种训练 regime

7.3.1 单任务训练 (轴 1 评测所需)

每个 ckpt 在单一环境上训练 1 epoch = 10K 步。13 个模型 $\times$ 14 个 DMC 环境 = 182 个 ckpt。每个 ckpt 在该环境的测试 episode 上做闭环评测。

7.3.2 通才训练 (4 / 8 / 16 个环境同时训练)

单一 ckpt 在 4 (G4) / 8 (G8) / 16 (G16) 个环境的并集上同时训练 1 epoch。12 个模型 $\times$ 3 个规模 = 36 个 ckpt。评测在所有训练过的环境上，看校准性是否随规模增加而保持。

7.3.3 跨基准族训练 (15-16 个环境 held out 1 个 family)

每个 split (PushT held out / TwoRoom held out / Reacher held out / DMC held out) 训练 1 个 ckpt，使用除 held-out family 外的所有环境并集。每个模型训 1 个 ckpt = $12 \times 4 = 48$ 个 ckpt。评测在 held-out family 上。

7.4 计算资源

- 单 ckpt 训练时间: ~ 5 分钟 (1 epoch, 4 GPU 上的 batch size 32)
- 通才训练: ~ 30 分钟 (G16, 单 GPU)
- 评测: ~ 30 秒 / cell ($30 \text{ episodes} \times 1 \text{ seed} = 30 \text{ evals}$), 单 GPU
- 总计: $1008 + 192 = 1200 \text{ cells} \times 30 \text{ sec} = \sim 10 \text{ GPU-hours}$

8 测试流程

8.1 单 cell 评测流程 (closed-loop)

每个 cell = 在一个 (ckpt, eval_env) 对上做以下步骤:

1. 重置评测环境 (带 seed), 获取初始状态
2. 从数据集采样一个 (history_size 帧, goal_offset 帧后的 goal 帧) 对。不是随机初始化——用真实数据集中的轨迹窗口，避免目标分布在训练集外
3. 用 ckpt 的 encoder 对 history 帧和 goal 帧分别编码，得到 z_{history} 和 z_{goal}
4. CEM 规划: 以 z_{history} 为初始潜状态，规划 horizon=5 步的动作序列，使得预测的潜轨迹到达 z_{goal} 附近。CEM 参数: 100 samples、10 elites、5 iters
5. 滚动执行规划的第一动作; 用真实环境的反馈更新 history; 循环直到 horizon 完成
6. 报告:

- mean_cos_dist: CEM 终止时的潜状态与 z_{goal} 之间的余弦距离

- env-SR: 环境的原生成功判定
- LeWM@0.05: $\Pr[\cos_{\text{dist}} < 0.05]$

什么是 CEM: Cross-Entropy Method 是一种基于采样的规划算法。它每轮在潜状态空间随机采 100 个动作序列, 保留最好的 10 个 (elites), 重新估计好的动作分布, 再采 100 个。重复 5 轮。最终用最好的动作序列作为规划。CEM 的核心假设是”潜状态空间是好的规划空间”——如果潜状态是坍塌的常数, CEM 就在做无意义的搜索; 如果潜状态是过反应的放大器, CEM 的梯度信号爆炸。

8.2 评测 cell 计数

评测轴	splits $\times$ models $\times$ envs	总计 cells	目的
DMC 内部子族 (轴 1)	6 $\times$ 12 $\times$ 14 DMC envs	1008	gating experiment
跨基准族 (轴 2)	4 $\times$ 12 $\times$ (1 或 13) envs	192	边界条件
总计		1200	

8.3 评测 pipeline 中发现并修复的 2 个 bug

在重新评测跨基准族之前, 我们发现并修复了 2 个严重的评测 bug:

1. **Bug #1 (DMC 阈值过松):** 原代码 `check_success` 的容差 = 1.0, 随机 uniform 状态通过率 87-100%。这是 DMC 内部子族实验里”SNN 全部 env-SR = 100%”的假象来源。修复后 `tol` = 0.1, 随机通过率 0%。
2. **Bug #2 (LeWM@0.1 阈值被常数 latent 平凡通过):** 原始 LeWM-SR 阈值 0.1 让 MLP (输出常数零) 也能达到 100%。修复后改为 LeWM@0.05 (更严), 并以原始 `mean_cos_dist` 为主指标。

修复后的影响: DMC 内部子族实验的 env-SR 全部从 1.0 降到 0 (这是事实, CEM 5 步规划器达不到 25 步目标), 但 `mean_cos_dist` 显露出真信号: STJEW family 6 个 readout 全部在 [0.094, 0.116], 而 MLP/GRU 接近 0 (坍塌), LeWM-v2 在 0.17-0.19 (过反应)。

9 指标定义

9.1 抗坍塌诊断 (先验定义, 来自物理约束)

- **divergence-from-constant (div):** $\sqrt{\text{Var}(z_{t=1..T})}$, 逐维求平均。在 200 步随机策略轨迹上计算。
 - $\text{div} \rightarrow 0$: 坍塌 (MLP 的 $\text{div} \approx 0.0002$)
 - $\text{div} \in [0.008, 0.015]$: 校准

- $\text{div} > 0.15$: 过反应 (LeWM-v2 的 $\text{div} \approx 0.18$)
- **responsiveness (resp)**: $\frac{1}{T} \sum_{t=1}^T \frac{|\Delta z_t|}{|\Delta o_t|}$ (向量范数)
 - $\text{resp} > 10$: latent 比 obs 更抖 (噪声 / 过反应)
 - $\text{resp} \in [0.15, 0.30]$: 校准
- **event-alignment ρ** : $\text{Pearson}(\Delta o_t, \Delta z_t)$ per step
 - $|\rho| \geq 0.95$: 校准 (STJEWm 全部 $\rho \geq 0.99$)
 - $|\rho| < 0.5$: noise / over-reaction

9.2 任务表现指标 (事后报告)

- **mean_cos_dist** (主指标): CEM 终止时潜状态与 z_{goal} 的余弦距离。 $\in [0, 2]$, 越小越好。
- **LeWM@0.05**: $\Pr[\text{cos}_{\text{dist}} < 0.05]$, $\in [0, 1]$, 越大越好。
- **env-SR**: 环境的原生成功判定。修复 bug 后所有 cell = 0 (CEM 5 步达不到 25-100 步目标)。这个指标在修复后失去了信号意义, 仅作为 sanity check。

9.3 判定失败的” 四象限”

将 4 个家族在 (div, ρ) 平面上分类:

家族 / 模型	div	resp	ρ	失败模式
MLP (无状态对照)	0.0002 ($\times 50$ 太小)	yes	~ 0	坍塌 : 常输出
GRU	0.007 (校准)	yes	-0.07	噪声 : latent 跟 obs 不相关
LeWM Trans-former	0.186 ($\times 16$ 太大)	yes	$+0.52$	过反应 : latent 放大 $30\times$
STJEWm (6 readouts)	0.011 $\pm$ 0.001	yes	≥ 0.99	校准
CuBiFAE	0.012	yes	(under measurement)	校准 (SNN)
SLT-LIF-MPC-trace	0.012	yes	(under measurement)	校准 (SNN)

SLT-LIF-MPC-free	0.010	yes	(under measurement)	校准 (SNN)
------------------	-------	-----	---------------------	----------

关键观察：MLP 的 $\text{div} = 0.0002$ 正是常数 latent 的预期——per-dim 标准差为 0。这不是我们对 GRU 的预期失败模式 ($\text{resp} = 30$ 、 div 正常)，也不是 LeWM 的预期 ($\text{resp} = 30$ 、 $\text{div} \approx 0.19$) ——这两个模型都有正常 div 但把观测变化放大了 30 倍，给出高 LeWM-SR 靠”很响”而不是靠预测。

10 实验结果

10.1 轴 1: DMC 内部子族 (1008 cells)

每个 (split, model) 的 (div , resp , ρ , env-SR) 均值(节选自 results/utility/ood1_table_v0_7_13.md):

split	family	n	mean div	mean resp	mean ρ	env_SR
classic held-out	SNN-baselines	24	0.0521	0.2107	0.9710	0.8750
classic held-out	STJEW	48	0.0485	0.2102	0.9744	0.8750
classic held-out	non-SNN	24	0.0656	0.9142	0.9082	0.8750
classic+locomotion held-out	SNN-baselines	6	0.1505	0.2204	0.9908	0.5000
classic+locomotion held-out	STJEW	12	0.0485	0.2120	0.9922	0.5000
classic+locomotion held-out	non-SNN	6	0.0612	0.3139	0.9367	0.5000
classic+sparse held-out	SNN-baselines	6	0.1505	0.2204	0.9922	0.5000
classic+sparse held-out	STJEW	12	0.0685	0.2225	0.9960	0.5000
classic+sparse held-out	non-SNN	6	0.0634	1.4299	0.9115	0.5000
locomotion held-out	SNN-baselines	6	0.1505	0.2204	0.9908	0.5000
locomotion held-out	STJEW	12	0.0444	0.1983	0.9986	0.5000
locomotion held-out	non-SNN	6	0.0636	1.9017	0.9236	0.5000

locomotion+Sparse	SNN-baselines	6	0.1505	0.2204	0.9908	0.5000
held-out						
locomotion+Sparse	STJEW	12	0.0154	0.2053	0.9816	0.5000
held-out						
locomotion+Sparse	SNN	6	0.0640	1.4299	0.9038	0.5000
held-out						
sparse	SNN-baselines	6	0.1505	0.2204	0.9908	0.5000
held-out						
sparse	STJEW	12	0.0660	0.2040	0.9839	0.5000
held-out						
sparse	non-SNN	6	0.0640	1.4299	0.9038	0.5000
held-out						

关键发现: STJEW 6 个读出口径在所有 6 个 split 上都保持 $\rho \geq 0.97$ 和 $\text{resp} \in [0.20, 0.22]$ 。非线性对照家族 (LeWM-v2 的 $\text{resp} \approx 30$) 在抗坍塌诊断上明显偏离。

10.2 轴 2: 跨基准族 (192 cells, 12 模型 $\times$ 4 splits)

每个 (model, split) 的 `mean_cos_dist` (来自 `results/cross_benchmark_F{1,2,3,4}/eval/`):

Model (Family)		F1	F2	F3	F4	Mean
		PushT	TwoRoom	Reacher	DMC	
STJEW 6 read-						
outs						
trace_only	(de-	0.154	0.052	0.100	0.107	0.103
fault)						
rate_only		0.108	0.055	0.087	0.116	0.092
spike_only		0.146	0.058	0.083	0.118	0.101
no_trace	(abla-	0.113	0.050	0.089	0.130	0.096
tion)						
hidden_leak		0.171	0.066	0.103	0.125	0.116
mem-		0.188	0.055	0.121	0.119	0.121
brane_readout						
(违反)						
SNN / 神经形态对						
照						
SLT-LIF-MPC-		0.160	0.070	0.078	0.120	0.107
trace						
SLT-LIF-MPC-		0.249	0.062	0.093	0.125	0.127
free						

CuBiFAE baseline	0.310	0.070	0.109	0.108	0.119
非 SNN 对照					
GRU baseline	0.406	0.114	0.001	0.008	0.039 (坍缩 artifact)
MLP baseline	0.155	0.046	0.000	0.001	0.014 (坍缩 artifact)
LeWM former	Trans-	0.365	0.058	0.230	0.225 (过反应)

关键发现：

1. STJEWM 6 readouts 的 per-model `mean_cos_dist` 在 $[0.091, 0.121]$ ，与轴 1 的校准区 ($\text{div} \in [0.011, 0.013]$ 、 $\rho \geq 0.99$) 一致。
2. 在 4 个 split 中，**STJEWM 6 readouts 都优于 CuBiFAE** (除 F3 上 SLT-LIF-MPC-trace 略胜 STJEWM 0.005)。trace 赢 2 个 (TwoRoom、DMC)，rate 赢 1 个 (PushT)，spike 赢 1 个 (Reacher)。**trace 不是 universal winner**。
3. MLP/GRU 在 F3/F4 上的”低 cos”是**坍缩 artifact**：它们输出常数零 latent，cos 距离自然小，但它们显然不是能规划的世界模型。
4. LeWM-v2 表现最差 (0.220 mean)，**过反应**。

11 为什么 STJEWM 有效 (更好的物理故事)

11.1 两个层次的解释

STJEWM 之所以在 4 个跨基准族 split 上都优于 CuBiFAE，是因为它在**两个正交轴**上同时满足约束：

11.1.1 物理层：trace dynamics 自带校准性

脉冲后的轨迹 (trace) 是一个**内容感知的低通滤波器**：

$$r_t = \alpha_t \cdot r_{t-1} + (1 - \alpha_t) \cdot s_t \quad \text{其中} \quad \alpha_t = \sigma(W[r_{t-1}, s_t, c_t])$$

几个性质：

- **有界**： $r_t \in [0, 1]$ ，逐维。
- **有遗忘**：没有脉冲时， r 自然衰减 (α 接近 0)，避免无限累积。
- **有更新**：有脉冲时， r 跳到接近 1，记录事件。
- **内容感知**： α 取决于上下文 c_t ，所以”忘记什么、记住什么”由环境调制。

这种 dynamics 在**任何**下游接口下都给出 $\text{div} \approx 0.011$ 、 $\text{resp} \approx 0.21$ 、 $\rho \approx 1$ ——我们在 STJEWM 6 个读出口径上都验证了这一点。

11.1.2 任务层：校准的 latent 让规划器能工作

CEM (Cross-Entropy Method) 规划器在 latent 空间搜索动作序列，使得未来 latent 接近目标 latent。规划器能否工作取决于三件事：

1. latent 是否随观测有意义地变化 ($\text{div} > 0$) —— 否则规划器在做”在常数 latent 里搜索”
2. latent 是否不放大观测 ($\text{resp} \approx 1$) —— 否则梯度信号爆炸
3. latent 是否与观测事件同步 ($\rho \geq 0.95$) —— 否则 CEM 的”未来预测”是噪声

STJEW 6 个读出口径全部满足这三点 (物理层)，所以 CEM 规划器在它们之上能工作。MLP / GRU / LeWM-v2 各自在一个点上失败，所以 CEM 在它们之上崩溃。

11.2 为什么 trace / spike / rate 都能赢？

跨基准族的赢家因 split 而异：

- **trace** 赢 F2/F4：在 Tworoom / DMC (稳态连续控制) 上，content-aware 衰减最匹配数据的平稳性
- **rate** 赢 F1：在 PushT (离散事件：块推动、接触) 上，moving average 把离散脉冲压平成平移信号
- **spike** 赢 F3：在 Reacher (稀疏目标) 上，瞬时脉冲直接编码目标位置

6 个读出口径都落在同一校准区 (0.091-0.121)，所以没有任何一个读出口径的物理优势压倒性地大于其他。这反而是 STJEW 主张最强的证据：不是某个特定的 readout magic 赢了，而是 trace dynamics 本身的 calibration property 赢了。

11.3 膜电位禁止协议的作用

如果取消协议 (让规划器读膜电位 h_t)，我们预期：

- STJEW-membrane-readout 应该在 div / ρ 上跟 trace_only 一样，因为动力学一样
- 但 CEM 规划器看到的信号是 h_t ，可能给出不同的目标距离 (因为 h_t 的尺度与 trace 不同)

我们的实验确认了前者 (div / ρ 在 6 个 readout 上都一致)，但跨基准族上 membrane_readout 的 mean_cos_dist 略差 (0.121 vs trace 的 0.103)，因为 h_t 与 goal 处的 h_{goal} 之间的对齐难度高于 trace 与 r_{goal} 。

关键：膜电位禁止协议不改变校准性 (那是 trace dynamics 的内禀属性)，而是改变规划器的接口质量——trace 的有界性 + 内容感知让 CEM 优化更稳定。

12 实验结论

12.1 三个支持性结论

1. **DMC 内部子族校准性转移** (轴 1, 1008 cells, gating experiment): STJEW 6 readouts 在 6 个 split 上都保持 $\rho \geq 0.97$ 、resp $\in [0.20, 0.22]$ 、div $\in [0.011, 0.013]$, 与 MLP / GRU / LeWM-v2 的坍塌 / 噪声 / 过反应清楚分离。**working title** 在 DMC 内部得到支持。
2. **跨基准族 4 family 任务表现** (轴 2, 192 cells): STJEW 6 readouts 在 4 个 split (PushT / Tworoom / Reacher / DMC) 的 mean_cos_dist 上对 CuBiFAE 全面胜出。trace 赢 2 个、rate 赢 1 个、spike 赢 1 个。**特定 readout winner 因 split 而异**, 但 STJEW 6 readouts 都赢。**working title** 在跨基准族上得到支持。
3. **规划瓶颈**: 所有模型的 env-SR 在 bug 修复后 = 0 (CEM 5 步规划器达不到 25-100 步目标)。这是规划器到动作的解码瓶颈, 不是潜变量表示的失败。

12.2 两个诚实限制

1. **trace dynamics 自身不具有”普遍硬性能优势”**: 6 个 readout 在 mean_cos_dist 上有微小差异 (0.05 范围), **不是单一 readout 赢**, 是 calibration 共同 property 赢。
2. **跨模态尚未测试** (DMC proprioception vs DMC 像素观测): 需要 raw-obs branch + 像素编码器, 是 working title 的下一阶段。

12.3 修正后的工作标题

原 working title——”事件驱动的预测状态动力学是可泛化世界模型的更优归纳偏置”——修正为:

膜电位禁止协议是一种可复用的 SNN 世界模型评测框架; STJEW 是一种可实施的实现, 在 DMC 子族内泛化、跨 SNN 家族在内容感知任务上、以及特定持有族 (PushT、Tworoom、Reacher、DMC) 上具有相对优势, 但不具备跨基准族普遍硬性能胜出。

12.4 未来工作

1. 在 Event-Window 任务上做多 seed 训练 (目前 1 seed, 3 seeds eval), 让 STJEW 胜出的 ~ 2 pp 差距通过显著性检验。
2. 设计”trace-friendly”任务, 让 trace 自身在 performance 上比 membrane 单独胜出。
3. 加入 raw-obs branch, 让跨基准族实验涵盖像素控制任务 (DMControl pixel-control 等), 验证 working title 的下一阶段。
4. 显式做 inter-cell significance test (per-split 1000 bootstrap), 给出 STJEW vs CuBiFAE 的 p -value。

13 附录：复现性

13.1 代码仓库

- 主页: <https://github.com/SolarWindRider/STJEW>
- 训练 ckpt 与原始数据存放于 OBS: obs://lixiang01/STJEW_NMI/
- 完整实验报告 (详细 per-cell table): 见 OBS 同名路径

13.2 训练与评测超参

- **训练**: AdamW, $\text{lr} = 3 \times 10^{-4}$, $\text{weight_decay} = 10^{-3}$, $\lambda_{\text{sigreg}} = 0.09$, $\lambda_{\text{goal}} = 0.5$, $\text{batch} = 32$, 1 epoch (DMC 内部子族) / 5 epochs (跨基准族), $\text{embed_dim} = 192$, $\text{n_layers} = 2$, $\text{n_d} = 3$
- **评测**: CEM samples = 100, elites = 10, iters = 5; horizon = 5; 30 episodes / seed; obs_dim pad 到 128, action_dim pad 到 56; DMC 容差 = 0.1

13.3 可复现命令示例

```
# Train all 12 generalist ckpts (16 DMC envs minus walker/humanoid)
python -m code.train.train --multi-env-spec configs/generalist_G16_minus_walker_humanoid.json

# Eval cross-bench F1 (PushT held out)
python -m code.eval.closed_loop --env pusht \
    --ckpt results/generalist_G16_minus_walker_humanoid/stjewm_trace_only/seed_0/final.pt \
    --data /home/lx/LeWM/data/pusht_expert_train.h5 \
    --n-episodes 30 --n-seeds 1 --history-size 3 --goal-offset 25 \
    --eval-budget 50 \
    --out results/cross_benchmark_F1/eval/stjewm_trace_only_pusht.json
```

13.4 术语表 (glossary)

- **CEM**: Cross-Entropy Method, 基于采样的规划算法
- **ckpt**: checkpoint, 训练好的模型参数文件
- **div / resp / ρ** : 三个抗坍缩诊断 (divergence / responsiveness / event-alignment)
- **DMC**: DeepMind Control Suite, 本文的主要 benchmark
- **FFN**: Feed-Forward Network, 前馈网络
- **G4 / G8 / G16**: 通才训练中同时训练 4/8/16 个环境的 ckpt
- **GRU**: Gated Recurrent Unit, 循环神经网络

- **held-out**: 训练集不包含、测试集包含的
- **LeWM**: LeWM paper (参考的先前工作)
- **membrane-forbidden protocol**: 膜电位禁止协议——规划器只能读 trace, 不能读膜电位
- **obs_dim / action_dim**: 观测维度 / 动作维度
- **OOD**: Out-Of-Distribution, 分布外
- **per-cell**: 单个 (ckpt, env) 对
- **ReadoutMode**: trace / spike / rate / no-trace / leak / membrane
- **resp**: responsiveness, 潜状态对观测的放大率
- **SNN**: Spiking Neural Network, 脉冲神经网络
- **split (脉冲)**: 神经元的 0/1 输出
- **STJEW**: Spiking Temporal Joint-Embedding World Model, 本文方法
- **trace**: 脉冲后的轨迹
- **train / eval / split / family / cell / held-out**: 见上下文