

ST-JEWM 实验报告：标定事件驱动的预测状态用于可泛化世界模型

v0.7.13 完整版（含 12 模型 $\times$ 4 跨基准族 split = 192 cells + 1008 OOD cells）

工作的意义、设置、数据集、方法、训练、测试、指标、为什么 STJEWM 有效

研究团队

2026-07-21

目录

1 工作的意义与目的	3
1.1 研究问题	3
1.2 ST-JEWM 的回答	3
1.3 工作的目的	3
2 实验设置	4
2.1 三个评测轴（axis of evaluation）	4
2.2 评测 metric 的双层定义	4
2.2.1 物理诊断层（v0.7.10b prior）	4
2.2.2 任务表现层（v0.7.13 引入）	5
2.3 为什么需要三轴 + 双层诊断？	5
3 数据集	5
3.1 DMC 标准 20 环境（用于轴 1 评测）	5
3.2 Cross-bench 4 个 held-out family（用于轴 2 评测）	6
3.3 压力测试（stress）4 环境	6
4 方法	6
4.1 STJEWM 系列（6 个读出口径）	6
4.2 非 STJEWM 对比方法（6 个）	7
4.3 4 个 baseline 家族的角色	7
5 训练流程	7
5.1 统一训练超参	7
5.2 数据加载与预处理	8

5.3	三种训练 regime	8
5.3.1	v0.7.10b 单任务训练	8
5.3.2	v0.7.5 通才训练 (4 / 8 / 16 个环境同时训练)	8
5.3.3	v0.7.13 跨基准族训练 (15-16 个环境 held out 1 个 family)	8
5.4	计算资源	8
6	测试流程	8
6.1	单 cell 评测流程 (closed-loop)	8
6.2	跨基准族评测协议 (v0.7.13 修复)	9
6.3	评测 cell 计数	9
7	指标定义	10
7.1	抗坍缩诊断 (v0.7.10b, 先验定义)	10
7.2	任务表现指标 (v0.7.13 引入)	10
7.3	判定失败的”四象限”	10
8	实验结果	11
8.1	v0.7.10b Within-DMC: 1008 cells (轴 1)	11
8.2	v0.7.13 Cross-bench: 192 cells (轴 2, 12 模型 $\times$ 4 splits)	12
9	为什么 STJEW 有效 (更好的物理故事)	13
9.1	两个层次的解释	13
9.1.1	物理层: trace dynamics 自带校准性	13
9.1.2	任务层: 校准的 latent 让规划器能工作	13
9.2	为什么 trace / spike / rate 都能赢?	14
9.3	膜电位禁止协议的作用	14
10	实验结论	14
10.1	三个支持性结论	14
10.2	两个诚实限制	15
10.3	修正后的工作标题	15
10.4	未来工作	15
11	附录: 复现性	15
11.1	代码仓库	15
11.2	关键 commit 历史	15
11.3	训练与评测超参	16
11.4	可复现命令	16

1 工作的意义与目的

1.1 研究问题

潜变量世界模型 (latent world model) 通过压缩观测轨迹到一个低维状态空间, 支撑想象、规划与决策。现有评估几乎完全集中在分布内 (in-distribution) 的预测精度上, 但所学潜状态是否能跨环境泛化仍不清楚。本文作者提出, 更关键的问题不是”哪个世界模型预测得更准”, 而是”什么形式的潜状态是可学习、可泛化、对规划友好的预测状态”。

世界模型的设计主流——连续循环隐状态 (continuous recurrent hidden state), 在正向传播中无任何约束——具有表达力强、可端到端训练、兼容稠密梯度的优势。但这种表达力掩盖了一个接口问题 (interface question), 而这一接口问题在领域内很少被显式提出:

当规划器 (planner) 选择下一个动作时, 它被允许读取模型的哪一部分?

如果答案是”网络暴露出的任何张量”, 则预测状态就是训练损失最方便的任何表示——一种事后合理化 (post-hoc rationalization) 的设计。

1.2 ST-JEWM 的回答

我们提出 **ST-JEWM** (Spiking Temporal Joint-Embedding World Model), 一个纯 **SNN** (spiking neural network) **无重建** (reconstruction-free) 世界模型, 其预测潜状态从脉冲后的轨迹 (post-spike trace) 读出, 而不是从连续循环隐状态读出。轨迹 (trace) 特性:

- 逐维有界于 $[0, 1]$
- **内容感知** (content-aware): 遗忘门 $\alpha_t = \sigma(W[r_{t-1}, s_t, c_t])$, 由上一时刻轨迹、当前脉冲、当前上下文调制
- **事件驱动** (event-driven): 仅在脉冲到来时更新

我们将其与 **膜电位禁止协议** (membrane-forbidden protocol) 耦合: **规划器被禁止读取连续膜电位**, 只能读取脉冲后的轨迹。这一约束是 ST-JEWM 的核心——它将”什么是预测状态”这一问题从模型架构问题转换为**接口合约问题**。

1.3 工作的目的

本文的实验部分有三个具体目的:

1. **诊断贡献**: 证明仅用潜余弦成功率 (latent cosine success) 这一指标会**误判坍塌表征** (collapsed representations), 并引入三个**抗坍塌诊断**指标: *divergence-from-constant* (对常量的散度)、*responsiveness* (响应度)、*event-alignment* (事件对齐度)。
2. **校准性**: 在 13 个专家模型 $\times$ 24 个环境、12 个通才模型 $\times$ 3 个任务规模 (G4 / G8 / G16) 上证明, ST-JEWM 全部 6 个读出口径在抗坍塌诊断上落在**同一个”校准”区域** ($\text{div} \approx 0.011$ 、 $\text{resp} \approx 0.21$ 、 $\rho \geq 0.99$), 而 MLP / GRU / LeWM-v2 都偏离该区域, 分别表现为坍塌、噪声、过反应。

3. **跨基准族泛化**: 在 v0.7.13 修复 2 个评测 bug 后, 将 STJEW 6 个读出口径与 6 个非 STJEW 对比方法在 4 个跨基准族 split (共 192 cells) 上做对比, 证明 STJEW 在 `mean_cos_dist` 上对所有 4 个 split 都优于 CuBiFAE 对照。

关键发现: 本文的 working title——”事件驱动的预测状态动力学是可泛化世界模型的更优归纳偏置”——在 v0.7.10b 的 within-DMC 子族内得到支持 (1008 cells, $\rho \geq 0.99$ in all splits), 并在 v0.7.13 的 cross-bench 4 个 split 上以 `mean_cos_dist` 形式得到交叉验证 (192 cells, STJEW 在 4/4 splits 上优于 CuBiFAE)。

2 实验设置

2.1 三个评测轴 (axis of evaluation)

我们沿着三个正交轴评测世界模型的”可泛化”声明:

1. **Within-DMC sub-family transfer** (v0.7.10b, gating experiment): 将 DMC 的 14 个标准环境按”经典控制 / 运动 / 稀疏 POMDP”分为 3 个子族 (F1/F2/F3), 做 1-、2-、3-子族 held-out 训练, 6 种 split $\times$ 12 模型 $\times$ 13-14 评测环境 = **1008 cells**。这是 working title 的 gating 实验。
2. **Cross-benchmark family transfer** (v0.7.13): 在 4 个不同范式的基准族 (PushT / TwoRoom / Reacher / DMC) 上做 held-out 训练, 4 splits $\times$ 12 模型 = **48 cells (3-model) $\rightarrow$ 192 cells (12-model)**。这是 working title 的边界条件。
3. **Cross-task-scale** (v0.7.5 generalist): 同一模型在 4 / 8 / 16 个环境上同时训练, 测试 1 个 ckpt 是否能保持校准。这是 working title 的”非遗忘性”声明。

本文实验报告聚焦 **轴 1 + 轴 2** (v0.7.10b + v0.7.13)。轴 3 见 `results/aggregate/generalist_master_tab`

2.2 评测 metric 的双层定义

2.2.1 物理诊断层 (v0.7.10b prior)

这一层的 metric 是先验定义的, 源自物理约束而非数据:

- **divergence-from-constant** (div): 在 200 步随机策略轨迹上, 潜状态每维的标准差。
 - $\text{div} \rightarrow 0$: 常输出 (collapse) ——一个**有意义的**潜状态必须有非零的 per-dim 方差
- **responsiveness** (resp): $E[|\Delta_{\text{latent}}|/|\Delta_{\text{obs}}|]$, 潜状态对观测的放大率。
 - $\text{resp} \rightarrow \infty$ (或 > 10): latent 比 obs 更抖 (noise / over-reaction)
 - **好的 latent 应该是 obs 的温和放大** ($\approx 1\times$), 不是 $30\times$ 放大
- **event-alignment**: $\text{Pearson}(\Delta_{\text{obs}}, \Delta_{\text{latent}})$ 。latent 跳变与观测事件的相关性。
 - $|\rho| \geq 0.95$: latent 在 obs 事件发生时同步跳变
 - $\rho \approx 0$: latent 跟 obs 不相关 (noise)

2.2.2 任务表现层 (v0.7.13 引入)

- **mean_cos_dist**: 在一个测试 episode 中, 规划器执行 CEM (Cross-Entropy Method) 规划 5 步之后, 潜状态与目标潜状态 ($t + \text{goal_offset}$ 帧处的) 之间的余弦距离。**这是 cross-bench 的主指标。**
- **LeWM@0.05**: $\Pr[\cos_dist < 0.05]$ (以 LeWM paper 的 0.1 阈值为参照, 更严的 0.05 阈值用于避免被常数 latent 平凡通过)。
- **env-SR**: 环境的原生成功判定 (DMC 状态下 L_2 距离 ≤ 0.1 阈值内即算成功)。**注意: v0.7.13 修复了 DMC 阈值 bug ($1.0 \rightarrow 0.1$), 修复后所有 cell 的 env-SR = 0, 因为 CEM 5 步规划器达不到 25-100 步的 DMC 目标。**

2.3 为什么需要三轴 + 双层诊断?

仅用 LeWM-SR 这一指标会**误判**: MLP 在 v0.7.10b 的 LeWM@0.1 上达到 $\sim 100\%$ (因为其常数零 latent 到任何目标 latent 的余弦距离都接近 0), 但它**显然不是一个能规划的世界模型**。要剔除这种伪赢家, 必须联合使用 div / resp / 三个物理诊断。

3 数据集

3.1 DMC 标准 20 环境 (用于轴 1 评测)

DMC (DeepMind Control) Suite 的 14 个标准 proprioceptive 任务, 加上 6 个补充任务:

环境	obs_dim $\times$ action_dim	子族	goal_offset
cartpole_2d	5×1	经典控制 (F1)	25
pendulum_2d	4×1	经典控制 (F1)	25
finger	3×1	经典控制 (F1)	25
ball_in_cup	6×2	经典控制 (F1)	25
cheetah	6×6	运动 (F2)	25
walker	8×6	运动 (F2)	25
hopper	8×3	运动 (F2)	25
quadruped	12×6	运动 (F2)	25
humanoid	28×6	运动 (F2)	25
humanoid_CMU	63×6	运动 (F2)	25
dog	79×6	运动 (F2)	25
fish	13×5	运动 (F2)	25
stacker	11×6	运动 (F2)	25
reacher (4D)	7×2	稀疏 POMDP (F3)	25

所有 DMC 数据由 250k 步的专家轨迹提取, 每个任务取 10K 个 window (每 window = 1 个 history frame + 1 个 goal frame, 间隔 25 帧)。

3.2 Cross-bench 4 个 held-out family (用于轴 2 评测)

- **F1 PushT** (LeWM-style 2D 块推动): obs = 5 维 (target_xy, block_xy, block_angle), goal_offset = 100 帧
- **F2 TwoRoom** (LeWM 部分观测导航): obs = 4 维 (agent_x, agent_y, goal_x, goal_y), goal_offset = 100 帧
- **F3 Reacher** (4D reacher): obs = 7 维, goal_offset = 25 帧
- **F4 DMC** (14 个 DMC 环境 held out): 见上表

训练集 vs 评测集: cross-bench 训练使用 15-16 个环境的并集 (gating family held out), 评测在 held-out family 上。例如, F1 的训练集是 {DMC $\times$ 14, Reacher, TwoRoom} (15 个环境), 评测只在 PushT 上。

3.3 压力测试 (stress) 4 环境

Flickering / vel-hidden / 像素扰动 / 长视野版本, 用于测试校准性在不同观测扰动下的鲁棒性。详见 results/aggregate/MASTER_TABLE.md §3-§4。

4 方法

4.1 STJEWL 系列 (6 个读出口径)

所有 STJEWL 模型共享同一个 **8.20M 参数的纯 SNN 骨架** (MultiCompStack 4 层, embed_dim = 192), 区别仅在**读出口径** (readout mode):

- **trace_only** (默认, 膜电位禁止): $z_{\text{final}} = r_t = \text{trace}(\text{spike})$ 。规划器只能看到有界的、内容感知的轨迹。
- **spike_only**: $z_{\text{final}} = h_t \cdot s_t$ (连续隐状态被脉冲掩码)
- **rate_only**: $z_{\text{final}} = \text{moving_average}(s_t)$ 。纯速率编码。
- **no_trace**: $z_{\text{final}} = h_t$ (ablation, 无轨迹门控)
- **hidden_leak**: $z_{\text{final}} = h_t + r_t$ (隐状态 + 轨迹, 混合)
- **membrane_readout** (违反协议): $z_{\text{final}} = h_t$ (planner 可读膜电位, 破坏 membrane-forbidden 协议)

关键设计: trace 是内容感知的, 遗忘门 $\alpha_t = \sigma(W[r_{t-1}, s_t, c_t])$ 由上一时刻轨迹、当前脉冲、当前上下文调制。这避免了两个常见失败模式: (1) 无限累积 (无遗忘); (2) 完全遗忘 ($\alpha \rightarrow 0$)。

4.2 非 STJEW 对比方法 (6 个)

- **CuBiFAE baseline** (SNN, 7.5M 参数, 违反协议): 多时间尺度 ALIF (Adaptive Leaky Integrate-and-Fire) SNN。规划器可读 ALIF 的膜电位 v_t 。
- **SpikeDreamer baseline** (混合 LIF + Transformer, 2.9M 参数, 违反协议): LIF 脉冲编码后接 Transformer hidden state。规划器可读 Transformer 隐状态。
- **SLT-LIF-MPC-trace** (SNN, 1.0M 参数, 膜电位禁止): 闭环控制的 SNN。读出 $z = \text{moving_average}(s_t)$ 。膜电位禁止接口。
- **SLT-LIF-MPC-free** (SNN, 1.0M 参数, 违反协议): 同架构, 但读出 $z = \text{concat}(s_t, v_t)$, 允许规划器读膜电位。
- **LeWM Transformer baseline v2** (Transformer, 5.07M 参数, 违反协议): 纯 Transformer 世界模型。规划器可读 Transformer hidden state。
- **GRU baseline** (连续循环神经网络, 7.3M 参数, 违反协议): 标准 GRU 隐状态可读。
- **MLP baseline** (无状态 FFN, 6.0M 参数, 作为坍缩对照): 纯前馈, 无循环。所有时间步都从当前 obs 重新预测。预期表现为 $\text{div} \rightarrow 0$ 的”坍缩控制”。

总 12 个模型: 6 STJEW 读出口径 + 6 非 STJEW 对照。

4.3 4 个 baseline 家族的角色

| 家族 | 模型 | 测试内容 | |—|—|—| | **STJEW 读出口径** | trace, spike, rate, no-trace, leak, membrane | 同一 SNN 骨架, 6 种接口变量 | | **连续循环对照** | LeWM Transformer, GRU, stateless MLP | 连续循环、循环、记忆缺失 (坍缩控制) | | **SNN / 神经形态对照** | CuBiFAE, SpikeDreamer, SLT-LIF-MPC-trace, SLT-LIFMPC-free | 已有 SNN 世界模型及其各自的轨迹约定 |

4 个 baseline 家族共同构成本文的**可测试声明**: 如果 STJEW 的”校准非坍缩”性质是膜电位禁止协议的属性, 则 6 个禁止读口的读出口径应全部落在校准区域; 如果是膜电位读出口径的属性, 则仅有 membrane 读出口径应在那里。

5 训练流程

5.1 统一训练超参

所有 12 个模型使用**完全相同的训练超参** (仅架构不同):

- 优化器: AdamW, $\text{lr} = 3 \times 10^{-4}$, $\text{weight_decay} = 10^{-3}$
- 损失权重: $\lambda_{\text{sigreg}} = 0.09$, $\lambda_{\text{goal}} = 0.5$
- 批次大小: 32
- 训练轮数: 1 epoch (v0.7.10b OOD) 或 5 epochs (v0.7.13 cross-bench)

- 网络结构: $\text{embed_dim} = 192$, $\text{n_layers} = 2$, $\text{n_d} = 3$ (MultiComp compartment 数量)

5.2 数据加载与预处理

1. 从每个任务的 250k 专家轨迹中, 按 $\text{history_size}=1$ 取 10K 个 (state, next_state) 窗口
2. 状态标准化: 按所有任务的联合均值/方差归一化 (为跨任务共享权重)
3. obs_dim pad 到 128 (最大维度), action_dim pad 到 56 (最大维度)
4. goal_offset 帧后的状态作为目标状态

5.3 三种训练 regime

5.3.1 v0.7.10b 单任务训练

每个 ckpt 在单一环境上训练 1 epoch = 10K 步。13 个模型 $\times$ 14 个 DMC 环境 = 182 个 ckpt。每个 ckpt 在该环境的测试 episode 上做闭环评测。

5.3.2 v0.7.5 通才训练 (4 / 8 / 16 个环境同时训练)

单一 ckpt 在 4 (G4) / 8 (G8) / 16 (G16) 个环境的并集上同时训练 1 epoch。12 个模型 $\times$ 3 个规模 = 36 个 ckpt。评测在所有训练过的环境上, 看校准性是否随规模增加而保持。

5.3.3 v0.7.13 跨基准族训练 (15-16 个环境 held out 1 个 family)

每个 split (PushT held out / TwoRoom held out / Reacher held out / DMC held out) 训练 1 个 ckpt, 使用除 held-out family 外的所有环境并集。每个模型训 1 个 ckpt = $12 \times 4 = 48$ 个 ckpt。评测在 held-out family 上。

5.4 计算资源

- 单 ckpt 训练时间: ~ 5 分钟 (1 epoch, 4 GPU 上的 batch size 32)
- 通才训练: ~ 30 分钟 (G16, 单 GPU)
- 评测: ~ 30 秒 / cell ($30 \text{ episodes} \times 1 \text{ seed} = 30 \text{ evals}$), 单 GPU
- 总计: $1008 + 192 = 1200 \text{ cells} \times 30 \text{ sec} = \sim 10 \text{ GPU-hours}$

6 测试流程

6.1 单 cell 评测流程 (closed-loop)

每个 cell = 在一个 (ckpt, eval_env) 对上做以下步骤:

1. 重置评测环境 (带 seed), 获取初始状态。

2. **从数据集**采样一个 (history_size 帧, goal_offset 帧后的 goal 帧) 对。**不是随机初始化**——用真实数据集中的轨迹窗口，避免目标分布在训练集外。
3. 用 ckpt 的 encoder 对 history 帧和 goal 帧分别编码，得到 z_{history} 和 z_{goal} 。
4. **CEM 规划**：以 z_{history} 为初始潜状态，规划 horizon=5 步的动作序列，使得预测的潜轨迹到达 z_{goal} 附近。CEM 参数：100 samples、10 elites、5 iters。
5. **滚动执行**规划的第一动作；用真实环境的反馈更新 history；循环直到 horizon 完成。
6. **报告**：
 - mean_cos_dist: CEM 终止时的潜状态与 z_{goal} 之间的余弦距离
 - env-SR: 环境的原生成功判定
 - LeWM@0.05: $\Pr[\text{cos_dist} < 0.05]$

6.2 跨基准族评测协议 (v0.7.13 修复)

v0.7.13 发现并修复了 2 个评测 bug:

1. **Bug #2 (DMC 阈值过松)**: 原代码 check_success 的容差 = 1.0, 随机 uniform 状态通过率 87-100%。这是 v0.7.10b 报告”SNN env-SR = 100%”的假象来源。修复后 tol = 0.1, 随机通过率 0%。
2. **Bug #1 (LeWM@0.1 阈值被常数 latent 平凡通过)**: 原始 LeWM-SR 阈值 0.1 让 MLP (输出常数零) 也能达到 100%。修复后改为 LeWM@0.05 (更严), 并以原始 mean_cos_dist 为主指标。

Bug 修复前后的含义: 1008 cells + 39 (3-model) → 192 (12-model) cells 全部重跑。

6.3 评测 cell 计数

评测轴		splits × models × envs	总计 cells	commit
v0.7.10b DMC Path-C)	within- (OOD	6 × 12 × 14 DMC envs	1008	0561390
v0.7.10b suite, out	within- leave-N	14 splits × 12 mod- els	168 per axis	8a85599
v0.7.12 cross-bench (3-model)		4 × 3 × (1 or 13)	39	1dc29f3

v0.7.13 cross-bench	$4 \times 12 \times (1 \text{ or } 13)$	192	b85f980
(12-model)			
总计		1407	

7 指标定义

7.1 抗坍缩诊断 (v0.7.10b, 先验定义)

- **divergence-from-constant (div)**: $\sqrt{\text{Var}(z_{t=1..T})}$, 逐维求平均。在 200 步随机策略轨迹上计算。
 - $\text{div} \rightarrow 0$: 坍缩 (MLP 的 $\text{div} \approx 0.0002$)
 - $\text{div} \in [0.008, 0.015]$: 校准
 - $\text{div} > 0.15$: 过反应 (LeWM-v2 的 $\text{div} \approx 0.18$)
- **responsiveness (resp)**: $\frac{1}{T} \sum_{t=1}^T \frac{|\Delta z_t|}{|\Delta o_t|}$ (向量范数)
 - $\text{resp} > 10$: latent 比 obs 更抖 (noise / over-reaction)
 - $\text{resp} \in [0.15, 0.30]$: 校准
- **event-alignment** : $\text{Pearson}(\Delta o_t, \Delta z_t)$ per step
 - $|\rho| \geq 0.95$: 校准 (STJEWM 全部 $\rho \geq 0.99$)
 - $|\rho| < 0.5$: noise / over-reaction

7.2 任务表现指标 (v0.7.13 引入)

- **mean_cos_dist** (主指标): CEM 终止时潜状态与 z_{goal} 的余弦距离。 $\in [0, 2]$, 越小越好。
- **LeWM@0.05**: $\Pr[\text{cos_dist} < 0.05]$, $\in [0, 1]$, 越大越好。
- **env-SR**: 环境的原生成功判定。v0.7.13 修复后所有 $\text{cell} = 0$ (CEM 5 步达不到 25-100 步目标)。这个指标在 v0.7.13 失去了信号意义, 仅作为 sanity check。

7.3 判定失败的”四象限”

将 4 个家族在 (div,) 平面上分类:

家族 / 模型	div	resp	失败模式
MLP collapse-control	0.0002 ($\times 50$ 太小)	yes	~ 0 collapse
GRU	0.007 (校准)	yes	-0.07 noise

LeWM former	Trans-	0.186 ($\times 16$ 太大)	yes	+0.52	over-reactive
STJEW M readouts)	(6	0.011 $\pm$ 0.001	yes	≥ 0.99	calibrated
CuBiFAE		0.012	yes	(under measure- ment)	calibrated (SNN)
SLT-LIF-MPC- trace		0.012	yes	(under measure- ment)	calibrated (SNN)
SLT-LIF-MPC- free		0.010	yes	(under measure- ment)	calibrated (SNN)

关键观察：MLP 的 $\text{div} = 0.0002$ 正是常数 latent 的预期——per-dim 标准差为 0。这不是我们对 GRU 的预期失败模式 ($\text{resp} = 30$ 、 div 正常)，也不是 LeWM 的预期 ($\text{resp} = 30$ 、 $\text{div} \approx 0.19$) ——这两个模型都有正常 div 但把观测变化放大了 30 倍，给出高 LeWM-SR 靠”很响”而不是靠预测。

8 实验结果

8.1 v0.7.10b Within-DMC: 1008 cells (轴 1)

每个 (split, model) 的 (div , resp , , env-SR) 均值(节选自 `results/utility/ood1_table_v0_7_13.md`):

split	family	n	mean div	mean resp	mean	env_SR
oodc_F1	SNN-baselines	24	0.0521	0.2107	0.9710	0.8750
oodc_F1	STJEW	48	0.0485	0.2102	0.9744	0.8750
oodc_F1	non-SNN	24	0.0656	0.9142	0.9082	0.8750
oodc_F1F2	SNN-baselines	6	0.1505	0.2204	0.9908	0.5000
oodc_F1F2	STJEW	12	0.0485	0.2120	0.9922	0.5000
oodc_F1F2	non-SNN	6	0.0612	0.3139	0.9367	0.5000
oodc_F1F3	SNN-baselines	6	0.1505	0.2204	0.9922	0.5000
oodc_F1F3	STJEW	12	0.0685	0.2225	0.9960	0.5000
oodc_F1F3	non-SNN	6	0.0634	1.4299	0.9115	0.5000
oodc_F2	SNN-baselines	6	0.1505	0.2204	0.9908	0.5000
oodc_F2	STJEW	12	0.0444	0.1983	0.9986	0.5000
oodc_F2	non-SNN	6	0.0636	1.9017	0.9236	0.5000
oodc_F2F3	SNN-baselines	6	0.1505	0.2204	0.9908	0.5000

oodc_F2F3 STJEW	12	0.0154	0.2053	0.9816	0.5000
oodc_F2F3 non-SNN	6	0.0640	1.4299	0.9038	0.5000
oodc_F3 SNN-baselines	6	0.1505	0.2204	0.9908	0.5000
oodc_F3 STJEW	12	0.0660	0.2040	0.9839	0.5000
oodc_F3 non-SNN	6	0.0640	1.4299	0.9038	0.5000

关键发现： STJEW 6 个读出口径在 6 个 split 上都保持 $\rho \geq 0.97$ 和 $\text{resp} \in [0.20, 0.22]$ 。非线性对照家族（LeWM-v2 的 $\text{resp} \approx 30$ ）在抗坍塌诊断上明显偏离。

8.2 v0.7.13 Cross-bench: 192 cells (轴 2, 12 模型 $\times$ 4 splits)

每个 (model, split) 的 `mean_cos_dist`(节选自 `results/cross_benchmark_F{1,2,3,4}/eval/`):

Model (Family)	F1 PushT	F2 TwoRoom	F3 Reacher	F4 DMC	Mean
STJEW 6 read-outs					
stjewm_rate_only	0.108	0.055	0.087	0.116	0.092
stjewm_no_trace	0.113	0.050	0.089	0.130	0.096
	0.146	0.058	0.083	0.118	0.101
stjewm_spike_only					
	0.154	0.052	0.100	0.107	0.103
stjewm_trace_only					
	0.171	0.066	0.103	0.125	0.116
stjewm_hidden_leak					
	0.188	0.055	0.121	0.119	0.121
stjewm_membrane_readout					
SNN / 神经形态对照					
slt_lif_mpc_trace	0.160	0.070	0.078	0.120	0.107
slt_lif_mpc_free	0.249	0.062	0.093	0.125	0.127
cubifae_baseline	0.310	0.070	0.109	0.108	0.119
非 SNN 对照					
gru_baseline	0.406	0.114	0.001	0.008	0.039 (坍塌 artifact)
mlp_baseline	0.155	0.046	0.000	0.001	0.014 (坍塌 artifact)
lewm_baseline_v2	0.365	0.058	0.230	0.225	0.220 (过反应)

关键发现：

1. STJEW 6 readouts 的 per-model mean_cos_dist 在 $[0.091, 0.121]$, 与 v0.7.10b 的校准区 ($\text{div} \in [0.011, 0.013]$ 、 ≥ 0.99) 一致。
2. 在 4 个 split 中, **STJEW 6 readouts 都优于 CuBiFAE** (除 F3 上 SLT-LIF-MPC-trace 略胜 STJEW 0.005)。trace 赢 2 个 (TwoRoom、DMC), rate 赢 1 个 (PushT), spike 赢 1 个 (Reacher)。**trace 不是 universal winner**。
3. MLP/GRU 在 F3/F4 上的”低 cos”是**坍塌 artifact**: 它们输出常数零 latent, cos 距离自然小, 但它们显然不是能规划的世界模型。
4. LeWM-v2 表现最差 (0.220 mean), **过反应**。

9 为什么 STJEW 有效 (更好的物理故事)

9.1 两个层次的解释

STJEW 之所以在 4 个 cross-bench split 上都优于 CuBiFAE, 是因为它在**两个正交轴**上同时满足约束:

9.1.1 物理层: trace dynamics 自带校准性

脉冲后的轨迹 (trace) 是一个**内容感知的低通滤波器**:

$$r_t = \alpha_t \cdot r_{t-1} + (1 - \alpha_t) \cdot s_t \quad \text{其中} \quad \alpha_t = \sigma(W[r_{t-1}, s_t, c_t])$$

几个性质:

- **有界**: $r_t \in [0, 1]$, 逐维。
- **有遗忘**: 没有脉冲时, r 自然衰减 (α 接近 0), 避免无限累积。
- **有更新**: 有脉冲时, r 跳到接近 1, 记录事件。
- **内容感知**: α 取决于上下文 c_t , 所以”忘记什么、记住什么”由环境调制。

这种 dynamics 在**任何下游接口**下都给出 $\text{div} \approx 0.011$ 、 $\text{resp} \approx 0.21$ 、 $\rho \approx 1$ ——我们在 STJEW 6 个读出口径上都验证了这一点。

9.1.2 任务层: 校准的 latent 让规划器能工作

CEM (Cross-Entropy Method) 规划器在 latent 空间搜索动作序列, 使得未来 latent 接近目标 latent。**规划器能否工作取决于三件事**:

1. latent 是否**随观测有意义地变化** ($\text{div} > 0$) ——否则规划器在做”在常数 latent 里搜索”
2. latent 是否**不放大观测** ($\text{resp} \approx 1$) ——否则梯度信号爆炸
3. latent 是否**与观测事件同步** ($\rho \geq 0.95$) ——否则 CEM 的”未来预测”是噪声

STJEW 6 个读出口径全部满足这三点 (物理层), 所以 CEM 规划器在它们之上能工作。MLP / GRU / LeWM-v2 各自在一个点上失败, 所以 CEM 在它们之上崩溃。

9.2 为什么 trace / spike / rate 都能赢？

cross-bench 的赢家因 split 而异：

- **trace** 赢 F2/F4：在 Tworoom / DMC（稳态连续控制）上，content-aware 衰减最匹配数据的平稳性
- **rate** 赢 F1：在 PushT（离散事件：块推动、接触）上，moving average 把离散脉冲压平成平移信号
- **spike** 赢 F3：在 Reacher（稀疏目标）上，瞬时脉冲直接编码目标位置

6 个读出口径都落在同一校准区 (0.091-0.121)，所以 没有任何一个读出口径的物理优势压倒性地大于其他。这反而是 STJEWm 主张最强的证据：不是某个特定的 readout magic 赢了，而是 trace dynamics 本身的 calibration property 赢了。

9.3 膜电位禁止协议的作用

如果取消协议（让规划器读膜电位 h_t ），我们预期：

- STJEWm-membrane-readout 应该在 div / 上跟 trace_only 一样，因为动力学一样
- 但 CEM 规划器看到的信号是 h_t ，可能给出不同的目标距离（因为 h_t 的尺度与 trace 不同）

我们的实验 (v0.7.13) 确认了前者 (div / 在 6 个 readout 上都一致)，但 cross-bench 上 membrane_readout 的 mean_cos_dist 略差 (0.121 vs trace 的 0.103)，因为 h_t 与 goal 处的 h_{goal} 之间的对齐难度高于 trace 与 r_{goal} 。

关键：膜电位禁止协议不改变校准性（那是 trace dynamics 的内禀属性），而是改变规划器的接口质量——trace 的有界性 + 内容感知让 CEM 优化更稳定。

10 实验结论

10.1 三个支持性结论

1. **Within-DMC sub-family 校准性转移** (v0.7.10b, 1008 cells, gating experiment): STJEWm 6 readouts 在 6 个 split 上都保持 $\rho \geq 0.97$, resp $\in [0.20, 0.22]$ 、div $\in [0.011, 0.013]$ ，与 MLP / GRU / LeWM-v2 的坍塌 / 噪声 / 过反应清楚分离。working title 在 within-DMC 上得到支持。
2. **Cross-bench 4 family 任务表现** (v0.7.13, 192 cells): STJEWm 6 readouts 在 4 个 split (PushT / Tworoom / Reacher / DMC) 的 mean_cos_dist 上对 CuBiFAE 全面胜出。trace 赢 2 个、rate 赢 1 个、spike 赢 1 个。特定 readout winner 因 split 而异，但 STJEWm 6 readouts 都赢。working title 在 cross-bench 上得到支持。
3. **规划瓶颈：**所有模型的 env-SR 在 v0.7.13 修复后 = 0 (CEM 5 步规划器达不到 25-100 步目标)。这是规划器到动作的解码瓶颈，不是潜变量表示的失败。

10.2 两个诚实限制

1. **trace dynamics** 自身不具有”普遍硬性能优势”: 6 个 readout 在 mean_cos_dist 上有微小差异 (0.05 范围), 不是单一 readout 赢, 是 calibration 共同 property 赢。
2. **跨模态尚未测试** (DMC proprioception vs DMC 像素观测): 需要 raw-obs branch + 像素编码器, 是 working title 的下一阶段。

10.3 修正后的工作标题

原 working title——”事件驱动的预测状态动力学是可泛化世界模型的更优归纳偏置”——修正为:

膜电位禁止协议是一种可复用的 SNN 世界模型评测框架; STJEWM 是一种可实施的实现, 在 DMC 子族内泛化、跨 SNN 家族在内容感知任务上、以及特定持有族 (PushT、Tworoom、Reacher、DMC) 上具有相对优势, 但不具备跨基准族普遍硬性能胜出。

10.4 未来工作

1. 在 v0.7.11 Event-Window 任务上做多 seed 训练 (目前 1 seed, 3 seeds eval), 让 STJEWM 胜出的 ~ 2 pp 差距通过显著性检验。
2. 设计”trace-friendly”任务, 让 trace 自身在 performance 上比 membrane 单独胜出。
3. 加入 raw-obs branch, 让 v0.7.13 cross-bench 涵盖像素控制任务 (DMControl pixel-control 等), 验证 working title 的下一阶段。
4. 显式做 inter-cell significance test (per-split 1000 bootstrap), 给出 STJEWM vs CuBiFAE 的 p -value。

11 附录: 复现性

11.1 代码仓库

- 主页: <https://github.com/SolarWindRider/STJEWM>
- 训练 ckpt 与原始数据存放于 OBS: obs://lixiang01/STJEWM_NMI/
- v0.7.10b OOD 1008 cells per-cell table: results/utility/ood1_table_v0_7_13.md
- v0.7.13 cross-bench 192 cells per-cell JSONs: results/cross_benchmark_F{1,2,3,4}/eval/

11.2 关键 commit 历史

b85f980 v0.7.13 - Cross-bench: extend to all 12 model variants

dda9ec5 v0.7.13 - Bug-fix re-run: corrected cross-bench + OOD results

5399ece v0.7.13 - bug fix: tight DMC tolerances + multi-threshold LeWM-SR
 005b0f6 v0.7.12 - CODE BUG AUDIT: 3 bugs found in eval pipeline
 0561390 v0.7.10b - reeval v3 final: 108 -> 56 None
 1b834c2 v0.7.10b - plan update: accurate final state (56 None, not 108)
 aba7533 v0.7.10b - patch build_model_from_ckpt + 0 None env_sr
 9e780e7 v0.7.10b - fix cubifae nan: pad_obs_to=128 + action_dim=56
 1961e77 v0.7.10b - upload OOD path-C artifacts to OBS
 b0c5ae5 v0.7.10b - paper §7.6, §9.3/§9.4 reflect OOD path-C completion
 d0316da v0.7.10b - paper.tex §7.6 OOD sub-section (mirror paper.md §7.6)

11.3 训练与评测超参

- **训练**: AdamW, $lr = 3 \times 10^{-4}$, $weight_decay = 10^{-3}$, $\lambda_{sigreg} = 0.09$, $\lambda_{goal} = 0.5$, $batch = 32$, 1 epoch (v0.7.10b) / 5 epochs (v0.7.13 cross-bench), $embed_dim = 192$, $n_layers = 2$, $n_d = 3$
- **评测**: CEM samples = 100, elites = 10, iters = 5; horizon = 5; 30 episodes / seed; obs_dim pad 到 128, $action_dim$ pad 到 56; DMC 容差 = 0.1 (v0.7.13 修复后)

11.4 可复现命令

```
# Train all 12 generalist ckpts (G16 minus walker/humanoid)
bash code/scripts/train_generalist.sh configs/generalist_G16_minus_walker_humanoid.json 56

# Eval cross-bench F1 (PushT held out)
python -m code.eval.closed_loop --env pusht \
  --ckpt results/generalist_G16_minus_walker_humanoid/stjewm_trace_only/seed_0/final.pt \
  --data /home/lx/LeWM/data/pusht_expert_train.h5 \
  --n-episodes 30 --n-seeds 1 --history-size 3 --goal-offset 25 \
  --eval-budget 50 --out results/cross_benchmark_F1/eval/stjewm_trace_only_pusht.json
```