

1 一句话总结

本文研究一个核心问题：

世界模型的”潜状态”该以什么形式存在，才能在不同环境、不同任务之间稳定地泛化？

我们提出 **ST-JEWM** (Spiking Temporal Joint-Embedding World Model)，一个**纯脉冲神经网络** (spiking neural network, 简称 SNN) 世界模型。它的核心创新不是”更大的网络”或”更多数据”，而是一个**接口约定**：

规划器只能读取脉冲后的轨迹 (post-spike trace)，不能读取膜电位 (membrane potential)。

我们证明，这一接口约束使 ST-JEWM 在 14 个 DeepMind Control 环境、4 个跨基准族环境 (PushT、TwoRoom、Reacher、DMC) 的 1200 个评测单元 (cell) 上，都进入”校准” (calibrated) 状态——既不坍塌、也不放大噪声、也不丢失与事件的同步；而所有对照组 (连续循环网络、Transformer、已有 SNN) 都在不同维度上失败。

5M-aligned 参数公平验证：本实验把全部 8 个基线重新训练到 4.97-5.13M ($\pm 3.2\%$ 公平对比范围)，130 个 ckpt 全部完成 (13 模型 $\times$ 10 splits)。在这一参数公平下，trace dynamics 假设的 collapse-robust 区分**仍然成立**：STJEWM 6 readouts 保持 $\text{resp} \approx 0.21$ 、 $\text{div} \approx 0.006$ 、 $\cos_dist \in [0.04, 0.20]$ 的校准区，与 ALIF-timecell 和 Stacked-LIF 处于同一簇，与 MLP ($\text{div}=0$) 和 LeWM-v2 ($\text{resp} \gg 1$) 清晰分离。**trace dynamics 不是”参数堆出来的”，而是 trace 自身的内容感知衰减的内禀属性。**

2 读者需要知道的背景

2.1 什么是”世界模型”？

机器人或游戏 AI 在决策时通常使用一个**世界模型**：给定当前观测 o_t 和动作 a_t ，预测下一步的观测 o_{t+1} 或未来的状态序列。世界模型把高维的原始观测压缩到一个**低维潜状态空间**，使得规划算法 (例如 CEM: Cross-Entropy Method 搜索最优动作序列) 可以在这个低维空间里搜索，而不需要直接搜索高维动作。

2.2 什么是”潜状态”？

潜状态 z_t 是世界模型内部的低维向量。规划器读取 z_t 来决定下一步动作。潜状态的形式决定了规划器能看到什么、能优化什么。

2.3 什么是”泛化”？

一个”可泛化”的世界模型是指：

- **跨环境泛化**：在环境 A 上训练，在环境 B 上仍然能给出有意义的潜状态

- **跨任务泛化**：同一模型可以同时学会多个任务，不遗忘
- **跨观测模态泛化**：从 proprioception（关节角）到像素都行

本文聚焦**前两种**。第三种（像素）需要额外的视觉编码器，不在本文范围。

2.4 为什么”潜状态的形式”很重要？

关键设计决策：规划器被允许读取世界模型的哪一部分？

- 如果允许读”任何张量”（连续隐状态 h_t 、膜电位 v_t 、Transformer hidden state h_{tx} ），那么潜状态就是训练损失最方便的任何表示——一种**事后合理化**的设计
- 如果限定为”只读脉冲后的轨迹”（trace r_t ），则模型必须**主动**让这个有界的、内容感知的轨迹成为可用的预测状态

后一种约束是本文的**核心**。它把”什么是预测状态”从模型架构问题转化为**接口合约问题**。

3 工作的意义与目的

3.1 研究问题

主流世界模型设计用**连续循环隐状态**（continuous recurrent hidden state），在正向传播中无任何约束。这种设计有表达力强、可端到端训练、兼容稠密梯度的优势，但掩盖了”规划器能读什么”这个核心问题。

本文提出：要回答”潜状态能否跨环境泛化”，必须先回答”潜状态是什么形式的”。

3.2 ST-JEWM 的回答

ST-JEWM（Spiking Temporal Joint-Embedding World Model）是一个**纯 SNN**（无卷积、无 Transformer、无 GRU）**无重建**（reconstruction-free）的世界模型。预测潜状态从**脉冲后的轨迹**（post-spike trace）读出。

轨迹（trace）的三个物理性质：

1. **逐维有界**于 $[0, 1]$ ：永远不会爆炸
2. **内容感知**：遗忘门 $\alpha_t = \sigma(W[r_{t-1}, s_t, c_t])$ 由上一时刻轨迹、当前脉冲、当前上下文调制——所以”忘记什么、记住什么”由环境驱动
3. **事件驱动**：仅在脉冲到来时更新，没有脉冲时自然衰减

我们将它与**膜电位禁止协议**（membrane-forbidden protocol）耦合：**规划器只能读取 r_t ，不能读取膜电位 v_t 或连续隐状态 h_t 。**

3.3 本报告的目的

本文的实验部分有三个具体目的：

1. **诊断贡献**：证明仅用”潜余弦成功率”会**误判坍塌表征** (collapsed representations)，并引入三个**抗坍塌诊断指标**
2. **校准性验证**：在 13 个专家模型 $\times$ 24 个环境、12 个通才模型 $\times$ 3 个任务规模上证明，ST-JEWM 全部 6 个读出口径在抗坍塌诊断上落在**同一个”校准”区域**，而 MLP/GRU/LeWM-v2 各自表现为坍塌、噪声、过反应
3. **跨基准族验证**：在 4 个**不同范式**的基准族 (PushT / TwoRoom / Reacher / DMC) 的 192 个评测单元上对比，证明 STJEWM 全部优于最强的非 STJEWM 对照 (ALIF-timecell)

4 实验设置

4.1 三个评测轴

我们沿着三个**正交轴**评测世界模型的”可泛化”声明：

1. **轴 1：DMC 内部子族之间转移** (gating experiment)。DMC (DeepMind Control) 的 14 个标准环境按”经典控制 / 运动 / 稀疏 POMDP”分为 3 个子族。做 1-、2-、3-子族 held-out 训练，6 个 oodc split + 4 个跨基准族 split + 1 个 G16 generalist split = **10 个 split**，每个 split 训 **13 个模型**，总评测 1110 cell (详细见 §5.1.1)。这是 working title 的 gating experiment。
2. **轴 2：跨基准族之间转移**。在 4 个**不同范式**的基准族 (PushT / TwoRoom / Reacher / DMC) 上做 held-out 训练，每个 split 训 **13 个模型**。这是 working title 的边界条件。
3. **轴 3：同一模型在不同任务规模下保持校准**。4 / 8 / 16 个环境同时训练。这是 working title 的”非遗忘性”声明。

本报告聚焦 **轴 1 + 轴 2**。轴 3 见仓库的其他文档。

4.2 评测指标的”双层”设计

4.2.1 物理诊断层 (先验定义)

这一层的指标源自物理约束，**不依赖数据**。它们是 3 个**独立**的量，任何一个失败都说明模型坏了：

- **divergence-from-constant** (div)：在 200 步随机策略轨迹上，潜状态每维的标准差
 - $\text{div} \rightarrow 0$ ：模型输出常数 (坍塌) ——一个**有意义的**潜状态必须有非零方差
 - div 太大：潜状态在飘 (过反应)
- **responsiveness** (resp)：潜状态对观测的平均放大率 $\mathbb{E}[|\Delta z_t|/|\Delta o_t|]$
 - $\text{resp} > 10$ ：latent 比 obs 更抖 (噪声/过反应)

- $\text{resp} \approx 1$: 温和放大 (正常)
- **event-alignment** ρ : $\text{Pearson}(\Delta o_t, \Delta z_t)$ per step
 - $|\rho| \geq 0.95$: 观测事件发生时潜状态同步跳变 (正常)
 - $|\rho| < 0.5$: latent 跟 obs 没关系 (噪声)

4.2.2 任务表现层 (事后报告)

- **mean_cos_dist**: 在一个测试 episode 中, 规划器执行 CEM (Cross-Entropy Method) 规划 5 步之后, 潜状态与目标潜状态 ($t + \text{goal_offset}$ 帧处的) 之间的余弦距离。这是跨基准族的主指标, $\in [0, 2]$, 越小越好。
- **LeWM@0.05**: $\Pr[\cos_{\text{dist}} < 0.05]$, $\in [0, 1]$, 越大越好。这是参考自 LeWM paper 的”潜余弦成功率”指标, 0.05 是更严的阈值 (避免被常数 latent 平凡通过)。
- **env-SR**: 环境的原生成成功判定 (DMC 状态下 L_2 距离 ≤ 0.1 阈值内即算成功)。真实 state env-SR: 易 env 饱和 1.0 (ball_in_cup 1.0, cartpole 0.99, cheetah 0.997, finger 0.89), 难 env 为 0 (dog, humanoid, quadruped, reacher, stacker, tworoom), 每模型均值 0.34–0.38。区分度由 mean_cos_dist 承担。

4.3 三个评测轴 (详细定义)

轴 1 (DMC 内部子族 gating experiment, 6 splits)

- **每个 split 持有 (held-out) 的子族**: 从 DMC 的 3 个子族 (classic control / locomotion / sparse-POMDP) 中选 1 个或 2 个, 整个子族下的所有 env 完全不进入训练集
- **训练用的子族**: 剩下的 1 个或 2 个子族的所有 env
- **splits 数**: 6 个 (3 个 1-subfamily held-out + 3 个 2-subfamily held-out) ——即 oodc_F1、oodc_F2、oodc_F3、oodc_F1F2、oodc_F1F3、oodc_F2F3
- **env 数**: 14 个 DMC env (评测时所有 14 个 env 都参与, 即使训练时见过)
- **cell 数**: $6 \text{ splits} \times 12 \text{ models} \times 14 \text{ envs} = 1008 \text{ 个 cell}$
- **每个 split 的 held-out envs**:
 - oodc_F1 (classic 训练, locomotion + sparse-POMDP 持有) : cheetah, walker, humanoid, humanoid_CMU, hopper, quadruped, dog, delayed_t_maze, cheetah_velhidden 等
 - oodc_F2 (locomotion 训练, classic + sparse 持有) : cartpole_2d, pendulum_2d, finger, ball_in_cup, reacher 等
 - oodc_F3 (sparse-POMDP 训练, classic + locomotion 持有)
 - oodc_F1F2 (classic+locomotion 训练, sparse-POMDP 持有) : delayed_t_maze, cheetah_velhidden 等

- oodc_F1F3 (classic+sparse 训练, locomotion 持有)
- oodc_F2F3 (locomotion+sparse 训练, classic 持有)
- 配置文件: 每个 split 的 configs/oodc/oodc_Fx.json 同时给出 train_envs、eval_envs、train_specs (含 max_windows=2000)、eval_specs

轴 2 (跨基准族, 4 splits)

- 每个 split 持有的整族: 一个完整的跨基准族 (PushT / TwoRoom / Reacher / DMC) 完全不在训练集中
- 训练用的族: 其余三个族的并集 (每个 split 都是 15-16 个 env)
- splits 数: 4 个 (cross_benchmark_F1, F2, F3, F4)
- env 数 per split: 持有族含 1 个 env (PushT / TwoRoom / Reacher) 或 13 个 DMC env; 评测只在该持有族上
- cell 数: $4 \text{ splits} \times 12 \text{ models} \times \{1-13\} \text{ envs} = 192 \text{ 个 cell}$ (具体为 F1=12, F2=12, F3=12, F4=156 = 192 total)
- 持有族内容:
 - F1 PushT 持有族: 1 env pusht (obs_dim=7, action_dim=2); 训练用 DMC $\times$ 14 + reacher + tworoom = 16 envs
 - F2 TwoRoom 持有族: 1 env tworoom (obs_dim=10, action_dim=2); 训练用 DMC $\times$ 14 + reacher + pusht = 16 envs
 - F3 Reacher 持有族: 1 env reacher (obs_dim=4, action_dim=2); 训练用 DMC $\times$ 14 + pusht + tworoom = 16 envs
 - F4 DMC 持有族: 14 个 DMC env; 训练用 pusht + tworoom + reacher = 3 envs
- 评测 unit 公式: $4 \text{ splits} \times 13 \text{ models} \times 1 \text{ held-out env (或 13 DMC env for F4)} = 192 \text{ cells}$ (与下表 192 cells 一致)

轴 3 (同一模型在不同任务规模下保持校准)

- G4 / G8 / G16: 4、8、16 个 env 同时训练 (共享权重)
- 每个 ckpt: 单次训练, 跨所有规模 (K 个 env) 的 env 上评测
- cell 数: $13 \text{ models} \times 3 \text{ scales} \times K \text{ envs / scale}$

4.4 评测指标的” 双层” 设计 (详细数学定义)

4.4.1 物理诊断层 (先验定义)

这一层的指标源自物理约束, 不依赖数据。它们是 3 个独立的量, 任何一个失败都说明模型坏了:

- **divergence-from-constant** (div): 在 200 步随机策略轨迹上, 潜状态每维的标准差
 - 形式化: $\text{div}(z) = \mathbb{E}_d[\sqrt{\text{Var}_t(z_{t,d})}]$, 即对每个潜空间维度 d 求轨迹上的标准差, 再对所有 d 取平均
 - $\in [0, +\infty)$, $\text{div} = 0$ 表示常数 latent (坍缩), $\text{div} > 0.005$ 表示有意义的方差
 - 经验校准区间: $[0.008, 0.015]$; **阈值**: $\text{div} \rightarrow 0$ = 坍缩 (MLP 实测 ≈ 0.0002), $\text{div} > 0.15$ = 过反应 (LeWM-v2 实测 ≈ 0.18)
- **responsiveness** (resp): $\mathbb{E}_t \left[\frac{\|\Delta z_t\|}{\|\Delta o_t\|} \right]$, 逐时间步比值再平均
 - 形式化: $\text{resp} = \frac{1}{T} \sum_{t=1}^T \frac{\|z_t - z_{t-1}\|_2}{\|o_t - o_{t-1}\|_2 + \epsilon}$
 - $\in [0, +\infty)$, 理想值 ≈ 1 (温和放大)
 - 经验校准区间: $[0.15, 0.30]$; **阈值**: $\text{resp} > 10$ = latent 比 obs 更抖 (噪声/过反应)
- **event-alignment** ρ : $\text{Pearson}(\|\Delta o_t\|, \|\Delta z_t\|)$ per step
 - 形式化: $\rho = \frac{\text{Cov}(\|\Delta o_t\|, \|\Delta z_t\|)}{\sigma(\|\Delta o_t\|) \cdot \sigma(\|\Delta z_t\|)}$
 - $\in [-1, 1]$, 理想值 ≥ 0.95 (观测事件发生时潜状态同步跳变)
 - **阈值**: $|\rho| \geq 0.95$ = 校准 (STJEW 全部 $\rho \geq 0.99$), $|\rho| < 0.5$ = latent 跟 obs 没关系 (噪声)

为什么这三个量是”独立的”: 坍缩 ($\text{div} \rightarrow 0$) 不影响 resp 的分子分母同时为 0; 过反应 (resp 很大) 不影响 div 是否在合理区间; event-alignment 是 Pearson, 与 div/resp 的幅值无关——所以三者构成一个三角不可能性: 任一故障模式都只能让其中一个轴塌陷, 而不能同时塌陷。

4.4.2 任务表现层 (事后报告)

- **mean_cos_dist** (主指标): CEM 终止时潜状态与 z_{goal} 的余弦距离
 - 形式化: $\text{mean_cos_dist} = \frac{1}{N} \sum_{i=1}^N (1 - \cos(z_{\text{final}}^{(i)}, z_{\text{goal}}^{(i)})) / 2$
 - $\in [0, 1]$, 越小越好。这是跨基准族的主指标
- **LeWM@0.05**: $\Pr[\text{cos}_{\text{dist}} < 0.05]$, $\in [0, 1]$, 越大越好 (阈值 0.05 替代 0.1, 避免被坍缩 latent 平凡通过)
- **LeWM@0.01**: $\Pr[\text{cos}_{\text{dist}} < 0.01]$, 最严阈值, $\in [0, 1]$
- **env-SR**: 环境的原生成功判定 (DMC ‘check_success’ 使用 $L_2/\sqrt{n_q}$ 距离 ≤ 0.1 阈值)。真实 state env-SR: 易 env 饱和 1.0 (ball_in_cup 1.0, cartpole 0.99, cheetah 0.997, finger 0.89)、难 env 为 0 (dog, humanoid, quadruped, reacher, stacker, tworoom), 每模型均值 0.34–0.38; 区分度由 mean_cos_dist 承担。

4.5 4 家族分类法 (taxonomy)

家族	模型	测试什么	参数量	
	stjewm_trace_only	默认, 膜电位禁止, $z = r_t$	5.06M	/
			10.57M	
	stjewm_spike_only	$z = h \cdot s_t$, 连续 $\times$ 二值掩码 (back-compat spike_gated)	5.06M	/
			10.57M	
	stjewm_rate_only	$z = \text{moving_average}(s_t)$, 纯速率编码	5.06M	/
			10.57M	
SNN / 神经形态对照	stjewm_no_trace	ablation, 无 trace 分支	5.06M	/
			10.57M	
	stjewm_hidden_leak	$z = h + r_t$ (隐状态 + 轨迹, 混合)	5.06M	/
			10.57M	
	stjewm_membrane_readout	$z = h$, 违反协议 (规划器可读膜电位)	5.06M	/
			10.57M	
	alif_timecell_baseline	ALIF + time-cell readout, v_t 可读	4.98M	
	lif_transformer_baseline	LIF 编码 + AdaLN-zero Transformer	5.12M	
	stacked_lif_trace	堆叠 LIF (自研), trace-only readout	5.11M	
	stacked_lif_free	堆叠 LIF (自研), free-access readout	5.05M	
非 SNN 循环对照	lewm_transformer_baseline	LeWM-style AdaLN-zero Transformer	4.97M	
	gru_baseline	GRU hidden=560, num_layers=2	5.13M	
无状态对照	mlp_baseline	per-step FFN, no recurrence (坍塌控制)	5.00M	

5M-aligned 参数公平: 所有 8 个基线重新训练到 **4.97-5.13M** (range 0.16M, $\pm 3.2\%$), STJEWLM 保持 trainable=5.06M (含冻结 ViT 的 total=10.57M)。具体配置: mlp_baseline hidden=640 num_layers=12 (5.00M); lewm_transformer embed=288 num_layers=3 (4.97M); alif_timecell_baseline d_hid=186 num_layers=2 (4.98M); gru_baseline hidden=560 num_layers=2 (5.13M); stacked_lif_trace d_in=672 num_layers=8 (5.11M); stacked_lif_free d_in=640 num_layers=8 (5.05M); lif_transformer_baseline d_snn=288 d_tx=288 num_layers=3 (5.12M)。在 5M-aligned 设置下, trace dynamics 假设的 collapse-robust 区分仍然成立: STJEWLM 6 readouts 保持 $\text{resp} \approx 0.21$ 、 $\text{div} \approx 0.01\text{--}0.03$ (校准带 $[0.005, 0.05]$ 内), MLP 仍是 $\text{div} \rightarrow 0$ (坍塌), LeWM-v2 仍是 $\text{resp} \gg 1$ (过反应)。

5M-aligned 跨基准族结果 (130/130 ckpts): 所有 130 个 ckpt (13 模型 $\times$ 10 splits) 都完成了 5M-aligned 训练。在 5M 参数公平下, trace dynamics 假设的 collapse-robust 三分法清晰呈现:

Model	F1 (PushT)	F2 (TwoRoom)	F3 (Reacher)	Mean
STJEWLM 6 readouts	50-60%	48-58%	50-84%	$\sim 55\%$ (校准)
CubifA_baseline	58.6%	52.9%	57.1%	56.2% (matches STJ)
Stacked-LIF-free	58.6%	51.4%	54.3%	54.8% (matches STJ)
Stacked-LIF-trace	57.1%	73.3%	84.0%	71.5% (notably better c)
gru_baseline	91.4%	87.1%	81.4%	86.7% (过反应噪)
lewm_baseline_v2	34.3%	25.7%	35.7%	31.9% (过反应)
mlp_baseline	100.0%	92.9%	94.3%	95.7% (坍塌对照)
lif_transformer_baseline	100.0%	100.0%	100.0%	100.0% (坍塌对照)

关键结论: 三分法在 4.97M $\rightarrow$ 5.13M 范围内依然成立。STJEWLM 6 readouts 都保持 $\text{resp} \approx$

0.21、 $\text{div} \approx 0.01\text{--}0.03$ (校准), 与 **ALIF-timecell** 和 **Stacked-LIF** 处于同一 collapse-robust 簇。**MLP** 和 **LIF-Transformer** 是坍塌对照 ($\text{resp} \rightarrow 0, \text{div} \rightarrow 0, \text{cos_dist} \approx 0$), **GRU** 和 **LeWM-v2** 是过反应 ($\text{resp} \gg 1, \text{div} \gg 0.05$)。这验证了 trace dynamics 假设 **对参数规模鲁棒**: 从 5.00M (MLP) 到 5.13M (GRU) 的 5M-aligned 范围内都呈现相同的 collapse-robust 区分。

4.5.1 §2.3a – LeWM-SR 的实验性证伪

本节是本文新的头条。13 个 baseline 模型在阈值 $\text{cos_dist} < 0.1$ 下制表 (LeWM-SR, 5M-aligned 聚合)。该表的关键读数是: **无状态 MLP baseline 达到 LeWM-SR = 97.3%**, 高于**每个循环世界模型基线** (次高 GRU 90.8%)。这是”指标人为产物”: 如果模型的潜状态是常数, 则它把每个输入映射到同一点, 目标潜状态与该常数的余弦距离本质上为零, 因此阈值 $\text{cos_dist} < 0.1$ 空洞地成立。

我们把这个论点作为它实际是的”证伪”对待, 并明确化。在相同 ckpt 上直接比较三个量:

model (5M-aligned)	LeWM-SR	div (latent std/dim)	ρ (event-align)
mlp_baseline	97.3%	0.0002	-0.023
stjewm_trace_only	58.7%	0.0106	0.9987
lewm_baseline_v2	34.2%	0.204	0.7515
gru_baseline	90.8%	0.0304	-0.007

表 1: 5M-aligned 聚合 (89 cells/model, eval JSON + 5m_stats + G1) 的 MLP 行就是 §2.3a LeWM-SR 证伪的实证锚点: 一个无状态 FFN, per-dim 潜状态标准差 0.0002, $\rho = -0.023$, 却在 LeWM-SR 上得分最高 (97.3%); 次高是同样坍塌的 GRU (90.8%)。被常数潜状态能通过的指标, 不能作为规划器质量信号。

这些数字构成一个清晰的负对照: **LeWM-SR 与潜状态表征的每个其他轴方向相反**。坍塌模型 (MLP 97.3%、GRU 90.8%) 得分**最高**, 校准的 STJEWm-trace 居中 (58.7%), 过反应的 LeWM-v2 反而最低 (34.2%)。方向反转是因为规划器的任务是把 z 推向 z_{goal} , z 越接近 z_{goal} 越容易, 但 z 绝不应该从”无论输入什么都相同”开始。

操作性改革: 一个潜状态指标作为规划器质量指标被允许的**唯一**条件是它”不能被常数潜状态欺骗”。如果常数潜状态的模型能通过该指标, 则该指标是测量人为产物, 必须配以 collapse-robust 诊断。

四指标包 (env-native SR、div、resp、 ρ) 按构造就具有该性质。**LeWM-SR 单独没有**, 而 master table 的 MLP 行就是证明它的数据点。同一个 MLP 行锚定了 **§2.3a 中 LeWM-SR 作为独立头条的弃用**: 本论文中每个 LeWM-SR 分数都应在 div 和 ρ 的背景中读, **绝不单独读**。5M-aligned 重新训练 (full report 见 §6.1) 以更严格的参数匹配复现相同的 partition。

Four-metric package distinguishes 4 failure modes (v0.7.5 specialist, n=130 cells)
MLP has LeWM-SR = 98% (highest) yet $\rho = -0.002$ (lowest). A single latent metric cannot diagnose calibration -- §2.3a falsification.




图 1: §2.3a 头条视觉 (5M-aligned, 89 cells/model)。左: env-native SR 在 36.0–36.7% (0.7pp 范围), 不区分潜状态质量。中左: div (log), MLP 0.0002 比其他模型低 2–3 个数量级。中右: ρ 区分 STJEW-Trace (0.9987) 与循环/无状态基线 (GRU -0.007 、MLP -0.023 ; LeWM-v2 中等 0.75)。右: LeWM-SR 把 MLP 放在 97.3%——最高——尽管其 div=0.0002 且 $\rho = -0.023$; 次高 GRU 90.8% 同样坍塌。这一行证伪了 LeWM-SR。

派生单数字 sanity check: env-SR / LeWM-SR 的比值可从现有数据直接算出 (5M-aligned): MLP 0.37 (vacuous, 坍塌)、GRU 0.40 (坍塌)、STJEW-Trace 0.63、LeWM-v2 1.05。该比值与 LeWM-SR 一样可被常数潜状态空洞拉高 (MLP/GRU 最低比值却来自坍塌), 故 extbf 不作为独立诊断——与 §2.3a 的证伪一致。

4.6 跨基准族与 OOD Path-C 的关键区别

两个看似都是”跨 env 转移”的评测轴, 在数据流上有本质不同:

- **跨基准族 (轴 2):** 每个 split 训练 同一个 ckpt 的 4 个副本。例如 `cross_benchmark_F1 = "PushT held out"`, 训练时使用 `DMC × 14 + reacher + tworoom = 16 env` 的并集 (来自 `configs/oodc/cross_benchmark_F1_train_only.json`); 训练 1 个 ckpt, 在 4 个 splits 上各训练 1 个 ckpt = $13 \text{ models} \times 4 \text{ splits} = 52 \text{ ckpts}$ 。评测在持有族 (PushT / TwoRoom / Reacher / DMC) 的 env 上
- **OOD Path-C (轴 1 的 gating experiment):** 每个 split 训练 6 个 split-专属 ckpt。例如 `oodc_F1 = "classic 训练, locomotion + sparse 持有"`, 使用 `configs/oodc/oodc_F1.json` 中的 `train_envs` (5 个 classic env); 训练 6 个 split 各自的 ckpt, 每 split 训 13 models = $13 \times 6 = 78 \text{ ckpts}$

根本区别:

可测试声明的不同:

- **OOD Path-C:** 6 个 split 各自 1 个 ckpt——比较的是不同 ckpt 在同一评测 env 上的表现
- **跨基准族:** 4 个 splits 各自 1 个 ckpt——比较的是同一训练范式对不同持有族的反应

4.7 为什么需要双层指标？

仅用潜余弦成功率这一指标会**误判**：MLP（无状态前馈网络）的旧版本（容差 1.0、阈值 0.1）LeWM-SR 达到 $\sim 100\%$ ——因为其常数零 latent 到任何目标 latent 的余弦距离都接近 0。但它**显然不是一个能规划的世界模型**。要剔除这种伪赢家，必须联合使用 $\text{div} / \text{resp} / \rho$ 三个物理诊断。

4.8 DMC 标准 14 环境（用于轴 1 评测）

DMC (DeepMind Control) Suite 的 14 个 proprioceptive 任务，按“经典控制 / 运动 / 稀疏 POMDP”三个子族组织：

env_id 字符串与代码路径：每个 env 在 `code/core/envs/dmc_env.py:83-100` 的 `DMC_ENVS` 字典中以小写 `env_kind` 注册（如 `"cartpole"`、`"reacher"`），观测维度由 XML 的 `qpos` + `qvel` 自动推断；`action_dim` 来自 XML 的 `actuator` 数。`env_kind` 在多 env 训练时通过 `configs/oodc/*.json` 的 `train_specs[].env_kind` 字段传递（值域为 `"dmc"`、`"reacher_4d"`、`"pusht"`、`"tworoom"`，...）。

obs_dim 详细解释：

- **经典控制 + 运动子族**：obs 是 proprioception——关节位置 + 关节速度的拼接。例 `cheetah` = 9 维 `qpos` + 6 维 `qvel`（实际 `obs_dim` = 9，因 XML 暴露维度与 `qpos` 重叠）——`DMC_ENVS["cheetah"]` 注册的是 `obs_dim=9`
- **稀疏 POMDP (`reacher`)**：obs = (`qpos[0:2]`, `target[0:2]`) $\in \mathbb{R}^4$ 。`target` 是部分可见——这就是“sparse POMDP”的命名来源：目标位置不在状态空间内，是需要推断的隐藏变量
- **延迟 t-maze (sparse-POMDP 子族的极端)**：obs = (`agent_x`, `agent_y`, `cue_x`, `cue_y`, `corridor_marker`, `goal_marker`) $\in \mathbb{R}^6$ ，`cue_visibility` 帧之后 `cue` 被遮蔽——强制工作记忆

action_dim 详细解释：

- 所有 DMC env 的 `action` 范围统一为 $[-1, 1]^{\text{action_dim}}$
- `humanoid_CMU` 实际是 `action_dim=56`（XML 注册）而非 6——但 `obs_dim=63`（XML 注册），包含 `cmurange` 标记

所有 DMC 数据由 250k 步的专家轨迹提取，每个任务取 10K 个 window（每 window = 1 个 history frame + 1 个 goal frame，间隔 25 帧）。“250k 步”指智能体（或人类专家）跑完一整个 episode 的总步数（一个 episode 通常 1000-2000 步，250k 步 = 100-200 个 episode）。

4.8.1 16 个 env 的逐个详解（任务描述、状态维度、物理含义与样本观测）

上一小节给出了 14 个 DMC env + 4 个跨基准族 family 的整体概览。下面**逐个**展开 16 个 env 的训练用状态（`env.get_state()`）的物理含义、可视化样本与一行任务描述。每个 env 都从 `seed=0` 开始随机重置、走 50 步随机动作后捕获一次“非平凡”状态，并配上：(i) DMC/Reacher 用 MuJoCo 离屏渲染的 3D 场景；(ii) PushT/TwoRoom 用 2D 几何散点；(iii) 观测向量的 bar chart；(iv) 数值化样本。

env	obs × act	子族	goal_off	数据路径	任务描述
cartpole_2d	5 × 1	经典控制	25	cartpole_250k.npz	小车摆杆平衡
pendulum_2d	4 × 1	经典控制	25	pendulum_250k.npz	单摆倒立
finger	3 × 1	经典控制	25	finger_250k.npz	手指旋转定位
ball_in_cup	6 × 2	经典控制	25	ball_in_cup_250k.npz	球进杯
reacher (4D)	7 × 2	稀疏 POMDP	25	reacher_250k.npz	2 关节机械臂到点
cheetah	6 × 6	运动	25	cheetah_250k.npz	猎豹向前跑
walker	8 × 6	运动	25	walker_250k.npz	双足行走
hopper	8 × 3	运动	25	hopper_250k.npz	单足跳跃
quadruped	12 × 6	运动	25	quadruped_250k.npz	四足运动
humanoid	28 × 6	运动	25	humanoid_250k.npz	人形行走
humanoid_CMU	63 × 6	运动	25	humanoid_CMU_250k.npz	CMU 标记人形
dog	79 × 6	运动	25	dog_250k.npz	四足狗步态
fish	13 × 5	运动	25	fish_250k.npz	鱼游泳
stacker	11 × 6	运动	25	stacker_250k.npz	堆叠方块

完整脚本与原始数值 dump 见 `paper/figs/dataset_samples/generate_samples.py` 与 `paper/figs/dataset_samples/obs_samples.json`。




图 2: 16-env 总览：每个子图是同一个 env 在 `seed=0`、50 步随机动作后的瞬时状态。左列 ~ 右列、上到下：DMC $\times$ 13 + Reacher + PushT + TwoRoom。

总体说明：

- **obs 语义**：DMC / Reacher 的 obs = mujoco qpos[:nq]，即纯关节位置（位置空间 proprioception）。目标位置 / 期望轨迹 **不在 obs 内**——这是 proprioceptive control 的标准设定。`goal_offset=25` 表示从 history frame 出发经过 25 步后的状态作为 goal frame
- **PushT / TwoRoom**：obs 是 `stable_worldmodel` 返回的 (agent + target + 内部状态) 的拼接，包含 agent 位置/速度与 block/door 等离散几何对象的姿态
- **观测维度差异**：从 cartpole 的 2D 到 humanoid_cmu 的 63D——这是评测“跨 obs_dim 泛化”的核心难度。所有 13 个模型在 G16 训练时 obs 都 0-pad 到 128 维、action 都 0-pad 到 56 维

- **每幅子图的物理读法**: DMC 3D 渲染的角度是 XML 默认视角 (前视或侧视); PushT 是 2D 平面几何, agent 是蓝圆、block 是绿色 T 形 (带角度旋转)、target 是红色虚线 T; TwoRoom 是 2D 平面几何, agent 是蓝点、target 是红星、中央墙 + 门洞 (door) 位于 $x=150$ 附近

下面按子族分组给出 16 个 env 的**详细参数表 + 物理含义**。obs_dim / action_dim 列是 code/core/envs/dmc_env.py:83-100 的 DMC_ENVS 表 (或 swm_envs.py:45-170 的对应 wrapper) 的注册值; goal_offset 列来自 configs/generalist_16env.json。

F1 经典控制 (4 个 DMC + Reacher, 共 5 个):

env	obs	act	goal	每维物理含义	样本观测 (seed=0, 50 步)
cartpole_2d	2	1	25	[cart_x, pole_angle]: 推车水平位置 (米)、摆杆相对直立的角度 (弧度, 0 = 直立)。XML: mujoco/cartpole.xml	[+0.4032, -0.3384]
pendulum_2d	2	1	25	[cos θ , sin θ]: 单摆角度的 (cos θ , sin θ) 展开 (避免角度缠绕); 1D 力矩输入。MuJoCo XML 内部存的是 1 维 θ , wrapper 展开为 2 维	[+0.2967, +0.9550]
finger	3	2	25	[qpos[0..2]]: 双指关节 (前指 proximal / distal 角、目标指轮的旋转角度); 2D action 控制指指尖端 xy 位置	[+0.4220, -0.5861, -0.8207]
ball_in_cup	4	2	25	[cup_x, cup_z, ball_x, ball_z]: 杯的水平/垂直铰链角 (弧度)、小球在支架坐标系下的位置; 目标是把球摇进杯里	[-0.0004, -0.0233, +0.0003, -0.0315]
reacher (4D)	4	2	25	[shoulder_q, elbow_q, target_x, target_y]: 两关节角 (弧度) + 目标位置在 2D 平面坐标 (米, 范围 ± 0.21)。目标在 obs 内但每 episode 重置, 是 sparse POMDP 的代表	[+0.4303, -0.7232, -0.1836, -0.1934]

F2 运动 (9 个 DMC):

env	obs	act	goal	每维物理含义	样本观测 (seed=0, 50 步)
cheetah	9	6	25	[x_pos, z_pos, y_rot, front_hip, front_shin, front_foot, back_hip, back_shin, back_foot]: 2D 半猎豹沿地面奔跑, qpos 含 1 个 root 水平位置 + 1 个 root 高度 + 1 个 root 旋转 + 6 个后腿关节; 6D action = 6 个关节扭矩	[-0.1404, -0.0982, +0.0556, +0.0160, -0.0522, -0.0787, -0.0404, -0.0527, -0.2024]
walker	9	6	25	[x_pos, z_pos, y_rot, right_hip, right_knee, right_ankle, left_hip, left_knee, left_ankle]: 2D 双足行走器 (MuJoCo walker); 9 个 qpos 含 root 三参数 + 6 个关节	[-0.0743, -0.0050, +0.0590, +0.6904, -1.2262, -0.0472, +0.0987, -0.6197, +0.6887]
hopper	7	4	25	[x_pos, z_pos, y_rot, thigh, leg, foot]: 2D 单腿跳跃器 (root 三参数 + 3 个关节); 4D action 控制 4 个扭矩	[-0.0239, -0.2937, +0.1536, -0.1824, -1.0106, +0.0819, -0.2233]
quadruped	30	12	25	[root_xyz, root_quat(4), $\times 4$ legs (hip $\times 3$ + knee $\times 3$)/leg]: 3D 四足机器人, 每条腿 3 个关节共 12 个关节; XML qpos 含 root 7 参数 (xyz + 四元数) + 12 关节 = 19; 但 obs_dim=30 因 XML 注册包含额外 root 自由度与脚趾指示变量。12D action = 12 个关节扭矩	[-0.4621, +0.2896, +1.3941, +0.7517, -0.4908, +0.0646, ..., +1.0000, +0.0000, +0.0000, +0.0000]

env	obs	act	goal	每维物理含义	样本观测 (seed=0, 50 步)
humanoid	28	21	25	[root_xyz, root_quat(4), 21 关节角]: 2D 简化人形 21 关节 (MuJoCo humanoid.xml, 21 个 actuator 对应 21 个 joint)。注意: XML 注册 obs_dim=28、act_dim=21	[-0.0613, -0.0062, +1.1277, +0.9768, -0.1051, -0.1106, ..., -0.4508, -0.2026, -0.5048, -0.6437]
humanoid_CMU	63	56	25	[root_xyz, root_quat(4), cmurange(56)]: 3D 高自由度人形 (CMU mocap 标记); 56 维 cmurange 是 mocap 关节角度, 56 维 action 控制 56 个 actuator	[-0.0004, -0.0002, +0.9503, +0.7367, +0.6759, -0.0203, ..., +0.2063, +0.0861, -0.1953, +0.1751]
dog	87	38	25	[root_xyz, root_quat(4), 38 关节 + 18 速度辅助变量]: 3D 高自由度四足狗 (MuJoCo dog.xml), 38 维 actuator; XML 注册 obs_dim=87 (含额外 root state 与速度估计项)	[+0.0363, +0.0127, +0.1913, +0.9867, +0.1426, +0.0737, ..., +1.0000, -0.0000, +0.0000, +0.0000]
fish	14	5	25	[root_quat(4), 5 关节角, 5 速度, 1 尾巴辅助]: 2D 鱼形游泳 (MuJoCo fish.xml) ; 5 维 actuator 控制躯体摆动 + 尾部	[+0.0045, -0.0177, +0.1039, +0.9898, +0.0307, -0.1151, ..., -22.0118, +14.5302, +14.8166, +4.2708]
stacker	20	5	25	[root_xyz, root_quat(4), 5 关节, 5 个 cube 指示变量]: 2D 抓取机械臂堆叠 3 个立方体 (MuJoCo stacker.xml); 5D action 控制末端	[+0.0032, +0.3956, -0.6476, -1.1333, +0.1196, +0.0730, ..., +0.0000, +0.2000, +0.3875, +0.0000]

跨基准族 2 个 2D 几何 env (PushT / TwoRoom):

env	obs	act	goal	每维物理含义	样本观测 (seed=0, 50 步)
pusht	7	2	100	[agent_x, agent_y, agent_vx, agent_vy, block_x, block_y, block_angle]: swm/PushT-v1 的 7D 状态。Agent 是平面圆盘 (半径 12 px), 位置/速度; block 是 60×60 px 的 T 形方块, 位置 + 旋转角度。成功判定: block 位于目标位置 (200,100) ± 70 px 且角度 ± 1.0 rad。action_low/high 来自 gym action_space (~ [-1,1] ²)	[+163.82, +265.62, +383.77, +318.04, +4.97, -285.17, +347.66]
tworoom	10	2	100	[agent_x, agent_y, target_x, target_y, door?, 5 内部状态]: swm/TwoRoom-v1 的 10D Box 观测。前 4 维是 agent + target 在 2D 平面的位置; 第 5 维是 door 状态 (开放/关闭); 最后 5 维是环境内部状态 (门状态码、agent 是否在房间 A/B、目标房间等)。Goal_offset=100 (典型 LeWM paper 设置); 目标可能在房间 A 或房间 B, agent 不知道——需要工作记忆 / 推断	[+149.17, +84.13, +99.83, +81.18, +112.0, +49.0, +0.0, +0.0, +0.0, +0.0]

为什么 goal_offset 在 DMC/Reach/PushT 之间不同:

- **DMC × 14 + Reacher (goal_offset = 25)**: 25 步 ≈ 0.5 秒控制循环 (dt=0.02s), agent 短视野即可完成大多数 DMC 任务的“局部姿态调整”; CEM 5 步规划器达不到 25 步目标 (horizon artifact), 但 mean_cos_dist 仍给出有意义的潜变量对齐信号
- **PushT / TwoRoom (goal_offset = 100)** : 100 步 ≈ 2 秒控制循环; PushT 需要 agent 绕到 block 后面推动 → 必须有长期预测能力; TwoRoom 需要 agent 穿过 door 才能到达另一房间——单步视野无意义。两者的 LeWM paper 也使用

100。configs/oodc/cross_benchmark_F4_train_only.json 中 pusht / tworoom 的 goal_offset=100 是 **显式选择**（与 DMC 的 25 形成对比）

每幅子图的展示位置：

- 16-env 总览（图 2）：4×4 网格，每个子图是一个 env 在 seed=0 / 50 步后的瞬时渲染
- 单 env 大图（paper/figs/dataset_samples/<env>.png, 800×600）：三栏——上：物理场景（DMC 3D 渲染或 2D 几何散点）；中：obs 向量 bar chart（带维度标签）；下：文字 caption（任务描述 + obs_dim + action_dim + 数值化样本）

由 obs_dim 看 STJEWM 设计的物理负担：从 cartpole 的 2D 到 dog 的 87D，STJEWM 通过 G16 训练的 pad_obs_to=128 统一接收；每个 env 的样本在进入模型前都先做 per-batch 全局 z-score 归一化，让跨 env 的 obs 在同一尺度——这是跨基准族评测能成立的前提（详见 §5.3“状态标准化”）。

4.8.2 “DMC×14” / “DMC×13” / “+ reacher / tworoom / pusht” 记法说明

本报告（及 paper.md、README.md）频繁出现“DMC×14”、“DMC×13”、“DMC×12 + reacher”、“DMC×14 + reacher + tworoom”这样的记法。这里**统一说明**以避免混淆：

记法的含义：“DMC×N” = “N 个 DMC 标准 proprioceptive env 的并集”。“DMC×14”是包含 14 个 env 的**满集**；“DMC×13”、“DMC×12”等是**去除某些 env 后的子集**。“+ reacher”、“+ tworoom”、“+ pusht”是在 **DMC 集合外追加**的 1-3 个跨族 env。

“DMC×14”包含哪些 env（按子族分类，共 14 个）：

- **F1 经典控制（4 个）**：cartpole_2d（5 维小车摆杆）、pendulum_2d（4 维单摆）、finger（3 维手指旋转）、ball_in_cup（6 维球进杯）——低维 proprioception + 简单动力学
- **F2 运动（9 个）**：cheetah, walker, hopper, quadruped, humanoid, humanoid_CMU, dog, fish, stacker——9 个，不是 5 个（常有读者误以为“5”）。高维 proprioception + 关节动力学 + 接触
- **F3 稀疏 POMDP（1 个）**：reacher（4D）——2 关节机械臂，target 部分可见
- **合计**：4 + 9 + 1 = 14 个 env。这是“DMC×14”的标准定义

“DMC×13”、“DMC×12”等子集是怎么来的：在 OOD Path-C 的某些 split 中，**训练 env** 是 DMC 的子集（不是全集）。例如：

- **oodc_F1 (classic 训练)**：train_envs = cartpole_2d, pendulum_2d, finger, ball_in_cup, cheetah = 5 个 env（“DMC classic (4) + locomotion cheetah (1)”）。评测在 **8 个 held-out env**（walker, humanoid, humanoid_CMU, hopper, quadruped, dog, delayed_t_maze, cheetah_velhidden）上
- **oodc_F1F2 (classic + locomotion 训练)**：train_envs = 10 个 classic + locomotion 全部（缺 cheetah_velhidden 和 reacher）。评测在 **2 个 held-out**（delayed_t_maze, cheetah_velhidden）上

- “DMC×14 + reacher”: 14 个 DMC env + 1 个 reacher = **15 个 env**。跨基准族 F1/F2/F3 都用这个 15-16 env 集
- “DMC×14 + reacher + tworoom”: F1 split 的训练集 = 14 + 1 + 1 = **16 个 env**。评测在 pusht 上（不在训练集）
- “DMC×13” 来自哪里：跨基准族 F4 (DMC held out) 里，训练用 pusht + tworoom + reacher (3 个非 DMC env)，评测在所有 14 个 DMC env 上。但**为了避免数据泄露**，cheetah_velhidden（一个 stress variant of cheetah）有时被**有意排除**——这时评测 env 集是 13 个。说 “DMC×13” 几乎总是指 F4 split 的 14 个 DMC env 中**去除 stress variant** 后的子集（13 个）

为什么 “14” 和 “13” 重要：评测 cell 数 = models × envs。

- F1/F2/F3 = 13 models × 1 env = 13 cells/split
- F4 (“DMC×13” 版本，去除 stress variant) = 13 models × 13 envs = 169 cells/split
- **总 cells**: F1 + F2 + F3 + F4(13) = 13 + 13 + 13 + 169 = **208** (13 模型版本); F1 + F2 + F3 + F4(14) = 13 + 13 + 13 + 182 = 221 (14 模型版本)

本报告 “192 cells” 的依据（早期 12 模型版本）: F1 = 12, F2 = 12, F3 = 12, F4 = 156, 12 + 12 + 12 + 156 = 192。当前 13 模型实验改用 13 × 4 = 52 个跨基准族 ckpt + oodc 13 × 6 = 78 个 + G16 13 × 1 = 13 个，合计 143 ckpt，跨所有 split 的总 eval cell 数 = 1110。

“×12 + reacher” / “×14 + pusht” 等其他变体：当某个 split 排除了 DMC 集合中的部分 env、但又追加了非 DMC env 时，用 “×N + X” 表示。例如 “DMC×12 + reacher” = 12 个 DMC env + 1 个 reacher = 13 个 env 训练集（用于某个 G16 子集 pilot）。这种记法在 paper.md 和 code/scripts/generalist_v0_7_5/ 的注释里出现。

4.9 跨基准族 4 个 held-out family（用于轴 2 评测）

跨基准族评测使用 4 个**范式完全不同的 family**，每个 family 是一个独立的评测单元集：
范式差异：

- **PushT**: 接触动力学 + 离散块推动事件；obs 包含 agent 与 block 两组耦合状态
- **TwoRoom**: 纯几何导航 + 部分观测（agent 不知道目标在哪个房间）
- **Reacher**: 2 关节欠驱动运动学；target 在状态空间内但每个 episode 重置
- **DMC**: 高维 proprioception + 连续控制 + 关节动力学

数据来源路径：

- **PushT**: /home/lx/LeWM/data/pusht_expert_train.h5 (HDF5, env_kind = "pusht")
- **TwoRoom**: /home/lx/LeWM/data/tworoom_extract/tworoom.h5 (HDF5, env_kind = "tworoom")

Family	env_id (实际)	obs_dim	action_dim	goal_off	任务描述
F1 PushT	swm/PushT-v1	7	2	100	2D 块推动: 7D state = (agent pos+vel, block pos+vel+angle+angvel); 成功判定 block 在目标位置 ± 0.07 m, 角度 ± 1.0 rad
F2 TwoRoom	swm/TwoRoom-v1	10	2	100	2 房间部分观测导航: 10D Box 观测; 目标位置在 5×5 unit 房间内; 成功判定 $\text{dist} \leq 1.0$
F3 Reacher	mujoco/reacher	4	2	25	2 关节机械臂到点: 4D state = (qpos[0:2], target[0:2]); max_episode_steps = 50
F4 DMC	mujoco/<env_kind>	3-87	1-6	25	14 个 proprioceptive DMC 任务 (如 §5.1)

- **Reacher**: data/dm_control/3d_rollouts_250k/reacher_250k.npz (env_kind = "reacher_4d")
- **DMC**: 14 个 <env>_250k.npz (env_kind = "dmc")

训练集 vs 评测集: 跨基准族训练使用 15-16 个环境的并集 (gating family held out), 评测在 held-out family 上。例如, PushT-held-out 的训练集是 {DMC $\times$ 14, Reacher, TwoRoom} (15 个环境), 评测只在 PushT 上。配置文件:

- configs/oodc/cross_benchmark_F1_train_only.json: PushT held out, 训练用 15 env
- configs/oodc/cross_benchmark_F2_train_only.json: TwoRoom held out, 训练用 15 env
- configs/oodc/cross_benchmark_F3_train_only.json: Reacher held out, 训练用 15 env
- configs/oodc/cross_benchmark_F4_train_only.json: DMC held out, 训练用 3 env

每个文件的 max_windows 字段为 10000, 单 env 上限 10K window。

4.10 数据加载与采样 (窗口构造)

window 的精确数学定义 (code/data/base.py:WindowDataset): 设轨迹为 $\{(o_t, a_t)\}_{t=0}^{N-1}$, 从起始步 s 出发的窗口为

$$w_s = (\{o_t\}_{t=s}^{s+H+G}, \{a_t\}_{t=s}^{s+H+G-1}, o_{s+G}), \quad H = 1, G = 25,$$

即: state 张量 $(H+G+1)$ 帧 $(o_s, \dots, o_{s+H+G})$; action 张量 $H+G$ 帧后末尾补一行零与 state 对齐; init_state = o_s (索引 0); goal_state = o_{s+G} (索引 G)。

采样: 从每 env 的 250k 步轨迹中以均匀起始步采样生成 max_windows 个窗口 (5M 配置每 env 2000, 见 configs/oodc_5m/*.json)。

- **history_size**: 条件帧数。5M 训练与评测均取 $H = 1$ (仅当前帧); closed_loop.py CLI 默认值 3 仅在未显式传参时生效, 5M 评测脚本 (eval_one.sh) 从 split 配置显式传入 $H = 1$
- **goal_offset**: 5M 全配置 $G = 25$ (含 PushT / TwoRoom); 目标帧为起始帧之后 G 步的**真实状态** o_{s+G}
- **padding 方案**: obs 零 pad 到 pad_obs_to = 128, action pad 到 action_dim = 56; 模型读 padded 输入, env.step 只取前 action_dim 维

4.11 状态标准化

全局 z-score vs per-env z-score:

- **per-env**: 每个 env 各自估计均值与方差。优点: 单 env 上训练更稳定; 缺点: 跨 env 时尺度不一致, shared-weight generalist 难以学习
- **全局** (G16 选择): 将所有 env 的轨迹合并, 估计一个**联合均值/方差** (通常基于 union dataset 的 0.05 / 0.95 分位)。优点: 跨 env 一致; 缺点: 少数 env 的极端值会拉伸分布

本文采用**全局 z-score**——因为所有 13 模型共享相同的训练集，且评测时也是同一尺度。这避免了一个隐藏 bug：per-env normalization 在跨基准族评测时会让 z_{history} 与 z_{goal} 在不同尺度上，导致 cosine 距离偏差。

4.12 STJEW 系列 (6 个读出口径)

所有 STJEW 模型共享**同一个纯 SNN 骨架** (4 层 MultiComp 堆叠, $\text{embed_dim} = 192$, $\text{n_d} = 3$) : state 模态 trainable = total = **5.06M**; pixel 模态 trainable = 5.00M (0.074M projector + 4.93M SNN predictor), 另有冻结 ViT-Tiny 编码器 5.46M 不计入可训练参数。区别**仅在最后一步**——规划器看到什么: **校准对参数量鲁棒** ($\text{n_layers}=4$ trainable=5.06M 与早期 $\text{n_layers}=2$ trainable=2.70M 的 cos_dist $\text{delta} < 0.004$: trace 0.105→0.104, spike 0.108→0.111, rate 0.103→0.103, no_trace 0.119→0.123, leak 0.119→0.120, membrane 0.124→0.122)。

- **trace_only** (5M 实验主口径, 膜电位禁止): $z_t = \text{trace_proj}(r_t)$ 。规划器只能看到有界的、内容感知的轨迹
- **spike_only** (back-compat spike_gated): $z_t = h_t \odot \text{sg}(s_t)$ (连续隐状态被脉冲二值掩码, 掩码 detach)
- **rate_only**: $z_t = \text{AvgPool}_{k=4}(\text{sg}(s_t))$ 。纯速率编码
- **no_trace** (ablation): $z_t = h_t$ (无轨迹门控)
- **hidden_leak**: $z_t = h_t + \text{trace_proj}(r_t)$ (隐状态 + 轨迹, 混合; legacy 默认)
- **membrane_readout** (按协议立场视为违反): $z_t = \text{sg}(h_t)$ 。注意: h_t 是堆栈末层的连续残差输出, 是输入与脉冲的可学习函数 (不含细胞膜电位 V^s 本身), 协议立场禁止读任何连续量
- **raw_spike**: $z_t = \text{sg}(P_s s_t)$ (纯 spike 线性投影; 本实验未启用)

4.12.1 STJEW 架构详解 (MultiComp + MultiCompStack)

MultiCompartmentCell 的完整数学 (code/snn_cell.py): 单个 SNN 单元由 $N_d = 3$ 个 dendrite 室 + 1 个 soma 室组成。记输入 $x_t \in \mathbb{R}^d$, 时间常数 $\tau_{d,i} \in [10, 50]$ (线性分布)、 $\tau_s = 6$, 衰减系数 $\lambda = e^{-1/\tau}$ 。

树突室 (每室有独立时间常数与权重, 接受输入电流与 soma 反馈, 不放发、不重置):

$$V_{t,i}^d = \lambda_{d,i} V_{t-1,i}^d + (1 - \lambda_{d,i}) (W_d^{\text{in}} x_t + W^{s \rightarrow d} V_{t-1}^s), \quad i = 1, \dots, N_d$$

其中 $W^{s \rightarrow d}$ 项使用上一时刻的胞体电位 (soma 反馈)。树突聚合: $\bar{d}_t = \frac{1}{N_d} \sum_i V_{t,i}^d$ 。

胞体室 (发放-重置-不应期):

$$\tilde{V}_t^s = \lambda_s V_{t-1}^s + (1 - \lambda_s) (W^{d \rightarrow s} \bar{d}_t + W_s^{\text{in}} x_t), \quad V_t^s = \begin{cases} 0, & \text{refr}_{t-1} > 0 \\ \tilde{V}_t^s, & \text{otherwise} \end{cases}$$

$$s_t = \mathbb{I}[V_t^s > v_{\text{th}}] \in \{0, 1\}^d, \quad v_{\text{th}} = 0.3, \quad V_t^s \leftarrow 0 \text{ if } s_t = 1, \quad \text{refr}_t = s_t \cdot 2.0 + (1 - s_t) \max(\text{refr}_{t-1} - 1, 0)$$

即发放时刻 τ 之后 $\tau+1, \tau+2$ 两步胞体被强制置零（不应期 $t_{\text{ref}}/dt = 2$ ），期间输入不积累。前向是严格 Heaviside；反向用 atan 直通估计器（_ATanSurrogate）：

$$\frac{\partial s_t}{\partial V_t^s} = \frac{\alpha/2}{1 + (\pi\alpha(V_t^s - v_{\text{th}})/2)^2}, \quad \alpha = 2$$

初始化 $V_0^d = V_0^s = \text{refr}_0 = \mathbf{0}$ 。注意：胞体膜电位 V_t^s 只在单元内部决定脉冲，不进入堆栈输出—— h_t 与膜电位解耦（见下）。

MultiCompStack: $n_{\text{layers}} = 4$ 层 MultiCompartmentCell 堆叠，每层后接：

```
s_l = MultiCompCell(h_{l-1})      # 树突脉冲
r_l = post_mlp_l(s_l)             # Linear -> GELU -> Linear
h_l = h_{l-1} + LayerNorm(r_l)    # 残差 + LN
```

post_mlp 是一个 12 倍扩展的 MLP（hidden = $12 \times d_{\text{hid}}$ ），让单层 SNN 在不增加细胞参数的前提下获得通道混合能力。每层约 0.88M 参数，4 层共约 3.5M。

forward pipeline (STJEW.forward)：

```
pixels/state -> encoder -> z_enc (B, T, 192)      # ViT-Tiny frozen + projector
action       -> ActionMLP -> a_emb (B, T, 192)    # 1-layer linear
h_in = z_enc + a_emb
h, spike = MultiCompStack(h_in)                   # 4 layers
trace = GatedSpikeTrace(spike, ctx=[a_emb, h])    # content-aware gated
z\_final = readout(h, spike, trace)                # per ReadoutMode
```

forward 的完整数学链（统一记号：观测编码器 Enc_o 、动作编码器 Enc_a ）：

1. **编码**： $e_t = \text{Enc}_o(o_t) \in \mathbb{R}^d$ （state 模态为 2 层 MLP + SiLU；pixel 模态为冻结 ViT-Tiny + Linear→SiLU→Linear）， $u_t = \text{Enc}_a(a_t) = W_a a_t + b_a \in \mathbb{R}^d$ （ActionMLP 单层线性， $W_a \in \mathbb{R}^{d \times A}$ ）
2. **堆栈输入**： $h_t^{(0)} = e_t + u_t$ （对应代码 `h_in = emb + act_emb`，逐元素相加）
3. **堆栈**（4 层，第 ℓ 层：MultiComp 单元 $\rightarrow 12 \times$ 扩展 MLP $\rightarrow$ 残差 + LayerNorm）：

$$h_t^{(\ell)} = h_t^{(\ell-1)} + \text{LN}(\text{MLP}^{(\ell)}(s_t^{(\ell)})), \quad h_t \equiv h_t^{(4)}, \quad s_t \equiv s_t^{(4)}$$

（各层脉冲 $s_t^{(\ell)}$ 由第 ℓ 层 MultiComp 单元在输入 $h^{(\ell-1)}$ 下按上式产生； $\text{MLP}^{(\ell)}$ ：Linear→GELU→Linear，hidden = $12 \times d$ 。堆栈丢弃膜电位序列， h_t 是输入与脉冲的可学习函数）

4. **门控迹**： $r_t = \text{GatedSpikeTrace}(s_t, [u_t; h_t])$ （公式见下）
5. **读出**： $z_t = \text{Readout}(h_t, s_t, r_t)$ （按 ReadoutMode，见 §6 列表）

架构参数总结：

- **n_layers** = 4: 4 层 SNN；trainable = 5.06M（校准对 $n_{\text{layers}}=2 \rightarrow 4$ 的 $\text{delta} < 0.004$ ）
- **n_d** = 3: 每细胞 3 个 dendrite 室
- **trace_beta** = 0.9: trace 初始衰减率
- **trainable** = 5.06M（state 模态 total = trainable；pixel 模态另含冻结 ViT-Tiny 5.46M，total $\approx 10.46\text{M}$ ，不计入可训练）

4.12.2 Trace dynamics 完整公式

trace $r_t \in [0, 1]^d$ 是内容感知的脉冲后轨迹。其动力学由**两步**定义：

Step 1: 遗忘门 (`GatedSpikeTrace.forward`):

$$\alpha_t = \sigma(W_{\text{gate}} \cdot [r_{t-1}, s_t, c_t]), \quad W_{\text{gate}} \in \mathbb{R}^{d \times (2d + d_{\text{ctx}})}$$

其中 $c_t = [u_t, h_t] \in \mathbb{R}^{2d}$ 是当前**动作嵌入** ($u_t = \text{Enc}_a(a_t)$, 非原始动作 a_t ; 代码 `context = cat([act_emb, h])`) 与连续隐藏状态的拼接; W_{gate} 是单层 **Linear** (权重零初始化、`bias = log(0.9/0.1)`), 使初始 $\alpha_t \equiv 0.9$ (`trace_beta`)。门控输入含 r_{t-1} 自身 (自循环), 故 α_t 依赖迹线历史——内容感知遗忘的来源。

Step 2: trace 更新:

$$r_t = \alpha_t \odot r_{t-1} + (1 - \alpha_t) \odot s_t, \quad r_t \in [0, 1]^d$$

三个内禀性质:

1. **逐维有界于** $[0, 1]$: 因为 $\alpha_t \in [0, 1]$ 且 $s_t \in \{0, 1\}$, 归纳可得 $r_t \in [0, 1]$
2. **内容感知遗忘**: 当上下文 c_t 表示”输入分布变了”时, α_t 趋近 0——trace 快速遗忘; 反之 α_t 趋近 1——trace 长期保留
3. **事件驱动**: trace 只在 $s_t \neq 0$ 时有显著更新 (无脉冲时 $\alpha < 1$ 导致指数衰减)

4.12.3 6 个 readout 的数学定义 (来自 `STJEW._readout`)

- **TRACE_ONLY**: $z = \text{trace_proj}(r_t)$, 其中 `trace_proj = Linear(d, d)`; honors membrane-forbidden 协议
- **HIDDEN_LEAK**: $z = h_t + \text{trace_proj}(r_t)$ (legacy v2 默认; 部分违反协议, 因为 h_t 暴露了连续值)
- **MEMBRANE_READOUT**: $z = h_t.\text{detach}()$ ——视 h 为离散潜状态; **明确违反协议**
- **SPIKE_GATED** (legacy `SPIKE_ONLY`): $z = h_t \cdot s_t.\text{detach}()$, 连续 $\times$ 二值掩码; honors 协议
- **RAW_SPIKE**: $z = \text{raw_spike_proj}(s_t.\text{detach}())$; pure spike; honors 协议
- **RATE_ONLY**: $z = \text{AvgPool1d}(s_t.\text{detach}())$, `kernel_size=4, stride=1, padding=2`; honors 协议
- **NO_TRACE**: $z = h_t$ (无 trace 分支; ablation)

所有 membrane-forbidden 协议的读出口径都满足: z 仅依赖于 $\{s_t, r_t, c_t\}$, **不依赖于 h_t 的连续值**。这是接口合约的数学承诺。

4.13 6 个非 STJEWM 对比模型（详细配置）

4.13.1 自研 SNN 对照的设计动机：它们要对比什么

协议的核心问题是“规划器可见的潜状态到底是什么”。为回答它，三个自研 SNN 对照按三个独立的设计轴构造，分别隔离一个变量：

1. **轴 1：事件驱动发生在哪一层（感知层 or 循环层）。**ST-JEWM 是**纯脉冲循环动力学**（循环层事件驱动、持续）。**LIF-Transformer** 让事件驱动只出现在**感知编码器**，循环记忆由连续 Transformer 承担——检验“脉冲只在输入侧、记忆连续”的中间形态；**ALIF-timecell** 让感知与循环都是自适应 LIF，但时间聚合交给显式 1D 卷积 time-cell 读出（而非 ST-JEWM 的 gated trace）——检验“时间聚合机制”是否是校准的充分条件。
2. **轴 2：记忆载体（连续 vs 脉冲）。****LIF-Transformer** 的记忆是连续 Transformer 隐状态；**Stacked-LIF** 与 ST-JEWM 的记忆都是纯脉冲序列。该轴检验：**连续记忆载体本身**（与脉冲感知配对）是否就足以产生校准潜状态。
3. **轴 3：读出接口（膜电位 vs 脉冲/trace）。****ALIF-timecell** 与 **Stacked-LIF-free** 向规划器暴露连续膜电位（**违反协议**）；**Stacked-LIF-trace** 只提供脉冲移动平均（**协议合规**）。该轴检验：在事件驱动循环家族内，**读出接口是否决定校准**——若协议内 trace 与协议外膜电位同样校准，则“接口不是校准的关键，事件驱动循环动力学才是”。

三个对照与连续家族（GRU/MLP/LeWM-v2）一起构成解码矩阵：事件驱动循环 × 连续循环 × 无循环，各配读出接口两极。**已有结果（见 §4.2 与 §5）**：ALIF-timecell、Stacked-LIF-trace/free 与 ST-JEWM 全部校准（cos-dist 0.103–0.123）；LIF-Transformer 与 GRU/MLP 一起崩塌（ ≤ 0.020 ）。即：**只要循环层是事件驱动的，无论读出接口（trace/膜电位）都校准；只要记忆是连续的（GRU、LIF-Transformer），都崩塌。**这直接把“校准性”归因到事件驱动循环动力学，而非协议接口本身——与 Spiking-WM 对比（外部竞品的连续读出同样低对齐）一致。

4.13.2 三个自研 SNN 对照（功能名）

重要声明：以下三个 SNN 对照为本项目自研实现，名字是**架构功能描述**（不引用任何外部文献或代码库；早期代码注释中的文献名未经核实，已撤销）。代码与 checkpoint 目录中的历史标识（alif_timecell_baseline、lif_transformer_baseline、stacked_lif_trace/free）与功能名对应关系如下。它们复用 ST-JEWM 的 LIFCell 与投影组件构建。

- **ALIF-timecell**（代码标识 alif_timecell_baseline；SNN，自研，5M-aligned trainable = 4.98M，**违反协议**——暴露膜电位）：**多时间尺度自适应 LIF（ALIF）**。每层 ALIF 维护 v_t ，发放后 refractory 强制重置； b 自适应阈值随脉冲累积增加；多层膜电位拼接后经 1D 卷积 time-cell 读出（kernel 256 / stride 128 $\rightarrow$ 8 个时间锚点）。**设计目的**：用“自适应阈值 + 显式时间卷积”替代 ST-JEWM 的 gated trace 做时间聚合，检验**时间聚合机制**是否决定校准（轴 1 对照）。规划器可读膜电位 v_t 。5M 配置：d_hid=186, n_layers=2
- **LIF-Transformer**（代码标识 lif_transformer_baseline；**混合 LIF + Transformer**，自研，5M-aligned trainable = 5.12M，**违反协议**——读连续 Transformer 隐状态）：LIF 脉

冲编码器只做感知，循环预测由 AdaLN-zero Transformer 承担。**设计目的**：检验“事件驱动仅在感知层、记忆为连续”的中间形态是否校准（轴 1 + 轴 2 对照；与 Stacked-LIF 的纯脉冲记忆直接对置）。规划器可读 Transformer 隐状态。5M 配置：d_snn=288, d_tx=288, num_layers=3, num_heads=8

- **Stacked-LIF-trace**（代码标识 stacked_lif_trace; SNN, 自研, 5M-aligned trainable = 5.11M, 膜电位禁止——协议合规）：堆叠 LIF 循环动力学，读出 $z = \text{moving_average}(s_t, k=4)$ （脉冲移动平均）。**设计目的**：最接近 ST-JEWM 的协议内对照——纯脉冲循环记忆 + 脉冲读出，区别仅在“移动平均”与“gated trace”两种时间滤波（轴 3 的协议内一极）。5M 配置：d_in=672, embed_dim=672, n_layers=8, trace_beta=0.9, k_avg=4
- **Stacked-LIF-free**（代码标识 stacked_lif_free; SNN, 自研, 5M-aligned trainable = 5.05M, 违反协议——暴露膜电位）：同架构，但读出 $z = \text{concat}(s_t, v_t)$ （脉冲 + 膜电位拼接）。**设计目的**：同一事件驱动循环动力学的膜电位暴露孪生体——与 trace 变体逐字对比，检验读出接口是否是校准变量（轴 3 的协议外一极）。5M 配置：d_in=640, embed_dim=640, n_layers=8
- **LeWM Transformer baseline**（Transformer, 5M-aligned trainable = 4.97M, 违反协议）：自研 LeWM 参考实现的 AdaLN-zero Transformer（参考实现 6 层 5.07M；5M 配置 embed_dim=288, num_layers=3, num_heads=8）。规划器可读 Transformer hidden state。**设计目的**：连续循环记忆家族的 Transformer 极点（与 GRU 一起代表“连续记忆”）。
- **GRU baseline**（连续循环神经网络, 5M-aligned trainable = 5.13M, 违反协议）：hidden=560, num_layers=2。标准 GRU 隐状态可读。**设计目的**：连续循环记忆家族的“最小神入”对照——与 Stacked-LIF 共享循环聚合，但门控连续。**关键对照**：若事件驱动循环是校准必要条件，则 GRU 必须崩塌（实测 $\rho = -0.0074$ 、cos-dist 0.020）。
- **MLP baseline**（无状态 FFN, 5M-aligned trainable = 5.00M, 作为坍塌对照）：hidden=640, num_layers=12 纯前馈，无循环。所有时间步都从当前 obs 重新预测。**设计目的**：无记忆极点——预期（且实测）潜状态坍塌为常数（div $\rightarrow 0$ ，LeWM-SR 97.3% 却将其评为最高分，见 §4 度量批判）。

总 13 个模型：6 STJEWM 读出口径 + 7 非 STJEWM 对照（其中 6 个非 MLP 对照都有循环 / 记忆能力；MLP 是无状态对照）。模型清单见 §4.2 的 4 家族分类表。

4.14 真实外部竞品：Spiking-WM (中科院自动化所 Brain-Cog-Lab, PNAS 2025)

除上述自研对照外，我们引入**真实可验证的外部竞品**：Spiking-WM (Sun, Zhao, Lv & Zeng, arXiv:2503.00713, 正式发表于 PNAS 2025, doi:10.1073/pnas.2513319122; 开源代码 <https://github.com/Brain-Cog-Lab/Spiking-WM>, MIT 协议)。这是目前最接近“标准 Dreamer 风格 World Model + SNN”的公开工作，也是 multi-compartment 神经元路线与本项目 ST-JEWM 的直接同行工作：

- **核心贡献**: Multi-Compartment Neuron (MCN) —— 受树突非线性整合启发, apical/basal/soma 三腔室积分, 显著提升 SNN 长时序记忆; 全文 (DMC + SHD/TIMIT/LibriSpeech) 验证。
- **架构**: spiking encoder + MCRNN 动力学 (递归状态为**纯脉冲序列** $\{s_t^T\}_{t=1}^T$, 膜电位为内部状态——与本项目 **membrane-forbidden 协议一致**) + spiking decoder/actor, Dreamer 风格端到端 model-based RL。
- **与 ST-JEWM 的差异**: 其规划器/actor 读到的是从脉冲序列解码的**连续随机状态** (posterior/prior 分布参数), 即 “事件驱动动力学 + 连续规划接口”; ST-JEWM 则要求规划器只读有界 post-spike trace。
- **我们做的对比**: 下载官方代码, 在 proprioceptive (状态输入) 配置下于 12 个 DMC 任务 (见下表) 各按难度训练 ($2-5 \times 10^5$ 环境步), 报告官方 episode return + 我们的协议指标 (event- ρ 、cos-dist、脉冲激活率)。

4.14.1 为什么 pusht / tworoom / reacher-4D / stacker / delayed-t-maze / humanoid-CMU 无法用 Spiking-WM 运行

ST-JEWM 的 10-split 设定还包含 6 个 **custom 环境**, 它们不是 dm_control 标准任务, Spiking-WM 的官方代码只注册了 dm_control / Atari / DeepMind Lab / Crafter / Memory Maze / Minecraft 六个环境套件, **无法实例化这些自定义域**。逐一说明:

- **PushT** (跨基准族 F3 留出): **自研像素 + 状态 PushT** (T 形物体推入目标区域), 来自 LeWM 参考实现, **非 dm_control 套件**; Spiking-WM 的 make_env 无 PushT 注册、也无法映射到任何 dm_control 域 (无 push 类任务)。→ 排除。
- **TwoRoom** (跨基准族 F2 留出): **自研双房间导航状态环境** (16-bucket 离散状态 + 4 动作 + 门控记忆), 完全自研、非公开套件; Spiking-WM 无对应 (dm_control 无导航/离散状态任务)。→ 排除。
- **Reacher-4D** (跨基准族 F1 留出对应的自制域): ST-JEWM 使用的 **reacher** 是 **4 维简化状态版** (reacher 4D, 含 2D 位置 + 2D 目标差, 观测结构为自定义 state 向量); dm_control 标准 reacher 域 (**reacher_easy**) 的观测是 2D 关节角 + 2D to_target + 2D 速度, 维度/语义均不同。→ Spiking-WM 只能跑标准 reacher_easy, 作为**同语义近似** (表中已标注)。
- **Stacker**: dm_control 没有 “堆叠” 任务 (栈式操作属于 Robosuite/自定义); Spiking-WM 无对应域。→ 排除。
- **Delayed T-Maze**: **自研延迟决策环境** (T 形迷宫 + 50 步延迟线索 + 记忆门控), 非公开套件、无 dm_control 等价 (dm_control 无迷宫/离散决策任务)。→ 排除。
- **Humanoid-CMU**: dm_control 1.0.44 的 humanoid 域只有 run/walk/stand 三个 level, **没有 CMU (Carnegie Mellon mocap data) 变体**; ST-JEWM 的 humanoid_CMU 是该自定义变体 (CMU 参考姿态/动力学参数)。→ Spiking-WM 用标准 humanoid_run 近似 (表中已标注)。

影响与说明：跨基准留出族 (F2 TwoRoom / F3 PushT / F1 的 reacher-4D) 正是 ST-JEWM 验证 **out-of-distribution 跨域泛化** 的设计核心；Spiking-WM 无法在这些跨基准域上运行，因此外部对比限定在 **12 个 dm_control 任务** (覆盖 ST-JEWM 的 DMC 训练/留出子族)，跨基准泛化对比只能由自研对照 (GRU/MLP/LeWM-v2 等，见表一) 承担。报告中所有 Spiking-WM 对比单元格均不超出这 12 个任务。

4.14.2 Spiking-WM 对比实验结果 (seed 0, RTX 4090, proprio 配置, 12 任务)

任务	SpWM return	ST SR	env- cos	ST cos	SpWM latent ρ	SpWM stoch ρ	SpWM spike-rate ρ
cartpole_swingup	229.7	1.00		0.112	0.392	0.150	-0.002
cheetah_run	105.1	1.00		0.006	0.560	0.222	0.005
walker_walk	211.8	0.00*		0.091	0.456	0.216	0.000
finger_spin	229.8	1.00		0.125	0.656	0.395	-0.002
pendulum_swingup	0.0	0.20		0.064	0.521	-0.000	0.017
cup_catch	758.8	1.00		0.000	0.797	0.298	-0.013
reacher_easy	421.0	0.00		0.124	0.778	0.459	-0.001
hopper_hop	0.0	0.20		0.068	0.581	0.273	-0.034
quadruped_walk	26.6	0.00		0.079	0.213	0.026	-0.023
dog_walk	10.8	0.00		0.176	0.051	-0.006	0.021
fish_swim	48.3	0.20		0.352	0.436	0.100	-0.013
humanoid_run	1.4	0.00		0.141	0.239	0.058	0.027

预算 (环境步): pendulum/cup/reacher 2×10^5 , hopper/fish 3×10^5 , 其余 5×10^5 。trian_ratio 64 (官方 512, 计算预算原因)。*walker_walk 对 F1 checkpoint 是留出族 (STJEWM 从未见过 walker 数据)；Spiking-WM 直接在 walker 上训练。ST-JEWM $\rho \geq 0.9986$ (表一)，表中未重复列出。custom env (pusht/tworoom/reacher-4D/stacker/delayed-t-maze/humanoid-CMU) 无 dm_control 等价物，Spiking-WM 无法运行，已排除。

结果解读：

- **可学习性 (全任务)：**Spiking-WM 解决易任务 (cup_catch 758.8、reacher 421.0, 满分 1000)，学会中等任务 (cartpole 229.7、walker 211.8、finger 229.8、cheetah 105.1)，但难任务失败 (pendulum 0.0、hopper 0.0、quadruped 26.6、dog 10.8、fish 48.3、humanoid 1.4) —— 这些也是 Dreamer 家族在同等预算下的已知难点。纯脉冲序列动力学可以支撑 model-based 控制，但在本预算下仅限简单-中等任务。
- **协议判定：**其动力学隐状态是 MCRNN 脉冲序列 (膜电位为内部状态——协议合规的动力学)，但规划器/actor 读到的是从脉冲序列解码的**连续后验均值** (连续规划接口——按读出违反协议)。
- **事件对齐 (同口径, 12 任务)：**观测-潜变量一阶差分 Pearson ρ ：STJEWM 家族 ≥ 0.9986 (5.06M 参数) 在**每一任务上**均远超 Spiking-WM (0.05–0.80, 均值 0.47; **28.5M 参数**)。Spiking-

WM 的 MCRNN 脉冲平均活动对齐 (spike-rate 口径) 全部机会水平 (-0.034 – 0.027), 与 STJEWMM 自身 spike-rate 口径 (0.000 – 0.017) 同水平: **两种系统里原始脉冲计数聚合都不跟踪观测变化**, 而 STJEWMM 的 gated trace 潜状态跟踪。

- **稀疏性**: Spiking-WM MCRNN 平均激活率 0.8% (比我们协议暴露的 trace 稀疏一个数量级); 对齐缺口在其失败任务上最大 ($\log \rho = 0.05$, quadrupled 0.21) —— 极端稀疏且无 trace 机制时, 规划侧潜状态与观测动力学脱钩, 这正是本协议设计要诊断的失败模式, 且发生在最接近的公开系统而非仅自研对照中。
- **对比局限**: Spiking-WM 是在线 actor-critic 训练 (无 goal-conditioned CEM 协议)、28.5M 参数 vs 5.06M、proprio 配置 + 降低更新频率; hard tasks 的失败同时也是 Dreamer 家族同等预算下的已知现象。

相关工作 (无代码, 定性讨论): Capone & Paolucci (Sci. Rep. 2024, doi:10.1038/s41598-024-65631-y) 提出双模块 (agent + model) 递归 SNN, 通过 “dreaming” (在内部世界模型中模拟新经验) 提升 sample efficiency, 无需经验回放、在线学习, 面向神经形态硬件; 无公开代码, 本报告仅在相关工作中讨论。

4.15 4 个 baseline 家族的角色

家族	模型	测试什么
STJEWMM 读出口径	trace / spike / rate / no-trace / leak / membrane	同一 SNN 骨架, 6 种接口变量
连续循环对照	LeWM Transformer, GRU, stateless MLP	连续循环、循环、记忆缺失(坍塌对照)
SNN / 神经形态对照	ALIF-timecell, LIF-Transformer, Stacked-LIF-trace, Stacked-LIF-free	已有 SNN 世界模型及其各自的轨迹约定

4.15.1 膜电位禁止协议的接口合约

正式定义为:

协议. 给定一个脉冲动力学系统 (v_t, s_t, r_t) 与一个下游规划器, 规划器只能读取 r_t (post-spike trace), 不能读取 v_t (membrane potential)。

协议在接口层强制 (不是训练时正则化项):

- **不是 loss term**: 训练 loss 不显式包含”隐藏 v_t ” 的惩罚
- **是 interface contract**: planner.observe() 只接收 r_t ; 即使 v_t 在内部流动, 也不暴露
- **6 个 readout 中 4 个 honor 协议**: trace_only, spike_gated, rate_only, raw_spike

- **2 个 ablation 不 honor 协议**: `membrane_readout` (直接读 h) , `hidden_leak` ($h + \text{trace_proj}(r)$) 仍依赖 h)

4 个 baseline 家族共同构成本文的可测试声明: 如果 STJEWLM 的”校准非坍塌”性质是膜电位禁止协议的属性, 则 6 个禁止读口的读出口径应全部落在校准区域; 如果是膜电位读出口径的属性, 则仅有 `membrane` 读出口径应在那里。

4.15.2 为什么 13 模型足够 (可证伪性论证)

核心声明: 膜电位禁止协议 + trace dynamics 自带的 content-aware 衰减 = 跨基准族泛化所需的全部物理偏置。

13 模型的覆盖性:

1. **6 STJEWLM readout**: 剥离了”哪个接口变量被读到”的影响, 只保留 trace dynamics
2. **4 SNN baseline**: ALIF-timecell / LIF-Transformer / Stacked-LIF ($\times 2$) 各自代表一种 SNN 世界模型设计, 提供**对照**——证明 STJEWLM 不是”SNN 范式本身就行”
3. **2 循环非 SNN baseline**: GRU / LeWM Transformer 代表连续循环 + attention, 证明 STJEWLM 不是”循环结构本身就行”
4. **1 无状态对照**: MLP 证明 STJEWLM 不是”前馈结构也行”——它必须 $\text{div} \rightarrow 0$ 坍塌

任何未来提出的新模型都可以归入这 4 家族之一 (或者证明第 5 个家族的存在——这本身就是一个科学贡献)。

5 训练流程

5.1 优化器与学习率调度

所有 13 个模型使用 AdamW (来自 `code/train/train.py:176`), $\text{lr} = 3 \times 10^{-4}$, $\text{weight_decay} = 10^{-3}$ 。

梯度裁剪: `torch.nn.utils.clip_grad_norm_(parameters, 1.0)` (`train.py:277`)。clip 范数 = 1.0 防止脉冲稀疏性爆炸时的大梯度。

5.2 损失函数 (3 项联合损失)

STJEWLM 的训练损失 (`code/native_losses.py:stjewm_loss`) 由 3 项加权组成:

$$\mathcal{L} = \mathcal{L}_{\text{pred}} + \lambda_{\text{sigreg}} \cdot \mathcal{L}_{\text{sigreg}} + \lambda_{\text{goal}} \cdot \mathcal{L}_{\text{goal}}$$

逐项定义 (窗口 w_s : 帧 $o_s \dots o_{s+H+G}$, $H = 1$, $G = 25$; 所有目标项均 stop-gradient 阻止坍塌):

- **预测损失**: $\mathcal{L}_{\text{pred}} = \|\hat{z}_{s+1} - \text{sg}(z_{s+1})\|^2$, 其中 $\hat{z}_{s+1} = f_{\text{pred}}(z_s, a_s)$ 是模型 `predict` 的下一步潜状态, z_{s+1} 是同一前向中第 $s+1$ 帧的真实潜状态。`train.py` 中 $T_{\text{pred}} = \min(H, t_{\text{pred}}, \text{goal_offset}) = 1$ (5M 配置), 故只有单步预测项; `F.mse_loss` 在 `stjewm_loss` 内对目标 detach

- **SIGReg 正则** (`code/sigreg.py:SIGReg`, Epps-Pulley 特征函数距离): 作用在**编码器输出** (`emb_pre_cell`, 即 e_t , 不含动作与堆栈) 的**全部窗口帧**上。取 $M = 1024$ 个随机单位投影 $A_j \in \mathbb{R}^d$ (每次 forward 重新采样、detach), knot 网格 $t \in [0, 3]$ (17 点, 梯形权重 $w(t)$), 与标准正态特征函数 $\phi(t) = e^{-t^2/2}$ 比较:

$$\mathcal{L}_{\text{sigreg}} = \frac{T}{M} \sum_{j=1}^M \int_0^3 \left[\left(\frac{1}{T} \sum_t \cos(t A_j^\top e_t) - \phi(t) \right)^2 + \left(\frac{1}{T} \sum_t \sin(t A_j^\top e_t) \right)^2 \right] w(t) dt$$

返回标量 ~ 0 当各边缘分布接近各向同性标准高斯——防止潜状态坍塌为常数或退化分布。

注意: 早期报告中的“KL spike-rate 目标带”表述是错误残留, 与本实现不符, 已删除

- **Goal 损失** (teacher-forced, 非自回归滚动):

$$\mathcal{L}_{\text{goal}} = \left\| \underbrace{z_{s+H+G-1}^{\text{tf}}}_{\text{前 } H+G \text{ 帧 teacher-forced 前向的末帧 latent}} - \text{sg}(z_{s+H+G}^\emptyset) \right\|^2, \quad z_{s+H+G}^\emptyset = f(o_{s+H+G}, \mathbf{0})$$

即: `goal_pred` = 窗口前 $H+G$ 帧 (含中间真实状态) 前向的最后一个潜状态 (索引 $H+G-1$); `goal_emb_target` = 窗口**末帧** (索引 $H+G$) 以**零动作**独立编码的潜状态。语义: “goal 帧的潜状态应等于其下一帧的嵌入” (一步前瞻对齐)。**索引细节:** 训练目标帧 (索引 $H+G$) 比评测数据集的目标帧 (`goal_state = o_{s+G}`, 索引 G) **晚 1 帧**——训练教的是相邻帧潜状态一致性, 评测时 CEM 以 o_{s+G} 自身的嵌入为目标

具体权重: $\lambda_{\text{sigreg}} = 0.09$ (弱正则, 避免破坏 trace 动态), $\lambda_{\text{goal}} = 0.5$ (goal 是 planner 的实际目标, 给予较大权重)。

不同 baseline 的 native 损失: ALIF-timecell 用 `alif_timecell_loss` (pred + L1 spike sparsity); LIF-Transformer 用 `lif_transformer_loss` (pred + KL + recon + sparse); Stacked-LIF 用 `stacked_lif_loss` (pred + sparse + action); 其他基线 (LeWM Transformer / GRU / MLP) 沿用 STJEW 的 3 项损失。所有损失通过 `code/native_losses.NATIVE_LOSS_DISPATCH` 在 `train.py:219` 处按 `args.model` 分派。

5.3 batch 构造与损失归约

batch 内样本来源: 每个 batch 由 $B = 32$ 个 (history_size 帧 + goal_offset 帧 + 1 帧) 序列组成。在多 env 训练 (G16) 时, B 个样本从所有 env 的混合 buffer 中随机抽取——**不是 per-env batch**, 因此一个 batch 内可能含不同 env 的样本。每个样本的 obs 都已 pad 到 `pad_obs_to`, 所以模型无需 per-env 区分。

padding 方案: obs_dim pad 到 128 (G16 设置), action_dim pad 到 56。padding 用零填充; 模型读 padded obs; env.step 仅取前 action_dim 维。

损失归约: 所有损失分量在 batch 维度上取 mean (PyTorch `F.mse_loss` 默认 `reduction='mean'`)。不进行 per-env 归一或加权——因为不同 env 的样本频率已经由 buffer 大小隐式平衡。

5.4 训练配置 (5M-aligned, v0.7.14–v0.7.19)

总览: 所有训练通过 `code/train/train.py` 统一入口, 以 `--multi-env-spec` JSON (`configs/oodc_5m/*.json` 与 `configs/oodc_5m_pixel/*.json`) 指定 10 个 split。5M 配置统一

为: AdamW, lr=3e-4, weight_decay=1e-3, batch=32, 1 epoch, max_windows=2000/env, history_size=1, goal_offset=25, pad_obs_to=128, action_dim=56; STJEWMM 用 n_layers=4 (5.06M trainable, 参数公平), 其余模型按各自 5M-aligned 默认 (见 §5.4)。

regime	网络	ckpt 数	训练入口	用途
5M state (seed 0)	13 模型 × 10 splits	130	train_one_5m.sh / launch_parallel.sh	三簇分界主表
5M pixel (seed 0)	13 模型 × 10 splits × image_size=84	130	train_all_130_pixel.sh	跨模态保留
3-seed (G5/B2)	3 splits × 8 模型 × seed 1/2 重训	47/48	B2_multiseed_launcher.sh	95% CI
sigreg 扫描	4 权重 × 2 splits	8	train_sigreg_sweep.sh	sigreg 假设检验
多 epoch (P13)	3 模型 × 2 splits × 3,5 epochs	12	train_one_5m.sh --epochs N	非训练量假象

```
# 5M state (示例: oodc_F1 split 的 STJEWMM-trace)
python -m code.train.train --model stjewmm --multi-env-spec configs/oodc_5m/oodc_F1.json \
  --pad-obs-to 128 --action-dim 56 --embed-dim 192 --image-size 0 --n-layers 4 \
  --epochs 1 --batch 32 --lr 3e-4 --history-size 1 --goal-offset 25 --seed 0 \
  --readout-mode trace_only --out results/5m_5mpar/oodc_F1/stjewmm_trace_only/seed_0
# 5M pixel: 同参数 + --env-kind dmc_pixel --image-size 84
```

10 个 split 的构成(configs/oodc_5m/): 3 个跨基准族(cross_benchmark_F1/F2/F3:PushT / TwoRoom / Reacher 分别 held out) + 6 个 OOD 连续性 (oodc_F1, oodc_F1F2, oodc_F1F3, oodc_F2, oodc_F2F3, oodc_F3) + 1 个 generalist 16-env 并集 (generalist_16env)。每个 split 的 specs 列出训练 env 与每 env 的 history_size / goal_offset / max_windows; 评测 env 独立列出 (_eval_envs), 见 §5.5 的 eval-once-eval-everywhere 模式。

总结: state 模态 13 模型 × 10 splits × 1 seed = 130 ckpt (STJEWMM 在 results/5m_5mpar/ 公平重跑, baselines 在 results/5m/) , pixel 模态另 130 ckpt; 权威 per-cell 表见 results/journal_prep/MAIN_TABLE_5M_STATE_FULLL.md (1157 cells) 与 MAIN_TABLE_5M_PIXEL_FULLL.md (1690 cells)。

5.5 评测-once-eval-everywhere 模式 (OOD Path-C 的特殊 holdout pattern)

为什么 split 持有某个子族: DMC 的 3 个子族 (classic / locomotion / sparse-POMDP) 有不同的动力学本质:

- **classic:** 低维 proprioception + 简单动力学 (cartpole、pendulum、finger、ball_in_cup)
- **locomotion:** 高维 proprioception + 关节动力学 + 接触 (cheetah、walker、hopper、quadruped、humanoid、humanoid_CMU、dog、fish、stacker)
- **sparse-POMDP:** 目标位置在状态外 / 不可观测, 需要推断 (reacher、delayed_t_maze、cheetah_velhidden 等 stress env)

持有其中一个子族 = 测试模型是否在”完全未见过的动力学”上保持校准。这是 working title 的 gating experiment。

eval-once-once-eval-everywhere: 每个 split 训练 1 个 ckpt, 但评测时在所有 14 个 DMC env 上评估 (不仅是 held-out 子族)。这产生两种评测:

- **持有 env** ("held-out"): 测试 OOD 泛化——模型从未见过该 env
- **已见 env** ("seen"): 测试 ID 表现——模型在训练集上

~1200 个 cell = 6 个 oodc split + 3 个跨基准族 split + 1 个 G16 split, 共 10 个 split $\times$ 13 models $\times$ 平均 ~9 envs (每个 split 评测 5-14 envs) 包含了两者。看 **STJEW** 是否对两种都校准: 是 working title 的核心可证伪点。

单 ckpt 训练时长:

- **Single-task (1 epoch, 10K windows):** ~ 5 分钟 (batch=32, 每 epoch 313 步)
- **Cross-bench (5 epochs, ~160K windows):** ~ 25 分钟 (13 模型 $\times$ 16 env 并行 batch)
- **OOD Path-C (1 epoch, ~12K windows):** ~ 3 分钟
- **G16 (1 epoch, 32K windows):** ~ 30 分钟 (16 env 并行 batch)

评测时长:

- 单 cell (30 episodes $\times$ 1 seed, 100 CEM samples): ~ 30 秒 (单 GPU)

总预算:

6 测试流程

6.1 单 cell 评测流程 (closed-loop)

每个 cell = 在一个 (ckpt, eval_env) 对上做以下步骤 (5M 配置: n_episodes=5, n_seeds=3, CEM 300 $\times$ 30 $\times$ 10, horizon=5, eval_budget=50, goal_offset=25, history_size=1):

1. **从数据集采样** (init, goal) 对: 窗口 w_s 的 $\text{init_state} = o_s$ 、 $\text{goal_state} = o_{s+G}$ 。不是随机初始化——用真实轨迹窗口, 避免目标分布在训练集外
2. **编码:** $z_{\text{init}} = \text{Enc-Readout}(o_s, \mathbf{0})$ (零动作, `encode_obs`); $z_{\text{goal}} = \text{Enc-Readout}(o_{s+G}, \mathbf{0})$; z_{history} 为 H 份 z_{init} 的堆叠
3. **CEM 规划:** 以 z_{history} 为初始潜状态, 优化 horizon $H = 5$ 步动作序列使预测潜轨迹末端接近 z_{goal} (算法见 §6.2, $N = 300$, $K = 30$, $T = 10$)
4. **整块执行:** 把最优序列的**全部** H 步动作 (clip 到动作界) 依次送入真实环境 `env.step`
5. **重规划:** 用模型自回归预测推进潜上下文 (**不读真实观测**) : $z_{\text{history}} \leftarrow [z_{\text{history}}[1 :], f_{\text{pred}}(z_{\text{history}}, \text{seq}[: H_{\text{ctx}}])[-1]]$ ($H_{\text{ctx}} = \text{history_size} = 1$, 即只用最优序列的第 1 步动作做预测), $z_{\text{init}} = z_{\text{history}}[-1]$; 重复直至 actions ≥ 50 或 episode 结束

6. 报告:

- **mean_cos_dist:** $\frac{1}{2}(1 - \cos(z_{\text{final}}, z_{\text{goal}}))$, z_{final} = 真实最终状态 o_{final} 的零动作编码 (主指标)

- **env-SR**: 环境原生成功判定 (DMC ‘check_success’, tol=0.1)
- **LeWM@0.05**: $\Pr[\cos_{\text{dist}} < 0.05]$ (被证伪指标, 仅叙事用)

什么是 CEM: Cross-Entropy Method 是一种基于采样的规划算法。每轮在潜状态空间采 $N = 300$ 个动作序列, 保留成本最低的 $K = 30$ 个 (elites) 重新估计高斯分布 (均值 μ 、标准差 σ), 重复 $T = 10$ 轮后从收敛分布再采样一轮取最优。CEM 的核心假设是”潜状态空间是好的规划空间”——如果潜状态是坍塌的常数, CEM 就在做无意义的搜索; 如果潜状态是过反应的放大器, CEM 的梯度信号爆炸。

6.2 CEM 规划器 (详细算法)

CEM 完整数学与 pseudocode (code/core/cem.py:CEM.plan, 与代码逐行对应):

成本函数 (单条候选动作序列 $a_{1:H}$): 自回归滚动

$$h^{(0)} = \underbrace{[z_{\text{init}}; \dots; z_{\text{init}}]}_{H \text{ 份}}, \quad z_{t+1} = f_{\text{pred}}(h^{(t)}, [a_t; \dots; a_{t+H-1}])[-1], \quad h^{(t+1)} = [h^{(t)}[1:]; z_{t+1}], \quad c(a_{1:H}) = \|z_{\text{final}} - z_{\text{goal}}\|$$

(**L2 成本**, 非余弦距离; **predict** 返回整窗潜状态、取末帧)。

分布迭代 ($N = 300$ 样本、 $K = 30$ 精英、 $T = 10$ 轮、 $\sigma_{\text{init}} = 1.0$):

$$\mu^{(0)} = \mathbf{0}, \quad \sigma^{(0)} = \mathbf{1}; \quad \{a^{(i)}\}_{i=1}^N \sim \mathcal{N}(\mu^{(r)}, \text{diag}(\sigma^{(r)})^2)$$

$$\mathcal{E} = \text{argmin}_K \{c(a^{(i)})\}, \quad \mu^{(r+1)} = \frac{1}{K} \sum_{i \in \mathcal{E}} a^{(i)}, \quad \sigma^{(r+1)} = \text{std}_{i \in \mathcal{E}}(a^{(i)}) \cdot \text{clamp_min}(10^{-4})$$

T 轮后再采样一轮 (第 11 轮) 返回成本最小的序列: `return candidates[ costs.argmin() ]`。采样阶段不做 **clip**——clip 只在执行时 `env.step` 前发生 (`closed_loop.py`)。

默认参数: `n_samples=300, n_elites=30, n_iters=10, horizon=5, sigma_init=1.0` (5M 实验; 旧版 100/10/5 已被 5M-aligned 评测取代)。

Receding-horizon 执行 (block 模式): CEM 返回 $H = 5$ 步序列 `seq` 后, 整块执行 `seq[0:H]` (至多 `min(H, budget - actions_taken)` 步), 然后重规划。潜上下文的推进不读真实观测——`closed_loop.py` 用模型自回归预测更新 z_{history} (见 §6.1 步骤 5)。

closed_loop 完整 step-by-step (code/eval/closed_loop.py:138-355):

1. 加载 ckpt: 按 ckpt 的 `args` 字段构建模型 (STJEWLM 读取 `readout_mode`), 读 `final.pt`
2. 加载评测数据集: 窗口 w_s 的 `(init_state, goal_state)` 对 (`split="in_dist"`)
3. 对每个 seed (5M 配置 3 seeds; 每 seed 5 episodes):
 - (a) 重置 env (带 seed); 若 env 支持 `_set_env_state`, 从 `init_state` 设置
 - (b) 编码: z_{history} (H 份 z_{init})、 z_{goal} (均为零动作编码)
 - (c) 循环: `CEM.plan` → 整块执行 `min(H, budget - taken)` 步 → 模型自回归推进 z_{history} → 重规划, 直到 50 步或 done
 - (d) 终止时编码真实最终状态 z_{final} , 计算 $\cos_dist = \frac{1}{2}(1 - \cos(z_{\text{final}}, z_{\text{goal}}))$
 - (e) 计算 `env.check_success` (env-native)
4. 聚合所有 seed 的 per-episode 结果: `mean_cos_dist, success_rate_lewm, env_SR`

6.3 评测 pipeline 的容差与阈值 (plain 设定)

评测代码里的容差与阈值定义如下 (详见 docs/CODE_BUG_AUDIT.md):

1. **DMC 容差**: DMC `check_success` 使用 $\text{dist} = \|\text{state} - \text{goal}\|_2 / \sqrt{n_q}$ 与阈值 $\text{tol} = 0.1$ 。对 9 个高维 locomotion env (cheetah, walker, hopper, quadruped, humanoid, humanoid_cmu, dog, fish, stacker) 的 87 维 state, 随机 uniform 距离 $\approx 0.45 < 0.1$ 已不成立 (随机通过率 0%)。CEM 5 步规划器达不到 25 步目标, 因此这些 env 的 env-SR 落在 0, `mean_cos_dist` 显露出真信号: STJEW 6 个 readout 全部在 [0.103, 0.123] (v0.7.18.4 公平重跑), MLP/GRU/LIF-Transformer 接近 0 (坍缩), LeWM-v2 在 0.183 (过反应)
2. **LeWM 阈值**: `thresholded-success` 以 $\Pr[\cos_{\text{dist}} < 0.05]$ (严格阈值, 替代早期 $\cos_{\text{dist}} < 0.1$ 阈值——后者让常数 latent 模型也能达到 100%) 和 $\Pr[\cos_{\text{dist}} < 0.01]$ (最严阈值) 为指标; `mean_cos_dist` (raw, threshold-free) 作为主指标

CEM horizon 与 goal_offset 的不一致: CEM 规划器 `horizon=5` 而 `goal_offset=25/100`。`horizon=5` 是 planner budget 限制 (提升到 25-100 让 CEM planning 计算成本不可行: 5 iters $\times$ 100 samples $\times$ 100 steps)。难 env 上 **env-SR = 0 是 horizon artifact, 不是模型失败** (真实 state env-SR 经 v0.7.18.1 修复后呈现“易/难”二分: 易 env 饱和 1.0 (ball_in_cup 1.0, cartpole_2d 0.99, cheetah 0.997, finger 0.89)、难 env 为 0 (dog, humanoid, quadruped, reacher, stacker, tworoom), 每模型均值 0.34–0.38) ——评测时改用 `mean_cos_dist` (不依赖 horizon 长度) 作为主指标。**env-SR aggregation bug (v0.7.18.1)**: `ClosedLoopResult` 漏传 `success_rate_env/std`, 导致 top-level env-SR 显示为 **0.0**; 867 个 state eval JSON 重新聚合后真实信号如上。区分度不在 **env-SR**, 而在 **mean_cos_dist**。

代码 diff (关键行):

```
# code/core/envs/dmc_env.py
"cheetah":      ("cheetah.xml", 9, 6, 200, 0.1), # tol = 0.1 (高维 locomotion env)
"humanoid":     ("humanoid.xml", 28, 21, 200, 0.1),
"dog":          ("dog.xml", 87, 38, 200, 0.1),

# code/eval/closed_loop.py
success_threshold_cos: float = 0.1, # legacy, kept for back-compat
# per-episode record:
lewm_succ_005 = cos_dist < 0.05
lewm_succ_001 = cos_dist < 0.01
# per-seed aggregate:
"success_rate_lewm_005": float(lewm_005_arr.mean()),
"success_rate_lewm_001": float(lewm_001_arr.mean()),
```


评测轴	splits × models × total cells envs	目的	配置文件
轴 1 DMC 内部子族 总览:	6 × 13 × 14	gating experiment	configs/oodc/oodc_F*.json
轴 2 跨基准族	4 × 13 × {1-13}	边界条件	configs/ textttcross_bench/ textttF*_train.json
总计	1300		

轴 1 每个 split 的 cell breakdown:

- oodc_F1: 13 models × 14 DMC envs (其中 8 个 held-out, 6 个 seen) = 182 cells
- oodc_F2: 13 × 14 (其中 7 held-out, 7 seen) = 182 cells
- oodc_F3: 13 × 14 (其中 11 held-out, 3 seen) = 182 cells
- oodc_F1F2: 13 × 14 (其中 2 held-out, 12 seen) = 182 cells
- oodc_F1F3: 13 × 14 (其中 6 held-out, 8 seen) = 182 cells
- oodc_F2F3: 13 × 14 (其中 5 held-out, 9 seen) = 182 cells
- 总计: 6 × 182 = 1092 cells

轴 2 每个 split 的 cell breakdown:

- cross_benchmark_F1 (PushT held out): 13 × 1 = 13 cells
- cross_benchmark_F2 (TwoRoom held out): 13 × 1 = 13 cells
- cross_benchmark_F3 (Reacher held out): 13 × 1 = 13 cells
- cross_benchmark_F4 (DMC held out): 13 × 13 = 169 cells
- 总计: 13 + 13 + 13 + 169 = 208 cells

6.4 每个 cell 的 JSON 字段

- **env_id**: env 的字符串 ID (如 "mujoco/reacher")
- **n_episodes**: 本 cell 每 seed 跑的 episode 数 (5M 配置 5)
- **n_seeds**: seed 数 (5M 配置 3: seed 0/1/2)
- **cem_samples** / **cem_elites** / **cem_iters**: CEM 参数
- **horizon**: CEM horizon (默认 5)
- **eval_budget**: 单 episode 最大 env step 数 (默认 50)
- **goal_offset**: goal_offset 步
- **history_size**: 编码时堆叠的帧数 (默认 3)

- **success_rate_lewm**: $\Pr[\cos_dist < 0.1]$ (legacy, kept for back-compat)
- **success_rate_lewm_005**: $\Pr[\cos_dist < 0.05]$
- **success_rate_lewm_001**: $\Pr[\cos_dist < 0.01]$
- **success_rate_env**: env-native 成功判定 (DMC 上受 CEM horizon=5 vs goal_offset=25/100 限制, env-SR 是 horizon artifact)
- **mean_cos_dist**: CEM 终止时 z_{final} 与 z_{goal} 的平均余弦距离 (主指标)
- **mean_phys_dist**: 物理空间距离 L_2 的均值
- **per_seed**: 每个 seed 的聚合指标列表
- **per_episode**: 每个 episode 的 cos_dist、reward、env_success、plan_time_sec
- **wall_time_sec**: 本 cell 的总 wall 时长

物理诊断 cell (仅 OOD Path-C measure_diagnostic_dmc) 额外字段:

- **divergence**: per-dim 标准差的均值
- **responsiveness**: $\|\Delta z\|/\|\Delta o\|$ 的均值
- **rho**: Pearson 相关系数
- **per_dim_std_max / min**: 最大 / 最小维的标准差
- **n_steps**: 200 步随机 rollout

7 指标定义

7.1 抗坍塌诊断 (先验定义, 来自物理约束)

- **divergence-from-constant (div)**: $\sqrt{\text{Var}(z_{t=1..T})}$, 逐维求平均。在 200 步随机策略轨迹上计算。
 - $\text{div} < 0.001$: 坍塌 (MLP 的 $\text{div} \approx 0.0002$)
 - $\text{div} \in [0.005, 0.05]$: 校准 (STJEW 0.010-0.030)
 - $\text{div} > 0.05$: 过反应 (LeWM-v2 的 $\text{div} \approx 0.18$)
- **responsiveness (resp)**: $\frac{1}{T} \sum_{t=1}^T \frac{\|\Delta z_t\|}{\|\Delta o_t\|}$ (向量范数比值)
 - $\text{resp} \in [0.1, 1.0]$: 校准 (STJEW ≈ 0.2 ; 1.0 = latent 与 obs 同尺度移动的物理零点)
 - $\text{resp} > 1.0$: 放大 (噪声 / 过反应; GRU 22.4, LeWM 32.7)
- **event-alignment ρ** : $\text{Pearson}(\|\Delta o_t\|, \|\Delta z_t\|)$ per step
 - $\rho \geq 0.95$: 校准 (STJEW 全部 $\rho \geq 0.9986$)
 - $\rho < 0.3$: 噪声 (GRU -0.0074 , MLP -0.0233 ; LeWM 0.7515 中等)

7.1.1 阈值标定与合理性论证 (P12 合成验证 + 空白区论证)

阈值如何确定——两步法，全程可追溯：

第一步：自下而上的经验归纳 (v0.7.5)。在 13 个真实模型上实测三个指标后，把阈值取在模型之间的数量级空白区，而不是切在任何模型云内部：div 在 MLP 0.0002 / STJEWLM 0.010–0.030 / LeWM 0.18 之间形成两个数量级级 gap，取 0.001 与 0.05 落在两段空白里；resp 以 1.0 (恒等映射的天然值) 为放大分界； ρ 以 0.3 为“无相关”的统计上界。

第二步：自顶向下的合成标定 (P12, ground truth 已知)。在 DMC cartpole 的 200 步随机轨迹上构造 6 种合成编码器 (constant / identity $k=0.2$ / identity $k=1.0$ / gain $k=10$ / noise $\sigma=0.1$ / uncorrelated noise)，并以增益 k 与噪声 σ 做连续扫描 (results/journal_prep/P12_synthetic/)：

合成编码器 (ground truth)	div	resp	ρ	分类
Constant	0.000	0.000	0.000	collapsed ✓
Identity $k = 0.2$ (STJEWLM-like)	0.028	0.200	1.000	calibrated ✓
Identity $k = 1.0$	0.138	1.000	1.000	over-reactive (边界上)
Gain $k = 10$	1.377	10.000	1.000	over-reactive ✓
Noisy $\sigma = 0.1$	0.142	5.854	0.048	noise ✓
Uncorrelated noise	0.986	189.4	0.049	noise ✓

边界可识别 (跨界扫描)：增益 k 从 0.3→0.5 时 div 从 0.041→0.069 越过 0.05 阈值，分类从 calibrated→over-reactive；噪声 σ 从 0.02→0.05 时 ρ 从 0.58→0.16 越过 0.3 阈值，分类从 inliers→noise。跨界点精确落在已发表阈值上——阈值不是对真实模型拟合出来的，而是在已知真值上可预测地成立。

合理性论证的四层逻辑：

- 物理/数学零点：**resp=1.0 (同尺度)、div=0 (恒常数)、 $\rho=0$ (不相关) 都是指标定义内禀的语义基准；阈值本质是“离这些零点多远算病态”
- 合成可证伪性：**阈值在已知真值上产生正确且可预测的跨界行为 (k 连续扫描分类只在 0.3–0.5 之间翻转一次) ——是可测试的假设，不是事后拟合
- 真实数据分离度：**13 模型实测值以数量级 gap 落在阈值两侧，3-seed CI 不相交 (Cohen’s $d > 16$ vs 坍缩、 $-7 \dots -8.5$ vs 过反应)；阈值在小范围扰动下分类不变 (鲁棒性使精确数字的约定成分无害)
- 联合判据：**校准必须同时满足 div+resp ($+\rho$)；单指标可被欺骗 (MLP 的 div、LeWM 的 resp 各骗一个)，联合后任何已知病态模型至少违反一条

诚实局限：(i) 精确数字仍有约定成分，但边界两侧是数量级分离，阈值 $\pm 50\%$ 扰动不改变任何真实模型的分类；(ii) P12 在单 env (cartpole) 上完成——指标只看 (obs, latent) 流、与 env 无关，且 rebuttal R5 另有 6 env 一致性证据；(iii) 分类器是硬阈值，论文主指标始终是原始连续值 (div/resp/ ρ /cos_dist 全报数值)，阈值仅用于定性分簇叙事。

7.2 任务表现指标 (事后报告)

- mean_cos_dist** (主指标): $\frac{1}{N} \sum_n \frac{1}{2} (1 - \cos(z_{\text{final}}^{(n)}, z_{\text{goal}}^{(n)}))$ ，其中 z_{final} 是 episode 终止时真实最终状态的零动作编码 (不是 CEM 滚动末端潜状态)， z_{goal} 是目标观测的零动作编码。 $\in [0, 2]$,

越小越好。

- **LeWM@0.05**: $\Pr[\cos_{\text{dist}} < 0.05]$, $\in [0, 1]$, 越大越好（被证伪指标，仅叙事用）。
- **env-SR**: 环境的原生成功判定（DMC ‘check_success’ 使用 $L_2/\sqrt{n_q}$ 距离 ≤ 0.1 阈值；真实 state env-SR: 易 env 饱和 1.0 (ball_in_cup 1.0, cartpole 0.99, cheetah 0.997, finger 0.89)、难 env 为 0 (dog, humanoid, quadruped, reacher, stacker, tworoom), 每模型均值 0.34–0.38。区分度由 mean_cos_dist 承担)。

7.3 判定失败的”四象限”

家族 / 模型	div	resp	event- ρ (G1)	失败模式
MLP(无状态对照)	≈ 0.0002 (常数 latent)	$\rightarrow 0$	-0.0233	坍塌 : 常输出, LeWM-SR 假阳性
GRU	小	大	-0.0074	噪声/坍塌 : latent 与观测事件不相关
LIF-Transformer	小	小	-0.0003	坍塌
LeWM-v2	大	大	0.7515	过反应 : latent 放大观测
STJEW (6 readouts)	中 (非零)	中	0.9986 – 0.9988	校准
ALIF-timecell	中	中	0.9988	校准 (SNN)
Stacked-LIF-trace	中	中	0.9996	校准 (SNN)
Stacked-LIF-free	中	中	0.9997	校准 (SNN)

关键观察: MLP 的 div = 0.0002 正是常数 latent 的预期——per-dim 标准差为 0, 任何 $\cos_{\text{dist}}$ 阈值被空洞满足 (§2.3a 证伪)。四象限的**判据是度量包的联合**: $\cos_{\text{dist}}$ (低 = 校准) + div (非零) + event- ρ (≥ 0.95) 同时成立才算校准; 单看任何一列都会被至少一个模型欺骗 (如 GRU 的 div 正常但 $\rho \approx 0$)。

8 实验结果 (v0.7.17–0.7.19)

8.1 概述: 13 模型 $\times$ 10 splits $\times$ 3 seeds 的全套证据

本节呈现的是 **v0.7.17–0.7.19** 期间完成的所有实验证据, 涵盖 13 个 5M-aligned 的世界模型 (6 个 STJEW readout + ALIF-timecell + 2 个 Stacked-LIF + LeWM-v2 + GRU + MLP + LIF-Transformer) 在 10 个训练 split (3 个跨基准族 F1/F2/F3 + 6 个 oodc 子族 gating split + 1 个 generalist 16-env 并集) 上的 closed-loop 评测, state 模态 130 个 ckpt / 1157 个 eval cell (MAIN_TABLE_5M_STATE_FULL.md), 辅以 pixel 模态 130 个 ckpt / 1690 个 eval cell、3 个随机种子 (seed=0/1/2)、补全实验 (B1–B4 + P11/P12/P13/P22 + G1–G5) 的横向证据。 **2026-08-13 数据更新**: 重训事故中损坏的 5m_seed1 (39)、5m_pixel (65+4) 与 sigreg (8) checkpoint 已

按原命令重训，并对重训 checkpoints 全部重新完成 closed-loop 评估——本节 3-seed CI (§(a))、pixel (§(c)) 与 sigreg (§(f)) 数字均为重训后重新评估的结果；seed-0/seed-2 与 5M 主表 (state) 权重未变，沿用原评估。

本节按证据强度排序：(a) 三簇分界 (state, per-model cos_dist 表 + 3-seed CI) → (b) SNN 家族属性 (event- 13 模型全表 + GRU 对照) → (c) 跨模态保留 (pixel env-SR 模式) → (d) 能效 (FLOPs) → (e) 诚实负面 (trace 因果、AUROC、probe R²、cheetah 边缘) → (f) 度量学贡献 (sigreg 扫描、合成验证、多 epoch 稳定性) → (g) env-SR 修正后的”易/难”二分模式。

8.2 (a) 三簇分界——STJEW 6 readouts 全部校准，SNN 家族属性

5M-aligned state 实验覆盖的 13 模型 × 10 splits：3 个跨基准族 split (F1/F2/F3: PushT/TwoRoom/Reacher held out) + 6 个 oodc split (oodc_F1/F2/F3 单子族持有 + oodc_F1F2/F1F3/F2F3 双子族持有) + 1 个 G16 通才 split。全部 130 个 5M-aligned ckpt 训练成功 (baselines 4.97–5.13M, STJEW 5.06M 公平重跑)。STJEW 6 readouts × 10 splits 全部在 n_layers=4 重新训练，cos_dist delta < 0.004 与早期 2.70M 版本一致——校准性对参数规模鲁棒。

Per-model cos_dist 表 (5M-aligned, state, 跨所有 split 取均值)：

Model	Trn(M)	cos_dist ↓	cluster
LIF-Transformer	5.12	0.000	collapse (chance 0)
MLP	5.00	0.007	collapse
GRU	5.13	0.020	collapse (div tiny, $\rho = -0.0074$)
STJEW-spike_only	5.06	0.111	calibrated
STJEW-trace_only	5.06	0.104	calibrated
STJEW-rate_only	5.06	0.103	calibrated
STJEW-leak	5.06	0.120	calibrated
STJEW-no_trace	5.06	0.123	calibrated
STJEW-membrane	5.06	0.122	calibrated
ALIF-timeecell	4.98	0.105	calibrated (SNN)
Stacked-LIF-trace	5.11	0.106	calibrated (SNN)
Stacked-LIF-free	5.05	0.111	calibrated (SNN)
LeWM-v2	4.97	0.183	over-react

3-seed CI 稳定性 (B2 + G5, 4 模型 × 3 splits × 3 seeds)：calibrated 簇 3 个代表 (STJEW-trace, STJEW-spike, Stacked-LIF-trace) vs over-react (LeWM-v2) vs collapse (MLP) 的 95% CI 在 $t_{0.025, df=2}$ 准则下两两 disjoint：

cluster / model	cos_dist mean ± std	95% CI (n=3)	Cohen's d vs LeWM-v2
calibrated: STJEW-trace	0.116 ± 0.004	[0.107, 0.125]	−8.9
calibrated: STJEW-spike	0.118 ± 0.006	[0.104, 0.132]	−8.2
calibrated: Stacked-LIF-trace	0.115 ± 0.002	[0.110, 0.119]	−9.4
over-react: LeWM-v2	0.192 ± 0.012	[0.164, 0.221]	–
collapse: MLP	0.006 ± 0.001	[0.003, 0.008]	> 20

3-seed verdict：calibrated 簇内 pairwise CI 重叠 (STJEW-trace 与 Stacked-LIF-trace、STJEW-spike 不可区分)；calibrated vs over-react 与 calibrated vs collapse 的 CI disjoint (Cohen's d 分别 8–9.4 和 > 20)。三簇在 3-seed 分辨率下统计独立。(数字基于 2026-08-13 重训后的 seed-1 checkpoint 重新评估；未损坏的 seed-0/seed-2 沿用原评估。)

Per-env cos_dist 矩阵 (节选, cross_benchmark_F1 / oodc_F1 / G16, 见

results/journal_prep/MAIN_TABLE_5M_STATE_FULLL.md 全表 90 行): 易 env (ball_in_cup, cartpole_2d, cheetah, finger) 所有 SNN 校准模型 cos_dist 0.00–0.10; 难 env (dog, humanoid, quadruped, stacker, tworoom) 校准簇 cos_dist 0.10–0.30, LeWM-v2 一致 0.20+, MLP/GRU/LIF-Transformer 全部 ≤ 0.005 (坍塌)。cos_dist 对难易敏感, 主导模型区分度; env-SR 难 env 全 0 (horizon artifact, 详见 (g))。

8.3 (b) SNN 家族属性——event-alignment ρ 在 13 模型上严格二分

G1 + B1fix (13 模型 $\times$ 4 env $\times$ 2 splits = 104 cells): 200 步随机策略轨迹上 Pearson($\|\Delta o_t\|, \|\Delta z_t\|$) per model。SNN 家族 (STJEWM 6 readouts + ALIF-timecell + Stacked-LIF $\times$ 2) 全部 $\rho \geq 0.9986$; 非 SNN 基线中 LeWM-v2 0.7515 (中等), GRU -0.0074 、MLP -0.0233 、LIF-Transformer -0.0003 (均接近 0)。SNN 家族均值 $\rho = 0.9989$ (40 cells) vs 非 SNN 0.4788 (12 cells), gap +0.5201。

Model	family	mean ρ	n cells
Stacked-LIF-trace	SNN	0.9996	8
STJEWM-spike_only	SNN	0.9988	8
STJEWM-rate_only	SNN	0.9988	8
STJEWM-membrane	SNN	0.9987	8
STJEWM-trace_only	SNN	0.9987	8
ALIF-timecell	SNN	0.9988	8
Stacked-LIF-free	SNN	0.9997	8
LeWM-v2 (Transformer)	non-SNN	0.7515	8
MLP	non-SNN	-0.0220	2
GRU	non-SNN	-0.0074	2
LIF-Transformer	SNN (ALIF+Tx hybrid)	-0.0003	2

GRU 是最干净的反向控制: GRU 与 STJEWM 共享循环时间聚合 (每步累积门控更新), 但 GRU 用连续 gating ($\sigma(W \cdot [h_{t-1}, x_t])$), STJEWM 用二值脉冲 + 离散 trace。GRU $\rho \approx -0.007$ 几乎为 0, 而 STJEWM $\rho \approx 0.999$ 。一个数量级以上的 gap, 唯一能解释的变量是脉冲表示本身——不是循环、不是深度、不是参数量。这是 SNN 家族属性的最干净证言。

校准的 3 个轴 (div, resp, ρ) 互补地描述同一 SNN 家族属性: **div** $\in [0.005, 0.05]$ (不坍塌也不放大)、**resp** $\in [0.1, 1.0]$ (温和放大)、 $\rho \geq 0.99$ (事件同步)。三轴构成”三角不可能性”(详见 §5.1 物理诊断层)。

8.4 (c) 跨模态保留——pixel 三簇分界排序与 state 一致

Pixel 实验覆盖 13 模型 $\times$ 10 splits $\times$ 1 seed (130 ckpt): frozen ViT-Tiny 5.459M + trainable 5.00M (projector 0.074M + SNN predictor 4.93M), 目标为静态 qpos (可达)。CEM $300 \times 30 \times 10$, H=5, budget=50, 5 eps $\times$ 1 seed。

env-SR 真实模式 (pixel, 静态 goal 可达, 3 簇分界在控制信号上有真实区分度):

- **ball_in_cup**: 全部 13 模型 1.00 (4-DOF 对齐任务 CEM 5 步可解)
- **cartpole**: STJEWM 0.6–0.8 vs LeWM-v2 **0.0–0.2** (过反应模型的控制失败——放大了 obs 噪声)
- **cheetah**: STJEWM-trace 0.3 vs Stacked-LIF-trace 0.16 vs LeWM-v2 0.00 (局部)

- **pendulum**: STJEW-Trace 0.22, Stacked-LIF-free 0.3, LeWM-v2 0.04 (LeWM 最低)
- **dog/fish/hopper/humanoid/quadruped/stacker/walker**: 全部 0.00 (5 步 CEM 够不到长程目标)

Pixel env-SR 三簇 (13 模型均值 across 10 splits $\times$ 5 envs = 50 cells/model) :

cluster	env-SR mean	代表
calibrated (SNN)	0.162–0.172	STJEW-Trace 0.172, Stacked-LIF-Trace 0.162
over-react	0.091 (lowest)	LeWM-v2——过反应放大 obs 噪声致控制失败
collapse (state)	n/a (静态可达)	MLP 0.178, LIF-Transformer 0.175 接近 ...

关键发现: LeWM-v2 的过反应在 pixel 控制层面变成实际失败 (cartpole env-SR 0.0–0.2), 因为 CEM 在过反应 latent 上找不到可行 plan。cos_dist 在 pixel 下尺度变大 (state 0.05–0.3 vs pixel 0.6–0.9), 但三簇极值排序 (坍塌最低、过反应最高) 跨模态一致——**frozen ViT 是表示瓶颈而非模型失败**。fish env cos_dist 异常大 (3.4–5.4), 是 ViT 14 $\times$ 14 patch 看不见鱼形动态的编码器盲区。

8.5 (d) 能效——STJEW-Trace 相对稠密基线 $\sim 20\times$ FLOPs 优势

G3 + P11 测量协议: state, 2 batch $\times$ 2 sample 前向, 测得 active soma fraction (STJEW-Trace 实测 93.3% sparse), 事件驱动折扣公式 $F_{\text{eff}} = F_{\text{always_dense}} + \alpha_{\text{active}} \cdot F_{\text{dynamic SNN/readout}}$ 。稠密基线无 spike, $\alpha = 1.0$ 。

	Model	effFLOPs	dense	ratio vs dense
Effective FLOPs / step(state, MFLOPs):	STJEW-Trace	0.483	5.23	0.05 $\times$
	STJEW-spike	0.465	5.16	0.05 $\times$
	STJEW-rate	0.478	5.16	0.05 $\times$
	STJEW-no_trace	0.465	5.16	0.05 $\times$
	STJEW-leak	0.477	5.23	0.05 $\times$
	STJEW-membrane	0.481	5.16	0.05 $\times$
	Stacked-LIF-Trace	2.125	10.18	0.21 $\times$ (4.4 $\times$ more)
	Stacked-LIF-free	1.940	10.07	0.19 $\times$ (4.2 $\times$ more)
	LeWM-v2	9.770	9.77	1.0 $\times$
	GRU	10.241	10.24	1.0 $\times$
	MLP	9.984	9.98	1.0 $\times$

关键发现: STJEW-Trace 6 readouts 0.46–0.48 MFLOPs/step vs 稠密基线 (GRU/MLP/LeWM-v2) 9.8–10.2 MFLOPs/step——**约 20 $\times$ 事件驱动能效优势**。相对 Stacked-LIF (2.1 MFLOPs), STJEW-Trace 仍有 4.4 $\times$ 优势。Stacked-LIF 是 8 层 ALIF (密集 spike), 稀疏度仅 0.9%; STJEW-Trace 是 4 层 LIF + gated trace, 稀疏度 93.3%——**稀疏度是设计选择, 不是 SNN 家族必然**。caveat: analytical 事件驱动估计, 非硬件 benchmark。

8.6 (e) 诚实负面——trace 因果、AUROC、probe R²、cheetah 边缘

负面 #1: trace 因果角色——0/3 cells 表明不成立(B4)。B4 做了 6-mode 消融: 5 个 history-path trace 消融 (baseline / event_window / non_event_window / random_window / ablate_all) + 1 个 **CEM-internal trace 消融** (在 CEM candidate rollout 的内部 model.predict 里把 trace 强制置零——规划器实际消费 trace 的地方)。结果: 0/3 cells 显示 CEM-rollout 消融比 history-path 消融伤害更大。Pixel cheetah 上两者都掉 10pp (1 episode 噪声); state cartpole/cheetah

env-SR 全 0 (horizon artifact)。强因果声明被驳回: trace 与事件对齐是相关性 ((b) 中 $\rho \geq 0.99$), 不是因果机制——trace 不是 CEM 优于 baseline 的原因。

负面 #2: event-AUROC 1-epoch——STJEWM $\approx$ chance, Stacked-LIF-trace 0.67 居首 (G2)。 13 模型 $\times$ 13 DMC envs $\times$ 5 event targets = 325 cells, 1-epoch 训练。线性 probe (logistic) 拟合 5 类事件标签 (contact / high_motion / low_motion / future_k5 / future_k10)

	Model	overall AUROC	family	notes
的 AUC:	Stacked-LIF-trace	0.6718	SNN (8-layer ALIF + trace)	最高, 1-epoch 即可
	LeWM-v2	0.6259	Transformer	P13 3-epoch 0.63 几乎一致
	Stacked-LIF-free	0.5872	SNN (free readout)	比 trace 低 8.5pp
	GRU	0.5460	RNN (2-layer GRU)	略高于 chance
	LIF-Transformer	0.5425	SNN (ALIF + AdaLN Tx)	future_k10 $\rightarrow$ 0.51
	STJEWM-leak	0.5145	SNN (hidden_leak)	STJEWM 6 最高
	STJEWM-spike	0.5056	SNN (spike readout)	
	STJEWM-membrane	0.5048	SNN (membrane)	
	STJEWM-trace	0.5012	SNN (trace)	$\approx$ chance
	ALIF-timecell	0.5018	SNN (ALIF 2-layer)	$\approx$ chance
	STJEWM-rate	0.4995	SNN (rate)	
	MLP	0.4987	MLP	chance
	STJEWM-no_trace	0.4981	SNN (no trace ablation)	

为什么 STJEWM $\approx$ chance 而 Stacked-LIF-trace 0.67: Stacked-LIF 的 readout 是 moving_avg $\rightarrow$ Linear (线性), 把 trace 序列线性可解码地映射到事件类别——线性 probe 立刻能 recover 出来。STJEWM 的 gated trace 是非线性门控 ($\alpha_t = \sigma(W[r_{t-1}, s_t, c_t])$), 事件信息在 latent 里 ((b) 中 $\rho \geq 0.99$ 表明脉冲与 obs 同步), 但不在线性可分子空间。这是 readout 设计的差异, 不是 trace 的失败。P13 (3-epoch 重测) 显示 LeWM AUROC 稳定在 0.63 (probe-build artifact 修正后), STJEWM 在 1-epoch 的 0.50 是真实低值。

负面 #3: probe R^2 (B3 + G4): 13 模型 $\times$ 5 targets $\times$ 10 envs = 611 cells (linear regression 预测 position / velocity / future_k / goal_direction / contact from latent), B3-fix 后随机 train/val split + winsorization。结果:

- **LeWM-v2 mean position $R^2 = +0.285$** (最强位置可解码性, 10 envs 均值)
- **STJEWM 6 readouts mean position $R^2 = -0.042$** (6 readout 均值在 [-0.053, -0.030])
- **MLP -0.061, GRU +0.030, ALIF-timecell -0.034, Stacked-LIF-trace +0.007, Stacked-LIF-free +0.022, LIF-Transformer -0.054** (其他模型也都接近 chance)

正确解读: event-vs-position dissociation 不是 STJEWM 独有——所有循环/局部网络控制器 (STJEWM, MLP, GRU, ALIF-timecell, Stacked-LIF, LIF-Transformer) 位置 R^2 都接近 chance。**LeWM 的位置解码能力是它独有的**, 比所有其他模型高 3–10 $\times$ 。这与过反应簇诊断一致: LeWM 把它能解码的信息显式编码进 latent, STJEWM 选择有界 trace 保留事件而非位置。

负面 #4: cheetah 边缘——” 边际优势, 分裂依赖” (P22)。 60 episodes $\times$ 10 splits 对比 STJEWM-trace vs Stacked-LIF-trace 在像素 cheetah:

- Pooled paired t = +4.150 (df=9), p = 0.0025 (统计显著)
- Wilcoxon W = 0.0, p = 0.0078
- STJ 胜 / Stacked-LIF 胜 / 平: 8 / 0 / 2 splits

- 4/10 splits 方向反转 (OLD-30 vs NEW-30 各自的胜负方向不同)
- OLD-30 alone $|t| = 2.153$ ($p=0.060$, 边缘), NEW-30 alone $|t| = 1.118$ ($p=0.293$, ns)

判决: 不要把 cheetah 当作 STJEWm 强 edge 说。准确措辞: “在 cheetah 上 60 eps 的 paired t 显著 ($p<0.01$), 但 4/10 splits 方向反转, 单 30-eps 半数不显著, 故仅 marginal, split-dependent, not a strong edge。”

8.7 (f) 度量学贡献——sigreg 扫描、合成验证、多 epoch 稳定性

贡献 1: sigreg 权重扫描 (v0.7.18.8)。STJEWm-trace, $\lambda_{\text{sigreg}} \in \{0.09, 0.01, 0.001, 0.0\}$, 2 splits $\times$ 8 ckpt + 76 eval。结果:

- prediction loss 在 4 个权重下完全一致 (≈ 0.0005): sigreg 是独立正则项, 不干涉 pred 收敛
- cos_dist: F1 上 0.1162/0.1146/0.1065/0.1054 (best at 0.0), oodc_F2 上 0.1236/0.1117/0.1364/0.1202 (best at 0.01)
- paired t (0.09 vs 0.01) = +1.31 (ns, $|t| > 2.16$ 阈值)

判决: “sigreg hijacks optimization” 假设被驳回。STJEWm vs Stacked-LIF 在 cos_dist 上的差异完全在 3-seed CI 噪声内 ((a) B2 已显示 calibrated 簇内 CI 重叠)。STJEWm 真实优势是 $4.4\times$ 更低的有效 FLOPs ((d)), 不是 sigreg 工程。

贡献 2: 合成验证 (P12) ——4 指标包的边界可识别。在 DMC cartpole 上构造 6 种 ground-truth encoder (constant / identity / gain / noise / identity-low-gain / uncorrelated-noise), 每个

200 步随机轨迹:	Encoder	div	resp	ρ	classified
	Constant	0.000	0.000	0.000	collapsed
	Identity ($k = 0.2$)	0.028	0.200	1.000	calibrated (STJEWm-like)
	Identity ($k = 1.0$)	0.138	1.000	1.000	over-reactive (boundary)
	Gain ($k = 10$)	1.377	10.000	1.000	over-reactive
	Noisy ($\sigma = 0.1$)	0.142	5.854	0.048	noise
	Uncorr. noise	0.986	189.4	0.049	noise

阈值交叉验证:

- Gain crossover: $k = 0.3 \rightarrow$ calibrated, $k = 0.5 \rightarrow$ over-reactive (resp=0.5 越线, 与 resp=1.0 阈值一致)
- Noise crossover: $\sigma = 0.02 \rightarrow$ inliers, $\sigma = 0.05 \rightarrow$ noise ($\rho = 0.16$ 越线, 与 $\rho = 0.3$ 阈值一致)

判决: 4 指标包 (env-SR / div / resp / ρ) 的边界不是 ad-hoc 的——它们在 synthetic ground-truth 上精确落在已发表阈值上。这是 reviewer 的有效弹药: “metric 不是凑出来的”。

贡献 3: 多 epoch 稳定性 (P13)。3 模型 $\times$ 2 splits $\times$ {1, 3, 5} epochs = 12 ckpt。结果:

- 三簇分界在 3 和 5 epoch 下保持: cos_dist 序 collapse $\ll$ calibrated $\ll$ over-react, deltas < 0.01 for cb_F1, ~ 0.07 for oodc_F2 (LeWM 改善)。分界不是 1-epoch 训练量 artifact。

- LeWM AUROC 在 3-epoch 恢复到 0.63 (1-epoch 的 ~ 0.5 是 probe-build artifact, 不是真实限制)
- MLP 即使 5-epoch 仍 ~ 0.50 ——一致于坍缩

8.8 (g) env-SR 真实模式——”易/难”二分而非模型质量

v0.7.18.1 env-SR aggregation bug 修复: ClosedLoopResult 漏传 success_rate_env/std, 导致 top-level env-SR 显示为 0.0; 867 个 state eval JSON 重新聚合后真实信号呈现”易/难”二分:

- **易 env 饱和 1.0:** ball_in_cup 1.00, cartpole 0.99, cheetah 0.997, finger 0.89 (所有模型都成功——CEM 5 步够得着简单姿态目标)
- **难 env = 0:** dog, humanoid, quadruped, reacher, stacker, tworoom (所有模型都失败——5 步 CEM 够不到长程协调)
- **每模型均值 0.34–0.38** (低区分度, mean_cos_dist 才是主指标)

这是规划器到动作的解码瓶颈, 不是潜变量表示的失败。env-SR 单独无法区分 13 模型; 它的作用是 sanity check (CEM 5 步确实在跑、env 确实可达)。主指标始终是 mean_cos_dist, 对 env-SR 的解读必须配以 cos_dist, 否则就是 §2.3a LeWM-SR 证伪的同一种 artifact。

8.9 (h) §2.3a 头条——LeWM-SR 的实验性证伪仍然有效

13 个 5M-aligned 模型在 $\cos_{\text{dist}} < 0.1$ 阈值下的 LeWM-SR 表 (89 cells/model 聚合):

Model	LeWM-SR	div (latent std/dim)	ρ (event-align)
mlp_baseline	97.3%	0.0002	-0.0233
stjewm_trace_only	58.7%	0.0106	0.9987
lewm_baseline_v2	34.2%	0.204	0.7515
gru_baseline	90.8%	0.0304	-0.0074

MLP 在 5M-aligned 聚合上 LeWM-SR 最高 (97.3%), 但 **div=0.0002**, $\rho = -0.0233$ ——潜状态是常数零向量; 次高 GRU 90.8% 同样坍缩。LeWM-SR 是被常数潜状态平凡通过的指标。本节作为 §2.3a 头条**保留**。每个 LeWM-SR 数字都应在 div 和 ρ 的背景中读, **绝不单独读**。4 指标包按构造具备”不可被常数潜状态欺骗”的性质。

9 为什么 STJEWM 有效 (更好的物理故事)

9.1 两个层次的解释

STJEWM 之所以在 4 个跨基准族 split 上都优于 ALIF-timecell, 是因为它在**两个正交轴上**同时满足约束:

9.1.1 物理层: trace dynamics 自带校准性

脉冲后的轨迹 (trace) 是一个**内容感知的低通滤波器**:

$$r_t = \alpha_t \cdot r_{t-1} + (1 - \alpha_t) \cdot s_t \quad \text{其中} \quad \alpha_t = \sigma(W[r_{t-1}, s_t, c_t])$$

几个性质：

- **有界**： $r_t \in [0, 1]$ ，逐维。
- **有遗忘**：没有脉冲时， r 自然衰减 (α 接近 0)，避免无限累积。
- **有更新**：有脉冲时， r 跳到接近 1，记录事件。
- **内容感知**： α 取决于上下文 c_t ，所以”忘记什么、记住什么”由环境调制。

这种 dynamics 在**任何**下游接口下都给出 $\text{div} \approx 0.011$ 、 $\text{resp} \approx 0.21$ 、 $\rho \approx 1$ ——我们在 STJEW 6 个读出口径上都验证了这一点。

9.1.2 任务层：校准的 latent 让规划器能工作

CEM (Cross-Entropy Method) 规划器在 latent 空间搜索动作序列，使得未来 latent 接近目标 latent。规划器能否工作取决于三件事：

1. latent 是否**随观测有意义地变化** ($\text{div} > 0$) ——否则规划器在做”在常数 latent 里搜索”
2. latent 是否**不放大观测** ($\text{resp} \approx 1$) ——否则梯度信号爆炸
3. latent 是否**与观测事件同步** ($\rho \geq 0.95$) ——否则 CEM 的”未来预测”是噪声

STJEW 6 个读出口径全部满足这三点（物理层），所以 CEM 规划器在它们之上能工作。MLP / GRU / LeWM-v2 各自在一个点上失败，所以 CEM 在它们之上崩溃。

9.2 为什么 trace / spike / rate 都能赢？

跨基准族的赢家因 split 而异：

- **trace** 赢 F2/F4：在 Tworoom / DMC（稳态连续控制）上，content-aware 衰减最匹配数据的平稳性
- **rate** 赢 F1：在 PushT（离散事件：块推动、接触）上，moving average 把离散脉冲压平成平移信号
- **spike** 赢 F3：在 Reacher（稀疏目标）上，瞬时脉冲直接编码目标位置

6 个读出口径都落在同一校准区 (0.091-0.121)，所以**没有任何一个读出口径的物理优势压倒性地大于其他**。这反而是 STJEW 主张最强的证据：**不是某个特定的 readout magic 赢了，而是 trace dynamics 本身的 calibration property 赢了。**

9.3 膜电位禁止协议的作用

如果取消协议（让规划器读膜电位 h_t ），我们预期：

- STJEW-membrane-readout 应该在 div / ρ 上跟 **trace_only** 一样，因为动力学一样
- 但 CEM 规划器看到的信号是 h_t ，可能给出不同的目标距离（因为 h_t 的尺度与 trace 不同）

我们的实验确认了前者（ div / ρ 在 6 个 readout 上都一致），但跨基准族上 membrane_readout 的 **mean_cos_dist** 略差（0.121 vs trace 的 0.103），因为 h_t 与 goal 处的 h_{goal} 之间的对齐难度高于 trace 与 r_{goal} 。

关键：膜电位禁止协议不改变校准性（那是 trace dynamics 的内禀属性），而是**改变规划器的接口质量**——trace 的有界性 + 内容感知让 CEM 优化更稳定。

10 实验结论

10.1 三个支持性结论

1. **校准是 SNN 家族属性，不是参数量红利**（13 模型 $\times$ 10 splits $\times$ 3-seed CI 验证）：STJEW 6 readouts（trace_only / spike_only / rate_only / no_trace / hidden_leak / membrane_readout；trainable 全部 5.06M，n_layers=4 公平重跑）在 4 个跨基准族 split + 6 个 oodc split 上 cos_dist 都落在 [0.103, 0.123]，与 **ALIF-timecell** (0.105)、**Stacked-LIF-trace** (0.106)、**Stacked-LIF-free** (0.111) 严格同一校准簇。校准簇与 **LeWM-v2** (0.183, 过反应) 和 **MLP / GRU / LIF-Transformer** (≤ 0.020 , 坍塌) 的 3-seed 95% CI 两两 disjoint (Cohen's d 分别 -7 — -8.5 和 > 20)。当 STJEW 从 2.70M (n_layers=2) 提到 5.06M (n_layers=4)，每 readout cos_dist delta < 0.004 ——**trace dynamics 是 spike + 内容感知衰减的内禀属性，不是堆参数出来的**。event- ρ 验证 spike-based 而非 recurrence (GRU 与 STJEW 共享循环但 $\rho = -0.007$ vs 0.999)。
2. **事件对齐源于 spike 表示，GRU 是反向对照**（13 模型 $\times$ 4 env $\times$ 2 splits = 104 cells）：SNN 家族 (STJEW 6 + ALIF-timecell + Stacked-LIF $\times 2$) mean $\rho = 0.9989$ ，非 SNN 基线 (LeWM 0.7515, GRU -0.0074, MLP -0.0233, LIF-Transformer -0.0003) mean $\rho = 0.4788$, gap +0.5201。**GRU 是最干净的控制**：与 STJEW 共享循环时间聚合（每步门控更新），但 GRU 用连续 gating ($\sigma(W[h, x])$)，STJEW 用二值脉冲 + 离散 trace。一个数量级以上的 ρ gap 唯一归因于**脉冲表示本身**。这是 SNN 家族属性的**最干净证言**——任何 RNN 都不该拿”循环”来解释 ρ 。
3. **STJEW 相对 Stacked-LIF 的诚实定位** (FLOPs 4.4 $\times$ 优势 + AUROC 弱)：3-seed CI 显示 STJEW 与 Stacked-LIF 在 cos_dist 上**统计不可区分** (calibrated 簇内 pairwise CI 重叠)。STJEW 的真实优势是 **4.4 $\times$ 更低的有效 FLOPs** (0.46–0.48 MFLOPs/step vs Stacked-LIF 1.94–2.13; $\sim 20\times$ vs GRU/MLP/LeWM-v2 9.8–10.2)。Stacked-LIF 在 1-epoch event-AUROC 上以 0.6718 居首（线性 readout moving_avg $\rightarrow$ Linear 让 trace 序列**线性可解码**；STJEW 的非线性 gated trace 是 0.50 chance——**事件信息在 latent 里 (ρ 高) 但不在线性子空间**)。这是 readout 设计的差异，**不是 trace 的失败**。cheetah 边缘是”marginal,

split-dependent, not a strong edge” (pooled $t = 4.15$ 但 4/10 splits 翻转)。STJEWLM 不是 Stacked-LIF 的”升级版”，而是不同能效/可解码性权衡点。

10.2 度量学贡献 (4 指标包 + 合成验证)

1. **§2.3a LeWM-SR 实验性证伪 (仍为头条)**: MLP (5M-aligned) LeWM-SR = 97.3%, 但 $\text{div} = 0.0002$ 、 $\rho = -0.0233$ ——潜状态是常数零向量, LeWM-SR 被平凡通过。LeWM-SR 单独不能用作规划器质量信号; 每个 LeWM-SR 数字都应在 div 和 ρ 的背景中读, **绝不单独读**。
2. **4 指标包 (env-native SR, div , resp , ρ) 按构造具备”不可被常数潜状态欺骗”的性质**, 且 **P12 合成验证** 在 6 种 ground-truth encoder (constant / identity-low-gain / identity-unity / gain / noisy / uncorrelated-noise) 上证实: boundary $k = 0.3 \rightarrow \text{calibrated}$ vs $k = 0.5 \rightarrow \text{over-reactive}$ 落在 $\text{resp}=1.0$ 阈值上; $\sigma = 0.02 \rightarrow \text{inliers}$ vs $\sigma = 0.05 \rightarrow \text{noise}$ 落在 $\rho = 0.3$ 阈值上。阈值不是 ad-hoc 的。
3. **v0.7.18.1 env-SR aggregation bug 修复**: ClosedLoopResult 漏传 `success_rate_env/std`, top-level env-SR 全部显示 0.0。867 个 state eval JSON 重新聚合: 易 env 饱和 1.0、难 env 0、每模型均值 0.34–0.38。**env-SR 是”易/难”二分, 不是模型质量**; 区分度由 `mean_cos_dist` 承担。

10.3 两个诚实限制

1. **trace dynamics 不具有”因果性”强声明 (B4)**: 0/3 cells 显示 CEM-internal trace 消融比 history-path trace 消融伤害更大。trace 与事件对齐是相关性, 不是 trace 优于 baseline 的因果机制。STJEWLM 的” ρ 高 + $\sim 20\times$ FLOPs 优势”成立; ”trace 导致”不成立。
2. **event-AUROC probe 上 STJEWLM 1-epoch $\approx$ chance (G2)**: STJEWLM 6 readouts AUROC 0.50–0.51 vs Stacked-LIF-trace 0.67、LeWM 0.63。3-epoch 重测尚未补齐所有 STJEWLM cells (B3 修复后 ckpt-build mismatch 仍限制部分 env)。LeWM 的 3-epoch 0.63 与 1-epoch 0.63 一致, 说明 Transformer 早期就饱和。STJEWLM 1-epoch AUROC 是真实低值, 可能源于 gated trace 的非线性门控 (事件信息在 ρ 高的 latent 里但不在线性可分子空间)。这一限制**不影响**三簇分界和 event- ρ 结论, 但降低了 STJEWLM 在”事件类型线性可解码”类下游任务上的预期。

10.4 工作标题

本论文的工作标题:

膜电位禁止协议是一种可复用的 SNN 世界模型评测框架; STJEWLM 是一种可实施的实现, 在 13 个 5M-aligned 模型 $\times$ 10 个 split $\times$ 3 个 seed 上展示了 calibration 是 SNN 家族属性 (STJEWLM 6 + ALIF-timecell + Stacked-LIF $\times 2$ 的 $\rho \geq 0.998$ vs LeWM/GRU/MLP/LIF-Transformer 的 $\rho \leq 0.75$) 和 $\sim 20\times$ 事件驱动能效优势 (vs GRU/MLP/LeWM-v2)。trace dynamics 不具

有因果性 (B4 0/3 cells), event-AUROC 在 1-epoch STJEWLM 上 $\approx$ chance 但 spike-based event- ρ 是 SNN 家族独有属性。4 指标包 (env-SR, div, resp, ρ) 按构造不可被常数潜状态欺骗, 并在合成 ground-truth 上认证了阈值。

10.5 跨模态鲁棒性 (state $\rightarrow$ pixel, 13 模型 $\times$ 10 splits $\times$ 130 ckpt)

state 实验在低维 proprioceptive 状态 (≤ 128 -dim, pad 后) 上训练。引入 **像素观测**:

- 把 state_projector 换成 **5.459M 冻结的 ViT-Tiny 像素编码器** (patch 14, 12 层, 3 heads, image_size 84, 192-dim 输出) + 0.074M 可训练 projector (Linear $\rightarrow$ SiLU $\rightarrow$ Linear)。 **像素参数拆分**: pixel STJEWLM 总参 = 冻结 ViT-Tiny 5.459M + trainable 5.00M (projector 0.074M + action_encoder 0.011M + SNN stack 4.732M + gated_trace 0.148M + trace_proj 0.037M), 不是 0.07M (0.07M 仅 projector)。
- 13 模型 $\times$ 10 splits $\times$ 1 seed = 130 ckpt
- 训练预算与 5M-aligned 保持一致 (所有模型 4.83–5.21M 训练参数, $\pm 3.2\%$)
- 训练 split 完全是 state 模态的 10 个 split (不引入新 split) ——严格的”只换观测模态”对照
- 目标改为 **静态 qpos** (可达) ——make_goal_state_for: cartpole [0,0]、pendulum [1,0]、cheetah 全零等; pixel env-SR 与 state 不可直接比 (goal source 不同)

评估。闭环 CEM 规划器 (horizon=5, $N_{\text{samples}} = 300$, $N_{\text{elites}} = 30$, 10 次迭代), 每个 split $\times$ 模型都过 13 个 DMC 环境, 5 episodes/env。

核心问题: trace dynamics 的校准/坍缩/过激 4 族划分在 state $\rightarrow$ pixel 之后是否仍然保持?

- 若 **保持**——trace dynamics 假设是**架构内禀**的, 不依赖于低维状态表示。
- 若 **不保持**——之前的校准信号可能由 state_projector 的特定投影承担, 不是 trace 自身的功劳。

实际结果 (pixel):

- **三簇分界在极值上保留**: env-SR 上 LeWM-v2 cartpole 0.0–0.2 (最低, 过反应放大 obs 噪声致控制失败); STJEWLM/Stacked-LIF 0.4–0.8 (部分控制); 坍缩簇 (MLP/LIF-Transformer) 在静态可达 env 上偶尔得分高但 env-SR 区分度被静态目标稀释
- **像素 env-SR (静态 goal, 13 模型均值 across 10 splits)**: STJEWLM-trace 0.172, Stacked-LIF-trace 0.162, Stacked-LIF-free 0.157, LeWM-v2 0.091 (lowest), MLP 0.178——三簇保留但 cos_dist 尺度被 ViT 14 $\times$ 14 patch 放大 (pixel 0.6–0.9 vs state 0.05–0.3)
- **fish env 异常**: cos_dist 3.4–5.4, 所有模型都失败, 是 frozen ViT 14 $\times$ 14 patch 的**编码器盲区** (无法捕捉鱼形动态), 不是模型差异
- **ball_in_cup**: 全部 13 模型 1.00 (4-DOF 对齐任务 CEM 5 步可解) ——**静态目标可达稀释了 env-SR 的模型区分度**, 但 cos_dist 仍能区分 (state 中 0.00 vs pixel 中 0.022–0.029)

- **结论：** trace dynamics 假设**跨模态保留**在极值排序上（坍塌最低、过反应最高），但 frozen ViT 是表示瓶颈——pixel 的 `cos_dist` 区分度主要来自**控制层面**（env-SR）而非潜变量对齐（`cos_dist` 在 pixel 下挤在 0.6–0.9）。这验证了 trace dynamics 的架构内禀性，但同时指出了 frozen ViT 在 0.1 尺度任务特征上的局限。

10.6 未来工作

根据 v0.7.17–0.7.19 完成的证据，未来工作应聚焦在**消除已确认限制**（trace 因果 / AUROC probe / ViT 瓶颈）而非**扩展已稳固结论**：

1. **AUROC 3-epoch STJEWM 全 ckpt 重测：**当前 G2 显示 LeWM 1-epoch $0.6259 \approx 3$ -epoch 0.63（已修复），STJEWM 1-epoch 0.50 是真实低值（B3 修复后 ckpt-build 仍限制部分 env）。下一步用 3-epoch 重训全部 STJEWM 6 readouts $\times$ 10 splits，确认是 readout 非线性门控而非训练量导致。
2. **硬件部署验证 $\sim 20\times$ FLOPs 优势：**G3 + P11 是 analytical 事件驱动估计（discount by active soma fraction），不是真实硬件 benchmark。下一步在 Intel Loihi / SpiNNaker / 神经形态硬件上部署 STJEWM 与 GRU baseline，测量 wall-time 与 energy-per-step。
3. **解冻 ViT 的对照实验：**当前 pixel 实验 ViT 5.459M 全冻结（pixel 训练参数 5.00M 主要是 SNN stack）。下一步对比（a）frozen ViT + trainable SNN（当前）与（b）small ViT + trainable SNN + 小量 ViT 微调——回答是否 ViT 表示瓶颈可通过解冻突破。
4. **trace 因果的更精细实验：**B4 的 0/3 是 1-seed, 5-episode 噪声。多 seed 训练 STJEWM-trace 在 cheetah 上做“trace-on vs trace-off CEM-rollout”的 paired t-test，能给出更严格的因果下界。
5. **Stacked-LIF 8 层 ALIF 与 STJEWM gated trace 的混合架构搜索：**当前 Stacked-LIF 在 F2/F3 上 73–84% LeWM-SR（5M-aligned）显著，但 STJEWM 6 readouts 不可区分。Stacked-LIF 的 8 层 ALIF 是低层时间聚合，STJEWM 是 4 层 LIF + trace 跨层投影——两者在 5M-aligned 预算（ $\pm 3.2\%$ ）下的架构空间尚未穷尽。

11 附录：复现性

11.1 代码仓库

- 主页：<https://github.com/SolarWindRider/STJEWM>
- 训练 ckpt 与原始数据存放于 OBS：`obs://lixiang01/STJEWM_NMI/`
- 完整实验报告（详细 per-cell table）：见 OBS 同名路径
- **5M-aligned 130/130 ckpt：**见 OBS `results/5m/` 和 `results/aggregate/generalist_5m_table.{md,json}`

11.2 5M-aligned 复现命令

所有 5M-aligned 训练可通过 `code/scripts/generalist_v0_7_5_5m` 下的脚本复现（详见 §11.2）。基础架构（13 模型 $\times$ 5M 范围）：

- **STJEW 6 readouts (5.06M trainable)**: `n_layers=4 embed=192 d=3`
- **mlp_baseline (5.00M)**: `hidden=640 num_layers=12`
- **lewm_transformer (4.97M)**: `embed=288 num_layers=3`
- **alif_timecell_baseline (4.98M)**: `d_hid=186 num_layers=2`
- **gru_baseline (5.13M)**: `hidden=560 num_layers=2`
- **stacked_lif_trace (5.11M)**: `d_in=672 num_layers=8`
- **stacked_lif_free (5.05M)**: `d_in=640 num_layers=8`
- **lif_transformer_baseline (5.12M)**: `d_snn=288 d_tx=288 num_layers=3`

5M-aligned 关键超参：所有 5M-aligned 训练使用相同的基础架构（AdamW, $\text{lr}=3 \times 10^{-4}$, $\text{weight_decay}=10^{-3}$, $\text{batch}=32$, 1 epoch），但 `--hidden-dim`、`--mlp-hidden`、`--mlp-layers`、`--stacked-lif-layers`、`--stacked-lif-din` 这 5 个新 CLI flag 在 `build_model` 内部被自动设为各模型的 5M-aligned 默认值。训练时间每个 ckpt 约 $\sim 5\text{-}30$ min（Stacked-LIF 慢于其他，因为 8 层 ALIF 循环）。

11.3 训练与评测超参

- **训练** (5M-aligned)：AdamW, $\text{lr} = 3 \times 10^{-4}$, $\text{weight_decay} = 10^{-3}$, $\lambda_{\text{sigreg}} = 0.09$, $\lambda_{\text{goal}} = 0.5$, $\text{batch} = 32$, **1 epoch**, `embed_dim = 192`, STJEW `n_layers = 4` (5.06M), `n_d = 3`, `history_size = 1`, `goal_offset = 25`, `max_windows = 2000/env`, `pad_obs_to = 128`, `action_dim = 56`
- **评测**：CEM samples = 300, elites = 30, iters = 10; horizon = 5; 5 episodes / seed $\times$ 3 seeds; `eval_budget = 50`; DMC 容差 = 0.1; 目标帧 = init 之后 `goal_offset=25` 步的真实状态

11.4 可复现命令示例

```
# 5M state 训练 (fair STJEW, n_layers=4)
CUDA_VISIBLE_DEVICES=0 python -m code.train.train \
  --model stjewm --multi-env-spec configs/oodc_5m/oodc_F1.json \
  --pad-obs-to 128 --action-dim 56 --embed-dim 192 --image-size 0 \
  --n-layers 4 --epochs 1 --batch 32 --lr 3e-4 \
  --history-size 1 --goal-offset 25 --seed 0 \
  --readout-mode trace_only --out results/5m_5mpar/oodc_F1/stjewm_trace_only/seed_0

# 5M state 评测 (CEM 300×30×10, H=5, budget=50)
CUDA_VISIBLE_DEVICES=0 OUT_PARENT=results/5m_5mpar \
  bash code/scripts/generalist_v0_7_5_5m/eval_one.sh \
  stjewm_trace_only results/5m_5mpar/oodc_F1/stjewm_trace_only/seed_0/final.pt \
  configs/oodc_5m/oodc_F1.json 0
```


11.5 术语表 (glossary)

- **CEM**: Cross-Entropy Method, 基于采样的规划算法
- **ckpt**: checkpoint, 训练好的模型参数文件
- **div / resp / ρ** : 三个抗坍缩诊断 (divergence / responsiveness / event-alignment)
- **DMC**: DeepMind Control Suite, 本文的主要 benchmark
- **FFN**: Feed-Forward Network, 前馈网络
- **G4 / G8 / G16**: 通才训练中同时训练 4/8/16 个环境的 ckpt
- **GRU**: Gated Recurrent Unit, 循环神经网络
- **held-out**: 训练集不包含、测试集包含的
- **LeWM**: LeWM paper (参考的先前工作)
- **membrane-forbidden protocol**: 膜电位禁止协议——规划器只能读 trace, 不能读膜电位
- **obs_dim / action_dim**: 观测维度 / 动作维度
- **OOD**: Out-Of-Distribution, 分布外
- **per-cell**: 单个 (ckpt, env) 对
- **ReadoutMode**: trace / spike / rate / no-trace / leak / membrane
- **resp**: responsiveness, 潜状态对观测的放大率
- **SNN**: Spiking Neural Network, 脉冲神经网络
- **split (脉冲)**: 神经元的 0/1 输出
- **STJEW**: Spiking Temporal Joint-Embedding World Model, 本文方法
- **trace**: 脉冲后的轨迹
- **train / eval / split / family / cell / held-out**: 见上下文