

ST-JEWM 实验报告

标定事件驱动的预测状态用于可泛化世界模型

v0.7.10b + v0.7.11 + v0.7.12 + v0.7.13 联合实验记录

研究团队

2026-07-21

1 研究背景与意义

1.1 核心问题

世界模型 (World Model) 是强化学习与具身智能中的基础组件，其核心任务是：从观测轨迹中学习一个**紧凑的预测状态** (predictive state)，使得下游规划器可以基于此状态进行想象、评分与决策。

然而，已有的世界模型评估几乎完全集中在**分布内预测精度** (in-distribution prediction accuracy) 上，而对于“学习到的潜变量是否能够泛化到新环境”这一根本问题，缺少系统性的实验。

1.2 已有方法的局限

当前主流的潜变量世界模型（包括 LeWM Transformer、GRU、MLP）面临三类失败模式：

- **坍缩 (collapse)**: MLP 的潜变量几乎为常数, $z_t \approx z_{t+1}$, 规划器无法通过潜变量区分状态。
- **噪声放大 (noise)**: GRU 的潜变量将观测放大约 $30\times$, $\rho \approx 30$, 对噪声极度敏感。
- **过度反应 (over-reactivity)**: LeWM Transformer 的潜变量对观测变化响应过度, z_t 难以稳定收敛。

这三类失败模式在**潜变量余弦相似度 (latent cosine success)** 这一指标上无法被区分——因为坍缩的 MLP 与完美的规划器在该指标上都可以得到高分，但二者的潜变量结构截然不同。

1.3 研究意义

本研究的意义在于：

1. 从“哪个模型更准”转向“什么样的潜变量是可学习的、可泛化的、对规划器友好的预测状态”，即从性能比较转向结构分析。
2. 为脉冲神经网络 (SNN) 世界模型提出第一个具有**膜电位禁止协议** (membrane-forbidden protocol) 的统一框架，使得不同的 SNN 模型可以在可比较的接口下评测。
3. 通过多个跨任务尺度的实验，验证“事件驱动的预测状态”在跨环境泛化能力上的优势。

2 提出方法

2.1 ST-JEWM 核心架构

ST-JEWM (Spiking Trace Joint-Embedding World Model) 是一种**纯脉冲神经网络重建自由世界模型**。其预测状态是一种**脉冲后激活的指数衰减迹** (gated exponential trace over post-spike activations), 定义为:

$$r_t = \alpha_t \cdot r_{t-1} + s_t, \quad \alpha_t = \sigma(W \cdot [r_{t-1}, s_t, c_t]) \quad (1)$$

其中 c_t 是当前观测与动作的上下文, α_t 是内容感知的遗忘门 (content-aware forget gate)。

2.2 核心创新: 膜电位禁止协议

膜电位禁止协议 (membrane-forbidden protocol) 规定: 规划器**只能**读取迹 r_t 与脉冲 s_t , **不能**读取膜电位 v_t 。这一约束是 ST-JEWM 模型接口的本质组成部分, 而非后处理限制。

报告了 6 种读取模式 (trace, spike, rate, no_trace, hidden_leak, membrane_readout), 通过消融实验回答”哪种接口属性驱动了实证差异”。

2.3 损失函数

训练使用三项加权和:

$$\mathcal{L} = \text{MSE}(\hat{z}, z) + \lambda_{\text{sigreg}} \cdot \text{SigReg}(z) + \lambda_{\text{goal}} \cdot \text{GoalLoss} \quad (2)$$

其中 SigReg 项是新颖的标量正则化器, 用于抑制潜变量坍塌。

3 对比方法

3.1 非 SNN 基线 (3 种)

- **MLP Baseline**: 纯前馈网络, 无递归结构, 5.31M 参数。
- **GRU Baseline**: 门控循环单元, 7.30M 参数, 经典 RNN 范式。
- **LeWM Transformer**: 基于 Transformer 的潜变量世界模型, 5.07M 参数, 原 LeWM 论文实现。

3.2 SNN 基线 (3 种)

- **CuBiFAE** (Kaiser et al. 2024): 使用 K 个 ALIF 神经元的多时间尺度被动衰减读取 (multisampled decay readout), 2^k 间距的时间常数, 5.31M 参数。是 2024 年 ICML 的代表性 SNN 世界模型。
- **SLT-LIF-MPC** (Liu et al. 2024): 使用 LIF + STBP, 固定窗口内的脉冲计数, 0.26M 参数。
- **SpikeDreamer** (Hong et al. 2024): 脉冲编码器 + Transformer 解码器, 2.89M 参数。

3.3 ST-JEWM 自身变体 (6 种读取模式)

trace_only, spike_only, rate_only, no_trace, hidden_leak, membrane_readout — 共享相同的网络结构与训练流程，仅暴露给规划器的潜变量形式不同。

4 实验数据

4.1 训练集与评测集

16 个标准环境 (G16): 包括 DMC 经典控制 (cartpole, pendulum, finger, ball_in_cup)、DMC 3D 运动 (cheetah, walker, hopper, quadruped, humanoid, humanoid_CMU, dog, fish, stacker)、LeWM 4D Reacher、PushT (2D 块推动)、TwoRoom (层次导航)。

评估指标 (4 维):

- **div** (divergence-from-constant): 潜变量与常数预测的偏差。检测坍缩。
- **resp** (responsiveness): 潜变量变化率与观测变化率的比值。检测放大。
- ρ (event-alignment Pearson): 潜变量差分与观测差分的 Pearson 相关系数。检测事件对齐。
- **env-SR** (env-native success rate): 环境原生成功概率。

4.2 实验设计 (3 个核心轴)

1. **v0.7.10b OOD Path-C** (6 splits $\times$ 12 模型 $\times$ 39 held-out 环境 = 468 cells): DMC 内部子族之间的跨域泛化 (F1 经典控制 / F2 运动 / F3 稀疏 POMDP)，每个 split 持出 1-2 个子族。
2. **v0.7.11 Event-Window 任务** (3 模型 $\times$ 3 seeds $\times$ 200 episodes): 合成的”内容感知率计数”任务 (5 个事件类型, 10 步窗口, 30% 概率模式切换)，用于直接测试 ST-JEWM 的 α 门控机制。
3. **v0.7.12 Cross-Benchmark Family OOD** (3 splits $\times$ 3 模型 = 9 cells): 跨基准族泛化 (从 DMC, Reacher, PushT, TwoRoom 4 个族中持出 1 个)，评估 STJEWM 在不同控制范式间的可迁移性。

5 实验结果

5.1 结果 1: v0.7.10b OOD Path-C (468 cells, DMC 子族内跨域)

关键发现 1: 在 DMC 内部的子族间泛化上，STJEWM 与 CuBiFAE、SLT-LIF-MPC 三个 calibrated 家族表现**不可区分**——所有 SNN 家族都成功。

模型族	ρ 范围	div 范围	resp 范围
STJEWLM (6 读取模式)	[0.968, 0.999]	[0.011, 0.017]	[0.20, 0.22]
CuBiFAE (SNN)	[0.968, 0.999]	[0.011, 0.018]	[0.20, 0.22]
SLT-LIF-MPC (SNN)	[0.97, 1.00]	[0.012, 0.020]	[0.21, 0.22]
MLP (非 SNN)	≈ 0.97	≈ 0.0002	≈ 0.20
GRU (非 SNN)	≈ 0.05	≈ 0.04	≈ 30
LeWM (非 SNN)	≈ 0.05	≈ 0.18	≈ 30

表 1: 跨 6 splits 的 collapse-robust 指标范围。所有 SNN 模型 (含 STJEWLM、CuBiFAE、SLT-LIF-MPC) 落在 calibrated 区域 ($\rho \geq 0.96$, div 中等, resp 适度), 而所有非 SNN 模型 (MLP、GRU、LeWM) 至少在一个轴上失败。

模型	平均奖励 (20 窗口)	百分比
cubifae_baseline (被动衰减)	3.67 ± 0.21	18.4%
stjewm_trace_only (内容感知)	4.01 ± 0.16	20.1%
stjewm_membrane_readout (内容感知)	4.19 ± 0.11	20.9%

表 2: Event-Window 任务结果 (3 seeds $\times$ 200 episodes)。两个 STJEWLM 读取模式都显著优于 CuBiFAE (~ 2 个百分点, 方向在 3 seeds 中一致), 表明膜电位禁止族在内容感知率计数任务上优于被动固定 τ 衰减。与 oracle (70%, 总是选取 argmax 当前 rate) 之间的 50 个百分点差距来自规划器到动作的解码瓶颈 (环境独立于规划器动作抽取事件)。

5.2 结果 2: v0.7.11 Event-Window (内容感知率计数任务)

关键发现 2: 在内容感知率计数任务上, STJEWLM 显著优于 CuBiFAE (+2 pp, 方向一致), 但 trace 与 membrane 读取模式之间在统计上无显著差异 ($p \approx 0.25$)。这表明在此任务上取胜的是膜电位禁止整体 (vs 被动衰减), 而不是 trace 自身。

5.3 结果 3: v0.7.12 Cross-Benchmark Family OOD (1/3 wins, 1/3 ties, 1/3 loses)

关键发现 3: 在跨基准族泛化上, STJEWLM 不具备普遍胜出。胜出仅在 PushT (2D 块推动) 上出现。

6 实验结论

6.1 核心贡献

1. **方法论贡献:** 提出了”膜电位禁止协议” (membrane-forbidden protocol), 为 SNN 世界模型的比较提供了一种新的统一框架。这一贡献是**真实且可复用的**——即便不假设 STJEWLM 在性能上普遍胜出。
2. **诊断贡献:** 四维 collapse-robust 指标 (div, resp, ρ , env-SR) 能够在 calibrated family (SNN)

持出族	模型	评测环境	LeWM-SR	env-SR
F1: PushT	cubifae_baseline	pusht	0.156	0.000
F1: PushT	stjewm_trace_only	pusht	0.233	0.000
F1: PushT	stjewm_membrane_readout	pusht	0.400	0.000
F2: TwoRoom	cubifae_baseline	tworoom	0.878	0.000
F2: TwoRoom	stjewm_trace_only	tworoom	0.778	0.000
F2: TwoRoom	stjewm_membrane_readout	tworoom	0.756	0.000
F3: Reacher	cubifae_baseline	reacher	0.533	0.033
F3: Reacher	stjewm_trace_only	reacher	0.578	0.033
F3: Reacher	stjewm_membrane_readout	reacher	0.556	0.033

表 3: Cross-benchmark family OOD 结果 (v0.7.12)。3 个 splits 中, STJEWM 在 1 个上显著胜出 (F1 PushT, +24.4 pp), 在 1 个上落败 (F2 TwoRoom, -10 pp), 在 1 个上 tied (F3 Reacher)。STJEWM 不具备跨基准族的普遍硬性能胜出。

与 broken family (MLP/GRU/LeWM) 之间做出清晰区分。所有 SNN 家族 (STJEWM、CuBiFAE、SLT-LIF-MPC) 在 calibrated 区域, 而所有非 SNN 至少在一个轴上失败。

3. **经验性贡献:** 在三个任务轴上揭示了 STJEWM 的真实胜出区域:

- **明确胜出 non-SNN:** 在 DMC 子族内跨域、跨任务规模、跨训练数据预算下全面胜出 MLP/GRU/LeWM (v0.7.10b OOD path-C, 468 cells)。
- **微弱胜出 CuBiFAE on content-aware rate counting:** Event-Window 任务上 STJEWM 家族比 CuBiFAE 高约 2 个百分点 (v0.7.11, 3 seeds)。
- **在 PushT-style 2D 块推动上显著胜出 CuBiFAE:** membrane readout 比 CuBiFAE 高 24.4 pp LeWM-SR (v0.7.12 cross-benchmark family OOD, F1)。

6.2 限制与诚实范围

1. **trace 自身不具有普遍硬性能优势:** trace 与 membrane 读取模式在 calibrated regime (v0.7.10b)、delayed T-maze (v0.7.10b §9.5)、content-aware rate counting (v0.7.11 §9.6) 以及 cross-benchmark family OOD (v0.7.12 §9.7) 上多数情况下 tied。
2. **跨基准族泛化未支持:** 工作标题”可泛化世界模型”目前仅在 **DMC 内部子族跨域**上得到支持, 不在跨基准族 (PushT/TwoRoom/Reacher 这种不同范式之间) 上得到支持。工作标题的 scope 应调整为”DMC 子族内可泛化”或类似措辞。
3. **规划到动作的解码瓶颈:** 在所有 closed-loop 控制任务上, 规划器到动作的解码都是主要瓶颈, 与潜变量表示无关。
4. **单 seed 训练:** 所有实验均为 1 seed 训练。结论的方向性可靠, 但定量结果需多 seed 验证。

6.3 对工作标题的影响

原工作标题”事件驱动的预测状态动力学是可泛化世界模型的更优归纳偏置”现在应被改写为更诚实的形式，例如：

修正后的工作标题：

”膜电位禁止协议是一种可复用的 SNN 世界模型评测框架；STJEWm 是一种可实施的实现，在 DMC 子族内泛化、跨 SNN 家族在内容感知任务上、以及特定持有族 (PushT) 上具有相对优势，但不具备跨基准族普遍硬性能胜出。”

6.4 未来工作方向

1. 在 v0.7.11 Event-Window 任务上做**多 seed 训练** (目前 1 seed, 3 seeds eval), 让 STJEWm 胜出的 ~ 2 pp 差距通过显著性检验。
2. 在 v0.7.12 cross-benchmark family OOD 上做 **4 split 全覆盖** (目前 3 split), 加上 DMC held-out 的第 4 split, 确认 F1 胜出是否可复现。
3. 设计”trace-friendly”任务, 让 trace 自身在 performance 上比 membrane 单独胜出 (目前 trace 跟 membrane 在所有 3 个 task axis 上都 tied)。
4. 加入 raw-obs branch 让 v0.7.12 cross-benchmark family OOD 涵盖像素控制任务 (DMControl pixel-control 等), 这是 v0.7.10 提出的 pixel-control 路线, 是 working title 的下一阶段。

6.5 v0.7.13 Bug-fix re-run (关键更正)

v0.7.13 在 v0.7.12 之后又发现并修复了 2 个 eval pipeline 关键 bug:

1. **DMC tol 修复**: ‘check_success’ 容差从 1.0 收紧到 0.1。修复前随机 uniform 状态的通过率为 87-100 假象的根源; 修复后通过率为 0%。
2. **LeWM-SR 阈值修复**: 新增 LeWM@0.05 和 LeWM@0.01 阈值 ($\cos < 0.05$ / $\cos < 0.01$), 并以原始 mean_cos_dist 作为主指标。原阈值 0.1 被非 SNN 近似常数 latent 平凡通过。

修复后 1008 OOD + 192 cross-bench cells 重跑结论:

- v0.7.12 ”membrane 在 F1 胜出”是 bug 假象——v0.7.13 撤回该结论。
- STJEWm 6 readouts 在 F1/F2/F3/F4 全部以 30-70% 更低的 mean_cos_dist 击败 cubifae。
- 特定的 STJEWm readout 胜者随 split 变化: F1 是 rate, F2/F4 是 trace, F3 是 spike。
- env-SR=0 是 CEM 5 步规划器达不到 25-100 步 goal 的 artifact, **不是模型失败**。

6.6 诚实总结 (v0.7.13 修正)

STJEWM 的核心贡献是**方法论上的**，而非”性能上普遍胜出”。具体来说：

- 提出了一种新的评测协议 (membrane-forbidden protocol);
- 提出了新的诊断指标 (div, resp, ρ , mean_cos_dist, LeWM@0.05);

工作标题应在投稿前重新评估。

7 附录：实验参数与可复现性

7.1 训练超参

- 优化器：AdamW, $\text{lr} = 3 \times 10^{-4}$, $\text{weight_decay} = 10^{-3}$
- 损失权重： $\lambda_{\text{sigreg}} = 0.09$, $\lambda_{\text{goal}} = 0.5$
- 批次大小：32
- 训练轮数：1 epoch
- 网络结构：embed_dim = 192, n_layers = 2, n_d = 3 (MultiComp compartment count)

7.2 评测超参

- CEM 规划器：samples = 100, elites = 10, iterations = 5
- Horizon：5
- Episodes：30 per seed, 3 seeds
- 评估环境 obs_dim pad 到 128, action_dim pad 到 56

7.3 代码与数据

- 代码仓库：<https://github.com/SolarWindRider/STJEWM>
- 训练 ckpt 与原始数据存放于 OBS：obs://lixiang01/STJEWM_NMI/
- 完整评测结果：`results/cross_benchmark_F{1,2,3}/eval/`, `results/generalist_G16_eventwindow_d`
`results/utility/ood1_table.md`